

Aula 12

CBM-PE (Oficial) Estatística

Autor:

**Equipe Exatas Estratégia
Concursos**

06 de Maio de 2026

Índice


1) Correlação Linear.	3
2) Regressão Linear Simples.	30
3) Análise de Variância da Regressão.	48
4) Questões Comentadas - Correlação Linear - Multibancas	68
5) Questões Comentadas - Regressão Linear Simples - Multibancas	80
6) Questões Comentadas - Análise de Variância da Regressão - Multibancas	100
7) Lista de Questões - Correlação Linear - Multibancas	123
8) Lista de Questões - Regressão Linear Simples - Multibancas	128
9) Lista de Questões - Análise de Variância da Regressão - Multibancas	137



CORRELAÇÃO LINEAR

Neste tópico estudaremos a correlação linear. A correlação é usada para indicar a força que mantém unidos dois conjuntos de valores. Por meio da análise da correlação linear, buscamos identificar se existe alguma relação entre duas ou mais variáveis, ou seja, se as alterações nas variáveis estão associadas umas com as outras.

Para avaliar a existência de correlação podemos recorrer a uma forma de representação gráfica bem simples, que chamamos de **gráfico de dispersão**. Basicamente, ela é uma representação de pares ordenados em um plano cartesiano, composto por um eixo vertical (ordenada) e um eixo horizontal (abscissa).




A título exemplificativo, as informações da tabela a seguir referem-se ao número de questões resolvidas por um determinado aluno e a nota obtida por ele em uma avaliação. Observe que quanto maior o número de questões resolvidas, maior é a nota obtida na avaliação.

Aluno	Número de Questões (X)	Nota Obtida (Y)
1	20	2
2	60	8
3	30	3
4	50	6
5	40	4
6	70	8
7	80	9
8	90	10
9	40	6



10	30	4
11	10	1
12	60	6
13	50	5
14	70	6
15	90	9
16	100	10
17	20	3
18	40	5
19	60	7
20	50	4


A representação desses dados em formato de diagrama de dispersão sugere a existência de uma **relação linear positiva (variação no mesmo sentido)** entre as duas variáveis:



Neste exemplo, percebemos que a relação dos dados agrupados é quase linear. Por isso, se traçarmos uma reta de tendência no gráfico, observaremos que os pontos se comportarão em torno da reta.



Assim:







Há situações em que essa relação linear não é tão evidente. Um exemplo disso é quando os pontos estão mais dispersos. Nesse caso, para identificarmos a relação existente entre as variáveis, usamos o coeficiente de correlação linear de Pearson, definido por r .

Por fim, devemos ter em mente que a correlação linear pode ser:

- a) direta ou positiva – quando temos dois fenômenos que variam no mesmo sentido. Se aumentarmos ou diminuirmos um deles, o outro também aumentará ou diminuirá;
- b) inversa ou negativa – quando temos dois fenômenos que variam em sentido contrário. Se aumentarmos ou diminuirmos um deles, acontecerá o contrário com o outro, no caso, diminuirá ou aumentará;
- c) inexistente ou nula – quando não existe correlação ou dependência entre os dois fenômenos. Nessa situação, o valor do coeficiente de correlação linear será zero ($r = 0$) ou um valor aproximadamente igual a zero ($r \cong 0$); e
- d) perfeita – quando os fenômenos se ajustam perfeitamente a uma reta.



As figuras a seguir ilustram essas quatro situações:



Coeficiente de Correlação de Pearson

O coeficiente de correlação linear de Pearson é adotado para medir o quão forte é a relação linear entre duas variáveis. Esse coeficiente é calculado pela seguinte expressão:

$$r = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

Os somatórios dessa fórmula podem ser simplificados, o que facilita a resolução de muitas questões. Por isso, é muito importante que vocês aprendam as expressões apresentadas a seguir. A expressão do numerador pode ser simplificada da seguinte forma:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}$$



Para facilitar a compreensão e internalização, vou apresentar um raciocínio que podemos adotar para deduzir a fórmula alternativa mostrada anteriormente.

Primeiro, precisamos aplicar a propriedade distributiva:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n [X_i \times Y_i - X_i \times \bar{Y} - \bar{X} \times Y_i + \bar{X} \times \bar{Y}]$$

Agora, precisamos separar as quatro parcelas desse somatório principal. Reparem que as médias são constantes, portanto, podem sair do somatório:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - \bar{Y} \times \left(\sum_{i=1}^n X_i\right) - \bar{X} \times \left(\sum_{i=1}^n Y_i\right) + \bar{X} \times \bar{Y} \times \sum_{i=1}^n 1$$

Nesse ponto, devemos lembrar que $\sum_{i=1}^n X_i = n \times \bar{X}$ e $\sum_{i=1}^n Y_i = n \times \bar{Y}$. Logo,

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - (\bar{Y} \times n \times \bar{X}) - (\bar{X} \times n \times \bar{Y}) + (\bar{X} \times \bar{Y} \times n)$$

Observem que as duas últimas parcelas se anulam:



$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - (n \times \bar{X} \times \bar{Y}) - (n \times \bar{X} \times \bar{Y}) + (n \times \bar{X} \times \bar{Y})$$

Portanto,

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}$$

Utilizaremos essa fórmula alternativa para calcular o numerador do coeficiente de correlação. Reparem que a expressão do lado esquerdo nos obriga a calcular todos os desvios $(X_i - \bar{X})$ e $(Y_i - \bar{Y})$, enquanto a expressão do lado direito não. Nessa fórmula, n indica o número de pontos no gráfico de dispersão, isto é, o número de pares ordenados.

Na fórmula anterior, se substituirmos Y por X , teremos a seguinte expressão:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (X_i - \bar{X})] = \sum_{i=1}^n (X_i \times X_i) - n \times \bar{X} \times \bar{X}$$

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n \times (\bar{X})^2$$

Já, se substituirmos X por Y , iremos obter:

$$\sum_{i=1}^n [(Y_i - \bar{Y}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (Y_i \times Y_i) - n \times \bar{Y} \times \bar{Y}$$

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n \times (\bar{Y})^2$$

As últimas duas fórmulas são formas alternativas que podem ser empregadas no cálculo do denominador do coeficiente de correlação.

Substituindo as expressões alternativas na formulação inicial, o coeficiente de correlação linear de Pearson r passa a ser:

$$r = r_{XY} = r(X, Y) = \frac{\sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n \times (\bar{X})^2) \times (\sum_{i=1}^n Y_i^2 - n \times (\bar{Y})^2)}}$$

em que r , r_{XY} e $r(X, Y)$ representam a correlação linear entre as variáveis X e Y ; X_i e Y_i são os valores observados das variáveis X e Y para o i -ésimo ponto de dados; n é o número total de observações; e $\bar{X}$ e $\bar{Y}$ são as médias aritméticas das variáveis X e Y , respectivamente.



Os termos dessa fórmula também podem ser reorganizados, de forma a enfatizar as somas e as somas dos quadrados:

$$r = r_{XY} = r(X, Y) = \frac{n \times (\sum_{i=1}^n X_i \times Y_i) - (\sum_{i=1}^n X_i) \times (\sum_{i=1}^n Y_i)}{\sqrt{n \times (\sum_{i=1}^n X_i^2) - (\sum_{i=1}^n X_i)^2} \sqrt{n \times (\sum_{i=1}^n Y_i^2) - (\sum_{i=1}^n Y_i)^2}}$$

Aqui, o numerador calcula a diferença entre o produto das somas dos pares $X_i \times Y_i$ multiplicado por n e o produto das somas individuais de X e Y . O denominador, por sua vez, envolve a raiz quadrada de dois termos, que representam a variância das variáveis X e Y , cada uma multiplicada por n .

Para simplificar a fórmula do coeficiente de correlação linear de Pearson, alguns autores adotam a seguinte simbologia:

$$x_i = (X_i - \bar{X})$$

$$y_i = (Y_i - \bar{Y})$$

Esta abordagem está basicamente centrando os valores de X e Y em torno de suas médias.

A fórmula do coeficiente de correlação linear de Pearson usando essas novas variáveis centradas (x_i e y_i) fica:

$$r = \frac{\sum_{i=1}^n (x_i \times y_i)}{\sqrt{\sum_{i=1}^n x_i^2} \times \sqrt{\sum_{i=1}^n y_i^2}}$$

onde x_i e y_i são os desvios de X_i e Y_i em relação às médias $\bar{X}$ e $\bar{Y}$, respectivamente.


Agora que já conhecemos a fórmula do coeficiente de correlação de Pearson e suas variações, é importante entender o intervalo de seus possíveis valores. O coeficiente de correlação de Pearson pode assumir quaisquer valores entre -1 e $+1$, ou seja:

$$-1 \leq r \leq 1$$


Assim, quanto mais próximo r estiver de 0, menor será a relação linear entre as duas variáveis. Por sua vez, quanto mais próximo r estiver de (1 ou -1), maior será a relação linear entre as duas variáveis.



O valor de r é positivo quando a variável Y tende a aumentar ou a diminuir se X também aumentar ou diminuir, respectivamente. Nessa situação, dizemos que as variáveis são positivamente correlacionadas. No exemplo a seguir, os dados estão praticamente em cima de uma reta, indicando a existência de uma correlação positiva forte, isto é, r muito próximo de 1. No caso, o coeficiente de correlação foi de 0,99267.




Se a correlação for positiva e todos os pontos estiverem sobre uma mesma reta, o valor de r será exatamente 1. Nesse caso, dizemos que a correlação é **positiva e perfeita**.




O valor de r é negativo quando a variável Y tende a diminuir ou aumentar quando X aumentar ou diminuir, respectivamente. Nessa situação, dizemos que as variáveis estão negativamente correlacionadas. No




exemplo a seguir, os dados estão praticamente em cima de uma reta, indicando a existência de uma correlação negativa forte, isto é, r muito próximo de -1 . No caso, o coeficiente de correlação foi de $-0,9918$.



Se a correlação for negativa e todos os pontos estiverem sobre uma mesma reta, o valor de r será exatamente -1 . Nesse caso, dizemos que a correlação é **negativa e perfeita**.



O valor de r é zero (ou um valor muito próximo de zero) quando não existe uma relação linear entre as variáveis. No exemplo a seguir, o coeficiente de correlação é 0,1132. Nesse caso, dizemos que a **correlação linear é nula ou inexistente**.



Vejamos agora um exemplo numérico.

As questões normalmente informam os valores dos somatórios e exigem apenas a aplicação correta da fórmula. Apesar disso, vamos considerar uma tabela com 5 pares ordenados, representando as notas de 5 alunos nas disciplinas X e Y, para calcular o coeficiente de correlação pelas duas fórmulas:

Aluno	X_i	Y_i
1	6,50	7,00
2	7,50	8,00
3	8,00	8,00
4	8,50	9,00
5	9,50	10,00



Primeiro, teremos que calcular as médias de X e Y:

$$\bar{X} = \frac{6,50 + 7,50 + 8,00 + 8,50 + 9,50}{5} = \frac{40}{5} = 8,00$$

$$\bar{Y} = \frac{7,00 + 8,00 + 8,00 + 9,00 + 10,00}{5} = \frac{42}{5} = 8,40$$

Agora, calcularemos os desvios de X e Y em relação às suas médias:

Aluno	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$
1	6,50	7,00	6,50 - 8,00 = -1,50	7,00 - 8,40 = -1,40
2	7,50	8,00	7,50 - 8,00 = -0,50	8,00 - 8,40 = -0,40
3	8,00	8,00	8,00 - 8,00 = 0,00	8,00 - 8,40 = -0,40
4	8,50	9,00	8,50 - 8,00 = 0,50	9,00 - 8,40 = 0,60
5	9,50	10,0	9,50 - 8,00 = 1,50	10,00 - 8,40 = 1,60

Vou limpar a memória de cálculo para facilitar a visualização:

Aluno	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$
1	6,50	7,00	-1,50	-1,40
2	7,50	8,00	-0,50	-0,40
3	8,00	8,00	0,00	-0,40
4	8,50	9,00	0,50	0,60
5	9,50	10,0	1,50	1,60



Nesse ponto, teremos que calcular o numerador e o denominador do coeficiente de correlação. Para tanto, precisaremos multiplicar os desvios de X pelos desvios de Y, bem como calcular os quadrados dos desvios:

Aluno	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	6,50	7,00	-1,50	-1,40	$(-1,50) \times (-1,40) = 2,10$	$(-1,50)^2 = 2,25$	$(-1,40)^2 = 1,96$
2	7,50	8,00	-0,50	-0,40	$(-0,50) \times (-0,40) = 0,20$	$(-0,50)^2 = 0,25$	$(-0,40)^2 = 0,16$
3	8,00	8,00	0,00	-0,40	$(0,00) \times (-0,40) = 0,00$	$(0,00)^2 = 0,00$	$(-0,40)^2 = 0,16$
4	8,50	9,00	0,50	0,60	$(0,50) \times (0,60) = 0,30$	$(0,50)^2 = 0,25$	$(0,60)^2 = 0,36$
5	9,50	10,0	1,50	1,60	$(1,50) \times (1,60) = 2,40$	$(1,50)^2 = 2,25$	$(1,60)^2 = 2,56$

Limpendo a memória de cálculo e deixando apenas os resultados. Vejamos:

Aluno	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	6,50	7,00	-1,50	-1,40	2,10	2,25	1,96
2	7,50	8,00	-0,50	-0,40	0,20	0,25	0,16
3	8,00	8,00	0,00	-0,40	0,00	0,00	0,16
4	8,50	9,00	0,50	0,60	0,30	0,25	0,36
5	9,50	10,0	1,50	1,60	2,40	2,25	2,56

Conhecendo esses valores, podemos calcular os somatórios da fórmula de correlação.

$$\sum_{i=1}^5 [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = 2,10 + 0,20 + 0,00 + 0,30 + 2,40 = 5,00$$

$$\sum_{i=1}^5 (X_i - \bar{X})^2 = 2,25 + 0,25 + 0,00 + 0,25 + 2,25 = 5,00$$


$$\sum_{i=1}^5 (Y_i - \bar{Y})^2 = 1,96 + 0,16 + 0,16 + 0,36 + 2,56 = 5,20$$



Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$
$$r = \frac{5,00}{\sqrt{5,00 \times 5,20}}$$
$$r \cong 0,9805$$

O coeficiente de correlação linear ficou muito próximo de 1, o que implica dizer que existe uma relação linear intensa entre as notas das duas disciplinas. Vejamos o gráfico de dispersão das duas variáveis



Pronto, agora utilizaremos as fórmulas alternativas para calcular o mesmo coeficiente de correlação. Vamos relembrar a fórmula:

$$r = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

O numerador pode ser calculado mediante a aplicação da seguinte fórmula:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}$$



Por sua vez, o denominador pode ser calculado por meio das seguintes fórmulas:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n \times (\bar{X})^2$$

$$\sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n \times (\bar{Y})^2$$

Retornemos à tabela inicial:

Aluno	X_i	Y_i
1	6,50	7,00
2	7,50	8,00
3	8,00	8,00
4	8,50	9,00
5	9,50	10,00

Já calculamos as médias de X e Y:

$$\bar{X} = \frac{6,50 + 7,50 + 8,00 + 8,50 + 9,50}{5} = \frac{40}{5} = 8,00$$

$$\bar{Y} = \frac{7,00 + 8,00 + 8,00 + 9,00 + 10,00}{5} = \frac{42}{5} = 8,40$$

Precisamos de três colunas adicionais: $X \times Y$, X^2 e Y^2

Aluno	X_i	Y_i	$X_i \times Y_i$	X_i^2	Y_i^2
1	6,50	7,00	$6,50 \times 7,00 = 45,50$	$(6,50)^2 = 42,25$	$(7,00)^2 = 49,00$
2	7,50	8,00	$7,50 \times 8,00 = 60,00$	$(7,50)^2 = 56,25$	$(8,00)^2 = 64,00$
3	8,00	8,00	$8,00 \times 8,00 = 64,00$	$(8,00)^2 = 64,00$	$(8,00)^2 = 64,00$
4	8,50	9,00	$8,50 \times 9,00 = 76,50$	$(8,50)^2 = 72,25$	$(9,00)^2 = 81,00$
5	9,50	10,0	$9,50 \times 10,00 = 95,00$	$(9,50)^2 = 90,25$	$(10,00)^2 = 100,00$



Limpendo a memória de cálculo, ficamos com os seguintes resultados:

Aluno	X_i	Y_i	$X_i \cdot Y_i$	X_i^2	Y_i^2
1	6,50	7,00	45,50	42,25	49,00
2	7,50	8,00	60,00	56,25	64,00
3	8,00	8,00	64,00	64,00	64,00
4	8,50	9,00	76,50	72,25	81,00
5	9,50	10,0	95,00	90,25	100,00

Agora, podemos calcular os somatórios da fórmula:

$$\sum_{i=1}^5 (X_i \times Y_i) = 45,50 + 60,00 + 64,00 + 76,50 + 95,00 = 341,00$$

$$\sum_{i=1}^5 X_i^2 = 42,25 + 56,25 + 64,00 + 72,25 + 90,25 = 325,00$$

$$\sum_{i=1}^5 Y_i^2 = 49,00 + 64,00 + 64,00 + 81,00 + 100,00 = 358$$

Já temos todas as informações necessárias para a aplicação das fórmulas alternativas.

O numerador do coeficiente de correlação é calculado por:

$$\sum_{i=1}^5 (X_i \times Y_i) - 5 \times \bar{X} \times \bar{Y} = 341,00 - 5 \times 8,00 \times 8,40 = 5,00$$

Os termos do denominador são calculados pelas seguintes fórmulas:

$$\sum_{i=1}^5 X_i^2 - 5 \times (\bar{X})^2 = 325 - 5 \times 8,00^2 = 5,00$$

$$\sum_{i=1}^5 Y_i^2 - 5 \times (\bar{Y})^2 = 358 - 5 \times 8,40^2 = 5,20$$

Aplicando a fórmula do coeficiente de correlação, temos:

$$r = \frac{\sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}}{\sqrt{(\sum_{i=1}^n X_i^2 - n \times (\bar{X})^2) \times (\sum_{i=1}^n Y_i^2 - n \times (\bar{Y})^2)}}$$

$$r = \frac{5,00}{\sqrt{5,00 \times 5,20}}$$

$$r \cong 0,9805$$



Portanto, o resultado produzido mediante a aplicação das fórmulas alternativas é exatamente o mesmo das fórmulas tradicionais.



O coeficiente de correlação linear também pode ser definido por meio das seguintes expressões:

$$r = \frac{S_{XY}}{\sqrt{S_{XX} \times S_{YY}}}$$

em que S_{XX} representa a soma dos quadrados das diferenças entre cada valor X_i e a média $\bar{X}$, $S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2$; S_{YY} é a soma dos quadrados das diferenças entre cada valor Y_i e a média $\bar{Y}$, $S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2$; e S_{XY} é a soma dos produtos das diferenças entre cada X_i e $\bar{X}$ e cada Y_i e $\bar{Y}$, $S_{XY} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$.

Também pode aparecer na seguinte forma:

$$r = \frac{Cov(X, Y)}{\sigma_X \times \sigma_Y}$$

em que $Cov(X, Y)$ representa a covariância das variáveis X e Y ; σ_X e σ_Y representam o desvio padrão, respectivamente, das variáveis X e Y .



A covariância entre duas variáveis aleatórias X e Y pode ser expressa usando o conceito de esperança (ou valor esperado). Assim, a covariância é a diferença entre a esperança do produto e o produto das esperanças:

$$Cov(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$



Correlação Parcial

A correlação parcial é uma extensão do conceito de correlação linear de Pearson. Imagine que você está analisando a relação entre duas variáveis, X e Y , mas sabe que existe uma terceira variável, Z , que pode estar influenciando ambas. A correlação de Pearson entre X e Y pode ser influenciada por Z , o que pode distorcer nossa compreensão da verdadeira relação entre X e Y .

A **correlação parcial** entra em ação para resolver esse problema. Ela mede a força e a direção da relação linear entre X e Y , enquanto controla, ou "ajusta", o efeito de Z . Em outras palavras, a correlação parcial nos diz como X e Y estão relacionadas, independentemente do impacto que Z possa ter sobre elas.

Se o coeficiente de correlação parcial for significativamente diferente da correlação original de Pearson entre X e Y , isso indica que a variável Z estava influenciando a correlação inicial. Isso é útil, por exemplo, quando queremos entender a relação direta entre duas variáveis sem que outra esteja interferindo.

Suponha que você quer investigar a relação entre horas de estudo (X) e notas em uma prova (Y). No entanto, o nível de estresse (Z) pode estar influenciando tanto o tempo de estudo quanto as notas. Se você calcular a correlação de Pearson entre X e Y , o efeito do estresse pode estar misturado com o efeito real do estudo. Ao calcular a correlação parcial, você "elimina" o efeito do estresse, permitindo focar na verdadeira relação entre horas de estudo e desempenho.

A notação que utilizamos para simbolizar o coeficiente de correlação parcial entre X e Y , controlando o efeito de Z é:

$$r_{XY,Z}$$

Essa notação pode se aplicar a qualquer quantidade de variáveis controladas, adicionando-se, após a vírgula, as outras variáveis.

A correlação parcial entre X e Y , ajustada para a variável Z , pode ser calculada usando a seguinte fórmula:

$$r_{XY,Z} = \frac{r_{XY} - r_{XZ} \cdot r_{YZ}}{\sqrt{(1 - r_{XZ}^2) \cdot (1 - r_{YZ}^2)}}$$

em que r_{XY} é o coeficiente de correlação de Pearson entre as variáveis X e Y ; r_{XZ} é o coeficiente de correlação de Pearson entre as variáveis X e Z ; e r_{YZ} é o coeficiente de correlação de Pearson entre as variáveis Y e Z .



EXEMPLIFICANDO

Considere que $r_{XY} = 0,6$, $r_{XZ} = 0,5$ e $r_{YZ} = 0,7$. Substituindo esses valores na fórmula:

$$r_{XY,Z} = \frac{0,6 - 0,5 \cdot 0,7}{\sqrt{(1 - 0,5^2) \cdot (1 - 0,7^2)}}$$



$$r_{XY,Z} = \frac{0,6 - 0,35}{\sqrt{(1 - 0,25) \cdot (1 - 0,49)}}$$
$$r_{XY,Z} = \frac{0,6 - 0,35}{\sqrt{0,75 \cdot 0,51}} = \frac{0,25}{\sqrt{0,3825}} = \frac{0,25}{0,6185} = 0,404$$

Nesse caso, a correlação parcial $r_{XY,Z}$ é aproximadamente 0,404, menor que a correlação inicial de 0,6 entre X e Y , mostrando que Z tem algum impacto na relação entre X e Y .

Autocorrelação

A autocorrelação é outro conceito relacionado à correlação, mas em vez de comparar duas variáveis diferentes, ela mede a relação entre os valores de **uma mesma variável** em **diferentes momentos** ou **posições**. **A autocorrelação avalia se os valores de uma variável, como X , estão relacionados consigo mesmos em diferentes pontos**. Podemos perguntar: "o valor de X hoje está relacionado com o de ontem?"

Se a autocorrelação for positiva, isso significa que os valores de X tendem a ser semelhantes em diferentes momentos ou posições. Se for negativa, indica que os valores tendem a se mover em direções opostas. E se a autocorrelação for próxima de zero, isso sugere que não há uma relação linear clara entre os valores em diferentes pontos.

A **autocorrelação** é particularmente importante na análise de **séries temporais**, pois ajuda a identificar padrões como **sazonalidade** e **tendências**. Esses padrões podem ser importantes para prever valores futuros com base nos valores passados. Além disso, na modelagem estatística, a autocorrelação dos resíduos (os erros do modelo) pode indicar problemas na definição (especificação) do modelo. Se os resíduos têm alta autocorrelação, isso pode violar as suposições da regressão, como a independência dos erros.

De forma resumida, **a autocorrelação nos ajuda a entender se e como uma variável está relacionada consigo mesma ao longo do tempo (séries temporais) ou em diferentes posições no espaço (análise de dados espaciais)**. Ela é uma ferramenta fundamental em diversas áreas, como economia, meteorologia e finanças, para entender a dinâmica dos dados e melhorar a precisão das previsões.



Propriedades do Coeficiente de Correlação

1ª Propriedade

- O coeficiente de correlação não sofre alteração quando uma constante é adicionada a (ou subtraída de) uma variável.

Considere os dados da seguinte tabelar:

i	X_i	Y_i
1	1	6
2	2	7
3	3	8
4	4	9
5	5	10

Como vimos, primeiro temos que encontrar as médias das duas variáveis:

$$\bar{X} = \frac{1 + 2 + 3 + 4 + 5}{5} = 3$$

$$\bar{Y} = \frac{6 + 7 + 8 + 9 + 10}{5} = 8$$

Agora, vamos montar a tabela auxiliar com os desvios $(X_i - \bar{X})$ e $(Y_i - \bar{Y})$, e os respectivos produtos $(X_i - \bar{X}) \times (Y_i - \bar{Y})$, $(X_i - \bar{X})^2$ e $(Y_i - \bar{Y})^2$.

i	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	1	6	-2	-2	4	4	4
2	2	7	-1	-1	1	1	1
3	3	8	0	0	0	0	0
4	4	9	1	1	1	1	1
5	5	10	2	2	4	4	4
Total					10	10	10



Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

$$r = \frac{10}{\sqrt{10 \times 10}}$$

$$r(X, Y) = 1$$

Logo, o coeficiente de correlação linear das variáveis X e Y é 1.

Agora, vamos adicionar 3 unidades à variável X e 5 unidades à variável Y .

i	$X_i + 3$	$Y_i + 5$
1	4	11
2	5	12
3	6	13
4	7	14
5	8	15

Novamente, temos que encontrando as médias das duas variáveis:

$$\bar{X} = \frac{4 + 5 + 6 + 7 + 8}{5} = 6$$

$$\bar{Y} = \frac{11 + 12 + 13 + 14 + 15}{5} = 13$$

Construindo a tabela auxiliar:

i	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	4	11	-2	-2	4	4	4
2	5	12	-1	-1	1	1	1
3	6	13	0	0	0	0	0
4	7	14	1	1	1	1	1
5	8	15	2	2	4	4	4
Total					10	10	10



Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{10}{\sqrt{10 \times 10}}$$

$$r(X + 3, Y + 5) = 1$$

Portanto, o coeficiente de correlação não sofreu alteração quando com a adição de 3 unidades à variável X e 5 unidades à variável Y.



EXEMPLIFICANDO

Essa propriedade simplifica a resolução de certas questões. Suponhamos que tivéssemos uma tabela com os seguintes valores e precisássemos calcular a correlação entre as variáveis X e Y.

i	X_i	Y_i
1	201	301
2	202	302
3	204	308
4	205	309

Reparem que podemos subtrair 200 de todos os valores de X e 300 de todos os valores de Y. Poderíamos, então, fazer uma transformação nessas variáveis, obtendo:

i	X_i	Y_i	$(X_i - 200)$	$(Y_i - 300)$
1	201	301	1	1
2	202	302	2	2
3	204	308	4	8
4	205	309	5	9

A propriedade estudada nos garante que $r(X, Y) = r(X - 200, Y - 300)$. Logo, poderíamos calcular a correlação por meio dos valores transformados.



Encontrando as médias das variáveis transformadas:

$$\bar{X} = \frac{1 + 2 + 4 + 5}{4} = 3$$

$$\bar{Y} = \frac{1 + 2 + 8 + 9}{4} = 5$$

Organizando a tabela auxiliar, teríamos:

i	X_i	Y_i	$(X_i - 200)$	$(Y_i - 300)$	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	201	301	1	1	-2	-4	8	4	16
2	202	302	2	2	-1	-3	3	1	9
3	204	308	4	8	1	3	3	1	9
4	205	309	5	9	2	4	8	4	16
Total							22	10	50

Aplicando esses valores na fórmula do coeficiente de correlação linear, teríamos:

$$r(X - 200, Y - 300) = \frac{22}{\sqrt{10 \times 50}} \cong 0,984$$

De fato, se jogássemos a tabela inicial em um software de estatística, veríamos que $r(X, Y) = 0,984$.



2ª Propriedade

- O coeficiente de correlação pode não sofrer alteração ou pode ter seu sinal alterado quando uma variável é multiplicada (ou dividida) por uma constante. Caso as constantes tenham o mesmo sinal, o valor do coeficiente de correlação não será alterado. Por outro lado, se as constantes tiverem sinais contrários, o coeficiente mudará de sinal, mas o valor permanecerá inalterado.

Ainda com relação ao exemplo trabalhado na propriedade anterior, vamos multiplicar a variável X por 2 e a variável Y por 2.

i	$X_i \times 2$	$Y_i \times 2$
1	2	12
2	4	14
3	6	16
4	8	18
5	10	20

Encontrando as médias das duas variáveis:

$$\bar{X} = \frac{2 + 4 + 6 + 8 + 10}{5} = 6$$

$$\bar{Y} = \frac{12 + 14 + 16 + 18 + 20}{5} = 16$$

Montando a tabela auxiliar:

i	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	2	12	-4	-4	16	16	16
2	4	14	-2	-2	4	4	4
3	6	16	0	0	0	0	0
4	8	18	2	2	4	4	4
5	10	20	4	4	16	16	16
Total					40	40	40



Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{40}{\sqrt{40 \times 40}}$$

$$r(2X, 2Y) = 1$$

Logo, a multiplicação por constantes de mesmo sinal não alterou o valor do coeficiente de correlação, nem implicou na alteração de seu sinal.

Se tivéssemos multiplicado a variável X por -2 e a variável Y por -2:

i	$X_i \times (-2)$	$Y_i \times (-2)$
1	-2	-12
2	-4	-14
3	-6	-16
4	-8	-18
5	-10	-20

Nessa situação, as médias das duas variáveis são:

$$\bar{X} = \frac{(-2) + (-4) + (-6) + (-8) + (-10)}{5} = -6$$

$$\bar{Y} = \frac{(-12) + (-14) + (-16) + (-18) + (-20)}{5} = -16$$

Construindo a tabela auxiliar, temos:

i	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	-2	-12	4	4	16	16	16
2	-4	-14	2	2	4	4	4
3	-6	-16	0	0	0	0	0
4	-8	-18	-2	-2	4	4	4
5	-10	-20	-4	-4	16	16	16
Total					40	40	40



Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{40}{\sqrt{40 \times 40}}$$

Como as constantes possuíam sinais iguais, o sinal do coeficiente de correlação foi mantido.

$$r(-2X, -2Y) = 1$$

Novamente, a multiplicação por constantes de mesmo sinal não alterou o valor do coeficiente de correlação, nem implicou na alteração de seu sinal.

Finalmente, vamos multiplicar a variável X por 2 e a variável Y por -2, constantes com sinais contrários.

<i>i</i>	$X_i \times 2$	$Y_i \times (-2)$
1	2	- 12
2	4	- 14
3	6	- 16
4	8	- 18
5	10	- 20

Encontrando as médias das duas variáveis:

$$\bar{X} = \frac{2 + 4 + 6 + 8 + 10}{5} = 6$$

$$\bar{Y} = \frac{(-12) + (-14) + (-16) + (-18) + (-20)}{5} = -16$$

Organizando a tabela auxiliar, temos:

<i>i</i>	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	2	-12	-4	4	-16	16	16
2	4	-14	-2	2	-4	4	4
3	6	-16	0	0	0	0	0
4	8	-18	2	-2	-4	4	4
5	10	-20	4	-4	-16	16	16



Total	-40	40	40
-------	-----	----	----

Aplicando esses valores na fórmula do coeficiente de correlação linear, temos:

$$r = \frac{-40}{\sqrt{40 \times 40}}$$

Portanto, como as constantes possuem sinais contrários, o sinal do coeficiente de correlação foi invertido.

$$r(2X, -2Y) = -1$$



EXEMPLIFICANDO

Essa propriedade pode simplificar a resolução de determinadas questões. Suponhamos que tivéssemos uma tabela com os seguintes valores e precisássemos calcular a correlação entre as variáveis X e Y.

i	X_i	Y_i
1	200	300
2	350	350
3	400	450
4	450	500

Reparem que todos os valores podem ser divididos por 50. Poderíamos, então, fazer uma transformação nessas variáveis, obtendo:

i	X_i	Y_i	$(X_i/50)$	$(Y_i/50)$
1	200	300	4	6
2	350	350	7	7
3	400	450	8	9
4	450	500	9	10



A propriedade estudada nos garante que $r(X, Y) = r\left(\frac{X}{50}, \frac{Y}{50}\right)$. Logo, poderíamos calcular a correlação por meio dos valores transformados.

Encontrando as médias das variáveis transformadas:

$$\bar{X} = \frac{4 + 7 + 8 + 9}{4} = 7$$

$$\bar{Y} = \frac{6 + 7 + 9 + 10}{4} = 9$$

Organizando a tabela auxiliar, teríamos:

i	X_i	Y_i	$\left(\frac{X_i}{50}\right)$	$\left(\frac{Y_i}{50}\right)$	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	200	300	4	6	-3	-2	6	9	4
2	350	350	7	7	0	-1	0	0	1
3	400	450	8	9	1	1	1	1	1
4	450	500	9	10	2	2	4	4	4
Total							11	14	10

Aplicando esses valores na fórmula do coeficiente de correlação linear, teríamos:

$$r\left(\frac{X}{50}, \frac{Y}{50}\right) = \frac{11}{\sqrt{14 \times 10}} \cong 0,93$$

De fato, se jogássemos a tabela inicial em um software de estatística, veríamos que $r(X, Y) = 0,93$.



REGRESSÃO LINEAR SIMPLES

A regressão simples é uma continuação do conceito de correlação/covariância. A regressão tenta explicar a relação de uma variável chamada dependente, usando outra variável chamada independente.

Na regressão linear simples queremos calcular a expressão matemática que relaciona Y (variável dependente) em função de X (variável independente). Como estamos falando de regressão linear simples, trata-se da equação que representa uma reta. Essa equação pode ser escrita como:


$$y = m \cdot x + b$$

O coeficiente m é conhecido como **taxa de variação** ou **coeficiente angular da reta**. Esse coeficiente indica que uma função é **crescente se $m > 0$** ; **decrescente se $m < 0$** ; ou **constante se $m = 0$** . Para uma reta que passa pelos pontos (x_0, y_0) e (x, y) , o coeficiente angular é expresso por:

$$m = \frac{\Delta y}{\Delta x} = \frac{y - y_0}{x - x_0}$$

O coeficiente b é conhecido como **coeficiente linear da reta** e determina o ponto em que a reta intercepta o eixo y .

Vamos calcular a reta apresentada na figura abaixo, que passa pelos pontos $(2, 7)$ e $(4, 11)$.



O **coeficiente angular da reta (m)** é o quociente entre a variação de y e a variação de x . Podemos escolher qualquer um dos pontos como referência para o cálculo da variação, desde que tenhamos atenção na hora de aplicar os dados na fórmula. A ordem a ser considerada é sempre $x - x_0$ e $y - y_0$, em que x_0 e y_0 são as



coordenadas do ponto tomado como referência. Assim, se adotarmos o ponto (2,7) como referência, teremos:

$$m = \frac{\Delta y}{\Delta x} = \frac{11 - 7}{4 - 2} = 2$$

Dessa forma, a equação da reta fica:

$$y = m \cdot x + b$$

$$y = 2 \cdot x + b$$

Para calcular o valor de b , podemos usar qualquer ponto da reta, a exemplo de (2, 7).

$$7 = 2 \cdot 2 + b$$


$$7 = 4 + b$$

$$b = 3$$

Logo, a expressão que representa nossa reta nesse exemplo é:

$$y = 2 \cdot x + 3$$

Como $b = 3$, a reta intercepta o eixo y no ponto (0, 3). Vejamos:



No caso de uma correlação perfeita positiva, todos os pontos do gráfico se alinham exatamente em uma linha reta. Mas o que aconteceria se os pontos no gráfico estivessem mais dispersos, sem evidenciar uma correlação linear perfeita? Ainda assim conseguiríamos determinar uma reta que se ajustasse a esse tipo de gráfico? A resposta é sim, e isso é possível através da técnica de regressão linear, que acomoda a variabilidade nos dados.



A equação do modelo de regressão linear simples é:

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

onde $i = 1, 2, 3, \dots, n$.

Nesta equação, $\alpha + \beta X_i$, representa a parte de Y_i que varia linearmente com X_i . Ele fornece a previsão ou valor esperado de Y dado X . Mais formalmente, podemos expressar isso como:

$$E(Y_i | X_i = X) = \alpha + \beta X$$

O valor esperado de Y_i dado X_i indica que, para cada valor de X , esperamos que Y siga essa tendência linear.

O termo de erro aleatório, ε_i , captura a variabilidade não explicada pelo modelo linear. Ele representa os desvios ou erros cometidos ao tentarmos aproximar a série de observações (Y_i) por meio de uma reta. Esses erros são assumidos como tendo **média zero** e **variância constante**, refletindo a incerteza natural nos dados.

Nesse modelo, Y_i é a variável cujo comportamento desejamos prever ou explicar, sendo chamada de variável **dependente** ou **resposta**. Por outro lado, a variável X_i é utilizada para explicar o comportamento de Y_i , sendo conhecida como **independente**, **regressora**, **explanatória** ou **explicativa**.

Finalmente, o modelo de regressão linear requer que sejam atendidos alguns pressupostos básicos quanto à variável aleatória ε_i (erro ou desvio):

- i) $E(\varepsilon_i) = 0$. A média dos erros é igual a zero. Ou seja, os desvios "para cima da reta" igualam o valor dos desvios "para baixo da reta" na média.
- ii) $Var(\varepsilon_i) = \sigma^2$. A variância dos erros é constante. Essa propriedade é denominada de **homocedasticia**. Isso só é possível se a variável ε_i tiver variância constante. Ou seja, se ela tiver sempre a mesma variância, independente de qual o valor de X_i . Quando o modelo apresenta variâncias diferentes para o erro, temos uma situação de **heterocedasticia**.
- iii) $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Os erros cometidos não são correlacionados, isto é, **os desvios ε_i são variáveis aleatórias independentes**. Quando os erros não são independentes, temos uma situação denominada de **autocorrelação**.



(CESPE 2019/TJ-AM) Um estudo considerou um modelo de regressão linear simples na forma $y = 0,8x + b + \epsilon$, em que y é a variável dependente, x representa a variável explicativa do modelo, o coeficiente b denomina-se intercepto e ϵ é um erro aleatório que possui média nula e desvio padrão σ . Sabe-se que a variável y segue a distribuição normal padrão e que o modelo apresenta coeficiente de determinação R^2 igual a 85%.



Com base nessas informações, julgue o item que se segue.

O erro aleatório ϵ segue a distribuição normal padrão.

Comentários:

No modelo de regressão linear simples, as seguintes suposições sobre o erro devem ser observadas:

$E(\epsilon) = 0$, isto é, em média, o erro do modelo deve ser 0;

$Var(\epsilon) = \sigma^2$, a variância deve ser constante, isto é, deve existir homocedasticidade;

$Cov(\epsilon_i, \epsilon_j) = 0$, os erros devem ser independentes, ou seja, não há correlação entre os erros.

Nessa questão, o único ponto que precisamos mostrar é que o $Var(\epsilon) = 1$. O enunciado afirmou que Y segue distribuição normal padrão. De fato, Y tem distribuição $N(b + 0,8x + \mu; \sigma^2) = N(0,1)$ em que σ^2 é a variância do erro. Como Y segue uma normal padrão, então $\sigma^2 = 1$. Consequentemente, o erro também seguirá uma distribuição normal, $\epsilon \sim N(0,1)$.

Gabarito: Certo.

Estimativa por Mínimos Quadrados Ordinários (MQO)

O método dos mínimos quadrados estabelece que a **reta de regressão deve ser a que minimiza a soma dos quadrados das diferenças entre os pontos experimentais e a reta estimada**, medidas no sentido da variação aleatória. Em outras palavras, o objetivo é **minimizar a soma dos quadrados dos resíduos** ($\sum_{i=1}^n e_i^2$), ou seja, as diferenças entre os valores observados e os valores ajustados pelo modelo.

Esse método é empregado na obtenção das estimativas a e b dos parâmetros α e β de um modelo de regressão linear, descrito pela seguinte equação populacional:

$$Y_i = \alpha + \beta X_i + \epsilon_i$$

A expressão usada para determinar a reta de regressão estimada a partir dos dados amostrais é:

$$\hat{Y}_i = a + bX_i$$

em que a e b são as estimativas dos parâmetros α e β , respectivamente.

Os erros (ou resíduos) resultantes da aplicação do modelo de regressão linear correspondem às diferenças entre os valores observados e os valores estimados pelo modelo:

$$e_i = Y_i - \hat{Y}_i$$

O objetivo do método dos mínimos quadrados é minimizar o somatório dos quadrados desses resíduos:

$$\sum_{i=1}^n e_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$



Para encontrar as estimativas a e b que minimizam essa soma dos quadrados dos resíduos, precisamos derivar a função de soma dos quadrados dos resíduos em relação a a e b e igualar a zero. Isso nos leva às seguintes equações:

1. Derivada em relação a a :

$$\frac{\partial}{\partial a} \sum_{i=1}^n (Y_i - a - bX_i)^2 = -2 \sum_{i=1}^n (Y_i - a - bX_i) = 0$$

2. Derivada em relação a b :

$$\frac{\partial}{\partial b} \sum_{i=1}^n (Y_i - a - bX_i)^2 = -2 \sum_{i=1}^n X_i (Y_i - a - bX_i) = 0$$

Resolvendo esse sistema de equações simultâneas, obtemos as estimativas a e b que minimizam a soma dos quadrados dos resíduos e, portanto, proporcionam a melhor linha de ajuste para os dados amostrais de acordo com o critério dos mínimos quadrados.

Estimador do Coeficiente Angular (b)

O coeficiente b em um modelo de regressão linear simples representa a inclinação da linha de melhor ajuste, indicando a relação entre a variável independente X e a variável dependente Y . Por esse método, o valor de b é calculado por meio da fórmula:

$$b = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sum_{i=1}^n [(X_i - \bar{X})^2]}$$

Existem, no entanto, alternativas para calcular o coeficiente b , que podem ser mais convenientes em diversas situações. Uma dessas alternativas usa a covariância e a variância, onde b é calculado como:

$$b = \frac{Cov(X, Y)}{Var(X)}$$

aqui, a covariância entre X e Y é dada por $Cov(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n}$, e a variância de X é $Var(X) = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}$.

Outra abordagem utiliza uma formulação alternativa baseada em somas, onde o numerador da fórmula para b pode ser expresso como:

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}$$



e para o denominador, temos:

$$\sum_{i=1}^n [(X_i - \bar{X})^2] = \sum_{i=1}^n (X_i^2) - n \times \bar{X}^2$$

Dessa forma, o coeficiente b pode ser reescrito como:

$$b = \frac{\sum_{i=1}^n (X_i Y_i) - n \times \bar{X} \times \bar{Y}}{\sum_{i=1}^n (X_i^2) - n \times \bar{X}^2}$$

Além disso, as notações S_{XX} , S_{XY} e S_{YY} são amplamente utilizadas para simplificar cálculos de somas de quadrados e produtos. S_{XX} representa a soma dos quadrados das diferenças entre cada valor X_i e a média $\bar{X}$, ou seja, $S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n \times \bar{X}^2$, medindo a variabilidade de X .

Por outro lado, S_{XY} é a soma dos produtos das diferenças entre cada X_i e $\bar{X}$ e cada Y_i e $\bar{Y}$, ou seja, $S_{XY} = \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \sum_{i=1}^n X_i Y_i - n \times \bar{X} \times \bar{Y}$. Esta soma captura a relação linear entre X e Y .

Finalmente, S_{YY} é a soma dos quadrados das diferenças entre cada valor Y_i e a média $\bar{Y}$, ou seja, $S_{YY} = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n Y_i^2 - n \times \bar{Y}^2$, que mede a variabilidade de Y .

O coeficiente b pode então ser expresso de forma simples utilizando estas notações, como:

$$b = \frac{S_{XY}}{S_{XX}}$$

em que S_{XY} indica a direção e a força da relação linear entre X e Y , enquanto S_{XX} indica a variabilidade de X .

Além desses métodos, existe uma fórmula alternativa para a inclinação que usa o coeficiente de correlação de Pearson ρ e os desvios padrão das variáveis X e Y . A fórmula para calcular o coeficiente b usando o coeficiente de correlação é:

$$b = \rho \times \frac{\sigma_y}{\sigma_x}$$

onde ρ é o coeficiente de correlação de Pearson entre X e Y ; σ_x é o desvio padrão da variável X ; e σ_y é o desvio padrão da variável Y .

Esta fórmula expressa a inclinação da linha de regressão como uma função da força da correlação linear entre X e Y (ρ), ajustada pela relação entre suas variabilidades (σ_x e σ_y). O coeficiente de correlação ρ varia entre -1 e $+1$, indicando a direção e a força da relação linear. Um valor de ρ próximo de 1 ou -1 sugere uma forte relação linear, enquanto um valor próximo de 0 indica uma relação fraca.



Estimador do Intercepto (a)

Além do coeficiente b , que determina a **inclinação da linha de regressão**, também precisamos calcular o coeficiente a , que representa o **intercepto da linha de regressão** no eixo Y . A equação da reta de regressão linear simples é dada por:

$$\hat{Y}_i = a + bX_i$$

A reta de regressão passa pelos pontos médios $(\bar{X}, \bar{Y})$ das variáveis X e Y . Isso implica que o valor de a pode ser calculado substituindo o valor de b em:

$$a = \bar{Y} - b\bar{X}$$

onde $\bar{Y}$ é a média da variável dependente Y ; $\bar{X}$ é a média da variável independente X ; e b é o coeficiente que calculamos anteriormente.

O coeficiente a nos fornece uma interpretação do ponto em que a linha de regressão intercepta o eixo Y . Isso é particularmente útil quando queremos entender o valor de Y na ausência de qualquer efeito de X (ou seja, quando $X = 0$). Logo, o coeficiente a indica o valor esperado de Y quando X é igual a zero.

Estimador da Variância dos Erros

A variância dos erros, que indica a dispersão dos dados em torno da linha de regressão, é estimada pela fórmula:

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Essa fórmula fornece uma estimativa da variância σ^2 dos erros ϵ_i do modelo, e o valor obtido é a estimativa de $\hat{\sigma}^2$.

Variância do Estimador do Coeficiente b

A variância do coeficiente b é dada por:

$$Var(b) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

onde $\sum_{i=1}^n (X_i - \bar{X})^2$ é a soma dos quadrados das diferenças entre cada X_i e a média $\bar{X}$ da variável independente X . A variância de b indica a incerteza associada ao estimador da inclinação da reta de regressão.



Variância do Estimador do Coeficiente a

A variância do intercepto a é dada por:

$$Var(a) = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right)$$

onde $\bar{X}$ é a média dos valores de X_i . Esta fórmula mostra que a variância do intercepto a depende tanto da variabilidade dos valores de X_i quanto da posição média de X e do tamanho da amostra n . A variância de a indica a incerteza associada ao estimador do intercepto da reta de regressão.



A variância dos coeficientes estimados é essencial para várias análises estatísticas:

a) intervalos de confiança: a variância dos coeficientes permite a construção de intervalos de confiança para a e b , que indicam a faixa dentro da qual os valores verdadeiros dos parâmetros estão com um certo nível de confiança;

b) testes de hipóteses: a variância dos coeficientes é utilizada para realizar testes de hipóteses, como testar se o coeficiente b é significativamente diferente de zero, o que indicaria uma relação estatisticamente significativa entre X e Y ; e

c) precisão das previsões: uma menor variância dos coeficientes indica maior precisão na estimativa dos parâmetros, o que leva a previsões mais confiáveis do modelo.



Vejamos uma aplicação da regressão linear. A tabela a seguir apresenta as notas de 5 alunos nas disciplinas X e Y . Calcule os coeficientes da reta de regressão.

Aluno	X	Y	$X - \bar{X}$	$Y - \bar{Y}$	$(X - \bar{X}) \times (Y - \bar{Y})$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$
1	5	9	-2	1	-2	4	1
2	5	8	-2	0	0	4	0



3	8	10	1	2	2	1	4
4	8	7	1	-1	-1	1	1
5	9	6	2	-2	-4	4	4
Média	7	8	Total		-5	14	10

Calculando o valor de b :

$$b = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}$$

$$b = \frac{-5}{14}$$

$$b \cong -0,357$$

O valor de a é calculado por:

$$a = \bar{Y} - b\bar{X}$$

$$a = 8 - (-0,357) \times 7$$

$$a = 8 + 2,499$$

$$a = 10,499$$

Assim, a reta de regressão estimada é:

$$\hat{Y} = 10,499 - 0,357 \times X$$


Temos dessa reta estimada que a soma dos quadrados dos desvios é mínima. Podemos montar uma nova tabela contendo os valores observados de (Y) e os valores estimados pela reta ($\hat{Y}$):

Aluno	X	Y	$\hat{Y}$
1	5	9	8,714
2	5	8	8,714
3	8	10	7,643



4	8	7	7,643
5	9	6	7,286

Montando o gráfico com os valores estimados, temos:



Percebam que a reta tem uma correlação negativa. Os pontos azuis são os pares ordenados da amostra e a reta vermelha é a reta de regressão que calculamos de tal forma que os desvios de estimativa cometidos se comportem segundo a condição de mínimos quadrados.



O coeficiente b pode ser calculado por meio da seguinte expressão:

$$b = \frac{S_{XY}}{S_{XX}}$$

Em que $S_{XY} = \sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]$ e $S_{XX} = \sum_{i=1}^n (X_i - \bar{X})^2$.



(VUNESP 2019/MPE-SP). Um aluno teve as seguintes notas: 3; 5; 5,5; 6,5. O professor quer atribuir a nota final, escolhendo uma nota representativa desse conjunto com base no método dos mínimos quadrados. Desse modo, essa nota final será

- a) 4.
- b) 4,5.
- c) 5.
- d) 5,5.
- e) 6.

Comentários:

Vamos montar uma tabela com os dados fornecidos:

X	Y	$(X - \bar{X})$	$(Y - \bar{Y})$	$(X - \bar{X})(Y - \bar{Y})$	$(X - \bar{X})^2$
1	3	-1,5	-2	3	2,25
2	5	-0,5	0	0	0,25
3	5,5	0,5	0,5	0,25	0,25
4	6,5	1,5	1,5	2,25	2,25
$\bar{X} = 2,5$	$\bar{Y} = 5$	Total		5,5	5

Pelo método dos mínimos quadrados, temos:

$$\hat{Y} = a + bX_i$$

$$b = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2}$$

$$b = \frac{5,5}{5} = 1,1$$

$$a = \bar{Y} - b\bar{X}$$

$$a = 5 - 1,1 \times 2,5$$

$$a = 2,25$$

Nossa reta de regressão será:

$$\hat{Y} = a + bX_i$$

$$\hat{Y} = 2,25 + 1,1X$$



Sabendo que a reta de regressão passa pelo ponto $(\bar{X}, \bar{Y})$, então:

$$\hat{Y} = 2,25 + 1,1 \times 2,5$$

$$\hat{Y} = 5$$

Gabarito: C.

(CESPE 2018/ABIN) Ao avaliar o efeito das variações de uma grandeza X sobre outra grandeza Y por meio de uma regressão linear da forma $\hat{Y} = \hat{\alpha} + \hat{\beta}X$, um analista, usando o método dos mínimos quadrados, encontrou, a partir de 20 amostras, os seguintes somatórios (calculados sobre os vinte valores de cada variável):

$$\sum X = 300; \sum Y = 400; \sum X^2 = 6.000; \sum Y^2 = 12.800 \text{ e } \sum(XY) = 8.400$$

A partir desses resultados, julgue o item a seguir.

Para $X = 10$, a estimativa de Y é $\hat{Y} = 12$.

Comentários:

Inicialmente, vamos calcular os valores de $\bar{Y}$ e de $\bar{X}$:

$$\bar{Y} = \frac{\sum y}{n} = \frac{400}{20} = 20$$

$$\bar{X} = \frac{\sum x}{n} = \frac{300}{20} = 15$$

Agora, utilizaremos o método dos mínimos quadrados para determinar $\hat{\beta}$:

$$\begin{aligned}\hat{\beta} &= \frac{\sum X_i Y_i - n \bar{X} \bar{Y}}{\sum X_i^2 - n \bar{X}^2} \\ \hat{\beta} &= \frac{8400 - 20 \times 15 \times 20}{6000 - 20 \times 15^2} \\ \hat{\beta} &= \frac{2400}{1500} = 1,6\end{aligned}$$

Conhecendo $\hat{\beta}$, podemos determinar o valor de $\hat{\alpha}$:

$$\begin{aligned}\hat{\alpha} &= \frac{\sum Y_i - \hat{\beta} \sum X_i}{n} \\ \hat{\alpha} &= 20 - 1,6 \times 15 = -4\end{aligned}$$

Assim, o modelo de regressão é dado por:

$$\hat{Y} = -4 + 1,6X$$

Para $X = 10$, temos o seguinte valor de $\hat{Y}$:



$$\hat{Y} = -4 + 1,6 \times 10$$
$$\hat{Y} = 12$$

Gabarito: Certo.

(FCC 2018/Pref. São Luís) Analisando um gráfico de dispersão referente a 10 pares de observações (t, Y_t) com $t = 1, 2, 3, \dots, 10$, optou-se por utilizar o modelo linear $Y_t = \alpha + \beta t + \varepsilon_t$ com o objetivo de se prever a variável Y , que representa o faturamento anual de uma empresa em milhões de reais, no ano $(2007 + t)$. Os parâmetros α e β são desconhecidos e ε_t é o erro aleatório com as respectivas hipóteses do modelo de regressão linear simples. As estimativas de α e β (a e b , respectivamente) foram obtidas por meio do método dos mínimos quadrados com base nos dados dos 10 pares de observações citados. Se $\alpha = 2$ e a soma dos faturamentos dos 10 dados observados foi de 64 milhões de reais, então, pela equação da reta obtida, a previsão do faturamento para 2020 é, em milhões de reais, de

- a) 11,6
- b) 15,0
- c) 13,2
- d) 12,4
- e) 14,4

Comentários:

A reta calculada é expressa por:

$$\hat{Y} = a + b \times t$$

Sabemos que a soma dos faturamentos dos 10 dados observados foi de 64 milhões de reais, então, calculando a média temos:

$$\bar{Y} = \frac{64}{10} = 6,4.$$

Agora, vamos calcular a média de t :

$$\bar{t} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 + 9 + 10}{10} = 5,5$$

Sabemos que $a = 2$ e que a reta de regressão passa pelo ponto $(\bar{t}, \bar{Y})$. Portanto, vamos encontrar o valor de b :

$$\bar{Y} = a + b\bar{t}$$

$$6,4 = 2 + b \times 5,5$$

$$b = \frac{4,4}{5,5}$$

$$b = 0,8$$

A reta fica assim:



$$\hat{Y} = 2 + 0,8t$$

Em 2020, temos que $t = 13$, pois $2020 = 2007 + 13$. Logo:

$$\hat{Y} = 2 + 0,8 \times 13$$

$$\hat{Y} = 12,4$$

Gabarito: D.

Reta Passando pela Origem

Em determinadas situações, a reta de regressão deve **passar pela origem** para que consiga se ajustar adequadamente ao modelo teórico. Quando isso ocorre, temos uma situação em que o **coeficiente linear da reta de regressão é nulo ($\alpha = 0$)**.

Nesse caso, o modelo de regressão que passa obrigatoriamente pela origem é:

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

$$Y_i = 0 + \beta X_i + \varepsilon_i$$

$$Y_i = \beta X_i + \varepsilon_i.$$

em que X_i é a variável independente ou explicativa; Y_i é a variável dependente ou resposta; ε_i representa os erros aleatórios e β é o parâmetro populacional a ser estimado.

Assim, a estimativa de β , pelo **método dos mínimos quadrados**, é:

$$b = \frac{\sum X_i \times Y_i}{\sum X_i^2}$$

A reta de regressão ajustada é:

$$\hat{Y}_i = bX_i.$$

Os desvios ou resíduos são dados por:

$$e_i = Y_i - \hat{Y}_i.$$

Nesse caso, não há garantia de que o somatório dos resíduos seja igual a zero.






EXEMPLIFICANDO

Calcular a reta que passa pela origem e comparar os desvios dessa abordagem com os desvios do modelo linear tradicional para os dados abaixo:

i	X	Y
1	1	4
2	2	5
3	3	6
4	4	6
5	5	9

Se utilizássemos o modelo de regressão linear tradicional, a reta que iríamos obter seria a seguinte:



Agora, vamos calcular a reta de regressão que passa pela origem e comparar com o modelo tradicional. Para isso, adicionaremos duas colunas à tabela original:



i	X	Y	$X \times Y$	X^2
1	1	4	4	1
2	2	5	10	4
3	3	6	18	9
4	4	6	24	16
5	5	9	45	25
Total			101	55

De posse dos totais dessas duas colunas, podemos estimar o valor de β pelo método dos mínimos quadrados:


$$b = \frac{\sum X_i \times Y_i}{\sum X_i^2} = \frac{101}{55} \cong 1,836$$

Portanto, a reta de regressão ajustada é:

$$\hat{Y}_i = bX_i$$

$$\hat{Y}_i = 1,836 \times X_i$$

Vejamos como esse modelo se comporta em relação ao modelo tradicional:



Vamos, agora, comparar os resíduos da abordagem tradicional com os desvios do modelo que passa pela origem:

i	Modelo tradicional			Modelo que passa pela origem		
	Y_i	$\hat{Y}_i$	$e_i = Y_i - \hat{Y}_i$	Y_i	$\hat{Y}_i$	$e_i = Y_i - \hat{Y}_i$
1	4	3,8	0,2	4	1,8364	2,1636
2	5	4,9	0,1	5	3,6727	1,3273
3	6	6	0	6	5,5091	0,4909
4	6	7,1	-1,1	6	7,3455	-1,3455
5	9	8,2	0,8	9	9,1818	-0,1818
Total			0	Total		2,4545

Reparem que, no modelo que passa pela origem, não há garantia de que o somatório dos desvios seja zero.

Estimativa por Máxima Verossimilhança (EMV)

A estimativa por máxima verossimilhança (EMV) é outro método estatístico utilizado para estimar os parâmetros de um modelo de regressão linear simples, na forma $Y = \alpha + \beta X + \varepsilon$. A EMV busca encontrar os valores de α e β que tornam a probabilidade dos dados observados ser a maior possível.

O primeiro passo para a estimativa por máxima verossimilhança é definir a função de verossimilhança, que expressa a probabilidade de observar os dados amostrais em função dos parâmetros do modelo. Supondo que os erros ε sejam independentes e identicamente distribuídos segundo uma distribuição normal com média zero e variância σ^2 , a função de verossimilhança para uma amostra de tamanho n é dada por :

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(Y_i - \alpha - \beta X_i)^2}{2\sigma^2}\right)$$

Para simplificar o processo de maximização, tomamos o logaritmo natural da função de verossimilhança. A função de log-verossimilhança correspondente é :

$$\log L(\alpha, \beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (Y_i - \alpha - \beta X_i)^2$$



Agora, derivamos a função de log-verossimilhança em relação aos parâmetros α e β e substituímos pelos estimadores a e b . As derivadas parciais da log-verossimilhança em relação a a e b são:

$$\frac{\partial \log L}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - a - bX_i) = 0$$
$$\frac{\partial \log L}{\partial b} = \frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - a - bX_i)X_i = 0.$$

Para maximizar a verossimilhança, igualamos as derivadas a zero. Resolvendo esse sistema de equações, verificamos que **as estimativas obtidas por EMV coincidem com aquelas obtidas pelo método dos mínimos quadrados ordinários (MQO) quando se assume normalidade dos erros:**

$$b = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

e

$$a = \bar{Y} - b\bar{X}$$

A estimativa de $\hat{\sigma}^2$ é encontrada através da soma dos quadrados dos resíduos dividida pelos graus de liberdade do modelo de regressão:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - a - bX_i)^2$$

A interpretação das estimativas é simples: a representa a estimativa do valor médio de Y quando $X = 0$; b representa a mudança esperada em Y para cada unidade de aumento em X ; e $\hat{\sigma}^2$ representa a variância dos erros de regressão, indicando a dispersão dos valores observados em torno da reta de regressão.



ANÁLISE DE VARIÂNCIA DA REGRESSÃO

A estratégia que adotamos para verificar se compensa ou não utilizar um modelo de regressão linear, $Y_i = \alpha + \beta X_i + \varepsilon_i$, é observar a redução no resíduo (desvio) quando comparado com um modelo aproximadamente uniforme $Y_i = \mu + \varepsilon_i$.

Se a redução é muito pequena, significa dizer que os dois modelos são praticamente equivalentes. Isso ocorre quando a inclinação β for zero ou um valor muito pequeno, não compensando usar um modelo mais complexo. Assim, estamos interessados em testar a hipótese:

$$\begin{cases} H_0: \beta = 0 \\ H_1: \beta \neq 0 \end{cases}$$

Se a hipótese nula é aceita, concluímos que não existe relação linear significativa entre as variáveis X e Y .

O resultado da **análise de variância da regressão** é uma tabela que resume várias medidas usadas no teste de hipóteses anterior. Para montar a tabela de análise de variância (ANOVA), precisamos conhecer: os graus de liberdade, as somas dos quadrados e os quadrados médios do modelo, dos resíduos (erros ou desvios) e total.

A seguir, veremos como construir a tabela de análise de variância da regressão.

Graus de Liberdade

O número total de graus de liberdade de uma amostra de tamanho n é:

$$GL_{Total} = n - 1$$

Como vimos anteriormente, a equação de regressão possui apenas dois parâmetros (α e β). Portanto, o número de graus de liberdade do modelo é:

$$GL_{Modelo} = 2 - 1 = 1$$

Agora, temos que descobrir o número de graus de liberdade dos resíduos. Para isso, utilizamos a seguinte relação:

$$GL_{Total} = GL_{Modelo} + GL_{Resíduos}$$

Daí, concluímos que:

$$n - 1 = 1 + GL_{Resíduos}$$

$$GL_{Resíduos} = n - 2$$





O número de graus de liberdade do modelo de regressão é:

$$GL_{Modelo} = 2 - 1 = 1$$

O número de graus de liberdade dos resíduos é:

$$GL_{Resíduos} = n - 2$$

O número de graus de liberdade total é:

$$GL_{Total} = n - 1$$

Somas de Quadrados

Como vimos, a reta de regressão linear fornece uma estimativa $\hat{Y}_i$ para uma variável Y_i . Os erros (desvios) resultantes da aplicação do modelo de regressão linear correspondem às diferenças entre os valores observados e os valores estimados:

$$e_i = Y_i - \hat{Y}_i \Rightarrow Y_i = e_i + \hat{Y}_i$$

Subtraindo $\bar{Y}$ dos dois lados, temos:

$$Y_i - \bar{Y} = e_i + \hat{Y}_i - \bar{Y}$$

Agora, elevando os dois lados ao quadrado:

$$(Y_i - \bar{Y})^2 = (e_i + \hat{Y}_i - \bar{Y})^2$$

$$(Y_i - \bar{Y})^2 = e_i^2 + (\hat{Y}_i - \bar{Y})^2 + 2 \times e_i \times (\hat{Y}_i - \bar{Y})$$

Somando tudo, temos:

$$\sum (Y_i - \bar{Y})^2 = \sum e_i^2 + \sum (\hat{Y}_i - \bar{Y})^2 + 2 \times \sum e_i \times (\hat{Y}_i - \bar{Y})$$



É possível demonstrar que :

$$2 \times \sum e_i \times (\hat{Y}_i - \bar{Y}) = 0$$

Logo,

$$\sum (Y_i - \bar{Y})^2 = \sum e_i^2 + \sum (\hat{Y}_i - \bar{Y})^2.$$

Portanto, temos que o **desvio total do modelo de regressão**, $(Y_i - \bar{Y})$, corresponde à soma dos desvios de cada valor de Y_i , tomados em relação à média $\bar{Y}$, elevados ao quadrado:

$$SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Assim, a **soma dos quadrados totais**, definida por $\sum (Y_i - \bar{Y})^2$, é igual a soma dos quadrados dos resíduos/desvios/erros, definida por $\sum e_i^2$, mais a soma dos quadrados do modelo de regressão, definida na expressão por $\sum (\hat{Y}_i - \bar{Y})^2$:

$$SQT = SQM + SQR$$

A parcela do desvio total que o modelo de regressão é capaz de explicar é denominada de "**desvio explicável**". Essa parcela corresponde à diferença entre cada valor previsto pelo modelo ($\hat{Y}_i$) e o valor médio ($\bar{Y}$). Assim, a **soma dos quadrados do modelo de regressão** é:

$$SQM = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

Podemos demonstrar que:

$$SQM = b \times \sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]$$

Em que b é a estimativa do coeficiente angular da reta de regressão.



A fórmula a seguir também pode ser utilizada para o cálculo de SQM:

$$SQM = b^2 \times \sum_{i=1}^n (X_i - \bar{X})^2$$

A parcela do desvio total que o modelo de regressão não é capaz de explicar é chamada de "**desvio não explicável**". Essa parcela corresponde à diferença entre cada valor de Y_i e o valor previsto pelo modelo $\hat{Y}_i$. Assim, podemos definir a **soma dos quadrados dos erros (resíduos)**.

$$SQR = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$



Em algumas questões de concurso, a notação SQR é utilizada para representar a **soma dos quadrados do modelo de regressão**, e não dos resíduos, como fizemos nesta aula. Na maioria das questões, contudo, SQR representa a **soma dos quadrados dos resíduos (erros)**.



A **soma dos quadrados totais** é calculada por meio das seguintes fórmulas:

$$SQT = SQM + SQR$$

$$SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2 = S_{YY}$$



A **soma dos quadrados do modelo** de regressão é calculada mediante as seguintes fórmulas:

$$SQM = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$
$$SQM = b \times \sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = b \times S_{XY}$$
$$SQM = b^2 \times \sum_{i=1}^n (X_i - \bar{X})^2 = b^2 \times S_{XX}$$

A **soma dos quadrados dos resíduos** é calculada pela fórmula:

$$SQR = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Coeficiente de Determinação

O **coeficiente de determinação** mede a **qualidade do ajuste proporcionado pela reta de regressão**. Ele determina a parcela da variação total de Y que é explicada pelo modelo de regressão, comparando a variação dos valores estimados pelo modelo com a variação total dos valores observados:

$$R^2 = \frac{\text{Variância Explicada}}{\text{Variância Total}}$$

Matematicamente, o coeficiente de determinação é definido como:

$$R^2 = \frac{SQM}{SQT}$$

em que R é o coeficiente de correlação linear, calculado pela expressão:

$$R = \sqrt{\frac{SQM}{SQT}}$$

O coeficiente de determinação também pode ser escrito da seguinte forma:

$$R^2 = \frac{SQM}{SQT} = \frac{SQT - SQR}{SQT} = 1 - \frac{SQR}{SQT}$$



A análise que queremos fazer segue o mesmo raciocínio do coeficiente de correlação, assim temos que:

$$0 \leq R^2 \leq 1$$

Portanto, quanto mais próximo de 1 estiver o coeficiente de determinação, mais forte será a correlação entre as variáveis. Implica dizer que grande parte da variação de Y é explicada pelo modelo de regressão linear, ou seja, a reta de regressão é capaz de explicar as diferenças entre os valores observados (Y_i) e a média ($\bar{Y}$).

Por exemplo, um $R^2 = 0,95$ indica que 95% da variação total em Y é explicada pelo modelo, enquanto os 5% restantes são atribuídos a fatores não capturados pelo modelo, como variações aleatórias ou outros fatores não incluídos na regressão.

Por outro lado, quanto mais próximo de 0 estiver o coeficiente de determinação, mais fraca será a correlação linear entre as variáveis. Significa dizer que grande parte da variação de Y não é explicada pelo modelo de regressão, ou seja, a reta de regressão é capaz de explicar muito pouco sobre as diferenças entre os valores observados (Y_i) e a média ($\bar{Y}$).

Quadrados Médios

Os quadrados médios são obtidos pela divisão entre as somas dos quadrados e os respectivos graus de liberdade. Assim, temos:

a) quadrado médio do modelo (QMM):

$$QMM = \frac{SQM}{1}$$

b) quadrado médio dos resíduos (QMR):

$$QMR = \frac{SQR}{n - 2}$$

c) quadrado médio total (QMT):

$$QMT = \frac{SQT}{n - 1}$$





O Quadrado Médio dos Resíduos (QMR) é uma **estimativa da variância residual σ^2** , utilizada em análises de variância (ANOVA) para medir a variabilidade dos erros dentro do modelo. Ele é calculado dividindo a soma dos quadrados dos resíduos pelo número de graus de liberdade associados aos resíduos, proporcionando uma medida para avaliar a qualidade do ajuste do modelo.

Coeficiente de Determinação Ajustado

O coeficiente de determinação ajustado é mais utilizado quando estamos tratando de regressão múltipla. Contudo, esse assunto também tem sido abordado em algumas questões de regressão linear simples. Assim, é importante conhecermos essa medida.

Basicamente, **essa medida ajusta o coeficiente de determinação aos graus de liberdade**. Ela é obtida pela divisão de SQR e SQT pelos respectivos graus de liberdade:

$$\overline{R^2} = 1 - \frac{SQR / (n - 2)}{SQT / (n - 1)}$$

A relação entre o coeficiente de determinação ajustado ($\overline{R^2}$) e o coeficiente de determinação tradicional (R^2) é dada por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - 2)}$$

Usando os quadrados médios, o coeficiente de determinação ajustado pode ser expresso como:

$$\overline{R^2} = 1 - \frac{QMR}{QMT}$$



Estatística F (Razão F)

Para testar $H_0: \beta = 0$ contra $H_1: \beta \neq 0$, usamos a seguinte estatística teste, denominada de estatística F (ou razão F):

$$F^* = \frac{QMM}{QMR}$$

Se o valor de F^* for significativamente grande, teremos evidências para rejeitar H_0 .

Sob a hipótese H_0 , F^* tem distribuição F de Snedecor, com 1 e $n - 2$ graus de liberdade, em que n é o número de observações.

Dessa forma, para avaliar o teste de hipóteses, basta compararmos o valor da estatística teste com o valor crítico tabelado:

- Se $F^* > F_{\text{crítico}}$, podemos rejeitar a hipótese nula;
- Se $F^* < F_{\text{crítico}}$, não podemos rejeitar a hipótese nula.

O valor de $F_{\text{crítico}}$ é consultado em uma tabela F de Snedecor com 1 grau de liberdade no numerador e $n - 2$ graus de liberdade no denominador, para um determinado nível de significância.

Tabela de Análise de Variância da Regressão

Em geral, as questões de **análise de variância da regressão** fornecem uma tabela incompleta e pedem alguma medida que está faltando. Para descobrir o valor da medida solicitada, você deve conhecer a estrutura da tabela e as fórmulas apresentadas neste tópico. A estrutura da tabela de análise de variância da regressão sempre terá o seguinte formato:

Fonte de Variação	Graus de Liberdade	Soma dos Quadrados	Quadrados Médios	Estatística F (Razão F)
Modelo	1	SQM	$QMM = \frac{SQM}{1}$	$F^* = \frac{QMM}{QMR}$
Resíduos	$n - 2$	SQR	$QMR = \frac{SQR}{n - 2}$	
Total	$n - 1$	SQT	$QMT = \frac{SQT}{n - 1}$	





(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

O referido estudo contemplou um conjunto de dados obtidos de $n = 11$ municípios.

Comentários:

Na análise de variância (ANOVA) da regressão, o total de graus de liberdade corresponde a $n - 1$, em que n representa o número total de amostras. Logo, podemos estabelecer que:

$$n - 1 = 11$$

$$n = 12 \text{ municípios.}$$

Gabarito: Errado.

(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

A correlação linear entre o número de leitos hospitalares por habitante (y) e o indicador de qualidade de vida (x) foi igual a 0,9.



Comentários:

O coeficiente de correlação linear entre as variáveis X e Y é calculado por meio da seguinte expressão:

$$R = \sqrt{\frac{SQR}{SQT}}$$

em que SQR indica a soma dos quadrados da regressão (modelo) e SQT a soma dos quadrados totais.

Pela tabela, verificamos que $SQT = 1000$ e $SQR = 900$. Substituindo esses valores na equação anterior, teremos:

$$R = \sqrt{\frac{900}{1000}} = \sqrt{0,9}$$

Portanto, o coeficiente de determinação R^2 possui valor igual a 0,9, mas o coeficiente de correlação não.

Gabarito: Errado.

(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

A razão F da tabela ANOVA refere-se ao teste de significância estatística do intercepto β_0 , em que se testa a hipótese nula $H_0: \beta_0 = 0$ contra a hipótese alternativa $H_A: \beta_0 \neq 0$.

Comentários:

A estatística $F = \frac{QMM}{QMR}$ está relacionada com o teste de hipótese para o coeficiente angular β da reta de regressão, isto é:

$$\begin{cases} H_0: \beta = 0 \\ H_1: \beta \neq 0 \end{cases}$$

Se a hipótese H_0 não é rejeitada, significa dizer que não existe uma relação linear significativa entre a variável explicativa (X) e a variável dependente (Y).

Gabarito: Errado.



(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

O desvio padrão amostral do número de leitos por habitante foi superior a 10 leitos por habitante.

Comentários:

A soma dos quadrados totais (SQT) é dada por:

$$SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

A variância amostral é calculada por:

$$\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1}$$

Pela tabela, o grau de liberdade do total corresponde a 11, então:

$$n - 1 = 11$$

Logo, a variância amostral é:

$$\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1} = \frac{SQT}{11} = \frac{1000}{11} = 90,90$$

Como a variância amostral é menor que 100, o desvio padrão amostral será:

$$\sqrt{90,90} < \sqrt{100}$$

$$\sqrt{90,90} < 10$$

Gabarito: Errado.



(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

A estimativa de σ^2 foi igual a 10.

Comentários:

A estimativa de σ^2 equivale ao quadrado médio residual. Logo,

$$\sigma^2 = QMR = 10$$

Gabarito: Certo.

(CESPE/EBSERH/2018) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos Quadrados	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue os itens subsequentes.

O R^2 ajustado (*Adjusted R Square*) foi inferior a 0,9.

Comentários:



O coeficiente de determinação permite avaliar a qualidade do ajuste do modelo, quantificando, basicamente, a capacidade do modelo de explicar os dados coletados. Ele é calculado por meio da expressão:

$$R^2 = \frac{SQM}{SQT} = 1 - \frac{SQR}{SQT},$$

em que SQM = Soma dos quadrados da regressão (modelo), SQR = Soma dos quadrados dos resíduos (erros) e SQT = Soma dos quadrados totais. Além disso, para evitar dificuldades na interpretação de R^2 , alguns estatísticos preferem usar o $\bar{R}^2$ ajustado, definido para uma equação com 2 coeficientes como

$$\bar{R}^2 = 1 - \left(\frac{n-1}{n-2} \right) \times (1 - R^2).$$

Pela tabela temos que $SQT = 1000$ e $SQR = 900$. Substituindo os valores apresentados na tabela nas equações acima teremos:

$$R^2 = \frac{900}{1000} = 0,9.$$

Além disso, como temos $n - 1 = 11$ graus de liberdade totais, então

$$\bar{R}^2 = 1 - \left(\frac{n-1}{n-2} \right) \times (1 - R^2).$$

$$\bar{R}^2 = 1 - \left(\frac{11}{10} \right) \times (1 - 0,9).$$

$$\bar{R}^2 = 1 - 1,1 \times 0,1$$

$$\bar{R}^2 = 1 - 0,11$$

$$\bar{R}^2 = 0,89.$$





Gabarito: Certo.



RESUMO DA AULA

CORRELAÇÃO LINEAR

A **correlação** é usada para indicar a força que mantém unidos dois conjuntos de valores. A **correlação linear** pode ser:

Gráfico	Definição
Correlação Positiva 	Direta ou positiva – quando temos dois fenômenos que variam no mesmo sentido. Se aumentarmos ou diminuirmos um deles, o outro também aumentará ou diminuirá;
Correlação Negativa 	Inversa ou negativa – quando temos dois fenômenos que variam em sentido contrário. Se aumentarmos ou diminuirmos um deles, acontecerá o contrário com o outro, no caso, diminuirá ou aumentará;
Correlação Nula 	Inexistente ou nula – quando não existe correlação ou dependência entre os dois fenômenos. Nessa situação, o valor do coeficiente de correlação linear será zero ($r = 0$) ou um valor aproximadamente igual a zero ($r \cong 0$);
Correlação Perfeita 	Perfeita – quando os fenômenos se ajustam perfeitamente a uma reta.



Coeficiente de Correlação de Pearson

COEFICIENTE DE CORRELAÇÃO LINEAR DE PEARSON

É adotado para medir o quão forte é a **RELAÇÃO** linear entre duas **VARIÁVEIS**.

FÓRMULA

$$r = \frac{\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \times \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

FÓRMULAS ALTERNATIVAS

$$\sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})] = \sum_{i=1}^n (X_i \times Y_i) - n \times \bar{X} \times \bar{Y}$$

$$\sum_{i=1}^n [(X_i - \bar{X})^2] = \sum_{i=1}^n (X_i^2) - n \times \bar{X}^2$$

$$\sum_{i=1}^n [(Y_i - \bar{Y})^2] = \sum_{i=1}^n (Y_i^2) - n \times \bar{Y}^2$$

Sobre a Coeficiente de Correlação de Pearson, podemos afirmar que:

- I – Pode assumir quaisquer valores entre **1 e -1**, ou seja: $-1 \leq r \leq 1$.
- II – Quanto mais próximo **r** estiver de **0**, **menor** será a **relação linear** entre as duas variáveis
- III – Quanto mais próximo **r** estiver de **(1 ou -1)**, **maior** será a **relação linear** entre as duas variáveis.

Propriedades do Coeficiente de Correlação

1ª Propriedade

- O coeficiente de correlação não sofre alteração quando uma constante é adicionada a (ou subtraída de) uma variável.

2ª Propriedade

- O coeficiente de correlação pode não sofrer alteração ou pode ter seu sinal alterado quando uma variável é multiplicada (ou dividida) por uma constante. Caso as constantes tenham o mesmo sinal, o valor do coeficiente de correlação não será alterado. Por outro lado, se as constantes tiverem sinais contrários, o coeficiente mudará de sinal, mas o valor permanecerá inalterado.



REGRESSÃO LINEAR SIMPLES

REGRESSÃO LINEAR SIMPLES

Calcula a expressão matemática que relaciona Y (variável dependente) em função de X (variável independente).

Trata-se da equação que representa uma reta:

$$y = m \cdot x + b$$

- Propriedades

Sobre a Regressão Linear Simples, podemos afirmar que:

- I – O coeficiente m é conhecido como **taxa de variação** ou **coeficiente angular da reta**.
- II – O coeficiente angular é expresso por: $m = \frac{\Delta y}{\Delta x} = \frac{y - y_0}{x - x_0}$
- III – O coeficiente b é conhecido como **coeficiente linear da reta** e determina o ponto em que a reta intercepta o eixo y .
- IV – Quando a correlação linear **não é perfeita**, utilizamos a expressão $Y_i = \alpha + \beta X_i + \varepsilon_i$, para determinar a reta de regressão.

Método dos Mínimos Quadrados

MÉTODO DOS MÍNIMOS QUADRADOS

A reta a ser adotada deverá ser aquela que torna mínima a soma dos quadrados das distâncias da reta aos pontos experimentais, medidas no sentido da variação aleatória.

Esse método é empregado na obtenção dos estimadores α e β de um modelo de regressão linear:

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

Expressão usada para determinar a reta de regressão é:

$$\hat{Y}_i = a + bX_i$$



Reta Passando pela Origem

**MODELO DE REGRESSÃO QUE
PASSA OBRIGATORIAMENTE
PELA ORIGEM É:**

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

$$Y_i = 0 + \beta X_i + \varepsilon_i$$

$$\boxed{Y_i = \beta X_i + \varepsilon_i.}$$

ANÁLISE DE VARIÂNCIA DA REGRESSÃO

ANÁLISE DE VARIÂNCIA DA REGRESSÃO

Estratégia para verificar se
compensa ou não utilizar
um modelo de regressão
linear,

$$Y_i = \alpha + \beta X_i + \varepsilon_i$$

Observar a redução no
resíduo (desvio) quando
comparado com um
modelo aproximadamente
uniforme $Y_i = \mu + \varepsilon_i$.

Testar a hipótese:

$$\begin{cases} H_0: \beta = 0 \\ H_1: \beta \neq 0 \end{cases}$$

O resultado da **análise de
variância** da regressão é
uma tabela que resume
várias medidas usadas no
teste de hipóteses anterior.

Graus de Liberdade

O número de graus de liberdade do modelo de regressão é:

$$GL_{Modelo} = 2 - 1 = 1$$

O número de graus de liberdade dos resíduos é:

$$GL_{Resíduos} = n - 2$$

O número de graus de liberdade total é:

$$GL_{Total} = n - 1$$



Somas de Quadrados

A **soma dos quadrados totais** é calculada por meio das seguintes fórmulas:

$$SQT = SQM + SQR$$

$$SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

A **soma dos quadrados do modelo** de regressão é calculada mediante as seguintes fórmulas:

$$SQM = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$SQM = b \times \sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]$$

$$SQM = b^2 \times \sum_{i=1}^n (X_i - \bar{X})^2$$

A **soma dos quadrados dos resíduos** é calculada pela fórmula:

$$SQR = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Coefficiente de Determinação

O **coeficiente de determinação** é calculado pela fórmula:

$$R^2 = \frac{SQM}{SQT}$$

Em que **R** é o **coeficiente de correlação linear**, calculado pela expressão:

$$R = \sqrt{\frac{SQM}{SQT}}$$

O **coeficiente de determinação** também pode ser escrito da seguinte forma:

$$R^2 = \frac{SQM}{SQT} = \frac{SQT - SQR}{SQT} = 1 - \frac{SQR}{SQT}$$



Coeficiente de Determinação Ajustado

É obtida pela **divisão** de **SQR** e **SQT** pelos respectivos **graus de liberdade**:

$$\overline{R^2} = 1 - \frac{SQR / (n - 2)}{SQT / (n - 1)}$$

A **relação** entre o coeficiente de determinação **ajustado** ($\overline{R^2}$) e o coeficiente de determinação **tradicional** (R^2) é dada por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - 2)}$$

Quadrados Médios

Quadrado médio do **modelo (QMM)**: $QMM = \frac{SQM}{1}$

Quadrado médio dos **resíduos (QMR)**: $QMR = \frac{SQR}{n - 2}$

Quadrado médio **total (QMT)**: $QMT = \frac{SQT}{n - 1}$

Estatística F (Razão F)

Estatística **F (ou razão F)**: $F^* = \frac{QMM}{QMR}$

Se $F^* > F_{crítico}$, podemos **rejeitar a hipótese nula**;

Se $F^* < F_{crítico}$, **não** podemos **rejeitar a hipótese nula**.



Tabela de Análise de Variância da Regressão

Fonte de Variação	Graus de Liberdade	Soma dos Quadrados	Quadrados Médios	Estatística F (Razão F)
Modelo	1	SQM	$QMM = \frac{SQM}{1}$	$F^* = \frac{QMM}{QMR}$
Resíduos	$n - 2$	SQR	$QMR = \frac{SQR}{n - 2}$	
Total	$n - 1$	SQT	$QMT = \frac{SQT}{n - 1}$	



QUESTÕES COMENTADAS

Correlação Linear

1. (CEBRASPE/FINEP/2024) Duas variáveis, X e Y, possuem a mesma variância; se a correlação linear de Pearson entre elas for 0,8, e se a covariância entre X e Y for 2, então a variância de X será

- a) 2,50.
- b) 1,25.
- c) 0,20.
- d) 2,00.
- e) 0,40.

Comentários:

Inicialmente vamos organizar os dados do enunciado:

$$\rho(X, Y) = 0,8$$

$$\text{Cov}(X, Y) = 2$$

A correlação linear de Pearson é expressa por:

$$r = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \times \text{Var}(Y)}}$$

Em que $\text{Cov}(X, Y)$, representa a covariância entre X e Y.

O enunciado nos disse que a variância de X é igual a variância de Y. Substituindo os valores dados no enunciado, temos:

$$0,8 = \frac{2}{\sqrt{\text{Var}(X) \times \text{Var}(Y)}}$$

$$0,8 = \frac{2}{\text{Var}(X)}$$

$$\text{Var}(X) \times 0,8 = 2$$

$$\text{Var}(X) = \frac{2}{0,8}$$

$$\text{Var}(X) = 2,5$$

Portanto, como a variância de X e Y são iguais:



$$Var(X) = Var(Y) = 2,5$$

Gabarito: A.

2. (CEBRASPE/MPO/2024) Considerando os conceitos básicos e as técnicas de inferência causal, julgue o item a seguir.

O coeficiente de correlação de Pearson, que varia entre -1 e 1 , é uma medida estatística de causalidade, derivada da associação linear entre duas variáveis independente.

Comentários:

O coeficiente de correlação de Pearson realmente varia entre -1 e 1 , e mede o grau de associação linear entre duas variáveis. No entanto, correlação não implica causalidade.

A correlação de Pearson não é uma medida de causalidade, mas sim uma medida de associação estatística. Ela indica se duas variáveis se movem juntas linearmente - mas não explica por que isso acontece. Duas variáveis podem estar fortemente correlacionadas por coincidência ou por influência de uma terceira variável, sem que haja uma relação de causa e efeito entre elas.

Gabarito: Errado.

3. (CEBRASPE/STJ/2024)

Amostra	X	Y
1	25	13
2	20	10
3	20	12
4	20	10

Considerando os dados na tabela precedente, em que X denota o salário bruto e Y, o salário líquido de quatro servidores, em milhares de reais, julgue o item que se segue.

A correlação linear de Pearson entre X e Y é igual a $7/9$

Comentários:



Vamos iniciar calculando as médias de X e Y:

$$\bar{X} = \frac{25 + 20 + 20 + 20}{4} = \frac{85}{4}$$

$$\bar{Y} = \frac{13 + 10 + 12 + 10}{4} = \frac{45}{4}$$

Agora, vamos montar uma tabela com os valores necessários:

i	X_i	Y_i	$X_i - \bar{X}$	$Y_i - \bar{Y}$	$(X_i - \bar{X}) \times (Y_i - \bar{Y})$	$(X_i - \bar{X})^2$	$(Y_i - \bar{Y})^2$
1	25	13	$\frac{15}{4}$	$\frac{7}{4}$	$\frac{105}{16}$	$\frac{225}{16}$	$\frac{49}{16}$
2	20	10	$-\frac{5}{4}$	$-\frac{5}{4}$	$\frac{25}{16}$	$\frac{25}{16}$	$\frac{25}{16}$
3	20	12	$-\frac{5}{4}$	$\frac{3}{4}$	$-\frac{15}{4}$	$\frac{25}{16}$	$\frac{9}{16}$
4	20	10	$-\frac{5}{4}$	$-\frac{5}{4}$	$\frac{25}{16}$	$\frac{25}{16}$	$\frac{25}{16}$
Σ					$\frac{35}{4}$	$\frac{75}{4}$	$\frac{27}{4}$

Aplicando a fórmula de Pearson:

$$\rho = \frac{\Sigma(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\Sigma(X_i - \bar{X})^2 \times \Sigma(Y_i - \bar{Y})^2}} = \frac{\frac{35}{4}}{\sqrt{\frac{75}{4} \times \frac{27}{4}}}$$

Multiplicando os denominadores:

$$\sqrt{\frac{75 \times 27}{16}} = \sqrt{\frac{2025}{16}} = \frac{\sqrt{2025}}{4}$$

Sabemos que $\sqrt{2025} = 45$. Logo:

$$\rho = \frac{\frac{35}{4}}{\frac{45}{4}} = \frac{35}{4} \times \frac{4}{45} = \frac{35}{45} = \frac{7}{9}$$

Gabarito: Certo.



4. (FGV/STN/2024) Considere duas variáveis aleatórias X e Y tais que $E[X] = 5$, $\text{Var}[X] = 4$, $E[Y] = 4$, $\text{Var}[Y] = 9$ e $E[XY] = 18$. O coeficiente de correlação entre X e Y é, então, igual a

- a) $-1/2$.
- b) $-1/3$.
- c) 0 .
- d) $1/3$.
- e) $1/2$.

Comentários:

Para calcular o coeficiente de correlação entre duas variáveis aleatórias X e Y , precisamos usar a fórmula:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

onde:

- $\text{Cov}(X, Y)$ é a covariância entre X e Y ;
- σ_X é o desvio padrão de X ;
- σ_Y é o desvio padrão de Y .

Primeiro, vamos calcular a covariância $\text{Cov}(X, Y)$. A covariância é dada por:

$$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$$

Substituindo os valores fornecidos:

$$\text{Cov}(X, Y) = 18 - (5 \times 4) = 18 - 20 = -2$$

Agora, precisamos dos desvios padrões de X e Y . O desvio padrão é a raiz quadrada da variância. Então, temos:

$$\sigma_X = \sqrt{\text{Var}(X)} = \sqrt{4} = 2$$

$$\sigma_Y = \sqrt{\text{Var}(Y)} = \sqrt{9} = 3$$

Agora, podemos calcular o coeficiente de correlação ρ_{XY} :

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{-2}{2 \times 3} = \frac{-2}{6} = -\frac{1}{3}$$

Portanto, o coeficiente de correlação entre X e Y é $-\frac{1}{3}$.

Gabarito: B.



5. (FGV/Câmara dos Deputados/2023) Avalie se as seguintes afirmativas acerca do coeficiente de correlação linear r entre duas variáveis aleatórias contínuas estão corretas.

- I. O módulo de r é sempre menor ou igual a 1.
- II. Se $r = 0$, as duas variáveis são independentes.
- III. Valores de r próximos de +1 indicam uma correlação positiva forte.

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) I e II, apenas.
- d) I e III, apenas.
- e) II e III, apenas.

Comentários:

Vamos analisar cada item:

I. O módulo de r é sempre menor ou igual a 1.

Correto. O coeficiente de correlação linear r varia entre -1 e 1. Logo, o módulo de r é sempre menor ou igual a 1.

II. Se $r = 0$, as duas variáveis são independentes.

Incorreto. Se as duas variáveis são independentes, então, podemos sim afirmar que $r = 0$. No entanto, o fato de termos $r = 0$ não implica necessariamente que as duas variáveis são independentes, pois pode ser que exista uma relação não linear entre as variáveis, que o coeficiente de correlação linear não consegue capturar.

III. Valores de r próximos de +1 indicam uma correlação positiva forte.

Correto. Como dito anteriormente, o coeficiente de correlação linear r varia entre -1 e 1. Valores próximos de +1 indicam uma correlação positiva forte, enquanto valores próximos de -1 indicam uma correlação negativa forte.

Gabarito: D.



6. (FGV/SEFAZ-MG/2023) A tabela a seguir mostra a função de probabilidade conjunta de duas variáveis aleatórias X e Y:

		Valores de Y		
		-2	0	2
Valores de X	-1	0,2	0,1	0,2
	1	0,2	0,1	0,2

Assim, por exemplo, $P[X = 5; Y = 0] = 0,1$.

O coeficiente de correlação entre X e Y é igual a

- a) 0.
- b) 0,1.
- c) 0,2.
- d) 0,5.
- e) 1,0.

Comentários:

O coeficiente de correlação é a razão entre a covariância e o produto dos desvios padrão das variáveis:

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sigma_X \cdot \sigma_Y}$$

Por sua vez, a covariância é a diferença entre a esperança do produto e o produto das esperanças:

$$Cov(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$

Para calcular $E(X \cdot Y)$, multiplicamos cada possível valor das variáveis pela probabilidade correspondente e somamos os produtos:

$$E(X \cdot Y) = \sum_i \sum_j x_i \cdot y_j \cdot p(x_i, y_j)$$

Sabendo que X assume os valores -1 ou 1 e Y assume os valores -2, 0 ou 2, temos:



$$E(X.Y) = (-1) \times (-2) \times P(X = -1, Y = -2) + (-1) \times 0 \times P(X = -1, Y = 0) \\ + (-1) \times 2 \times P(X = -1, Y = 2) + 1 \times (-2) \times P(X = 1, Y = -2) \\ + 1 \times 0 \times P(X = 1, Y = 0) + 1 \times 2 \times P(X = 1, Y = 2)$$

Essas probabilidades constam na tabela da distribuição conjunta, fornecida:

$$E(X.Y) = (-1) \times (-2) \times 0,2 + (-1) \times 0 \times 0,1 + (-1) \times 2 \times 0,2 + 1 \times (-2) \times 0,2 + 1 \times 0 \times 0,1 \\ + 1 \times 2 \times 0,2$$

$$E(X.Y) = 0,4 + 0 - 0,4 - 0,4 + 0 + 0,4 = 0$$

Para calcular as esperanças marginais, vamos primeiro obter as probabilidades marginais para todos os valores de cada variável:

		Valores de Y			Total
		-2	0	2	
Valores de X	-1	0,2	0,1	0,2	0,5
	1	0,2	0,1	0,2	0,5
Total		0,4	0,2	0,4	1

A esperança marginal de X pode ser calculada como:

$$E(X) = \sum x.p(x)$$

$$E(X) = -1 \times 0,5 + 1 \times 0,5 = 0$$

E a esperança marginal de Y é:

$$E(Y) = -2 \times 0,4 + 0 \times 0,2 + 2 \times 0,4 = 0$$

Logo, a covariância é:

$$Cov(X, Y) = 0 - 0 \times 0 = 0$$

Consequentemente, o coeficiente de correlação também será igual a 0.

Gabarito: A.

7. (IBFC/Pref. Cuiabá/2023) Em relação à correlação, assinale a alternativa incorreta.

- a) Correlação não é casualidade
- b) No cálculo do coeficiente de correlação, não há distinção entre variável resposta ou explanatória



- c) Correlação nula indica variáveis independentes
- d) A correlação apenas não serve para descrever uma distribuição de dados

Comentários:

A correlação é usada para indicar a força que mantém unidos dois conjuntos de valores. Por meio da análise da correlação linear, buscamos identificar se existe alguma relação entre duas ou mais variáveis, ou seja, se as alterações nas variáveis estão associadas umas com a outras.

Vamos analisar as alternativas:

Alternativa A: **Correta**. Correlação não é casualidade. Correlação é a relação estatística entre duas variáveis, enquanto a causalidade expressa a relação de causa de consequência entre duas variáveis distintas, em que uma ocorre por causa da outra.

Alternativa B: **Correta**. No cálculo do coeficiente de correlação, não há distinção entre variável resposta ou explanatória. O coeficiente de correlação é adotado para medir o quão forte é a relação linear entre duas variáveis, ou seja, o grau de correlação entre duas variáveis. Portanto, não existe diferença entre variável resposta ou explanatória.

Alternativa C: **Incorreta**. Correlação nula indica variáveis independentes. Quando não existe uma relação linear entre as variáveis, dizemos que a correlação linear é nula ou inexistente. Isso não significa que as variáveis são independentes, apenas que não existe correlação entre elas.

Alternativa D: **Correta**. A correlação apenas não serve para descrever uma distribuição de dados. Conforme mencionado anteriormente, a correlação é usada para indicar a força que mantém unidos dois conjuntos de valores. Portanto, não descreve uma distribuição de dados.

Gabarito: C.

8. (IBFC/Pref. Cuiabá/2023) O coeficiente de correlação de Pearson fornece um grau de dependência entre duas variáveis contínuas. Analise as afirmativas a seguir e dê valores Verdadeiro (V) ou Falso (F).

() O coeficiente de correlação varia entre -1 e 1.

() O coeficiente de correlação é adimensional por calcular a dependência entre variáveis padronizados.

() Quanto mais próximo de 1 ou -1, a dependência entre as variáveis é linear.

Assinale a alternativa que apresenta a sequência correta de cima para baixo:



- a) V - F - F
- b) F - V - V
- c) V - V - V
- d) V - F - V

Comentários:

O coeficiente de correlação linear de Pearson é adotado para medir o quão forte é a relação linear entre duas variáveis. O coeficiente de correlação de Pearson pode assumir quaisquer valores entre 1 e -1, $-1 \leq r \leq 1$. Assim, quanto mais próximo r estiver de 0, menor será a relação linear entre as duas variáveis. Por sua vez, quanto mais próximo r estiver de (1 ou -1), maior será a relação linear entre as duas variáveis.

Considerando a explicação acima, vamos julgar as afirmativas:

- Item I. **Verdadeiro.** O coeficiente de correlação varia entre -1 e 1.
- Item II. **Verdadeiro.** O coeficiente de correlação é adimensional por calcular a dependência entre variáveis padronizados.
- Item III. **Verdadeiro.** Quanto mais próximo de 1 ou -1, a dependência entre as variáveis é linear.

Gabarito: C.

9. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y, tais que $\Sigma X = 24$; $\Sigma Y = 49$; $\Sigma XY = 181$; $\Sigma X^2 = 100$ e $\Sigma Y^2 = 343$.

O coeficiente de correlação de Pearson para os valores apresentados será negativo, o que indica que a regressão linear será representada por uma reta decrescente.

Comentários:

Calculando o coeficiente de correlação linear de Pearson, verificamos que:

$$\rho(X, Y) = \frac{n(\Sigma x_i y_i) - (\Sigma x_i)(\Sigma y_i)}{\sqrt{n(\Sigma x_i^2) - (\Sigma x_i)^2} \sqrt{n(\Sigma y_i^2) - (\Sigma y_i)^2}}$$
$$\rho(X, Y) = \frac{8 \times 181 - 24 \times 49}{\sqrt{8 \times 100 - 24^2} \sqrt{8 \times 343 - 49^2}}$$



$$\begin{aligned}\rho(X, Y) &= \frac{1448 - 1176}{\sqrt{800 - 576} \sqrt{2744 - 2401}} \\ \rho(X, Y) &= \frac{272}{\sqrt{224} \sqrt{343}} \\ \rho(X, Y) &= \frac{272}{14,96 \times 18,52} \\ \rho(X, Y) &= \frac{272}{277,06} = 0,98\end{aligned}$$

Portanto, o coeficiente de correlação de Pearson para os valores apresentados será positivo.

Gabarito: Errado.

10. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y, tais que $\Sigma X = 24$; $\Sigma Y = 49$; $\Sigma XY = 181$; $\Sigma X^2 = 100$ e $\Sigma Y^2 = 343$.

Existe uma correlação forte entre as variáveis X e Y.

Comentários:

Calculando o coeficiente de correlação linear de Pearson, verificamos que:

$$\begin{aligned}\rho(X, Y) &= \frac{n(\sum x_i y_i) - (\sum x_i)(\sum y_i)}{\sqrt{n(\sum x_i^2) - (\sum x_i)^2} \sqrt{n(\sum y_i^2) - (\sum y_i)^2}} \\ \rho(X, Y) &= \frac{8 \times 181 - 24 \times 49}{\sqrt{8 \times 100 - 24^2} \sqrt{8 \times 343 - 49^2}} \\ \rho(X, Y) &= \frac{1448 - 1176}{\sqrt{800 - 576} \sqrt{2744 - 2401}} \\ \rho(X, Y) &= \frac{272}{\sqrt{224} \sqrt{343}} \\ \rho(X, Y) &= \frac{272}{14,96 \times 18,52} \\ \rho(X, Y) &= \frac{272}{277,06} = 0,98\end{aligned}$$

Portanto, existe uma correlação forte (muito próxima de 1) entre as variáveis X e Y.

Gabarito: Certo.



11. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y, tais que $\Sigma X = 24$; $\Sigma Y = 49$; $\Sigma XY = 181$; $\Sigma X^2 = 100$ e $\Sigma Y^2 = 343$.

Com base no coeficiente de correlação linear, é correto afirmar, em face dos dados apresentados, que se trata de uma correlação espúria.

Comentários:

A correlação espúria normalmente ocorre quando duas variáveis não relacionadas são percebidas como se fossem, seja pelo acaso ou por um terceiro fator. Basicamente, a correlação espúria pode ser definida como uma associação entre variáveis que, na verdade, não apresentam uma relação natural.

O presente caso não é de correlação espúria, pois as variáveis apresentam uma correlação forte entre si, conforme verificamos a seguir:

$$\begin{aligned}\rho(X, Y) &= \frac{n(\sum x_i y_i) - (\sum x_i)(\sum y_i)}{\sqrt{n(\sum x_i^2) - (\sum x_i)^2} \sqrt{n(\sum y_i^2) - (\sum y_i)^2}} \\ \rho(X, Y) &= \frac{8 \times 181 - 24 \times 49}{\sqrt{8 \times 100 - 24^2} \sqrt{8 \times 343 - 49^2}} \\ \rho(X, Y) &= \frac{1448 - 1176}{\sqrt{800 - 576} \sqrt{2744 - 2401}} \\ \rho(X, Y) &= \frac{272}{\sqrt{224} \sqrt{343}} \\ \rho(X, Y) &= \frac{272}{14,96 \times 18,52} \\ \rho(X, Y) &= \frac{272}{277,06} = 0,98\end{aligned}$$

Gabarito: Errado.

12. (FGV/TRT-PB/2022) X e Y são variáveis aleatórias tais que

$E[X] = 5$, $E[Y] = 3$, $\text{Var}[X] = 16$, $\text{Var}[Y] = 4$, $E[XY] = 10$.

O coeficiente de correlação entre X e Y é igual a

a) - 0,625.

b) - 0,240.

c) 0,166.



d) 0,348.

e) 0,765.

Comentários:

O coeficiente de correlação entre X e Y é determinado pela divisão entre a covariância de X e Y e os desvios-padrões de X e de Y:

$$\rho = \frac{Cov(X, Y)}{\sigma_x \times \sigma_y}$$

A questão nos forneceu os valores das variâncias de X e de Y, então, podemos facilmente encontrar os valores dos desvios-padrões:

$$\sigma_x = \sqrt{Var[X]} = \sqrt{16} = 4$$

$$\sigma_y = \sqrt{Var[Y]} = \sqrt{4} = 2$$

A covariância é determinada pela seguinte expressão:

$$Cov(X, Y) = E[XY] - E[X] \times E[Y]$$

$$Cov(X, Y) = 10 - 5 \times 3$$

$$Cov(X, Y) = -5$$

Portanto, nosso coeficiente de correlação será:

$$\rho = \frac{-5}{2 \times 4}$$

$$\rho = \frac{-5}{8}$$

$$\rho = -0,625$$

Gabarito: A.



QUESTÕES COMENTADAS

Regressão Linear Simples

1. (FCC/CGM-SP/2025) Para prever a receita tributária (Y) no ano ($2014 + t$) em um município, optou-se pela utilização do modelo linear $Y_t = \alpha + \beta t + \varepsilon$, $t = 1, 2, 3, \dots$, sendo α e β parâmetros desconhecidos e ε o erro aleatório com as respectivas hipóteses consideradas para o modelo de regressão linear simples. Utilizando o método dos mínimos quadrados e com base nas observações da arrecadação anual da receita tributária, em bilhões de reais, de 2015 a 2024, obteve-se que o somatório das receitas de 2015 a 2024 foi de 370 bilhões de reais e a estimativa do parâmetro α igual a 15. Considerando, então, a equação da reta obtida pelo método dos mínimos quadrados, obtém-se que o acréscimo anual da receita tributária, em bilhões de reais, é igual a

- a) 4,8
- b) 3,6
- c) 2,4
- d) 4,0
- e) 6,0

Comentários:

A reta calculada é expressa por:

$$\bar{Y} = \alpha + \beta \bar{t}$$

Sabemos que a soma das receitas de 2015 a 2024 foi de 370 bilhões de reais, então, calculando a média, temos:

$$\bar{Y} = \frac{370}{10} = 37$$

Agora, vamos calcular a média de t :

$$\bar{t} = \frac{1 + 2 + 3 + 4 + 5 + 6 + 7 + 8 + 9 + 10}{10} = \frac{55}{10} = 5,5$$

Sabemos que $\alpha = 15$, logo, podemos encontrar o valor de β :

$$37 = 15 + b \times 5,5$$

$$37 - 15 = b \times 5,5$$



$$b = \frac{22}{5,5}$$

$$b = 4$$

Portanto, o acréscimo anual da receita tributária, em bilhões de reais, é igual a 4,0

Gabarito: D.

2. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V , em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.

A estimativa do coeficiente b é igual ou superior a 0,6.

Comentários:

Para encontrar a estimativa do coeficiente $\hat{b}$ na regressão linear simples, podemos usar a fórmula:

$$\hat{b} = r \times \frac{s_x}{s_y}$$

Onde:

- r é a correlação linear de Pearson entre y e x (dado como 0,5);
- s_y é o desvio padrão amostral de y (dado como 5);
- s_x é o desvio padrão amostral de x (dado como 4).

Substituindo os valores conhecidos na fórmula:

$$\hat{b} = 0,5 \times \frac{5}{4} = 5 \times 1,25 = 0,625$$



Portanto, a estimativa do coeficiente $\hat{b}$ é de 0,625. Assim, a afirmação de que a estimativa do coeficiente $\hat{b}$ é igual ou superior a 0,6 é verdadeira.

Gabarito: Certo.

3. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

$$\beta_1 = 3.$$

Comentários:

Para obtermos a estimativa do coeficiente angular β_1 no modelo de regressão, utilizamos a fórmula:

$$\hat{\beta} = \pm \sqrt{\frac{\sum_{j=1}^n (y_j - \bar{y})^2}{\sum_{j=1}^n (x_j - \bar{x})^2}}$$

Fazendo-se a substituição dos valores informados, encontra-se

$$\hat{\beta} = \pm \sqrt{\frac{720}{80}} = \pm \sqrt{9} = \pm 3$$



Considerando ainda que o problema especifica $\widehat{\beta}_1 > 0$, fica definido que $\widehat{\beta}_1 = 3$. Dessa forma, concluímos que a afirmativa apresentada está correta.

Gabarito: Certo.

4. (CEBRASPE/FINEP/2024)

x	0	1	2	3	4	5
y	0	1	3	13	14	25

Considerando que a tabela precedente exibe uma amostra aleatória bivariada (x,y) de tamanho 6, na qual representa uma variável dependente e denota uma variável regressora, assinale a opção que apresenta uma curva de regressão ($\hat{y}$) ajustada para esse conjunto de dados mediante aplicação do método de mínimos quadrados ordinários.

- a) $\hat{y} = x^2$
- b) $\hat{y} = 11,2$
- c) $\hat{y} = 3,73x$
- d) $\hat{y} = 0,5x^2 + 12,5$
- e) $\hat{y} = 5x - 2$

Comentários:

O objetivo do método dos mínimos quadrados é minimizar o somatório dos quadrados dos erros ($\sum_{i=1}^n e_i^2$). O enunciado pede para assinalarmos, dentre as alternativas, a opção que apresenta uma curva de regressão ($\hat{y}$) ajustada para esse conjunto de dados. Sendo assim, montaremos uma tabela para verificar qual alternativa minimiza o desvio quadrático:

X	Y	$\hat{Y} = X^2$	$\hat{Y} = 11,2$	$\hat{Y} = 3,73X$	$\hat{Y} = 0,5X^2 + 12,5$	$\hat{Y} = 5X - 2$
0	0	0	11,2	0	12,5	-2
1	1	1	11,2	3,73	13	3
2	3	4	11,2	7,46	14,5	8
3	13	9	11,2	11,19	17	13



4	14	16	11,2	14,92	20,5	18
5	25	25	11,2	18,65	25	23
$\bar{X} = 2,5$	$\bar{Y} = 9,33$					

Agora, calculando os desvios quadráticos para cada alternativa, temos que:

X	Y	$(Y - X^2)^2$	$(Y - 11,2)^2$	$(Y - 3,73X)^2$	$(Y - 0,5X^2 - 12,5)^2$	$(Y - 5X + 2)^2$
0	0	0	125,44	0	156,25	4
1	1	0	104,04	7,45	144	4
2	3	1	67,24	19,89	132,25	25
3	13	16	3,24	3,27	16	0
4	14	4	7,84	0,84	42,25	16
5	25	0	190,44	40,32	0	4
TOTAL		21	498,24	71,78	490,75	53

Portanto, dentre as opções apresentadas, a que minimiza o somatório do erro quadrático é a letra A.

Gabarito: A.

5. (CESGRANRIO/BNDES/2024) O método dos Mínimos Quadrados Ordinários (MQO) apresenta propriedades estatísticas que o tornam um dos métodos mais populares e eficientes de análise de regressão. A eficiência desse método depende da validade da seguinte hipótese:

- a) o modelo de regressão deve ser linear nos parâmetros e nas variáveis.
- b) o número de parâmetros estimados no modelo deve ser maior do que o número de variáveis utilizadas para estimá-lo.
- c) as variâncias dos erros do modelo devem ser constantes, isto é, heterocedásticas.



d) não deve haver autocorrelação entre os termos de erros do modelo, e o valor médio dos erros deve ser igual a zero.

e) não deve haver multicolinearidade e homocedasticidade entre as variáveis do modelo.

Comentários:

O método dos mínimos quadrados requer que alguns pressupostos sejam atendidos:

I – $E(\varepsilon_i) = 0$: a média dos erros deve ser igual a zero.

II – $Var(\varepsilon_i) = \sigma^2$: a variância do erro deve ser constante. Essa propriedade é denominada de homocedasticidade. Isto somente é possível se a variável ε tiver variância constante.

III – $Corr(\varepsilon_i, \varepsilon_j) = 0, para i \neq j$: essa propriedade garante que os erros cometidos pelo modelo são independentes, isto é, não se correlacionam.

IV – Os erros têm distribuição normal: outro importante pressuposto é de que não pode existir nenhuma relação linear entre as variáveis independentes. Se no modelo tivermos duas variáveis explicativas ou independentes proporcionais, ou seja, altamente correlacionadas, teremos um problema denominado de multicolinearidade.

Vamos às alternativas:

Alternativa A: **Incorreta**. O modelo de regressão deve ser linear nos parâmetros e nas variáveis.

O MQO requer que o modelo seja **linear nos parâmetros**, mas não necessariamente nas variáveis. Por exemplo, um modelo com $y = \beta_0 + \beta_1 x^2 + u$ é não linear em x , mas é linear nos parâmetros (β_0 e β_1), o que permite o uso do MQO.

Alternativa B: **Incorreta**. O número de parâmetros estimados no modelo deve ser maior do que o número de variáveis utilizadas para estimá-lo.

O número de observações no modelo deve ser maior que o número de parâmetros para garantir estimativas viáveis, mas o inverso (número de parâmetros maior que o de variáveis) não é necessário.

Alternativa C: **Incorreta**. As variâncias dos erros do modelo devem ser constantes, isto é, heterocedásticas.



A hipótese necessária para o MQO ser eficiente é a de homocedasticidade (variância constante dos erros). Heterocedasticidade (variância não constante) viola essa premissa.

Alternativa D: **Correta**. não deve haver autocorrelação entre os termos de erros do modelo, e o valor médio dos erros deve ser igual a zero.

Para que o MQO produza estimadores eficientes:

1. Os erros (u_i) devem ser independentes entre si (ausência de autocorrelação).
2. A média dos erros deve ser igual a zero, garantindo que as estimativas não sejam tendenciosas.

Alternativa E: **Incorreta**. Não deve haver multicolinearidade e homocedasticidade entre as variáveis do modelo.

A homocedasticidade é uma condição necessária, mas ela se refere aos erros do modelo, não às variáveis independentes. A multicolinearidade (alta correlação entre variáveis explicativas) dificulta a interpretação dos coeficientes, mas não invalida o uso do MQO.

Gabarito: D.

6. (FGV/TJ-MS/2024) Em um modelo de regressão linear simples, o estimador de máxima verossimilhança para o coeficiente angular (inclinação) é igual a:

- a) correlação (x,y) / desvio padrão (x) ;
- b) correlação (x,y) / variância (x) ;
- c) covariância (x,y) / correlação (x,y) ;
- d) covariância (x,y) / desvio padrão (x) ;
- e) covariância (x,y) / variância (x) .

Comentários:

Em um modelo de regressão linear simples, o estimador de máxima verossimilhança para os coeficientes é o mesmo que o estimador de mínimos quadrados ordinários (MQO). Ambos os métodos fornecem os mesmos valores para os coeficientes de regressão sob as suposições clássicas do modelo de regressão linear. Nesse caso, o coeficiente angular (b_1) é calculado como a covariância entre x e y dividida pela variância de x :



$$b_1 = \frac{Cov(x, y)}{Var(x)}$$

Gabarito: E.

7. (FGV/TJ-AP/2024) Uma pesquisa realizada em motores de carros relacionou a cilindrada à sua potência, obtendo os resultados da tabela abaixo.

Potência (cavalos)	Cilindrada (litros)
105	1,4
135	1,8
150	2,0

O valor da potência (em cavalos) estimada para um carro de 1.6 litro de cilindrada, ao se utilizar um modelo de regressão linear simples pelo método dos mínimos quadrados ordinários, é:

- a) 110;
- b) 115;
- c) 120;
- d) 125;
- e) 130.

Comentários:

Para encontrar a potência estimada para um carro de 1.6 litros de cilindrada usando um modelo de regressão linear simples pelo método dos mínimos quadrados ordinários, primeiro precisamos calcular os coeficientes da equação da reta de regressão.

A equação da regressão linear simples é dada por:

$$Y = a + bX$$

Onde Y é a variável dependente (potência em cavalos); X é a variável independente (cilindrada em litros); a é o intercepto da reta de regressão; b é o coeficiente angular.

Os coeficientes a e b podem ser calculados usando as fórmulas:

$$a = \bar{Y} - b\bar{X}$$



$$b = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

Vamos calcular os coeficientes usando os dados fornecidos. Antes, teremos que descobrir os valores das médias de X e Y :

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n} = \frac{1,4 + 1,8 + 2,0}{3} = \frac{5,2}{3} = 1,733$$

$$\bar{Y} = \frac{\sum_{i=1}^n Y_i}{n} = \frac{105 + 135 + 150}{3} = \frac{390}{3} = 130$$

Agora vamos utilizar uma tabela auxiliar para calcular as demais informações necessárias:

Potência (Y)	Cilindrada (X)	$X - \bar{X}$	$Y - \bar{Y}$	$(X_i - \bar{X})(Y_i - \bar{Y})$	$(X_i - \bar{X})^2$
105	1,4	-0,333	-25	8,333	0,111
135	1,8	0,067	5	0,333	0,004
150	2,0	0,267	20	5,333	0,071
Σ				14	0,1866667

Assim, o coeficiente b será:

$$b = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} = \frac{14}{0,18666} = 75$$

O coeficiente a será:

$$a = \bar{Y} - b\bar{X} = 130 - (75) \times 1,733 = 130 - 130 = 0$$

Portanto, a equação da reta será $Y = 75X$, bastando substituímos X por 1,6:

$$Y = 75X = 75 \times 1,6 = 120$$

Gabarito: C.

8. (FGV/TJ-AP/2024) Sejam $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, os dados da modelagem de uma regressão linear simples $Y_i = \alpha + \beta X_i + \varepsilon_i$ obtida pelo método dos mínimos quadrados. É correto afirmar que:

- a) o estimador de beta é dado pela covariância entre X e Y dividido pela variância de X ;
- b) o estimador de beta é dado pela covariância entre X e Y dividido pela variância de Y ;



- c) o estimador de alfa pode ser definido a partir da média de Y somada com o estimador de beta multiplicado pela média de X;
- d) a estimativa de alfa pode ser interpretada como o coeficiente angular da equação da reta no plano cartesiano bidimensional;
- e) a estimativa de beta pode ser interpretada como o coeficiente linear ou intercepto da equação da reta no plano cartesiano bidimensional.

Comentários:

De acordo com o modelo de regressão linear, podemos afirmar que o estimador de beta é dado pela covariância entre X e Y dividido pela variância de X:

$$b = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2} = \frac{\frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{n}}{\frac{\sum(X_i - \bar{X})^2}{n}} = \frac{Cov(X, Y)}{Var(X)}$$

Além disso, o estimador de alfa pode ser definido a partir da média de Y **subtraída** do estimador de beta multiplicado pela média de X;

$$a = \bar{Y} - b\bar{X}$$

Gabarito: A.

9. (CESGRANRIO/TRANSPETRO/2023) A gerência de uma pizzeria registrou a venda diária de pizzas napolitanas durante um ano (dentro do horário de 12 h a 23 h). Com os dados obtidos das vendas, ajustou-se a seguinte equação de regressão linear:

$$\text{Vendas} = 2 \times (\text{horário do pedido}) - 22$$

Com base nessas informações, o incremento horário no número de vendas é dado por

- a) -22
- b) 22
- c) 2
- d) -2
- e) -20

Comentários:

A equação de regressão linear fornecida é:



$$Vendas = 2 \cdot (\text{horário do pedido}) - 22$$

Uma equação de regressão linear tem a forma geral:

$$y = mx + b$$

onde:

- y é a variável dependente (número de vendas);
- x é a variável independente (horário do pedido);
- m é o coeficiente angular, que indica o incremento (ou decréscimo) na variável dependente por unidade de aumento na variável independente;
- b é o coeficiente linear, que representa o valor de y quando $x = 0$.

Na equação acima, o coeficiente angular é 2. Isso significa que, a cada 1 hora adicional no horário do pedido, o número de vendas aumenta em 2 unidades. Portanto, o incremento horário no número de vendas é 2.

Gabarito: C.

10. (FCC/COPERGÁS)/2023) Considere a equação a seguir como representação do modelo de regressão linear simples.

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Dado:

ε representa o erro aleatório.

De acordo com esse modelo,

- a) os erros associados a diferentes observações devem estar correlacionados.
- b) a equação resulta em uma parábola com concavidade voltada para o eixo das abscissas.
- c) os erros aleatórios devem apresentar heterocedasticidade.
- d) os erros aleatórios têm média zero.
- e) a equação deve relacionar uma variável dependente com inúmeras variáveis independentes.

Comentários:

O modelo de regressão linear requer que sejam atendidos alguns pressupostos básicos quanto à variável aleatória ε_i (erro ou desvio):



- i) $E(\varepsilon_i) = 0$. A média dos erros é igual a zero. Ou seja, os desvios "para cima da reta" igualam o valor dos desvios "para baixo da reta" na média.
- ii) $Var(\varepsilon_i) = \sigma^2$. A variância dos erros é constante. Essa propriedade é denominada de homocedasticidade. Isso só é possível se a variável ε_i tiver variância constante. Ou seja, se ela tiver sempre a mesma variância, independente de qual o valor de X_i . Quando o modelo apresenta variâncias diferentes para o erro, temos uma situação de heterocedasticidade.
- iii) $Cov(\varepsilon_i, \varepsilon_j) = 0$ para $i \neq j$. Os erros cometidos não são correlacionados, isto é, os desvios ε_i são variáveis aleatórias independentes. Quando os erros não são independentes, temos uma situação denominada de autocorrelação.

Portanto, a componente referente ao erro aleatório tem média zero.

Gabarito: D.

11. (FGV/BANESTES/2023) Quando se ajusta um modelo de Regressão Linear Simples no qual y é a variável a explicar e x é a variável explicativa, se r é o valor do coeficiente de correlação entre x e y , assinale a afirmativa correta.

- a) Não existe relação entre r e o coeficiente de determinação R^2 da regressão.
- b) O valor de r depende do ângulo formado pela reta de regressão de y contra x com o eixo horizontal.
- c) Se r for igual a zero, não existe nenhum tipo de dependência entre x e y .
- d) r pode assumir qualquer valor real entre $-\infty$ e $+\infty$.
- e) Quanto mais próximo r estiver de $+1$ ou de -1 , mais próximos os pontos estarão da reta de regressão.

Comentários:

O coeficiente de correlação pode assumir quaisquer valores entre 1 e -1 . Assim, quanto mais próximo o coeficiente estiver de 0 , menor será a relação linear entre as duas variáveis. Por sua vez, quanto mais próximo estiver de $(1$ ou $-1)$, maior será a relação linear entre as duas variáveis.

Gabarito: E.

12. (FGV/CGE SC/2023) Considere o modelo de regressão linear simples:

$$y_i = a + bx_i + u_i,$$



em que y é a variável dependente, x é a variável explicativa, a é o intercepto, b é o coeficiente de inclinação e u , o termo aleatório do modelo.

A partir de uma amostra aleatória, obtém-se as seguintes informações:

$$\bar{x} = 10, \bar{y} = 20, \text{Corr}(x, y) = 0,5, s_x = 5 \text{ e } s_y = 10$$

Assim, os estimadores dos parâmetros a e b que minimizam a soma dos quadrados dos resíduos são, respectivamente, iguais a

- a) 30 e 1.
- b) -20 e 4.
- c) 0 e 2.
- d) 10 e 1.
- e) 17,5 e 0,25.

Comentários:

Uma das maneiras de se determinar o coeficiente de correlação é por meio da fórmula:

$$\rho = \frac{\text{cov}(x, y)}{s_x \times s_y}$$

em que $\text{cov}(x, y)$ representa a covariância entre x e y ; e s representa o desvio padrão da variável aleatória. O enunciado nos forneceu os valores da correlação e do desvio padrão, então, aplicando a fórmula, descobrimos que:

$$0,5 = \frac{\text{cov}(x, y)}{5 \times 10}$$

$$0,5 = \frac{\text{cov}(x, y)}{50}$$

$$\text{cov}(x, y) = 0,5 \times 50$$

$$\text{cov}(x, y) = 25$$

O estimador do coeficiente b é dado por:

$$\hat{b} = \frac{\text{cov}(x, y)}{\text{var}(x)}$$

Já temos o valor da covariância que é igual a 25. Como a variância é o desvio padrão ao quadrado então temos:

$$\text{var}(x) = s_x^2 = 5^2$$

Substituindo na fórmula, obtemos:



$$\hat{b} = \frac{25}{5^2} = \frac{25}{25} = 1$$

O valor de a é calculado por:

$$\begin{aligned}a &= \bar{Y} - b\bar{X} \\a &= 20 - 1 \times 10 \\a &= 10\end{aligned}$$

Portanto, os valores de a e b são, respectivamente, 10 e 1.

Gabarito: D.

13. (FGV/RFB/2023) Uma reta de regressão linear simples foi obtida a partir do modelo

$$Y = \alpha X + \beta + e$$

pelo método de mínimos quadrados usual e mostrou as seguintes estimativas dos coeficientes: $a=3,4$ e $b=0,5$; além disso, obteve-se um coeficiente de correlação amostral igual a 0,9.

Com base nesses dados, avalie se as afirmativas a seguir estão corretas.

I. A porcentagem da variação total dos dados que é explicada pela regressão é menor do que 60%.

II. A reta de regressão obtida ajusta bem o modelo.

III. O intercepto $\alpha = 3,4$ mostra que a valor grandes de x correspondem valores grandes de y .

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) I e III, apenas.
- d) II e III, apenas.
- e) I e II, apenas.

Comentários:

Analisando as afirmativas, temos:

I - O coeficiente de determinação mede a qualidade do ajuste proporcionado pela reta de regressão. Ele determina a parcela da variação total de Y que é explicada pelo modelo de regressão, sendo calculado pela fórmula:



$$R^2 = \frac{SQM}{SQT}$$

O valor do coeficiente de correlação foi dado na questão, assim, basta fazermos:

$$R^2 = 0,9^2 = 0,81 \Rightarrow 81\%$$

Ou seja, é maior que 60%. Logo, a afirmação I está errada.

II – Quanto à análise feita pelo coeficiente de determinação, sabemos que quanto mais próximo o coeficiente estiver de 1, mais forte será a correlação entre as variáveis. Implica dizer que grande parte da variação de Y é explicada pelo modelo de regressão linear, ou seja, a reta de regressão é capaz de explicar as diferenças entre os valores observados (Y_i) e a média ($\bar{Y}$). Ora, o valor do coeficiente foi de 0,81, ou seja, podemos afirmar que a reta se ajusta bem ao modelo. Portanto, a afirmativa está correta.

III – O modelo de regressão dado é: $Y = \alpha X + \beta + e$

O intercepto do modelo é o termo independente que, nesse caso, é dado por β , ou seja, o intercepto é $b = 0,5$. Portanto, a afirmativa está errada.

Portanto, apenas a afirmativa II está correta.

Gabarito: B.

14. (FGV/RFB/2023) Numa regressão linear simples, verificou-se um coeficiente de correlação amostral igual a 0,756. Nesse caso, o coeficiente de determinação é aproximadamente igual a

- a) 0,48.
- b) 0,51.
- c) 0,54.
- d) 0,57.
- e) 0,60.

Comentários:

O coeficiente de correlação linear é calculado pela expressão:

$$R = \sqrt{\frac{SQM}{SQT}}$$



Já o coeficiente de determinação mede a qualidade do ajuste proporcionado pela reta de regressão. Ele determina a parcela da variação total de Y que é explicada pelo modelo de regressão, sendo calculado pela fórmula:

$$R^2 = \frac{SQM}{SQT}$$

Ora, se já temos o valor de R , basta calcularmos R^2 :

$$R^2 = 0,756^2 \cong 0,57$$

Gabarito: D.

15. (FGV/TCE SC/2023) Um modelo de regressão linear foi utilizado para relacionar 30 observações da variável dependente Y com a variável independente X_1 .

O coeficiente angular estimado foi de -0,10, com erro padrão igual a 0,01. O valor da soma dos quadrados totais foi 32.

A variância residual do modelo foi de:

- a) 0,01;
- b) 0,10;
- c) 0,25;
- d) 0,35;
- e) 0,40.

Comentários:

Para responder essa questão, precisaremos de todas as informações fornecidas no enunciado. Primeiro, temos que saber que o erro padrão do coeficiente angular é igual:

$$s(\hat{\beta}_1) = \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2}} = 0,01$$

Manipulando essa expressão, podemos verificar que:

$$\left(\sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2}} \right)^2 = (0,01)^2$$
$$\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2} = (0,01)^2$$



$$\sum_{i=1}^n (y_i - \hat{y}_i)^2 = (0,01)^2(n-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

Como $\sum_{i=1}^n (y_i - \hat{y}_i)^2$ é igual à soma dos quadrados dos resíduos, podemos dizer que:

$$SQR = (0,01)^2(n-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$SQR = (0,01)^2(30-2) \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$SQR = (0,01)^2(28) \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$SQR = 0,0028 \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

Agora, vamos usar a relação da soma dos quadrados totais, cujo valor foi fornecido no enunciado:

$$SQT = SQR + SQM = 32$$

A soma dos quadrados do modelo pode ser calculada a partir parâmetro $\hat{\beta}_1$, por meio da expressão:

$$SQM = (\hat{\beta}_1)^2 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$SQM = (-0,1)^2 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$SQM = 0,01 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

Voltando à soma dos quadrados totais, temos que:

$$SQR + SQM = 32$$

$$0,0028 \sum_{i=1}^n (x_i - \bar{x}_i)^2 + 0,01 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2 = 32$$

$$0,0128 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2 = 32$$

$$\sum_{i=1}^n (x_i - \bar{x}_i)^2 = 2.500$$

Por fim, a variância residual do modelo é igual ao quadrado médio dos resíduos



$$QMR = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n - 2)}$$

Já derivamos uma expressão similar a essa no início da resolução. Vamos relembrar:

$$\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n - 2) \sum_{i=1}^n (x_i - \bar{x}_i)^2} = (0,01)^2$$

Logo,

$$QMR = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{(n - 2)} = (0,01)^2 \times \sum_{i=1}^n (x_i - \bar{x}_i)^2$$

$$QMR = 0,0001 \times 2500 = 0,25$$

Gabarito: C.

16. (VUNESP/CAMPREV/2023) Considere a regressão de Y por X, duas variáveis não nulas. Chame de R os resíduos da regressão de Y por X estimada por mínimos quadrados ordinários. Se estimarmos uma regressão de R por X pelo método dos mínimos quadrados ordinários, o coeficiente angular dessa última regressão será:

- a) positivo.
- b) negativo.
- c) do mesmo sinal que o coeficiente angular da primeira regressão.
- d) do mesmo sinal que o coeficiente de correlação entre X e Y.
- e) zero.

Comentários:

Na regressão linear, queremos calcular a expressão matemática que relaciona Y (variável dependente) em função de X (variável independente). Os resíduos da regressão de Y por X correspondem à diferença entre os valores observados de Y e os valores previstos pela reta de melhor ajuste.

Segundo os pressupostos do método de regressão linear, os resíduos não devem se correlacionar. Logo, uma regressão de R por X deve resultar em um coeficiente angular igual a zero, já que X não explica nenhuma variação de R.

Gabarito: E.



17. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y, tais que $\Sigma X = 24$; $\Sigma Y = 49$; $\Sigma XY = 181$; $\Sigma X^2 = 100$ e $\Sigma Y^2 = 343$.

A reta dos mínimos quadrados ordinários que representa a regressão linear simples de Y em X com intercepto não nulo terá coeficiente linear aproximado de 2,48.

Comentários:

Em uma regressão linear na forma $Y_i = a + bX_i + \varepsilon_i$, os estimadores mínimos quadrados são dados pelas relações:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i Y_i) - n \times \bar{X} \times \bar{Y}}{\sum_{i=1}^n (X_i^2) - n \times \bar{X}^2}$$

$$\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{X}$$

em que $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$ e $\bar{Y} = \frac{\sum_{i=1}^n Y_i}{n}$.

Vamos utilizar as fórmulas acima para calcular o coeficiente angular da reta:

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i Y_i) - n \times \bar{X} \times \bar{Y}}{\sum_{i=1}^n (X_i^2) - n \times \bar{X}^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i Y_i) - n \times \frac{\sum_{i=1}^n X_i}{n} \times \frac{\sum_{i=1}^n Y_i}{n}}{\sum_{i=1}^n (X_i^2) - n \times \left(\frac{\sum_{i=1}^n X_i}{n}\right)^2}$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i Y_i) - \frac{\sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{n}}{\sum_{i=1}^n (X_i^2) - \frac{(\sum_{i=1}^n X_i)^2}{n}}$$

$$\hat{\beta} = \frac{181 - \frac{24 \times 49}{8}}{100 - \frac{24^2}{8}}$$

$$\hat{\beta} = \frac{181 - 3 \times 49}{100 - 3 \times 24}$$

$$\hat{\beta} = \frac{181 - 147}{100 - 72}$$

$$\hat{\beta} = \frac{34}{28}$$

Agora, vamos calcular o coeficiente linear:

$$\hat{\alpha} = \bar{Y} - \hat{\beta} \bar{X}$$



$$\begin{aligned}\hat{\alpha} &= \frac{\sum_{i=1}^n Y_i}{n} - \hat{\beta} \times \frac{\sum_{i=1}^n X_i}{n} \\ \hat{\alpha} &= \frac{49}{8} - \frac{34}{28} \times \frac{24}{8} \\ \hat{\alpha} &= \frac{49 \times 28 - 34 \times 24}{8 \times 28} \\ \hat{\alpha} &= \frac{1372 - 816}{224} = \frac{556}{224} = 2,48\end{aligned}$$

Gabarito: Certo.

18. (CESPE/PC-PB/2022) Para as variáveis Y e X , em que Y denota a variável resposta e X representa a variável regressora, a correlação linear de Pearson entre Y e X é 0,8, o desvio padrão amostral de Y é 2, e o desvio padrão amostral de X é 4. Nesse caso, a estimativa de mínimos quadrados ordinários do coeficiente angular da reta de regressão linear simples é igual a

- a) 0,40.
- b) 1,60.
- c) 0,64.
- d) 0,80.
- e) 0,50.

Comentários:

O coeficiente angular da reta de regressão pode ser calculada por

$$\hat{b} = r \cdot \frac{s_y}{s_x}$$

Como $r = 0,8$, $s_y = 2$ e $s_x = 4$, temos:

$$\hat{\beta} = 0,8 \times \frac{2}{4} = 0,4$$

Gabarito: A.



QUESTÕES COMENTADAS

Análise de Variância da Regressão

1. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V , em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.

Estima-se que a variância V seja inferior a 15.

Comentários:

A questão quer o valor da variância do modelo. Para descobrir esse valor, vamos precisar dos conceitos vistos em análise de variância da regressão. Começaremos desenvolvendo o desvio padrão amostral da seguinte forma:

$$s_y = \sqrt{\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1}}$$

$$\sqrt{(n - 1)} \times s_y = \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

$$(n - 1) \times s_y^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

Como $SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2$, temos que:



$$(n - 1) \times s_y^2 = SQT$$

$$SQT = (6 - 1) \times (5)^2$$

$$SQT = 5 \times (5)^2 = 125$$

A questão também nos forneceu o valor do coeficiente de correlação de Pearson. Sendo assim, podemos usar a relação abaixo para encontrar a soma dos quadrados dos erros:

$$R^2 = \frac{SQM}{SQT}$$

$$SQM = R^2 \times SQT$$

$$SQM = 0,25 \times 125 = 31,25$$

O valor da variância do modelo (V) é igual ao quadrado médio do modelo (QMM):

$$\sigma^2 = QMM = \frac{SQM}{1} = \frac{31,25}{1} = 31,25$$

Gabarito: Errado.

2. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V, em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.

50% da variação total de y é explicada por meio do modelo de regressão linear simples em questão.

Comentários:



Para determinar se 50% da variação total de y é explicada pelo modelo de regressão linear simples, podemos usar o coeficiente de determinação R^2 .

O coeficiente de determinação é dado por:

$$R^2 = \frac{\text{variância explicada}}{\text{variância total}}$$

Onde:

- A variância explicada é a variância de y prevista pelo modelo de regressão.
- A variância total é a variância de y .

Dado que a correlação linear de Pearson entre as variáveis y e x é 0,5, o coeficiente de determinação R^2 pode ser calculado como o quadrado dessa correlação:

$$R^2 = (0,5)^2 = 0,25$$

Portanto, 25% da variação total de y é explicada pelo modelo de regressão linear simples.

Para expressar isso em termos percentuais, precisamos multiplicar por 100:

$$0,25 \times 100\% = 25\%$$

Assim, apenas 25% da variação total de y é explicada pelo modelo de regressão linear simples. Portanto, a afirmação de que 50% da variação total de y é explicada pelo modelo está incorreta.

Gabarito: Errado.

3. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que



$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

O coeficiente de determinação do modelo (R^2) é igual ou superior a 0,9.

Comentários:

O coeficiente de determinação R^2 representa a proporção da variação total da variável dependente que é explicada pelo modelo. Ele é calculado como a razão entre a soma dos quadrados do modelo (SQM) e a soma dos quadrados totais (SQT):

$$R^2 = \frac{SQM}{SQT}$$

A soma dos quadrados do modelo corresponde à variabilidade explicada – ou seja, a soma das diferenças ao quadrado entre os valores ajustados pelo modelo e a média da variável dependente. Já a soma dos quadrados totais mede a variação total dos dados em torno da média, com base nos valores observados:

$$R^2 = \frac{\sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2}{\sum_{j=1}^{81} (y_j - \bar{y})^2}$$

De acordo com os dados fornecidos, temos no numerador o valor de 720 e no denominador, 1.000. Substituindo:

$$R^2 = \frac{720}{1.000} = 0,72 < 0,9$$

Como 0,72 é menor que 0,9, podemos concluir que o coeficiente de determinação do modelo é inferior a 0,9.

Gabarito: Errado.

4. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por



$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

A estimativa de σ^2 é igual ou inferior a 3,5.

Comentários:

No contexto de um modelo de regressão linear simples, a estimativa da variância do erro (σ^2) é obtida dividindo-se a soma dos quadrados dos resíduos (SQR) por $n - 2$:

$$\sigma^2 = \frac{SQR}{n - 2}$$

A soma dos quadrados dos resíduos, por sua vez, é dada pela diferença entre a soma dos quadrados totais (SQT) e a soma dos quadrados explicados pelo modelo (SQM):

$$SQR = SQT - SQM$$

Usando os dados fornecidos no enunciado:

$$SQM = \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720$$

$$SQT = \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000$$

Logo, temos:

$$SQR = SQT - SQM = 1.000 - 720 = 280$$

Sabemos também que $n = 81$, então:

$$\sigma^2 = \frac{280}{81 - 2} = \frac{280}{79} \cong 3,54 > 3,5$$

Portanto, a estimativa da variância do erro é superior a 3,5.

Comentários: Certo.



5. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

A correlação linear de Pearson entre a variável resposta e a regressora é igual ou superior a 0,8.

Comentários:

Vamos começar calculando o coeficiente de determinação do modelo, que é definido como a razão entre a soma dos quadrados do modelo (SQM) e a soma dos quadrados totais (SQT):

$$R^2 = \frac{SQM}{SQT}$$

A soma dos quadrados do modelo corresponde à variação explicada pelo modelo, ou seja, é a soma dos quadrados das diferenças entre os valores ajustados ($\hat{y}_j$) e a média da variável dependente ($\bar{y}$). Já a soma dos quadrados totais representa a variação total dos dados, sendo a soma dos quadrados das diferenças entre os valores observados (y_j) e a média:

$$R^2 = \frac{\sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2}{\sum_{j=1}^{81} (y_j - \bar{y})^2}$$

De acordo com os dados fornecidos, temos no numerador o valor de 720 e no denominador, 1.000. Substituindo:



$$R^2 = \frac{720}{1.000} = 0,72 < 0,9$$

Sabemos que o coeficiente de correlação linear de Pearson (ρ) é igual à raiz quadrada do coeficiente de determinação, com sinal positivo ou negativo dependendo da direção da relação:

$$\rho = \pm\sqrt{R^2} = \pm\sqrt{0,72} \cong \pm 0,84$$

A dúvida agora é se a correlação é positiva ou negativa. Isso depende do sinal de β_1 , o coeficiente angular da regressão. Como o enunciado informa que $\beta_1 > 0$, a relação entre as variáveis é positiva, logo:

$$\rho \cong 0,84 > 0,80$$

Portanto, a correlação é positiva e superior a 0,80, o que confirma que a assertiva está correta.

Gabarito: Certo.

6. (CEBRASPE/CAPES/2024) Um modelo de regressão linear entre uma variável aleatória (dependente) e uma variável não aleatória X (independente) é definido por

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

em que ε , denominado erro aleatório, é uma variável aleatória independente de X com média $E(\varepsilon) = 0$ e desvio padrão $Var(\varepsilon) = \sigma^2$. Um modelo de regressão linear é geralmente um modelo para a probabilidade condicional de Y em relação a X , denotada por $P(Y|X)$, e é chamado de simples se ε for uma variável aleatória gaussiana.

Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Pelo método dos mínimos quadrados, é possível obter estimadores $\widehat{\beta}_0$ e $\widehat{\beta}_1$ para os parâmetros β_0 e β_1 , definindo

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i$$

como o estimador para Y_i . Nesse contexto, são definidos os erros, denominados resíduos, como $\widehat{\varepsilon}_i = Y_i - \widehat{Y}_i$, e a soma dos quadrados dos resíduos

$$SQE = \sum_i \widehat{\varepsilon}_i^2,$$

a soma dos quadrados totais

$$SQT = \sum_i (Y_i - \bar{Y})^2$$



e a soma dos quadrados de regressão

$$SQR = \sum_i (\hat{Y}_i - \bar{Y})^2,$$

com

$$\bar{Y} = \frac{\sum_i Y_i}{n}.$$

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição t de Student com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95:

$$P(-2,042 < T < 2,042) = 0,95.$$

O coeficiente de determinação para um modelo de regressão linear é definido como $r^2 = (SQT - SQE)/SQT$ e sua raiz quadrada corresponde ao coeficiente de correlação linear entre as variáveis Y e X .

Comentários:

O coeficiente de determinação R^2 é utilizado para avaliar o quanto do comportamento da variável dependente Y é explicado pelo modelo de regressão. Ele é definido como a razão entre a soma dos quadrados da regressão (SQR) e a soma dos quadrados totais (SQT):

$$R^2 = \frac{SQR}{SQT}$$

Como a soma dos quadrados da regressão pode ser reescrita como $SQR = SQT - SQE$, também podemos expressar o coeficiente de determinação da seguinte forma:

$$R^2 = \frac{SQT - SQE}{SQT}$$

Além disso, no caso específico da regressão linear simples, a raiz quadrada de R^2 fornece o valor do coeficiente de correlação linear de Pearson entre as variáveis X e Y , isto é:

$$\rho = \pm\sqrt{R^2}$$

Portanto, como a assertiva considera um modelo de regressão linear simples, ela está correta.

Gabarito: Errado.

7. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de



bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

90% da variação do número de mãos por cacho pode ser explicada pela massa do cacho.

Comentários:

O coeficiente de determinação (R^2) mede a qualidade do ajuste proporcionado pela reta de regressão. Ele determina a parcela da variação total de Y que é explicada pelo modelo de regressão. O coeficiente de determinação é o mesmo coeficiente de explicação dado na questão.

Para o modelo $\hat{M} = -10 + 3 \times N$, em que N é o número de mãos por cacho produzido e $\hat{M}$ é a massa do cacho, temos que $R^2 = 90\%$. Então, 90% da massa do cacho é explicada pelo número de mãos por cacho. Contudo, devemos considerar que o coeficiente de determinação é o quadrado do coeficiente de correlação linear.

Uma vez calculada a reta de melhor ajuste, as correlações lineares entre M e N e entre N e M serão iguais, o que significa que também serão iguais os coeficientes R^2 . Dessa forma, é verdadeiro que 90% variação do número de mãos por cacho pode ser explicada pela massa do cacho.

Gabarito: Certo.

8. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

O desvio padrão das massas dos cachos é inferior ao desvio padrão dos números de mãos por cacho.

Comentários:

Para comparar o desvio padrão das massas dos cachos e o desvio padrão dos números de mãos por cacho, podemos usar a fórmula da estimativa do coeficiente $\hat{b}$ na regressão linear simples:

$$\hat{b} = r \times \frac{s_m}{s_n}$$

Onde:



- r é a correlação linear de Pearson entre N e M ;
- s_n é o desvio padrão amostral de N ;
- s_m é o desvio padrão amostral de M .

Lembrando que o coeficiente de determinação (R^2) é o quadrado do coeficiente de correlação linear (r). Como foi dado R^2 na questão, temos:

$$R^2 = 0,9$$

$$\rho = \sqrt{R^2} = \sqrt{0,9}$$

Substituindo os valores conhecidos na fórmula:

$$3 = \sqrt{0,9} \times \frac{s_m}{s_n}$$

$$\frac{s_m}{s_n} = \frac{3}{\sqrt{0,9}}$$

Portanto, a razão entre s_m e s_n é um número maior que 1, logo o desvio padrão das massas dos cachos (s_m) será superior ao desvio padrão dos números de mãos por cacho (s_n).

Gabarito: Errado.

9. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

As estimativas dos coeficientes do modelo invertido $\hat{N} = \frac{10}{3} + \frac{M}{3}$ resultam da aplicação do critério de mínimos quadrados ordinários.

Comentários:

A questão nos traz o modelo ajustado $\hat{M} = -10 + 3 \times N$, em que os coeficientes (-10) e 3 correspondem aos coeficientes da regressão de M (variável independente) contra N (variável dependente). Se isolarmos N , teremos a seguinte equação:

$$\hat{N} = \frac{10}{3} + \frac{M}{3}$$



Entretanto, essa é apenas a função inversa. Para obter os coeficientes corretos, é necessário reestimar o modelo por mínimos quadrados ordinários, invertendo as variáveis (N como dependente e M como independente).

Também podemos demonstrar da seguinte forma:

$$\hat{\beta}_{MN}\hat{\beta}_{NM} = R^2$$

Em que:

- $\hat{\beta}_{MN}$: é o coeficiente angular da regressão de M contra N (o modelo dado na questão).
- $\hat{\beta}_{NM}$: é o coeficiente angular da regressão de N contra M (o modelo proposto na assertiva).

Substituindo os dados, temos:

$$\hat{\beta}_{MN}\hat{\beta}_{NM} = R^2$$

$$3\hat{\beta}_{NM} = 0,9$$

$$\hat{\beta}_{NM} = \frac{0,9}{3}$$

$$\hat{\beta}_{NM} = 0,3$$

Portanto, alternativa errada.

Gabarito: Errado.

10. (FGV/TJ-AP/2024) Suponha que foram calculados a soma quadrática total (SQT), a soma quadrática explicada (SQE) e a soma quadrática dos resíduos (SQR) de uma regressão.

A partir disso, o cálculo da medida que representa o coeficiente de determinação R^2 é dado por:

- a) $1 - SQE / SQT$;
- b) SQE / SQT ;
- c) SQR / SQT ;
- d) SQE / SQR ;
- e) SQT / SQE .

Comentários:

O coeficiente de determinação R^2 é definido como a proporção da variabilidade total da variável dependente que é explicada pela regressão. Matematicamente, é calculado como:



$$R^2 = \frac{SQE}{SQT}$$

em que SQE é a soma quadrática explicada, que representa a variabilidade explicada pelo modelo de regressão; e SQT é a soma quadrática total, que representa a variabilidade total da variável dependente.

Gabarito: B.

11. (CESPE/FUB/2022) Uma regressão linear de Y sobre X consiste em obter a equação de uma reta, ou uma função linear, como o modelo que irá melhor representar a relação entre as variáveis; a determinação dos parâmetros dessa reta é denominada ajustamento.

Considerando essas informações, julgue o seguinte item.

Suponha-se que, em uma pesquisa, o coeficiente de correlação entre duas variáveis X e Y tenha gerado um valor para o coeficiente de correlação de Pearson de 0,9200. Nesse caso, considerando-se X a variável independente e Y a variável dependente, o percentual da variância de Y explicado por X será de 84,64%.

Comentários:

O coeficiente de determinação R^2 mede a variabilidade da variável dependente (Y) explicada pela variável independente (X). Como $R^2 = (0,92)^2 = 84,64\%$, podemos concluir que o percentual da variância de Y explicado por X será de, aproximadamente, 84,64%.

Gabarito: Certo.

12. (CESPE/FUB/2022) Uma regressão linear de Y sobre X consiste em obter a equação de uma reta, ou uma função linear, como o modelo que irá melhor representar a relação entre as variáveis; a determinação dos parâmetros dessa reta é denominada ajustamento.

Considerando essas informações, julgue o seguinte item.

Um coeficiente de determinação entre as variáveis X e Y de 95% implica necessariamente a obtenção de uma reta dos mínimos quadrados crescente, ou seja, em uma correlação positiva.

Comentários:

O coeficiente de determinação mede a variabilidade da variável dependente (Y) explicada pela variável independente (X), sendo expresso por R^2 . Se o coeficiente de correlação for negativo e



igual a $-0,974$, nosso coeficiente de determinação será 95%. Logo, um coeficiente de determinação de 95% **não implica** necessariamente na obtenção de uma reta dos mínimos quadrados crescente.

Gabarito: Errado.

13. (CESPE/PC PB/2022) Para as variáveis Y e X , em que Y denota a variável resposta e X representa a variável regressora, a correlação linear de Pearson entre Y e X é 0,8, o desvio padrão amostral de Y é 2, e o desvio padrão amostral de X é 4. Nesse caso, a estimativa de mínimos quadrados ordinários do coeficiente angular da reta de regressão linear simples é igual a

- a) 0,40.
- b) 1,60.
- c) 0,64.
- d) 0,80.
- e) 0,50.

Comentários:

O coeficiente de correlação entre as variáveis X e Y também pode ser expresso da seguinte forma:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

Como o enunciado nos disse que $\rho(X, Y) = 0,8$, $s_Y = 2$ e $s_X = 4$, podemos deduzir que:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

$$0,8 = \frac{Cov(X, Y)}{2 \times 4}$$

$$Cov(X, Y) = 6,4$$

A partir da covariância, podemos encontrar o coeficiente angular ($\hat{\beta}$) estimado pelo método dos mínimos quadrados:

$$\hat{\beta} = \frac{Cov(X, Y)}{s_X^2}$$

$$\hat{\beta} = \frac{6,4}{4^2}$$

$$\hat{\beta} = 0,4.$$



Gabarito: A.

14. (CESPE/POLITEC RO/2022) Em relação aos procedimentos técnicos relacionados aos procedimentos de amostragem, julgue os itens a seguir.

I. Quando se adiciona variáveis explicativas no modelo de regressão linear, espera-se o incremento da estatística R^2 .

II. Ao se comparar modelos com diferentes quantidades de variáveis explicativas, deve-se analisar o valor de R^2 ajustado.

III. O aumento de variáveis explicativas aumenta o R^2 ajustado.

IV. Ao se estimar um modelo com quatro variáveis explicativas e compará-lo com um modelo com três variáveis explicativas, escolhe-se o modelo que retornar o maior valor de R^2 ajustado, tudo o mais constante.

Estão corretos apenas os itens

- a) I e II.
- b) I e III.
- c) I e IV.
- d) II e III.
- e) III e IV.

Comentários:

O coeficiente de determinação (R^2) mede a variabilidade total da variável dependente (Y) explicada pela variável independente (X). Esse coeficiente assume valores no intervalo de 0 a 1, ficando mais próximo de 1 quanto melhor o modelo estiver ajustado ao conjunto de dados.

O coeficiente ajustado possui a característica de penalizar a inclusão de variáveis sem poder explicativo, fazendo seu valor diminuir. Assim, ao adicionarmos uma variável independente com baixo poder explicativo, haverá uma redução no valor do R^2 ajustado, o que não ocorre no R^2 simples.

Portanto, ao compararmos modelos de regressão múltipla com diferentes quantidades de variáveis explicativas, a comparação não pode ser realizada apenas com base no coeficiente de determinação (R^2), pois ele aumenta conforme a inclusão de novas variáveis explicativas.



Agora, vamos analisar cada item:

Item I. **Correto.** De fato, ao se adicionar variáveis explicativas ao modelo de regressão linear, espera-se o incremento da estatística R^2 .

Item II. **Correto.** Ao se comparar modelos com diferentes quantidades de variáveis explicativas, deve-se analisar o valor de R^2 ajustado.

Item III. **Incorreto.** O aumento de variáveis explicativas ~~aumenta~~ o R^2 ajustado. Não, o aumento de variáveis explicativas diminui o R^2 ajustado.

Item IV. **Incorreto.** Não necessariamente. Digamos que o R^2 ajustado sofra uma variação positiva muito pequena após a inclusão da nova variável. Nesse caso, embora o R^2 ajustado tenha sofrido um aumento, a nova variável não se mostra muito útil para explicar a variável dependente, pois o ganho com a sua inclusão é muito pequeno. Então, o R^2 ajustado ajuda a identificar quando variáveis adicionais estão contribuindo para o modelo.

Gabarito: A.

15. (CESPE/TELEBRAS/2022) O quadro a seguir mostra as estimativas de mínimos quadrados ordinários dos coeficientes de um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, em que $i \in \{1, \dots, 6\}$ e ϵ_i representa o erro aleatório com média zero e variância σ^2 .

Coeficiente	Estimativa	Erro Padrão	Razão t
β_0	0,9	0,10	9
β_1	0,2	0,05	4

Considerando essas informações e sabendo que $\sigma^2 = 0,01$, julgue o item seguinte.

$SQ_{RESÍDUOS} = \sum_{i=1}^6 (\hat{y}_i - \bar{y})^2 = 0,04$, em que $\hat{y}_i = 0,9 + 0,2x_i$.

Comentários:

A soma dos quadrados dos resíduos é calculada por meio da fórmula:

$$\sigma^2 = \frac{SQR}{n - 2}$$
$$0,01 = \frac{SQR}{4} \Rightarrow SQR = 0,04$$



Portanto, a soma dos quadrados dos resíduos vale 0,04, conforme afirma a assertiva. Porém, essa soma é calculada pelo somatório dos quadrados das diferenças entre o valor previsto e o valor observado:

$$SQR = \sum_{i=1}^6 (\hat{y}_i - y_i)^2$$

A assertiva chamou de soma dos quadrados dos resíduos o que, na verdade, é a soma dos quadrados do modelo:

$$SQM = \sum_{i=1}^6 (\hat{y}_i - \bar{y})^2$$

Gabarito: Errado.

16. (CESPE/TELEBRAS/2022) O quadro a seguir mostra as estimativas de mínimos quadrados ordinários dos coeficientes de um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, em que $i \in \{1, \dots, 6\}$ e ϵ_i representa o erro aleatório com média zero e variância σ^2 .

Coeficiente	Estimativa	Erro Padrão	Razão t
β_0	0,9	0,10	9
β_1	0,2	0,05	4

Considerando essas informações e sabendo que $\sigma^2 = 0,01$, julgue o item seguinte.

$$SQ_{TOTAL} = \sum_{i=1}^6 (y_i - \bar{y})^2 = 0,2$$

Comentários:

A partir da estimativa da variância dos termos de erro (σ^2), podemos calcular a soma dos quadrados dos resíduos:

$$\sigma^2 = \frac{SQR}{n-2}$$

$$0,01 = \frac{SQR}{4} \Rightarrow SQR = 0,04$$

Do enunciado, temos:



$$\text{Var}(\hat{\beta}_1) = 0,05^2 = 0,0025$$

e

$$\sigma^2 = 0,01.$$

Portanto,

$$0,0025 = \frac{0,01}{S_{xx}}$$
$$S_{xx} = \frac{0,01}{0,0025} = 4$$

Além disso,

$$SQM = \hat{\beta}_1^2 S_{xx} = (0,2)^2 \times 4 = 0,16$$

Portanto,

$$SQT = SQR + SQM = 0,04 + 0,16 = 0,2.$$

Gabarito: Certo.

17. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.

A soma de quadrados dos resíduos é igual ou inferior a 76.



Comentários:

Com os dados fornecidos pelo enunciado, podemos utilizar o coeficiente de correlação para calcular a soma dos quadrados dos resíduos:

$$R^2 = \frac{SQM}{SQT} = 1 - \frac{SQR}{SQT}$$

Portanto,

$$0,9^2 = 1 - \frac{SQR}{SQT}$$

$$0,81 = 1 - \frac{SQR}{SQT}$$

Como foi fornecida a variância amostral de Y , podemos chegar na soma dos quadrados total por meio da expressão:

$$s_Y^2 = \frac{SQT}{(n-1)}$$

$$SQT = (n-1) \times s_Y^2$$

Agora, jogando na expressão anterior, obtemos que:

$$0,81 - 1 = \frac{-SQR}{(100-1) \times 4^2}$$

$$-0,19 = \frac{-SQR}{99 \times 16}$$

$$0,19 = \frac{SQR}{1584}$$

$$SQR = 1584 \times 0,19$$

$$SQR = 300,96$$

Gabarito: Errado.

18. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
---	---------------------



0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.

A estimativa de mínimos quadrados ordinários para o intercepto do modelo é igual a zero.

Comentários:

Nessa questão, temos que iniciar calculando o desvio padrão amostral da variável X. A partir dessa informação, vamos conseguir calcular a covariância entre as duas variáveis. Vejamos:

X	Freq. (f_i)	$X - \bar{X}$	$(X - \bar{X})^2$	$(X - \bar{X})^2 \times f_i$
0	55	$0 - 0,45 = -0,45$	$(-0,45)^2 = 0,2025$	$0,2025 \times 55 = 11,1375$
1	45	$1 - 0,45 = 0,55$	$0,55^2 = 0,3025$	$0,3025 \times 45 = 13,8375$
Total	100		0,505	24,75

Assim, temos que:

$$s_X = \sqrt{\frac{(X - \bar{X})^2 \times f_i}{n - 1}} = \sqrt{\frac{24,75}{99}} = \sqrt{0,25} = 0,5$$

O coeficiente de correlação entre as variáveis X e Y também pode ser expresso da seguinte forma:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

Como o enunciado nos disse que $\rho(X, Y) = 0,9$ e $s_Y = 4$, podemos deduzir que:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

$$0,9 = \frac{Cov(X, Y)}{0,5 \times 4}$$

$$Cov(X, Y) = 1,8$$



A partir da covariância, podemos encontrar o coeficiente angular (a) estimado pelo método dos mínimos quadrados:

$$\hat{a} = \frac{Cov(X, Y)}{s_X^2}$$

$$\hat{a} = \frac{1,8}{(0,5)^2}$$

$$\hat{a} = 7,2.$$

Agora, vamos ver o cálculo do intercepto (coeficiente α). Para tanto, devemos lembrar que a reta de regressão estimada pelo método dos mínimos quadrados sempre passa pelo ponto $(\bar{X}, \bar{Y})$. Desse modo,

$$\bar{Y} = \hat{a}\bar{X} + \hat{b}$$

$$10 = 7,2 \times 0,45 + \hat{b}$$

$$\hat{b} = 10 - 3,24 = 6,76.$$

Gabarito: Errado.

19. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.

Se $\hat{a}$ denota a estimativa de mínimos quadrados ordinários do coeficiente angular a , então $\hat{a} = 7,2$.



Comentários:

Nessa questão, temos que iniciar calculando o desvio padrão amostral da variável X. A partir dessa informação, vamos conseguir calcular a covariância entre as duas variáveis. Vejamos:

X	Freq. (f_i)	$X - \bar{X}$	$(X - \bar{X})^2$	$(X - \bar{X})^2 \times f_i$
0	55	$0 - 0,45 = -0,45$	$(-0,45)^2 = 0,2025$	$0,2025 \times 55 = 11,1375$
1	45	$1 - 0,45 = 0,55$	$0,55^2 = 0,3025$	$0,3025 \times 45 = 13,8375$
Total	100		0,505	24,75

Assim, temos que:

$$s_X = \sqrt{\frac{(X - \bar{X})^2 \times f_i}{n - 1}} = \sqrt{\frac{24,75}{99}} = \sqrt{0,25} = 0,5$$

O coeficiente de correlação entre as variáveis X e Y também pode ser expresso da seguinte forma:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

Como o enunciado nos disse que $\rho(X, Y) = 0,9$ e $s_Y = 4$, podemos deduzir que:

$$\rho(X, Y) = \frac{Cov(X, Y)}{s_X \times s_Y}$$

$$0,9 = \frac{Cov(X, Y)}{0,5 \times 4}$$

$$Cov(X, Y) = 1,8$$

A partir da covariância, podemos encontrar o coeficiente angular (a) estimado pelo método dos mínimos quadrados:

$$\hat{a} = \frac{Cov(X, Y)}{s_X^2}$$

$$\hat{a} = \frac{1,8}{(0,5)^2}$$

$$\hat{a} = 7,2.$$

Gabarito: Certo.



20. (CESPE/TCE-SC/2022) Em artigo publicado em 2004 no Journal of Political Economy, E. Miguel, S. Satyanath e E. Sergenti mostraram o efeito que o crescimento econômico pode ter na ocorrência de conflitos civis, com dados de 41 países africanos, no período de 1981 até 1999. Em certo estágio da pesquisa, para verificar a possibilidade de usar dados sobre precipitação pluviométrica como variável instrumental, foi feita uma regressão entre o crescimento de tais precipitações (variável explicativa) e uma variável resposta que representa um indicador para a ocorrência de conflito: quanto maior for esse indicador, maior a possibilidade de conflitos no ano t no país i . Os resultados do modelo ajustado pelo método de mínimos quadrados ordinários se encontram na tabela a seguir.

Variável Explicativa	Variável Dependente	
	Conflito civil (mínimo de 25 mortos)	Conflito civil (mínimo de 1000 mortos)
Crescimento na precipitação em t	-0,024 (0,043)	-0,062 (0,030)
Crescimento na precipitação em $t-1$	-0,122 (0,052)	-0,069 (0,032)
Efeitos fixos	sim	sim
R^2	0,71	0,70
Observações	743	743

Internet: <<https://doi.org/10.1086/421174>> (com adaptações).

Os números entre parênteses na tabela apresentada indicam o erro padrão da estimativa dos coeficientes respectivos. Considere os valores críticos t_α da variável t de Student, com significância α para os graus de liberdades adequados aos dados apresentados, como sendo $t_{10\%} = 1,65$, $t_{5\%} = 1,96$ e $t_{1\%} = 2,58$. Considerando as informações precedentes, julgue o próximo item.

As variáveis explicativas usadas explicam em torno de 71% das variações na ocorrência de conflito civil com um mínimo de 25 mortos nos países pesquisados, no período analisado.

Comentários:



O coeficiente de determinação R^2 mede a variabilidade da variável dependente explicada pelas variáveis independentes. Na primeira regressão, como $R^2 = 0,71 = 71\%$, podemos concluir que as variáveis explicativas são capazes de explicar, aproximadamente, 71% das variações da variável explicada (conflito civil com mínimo de 25 mortos).

Gabarito: Certo.



LISTA DE QUESTÕES

Correlação Linear

1. (CEBRASPE/FINEP/2024) Duas variáveis, X e Y , possuem a mesma variância; se a correlação linear de Pearson entre elas for 0,8, e se a covariância entre X e Y for 2, então a variância de X será

- a) 2,50.
- b) 1,25.
- c) 0,20.
- d) 2,00.
- e) 0,40.

2. (CEBRASPE/MPO/2024) Considerando os conceitos básicos e as técnicas de inferência causal, julgue o item a seguir.

O coeficiente de correlação de Pearson, que varia entre -1 e 1 , é uma medida estatística de causalidade, derivada da associação linear entre duas variáveis independente.

3. (CEBRASPE/STJ/2024)

Amostra	X	Y
1	25	13
2	20	10
3	20	12
4	20	10

Considerando os dados na tabela precedente, em que X denota o salário bruto e Y , o salário líquido de quatro servidores, em milhares de reais, julgue o item que se segue.

A correlação linear de Pearson entre X e Y é igual a $7/9$



4. (FGV/STN/2024) Considere duas variáveis aleatórias X e Y tais que $E[X] = 5$, $\text{Var}[X] = 4$, $E[Y] = 4$, $\text{Var}[Y] = 9$ e $E[XY] = 18$. O coeficiente de correlação entre X e Y é, então, igual a

- a) $-1/2$.
- b) $-1/3$.
- c) 0.
- d) $1/3$.
- e) $1/2$.

5. (FGV/Câmara dos Deputados/2023) Avalie se as seguintes afirmativas acerca do coeficiente de correlação linear r entre duas variáveis aleatórias contínuas estão corretas.

- I. O módulo de r é sempre menor ou igual a 1.
- II. Se $r = 0$, as duas variáveis são independentes.
- III. Valores de r próximos de $+1$ indicam uma correlação positiva forte.

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) I e II, apenas.
- d) I e III, apenas.
- e) II e III, apenas.

6. (FGV/SEFAZ-MG/2023) A tabela a seguir mostra a função de probabilidade conjunta de duas variáveis aleatórias X e Y :

		Valores de Y		
		-2	0	2
Valores de X	-1	0,2	0,1	0,2
	1	0,2	0,1	0,2

Assim, por exemplo, $P[X = 5; Y = 0] = 0,1$.



O coeficiente de correlação entre X e Y é igual a

- a) 0.
- b) 0,1.
- c) 0,2.
- d) 0,5.
- e) 1,0.

7. (IBFC/Pref. Cuiabá/2023) Em relação à correlação, assinale a alternativa incorreta.

- a) Correlação não é casualidade
- b) No cálculo do coeficiente de correlação, não há distinção entre variável resposta ou explanatória
- c) Correlação nula indica variáveis independentes
- d) A correlação apenas não serve para descrever uma distribuição de dados

8. (IBFC/Pref. Cuiabá/2023) O coeficiente de correlação de Pearson fornece um grau de dependência entre duas variáveis contínuas. Analise as afirmativas a seguir e dê valores Verdadeiro (V) ou Falso (F).

- () O coeficiente de correlação varia entre -1 e 1.
- () O coeficiente de correlação é adimensional por calcular a dependência entre variáveis padronizados.
- () Quanto mais próximo de 1 ou -1, a dependência entre as variáveis é linear.

Assinale a alternativa que apresenta a sequência correta de cima para baixo:

- a) V - F - F
- b) F - V - V
- c) V - V - V
- d) V - F - V

9. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y, tais que $\Sigma X = 24$; $\Sigma Y = 49$; $\Sigma XY = 181$; $\Sigma X^2 = 100$ e $\Sigma Y^2 = 343$.



O coeficiente de correlação de Pearson para os valores apresentados será negativo, o que indica que a regressão linear será representada por uma reta decrescente.

10. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y , tais que $\sum X = 24$; $\sum Y = 49$; $\sum XY = 181$; $\sum X^2 = 100$ e $\sum Y^2 = 343$.

Existe uma correlação forte entre as variáveis X e Y .

11. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y , tais que $\sum X = 24$; $\sum Y = 49$; $\sum XY = 181$; $\sum X^2 = 100$ e $\sum Y^2 = 343$.

Com base no coeficiente de correlação linear, é correto afirmar, em face dos dados apresentados, que se trata de uma correlação espúria.

12. (FGV/TRT-PB/2022) X e Y são variáveis aleatórias tais que

$E[X] = 5$, $E[Y] = 3$, $\text{Var}[X] = 16$, $\text{Var}[Y] = 4$, $E[XY] = 10$.

O coeficiente de correlação entre X e Y é igual a

- a) $-0,625$.
- b) $-0,240$.
- c) $0,166$.
- d) $0,348$.
- e) $0,765$.



GABARITO

Correlação Linear

- | | | |
|------------|------------|-------------|
| 1. LETRA A | 5. LETRA D | 9. ERRADO |
| 2. ERRADO | 6. LETRA A | 10. CERTO |
| 3. CERTO | 7. LETRA C | 11. ERRADO |
| 4. LETRA B | 8. LETRA C | 12. LETRA A |



LISTA DE QUESTÕES

Regressão Linear Simples

1. (FCC/CGM-SP/2025) Para prever a receita tributária (Y) no ano $(2014 + t)$ em um município, optou-se pela utilização do modelo linear $Y_t = \alpha + \beta t + \varepsilon$, $t = 1, 2, 3, \dots$, sendo α e β parâmetros desconhecidos e ε o erro aleatório com as respectivas hipóteses consideradas para o modelo de regressão linear simples. Utilizando o método dos mínimos quadrados e com base nas observações da arrecadação anual da receita tributária, em bilhões de reais, de 2015 a 2024, obteve-se que o somatório das receitas de 2015 a 2024 foi de 370 bilhões de reais e a estimativa do parâmetro α igual a 15. Considerando, então, a equação da reta obtida pelo método dos mínimos quadrados, obtém-se que o acréscimo anual da receita tributária, em bilhões de reais, é igual a

- a) 4,8
- b) 3,6
- c) 2,4
- d) 4,0
- e) 6,0

2. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V , em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.

A estimativa do coeficiente b é igual ou superior a 0,6.



3. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

$$\beta_1 = 3.$$

4. (CEBRASPE/FINEP/2024)

x	0	1	2	3	4	5
y	0	1	3	13	14	25

Considerando que a tabela precedente exibe uma amostra aleatória bivariada (x,y) de tamanho 6, na qual representa uma variável dependente e denota uma variável regressora, assinale a opção que apresenta uma curva de regressão $(\hat{y})$ ajustada para esse conjunto de dados mediante aplicação do método de mínimos quadrados ordinários.

- a) $\hat{y} = x^2$
- b) $\hat{y} = 11,2$
- c) $\hat{y} = 3,73x$
- d) $\hat{y} = 0,5x^2 + 12,5$



e) $\hat{y} = 5x - 2$

5. (CESGRANRIO/BNDES/2024) O método dos Mínimos Quadrados Ordinários (MQO) apresenta propriedades estatísticas que o tornam um dos métodos mais populares e eficientes de análise de regressão. A eficiência desse método depende da validade da seguinte hipótese:

- a) o modelo de regressão deve ser linear nos parâmetros e nas variáveis.
- b) o número de parâmetros estimados no modelo deve ser maior do que o número de variáveis utilizadas para estimá-lo.
- c) as variâncias dos erros do modelo devem ser constantes, isto é, heterocedásticas.
- d) não deve haver autocorrelação entre os termos de erros do modelo, e o valor médio dos erros deve ser igual a zero.
- e) não deve haver multicolinearidade e homocedasticidade entre as variáveis do modelo.

6. (FGV/TJ-MS/2024) Em um modelo de regressão linear simples, o estimador de máxima verossimilhança para o coeficiente angular (inclinação) é igual a:

- a) correlação (x,y) / desvio padrão (x) ;
- b) correlação (x,y) / variância (x) ;
- c) covariância (x,y) / correlação (x,y) ;
- d) covariância (x,y) / desvio padrão (x) ;
- e) covariância (x,y) / variância (x) .

7. (FGV/TJ-AP/2024) Uma pesquisa realizada em motores de carros relacionou a cilindrada à sua potência, obtendo os resultados da tabela abaixo.

Potência (cavalos)	Cilindrada (litros)
105	1,4
135	1,8
150	2,0

O valor da potência (em cavalos) estimada para um carro de 1.6 litro de cilindrada, ao se utilizar um modelo de regressão linear simples pelo método dos mínimos quadrados ordinários, é:



- a) 110;
- b) 115;
- c) 120;
- d) 125;
- e) 130.

8. (FGV/TJ-AP/2024) Sejam $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, os dados da modelagem de uma regressão linear simples $Y_i = \alpha + \beta X_i + \varepsilon_i$ obtida pelo método dos mínimos quadrados. É correto afirmar que:

- a) o estimador de beta é dado pela covariância entre X e Y dividido pela variância de X;
- b) o estimador de beta é dado pela covariância entre X e Y dividido pela variância de Y;
- c) o estimador de alfa pode ser definido a partir da média de Y somada com o estimador de beta multiplicado pela média de X;
- d) a estimativa de alfa pode ser interpretada como o coeficiente angular da equação da reta no plano cartesiano bidimensional;
- e) a estimativa de beta pode ser interpretada como o coeficiente linear ou intercepto da equação da reta no plano cartesiano bidimensional.

9. (CESGRANRIO/TRANSPETRO/2023) A gerência de uma pizzeria registrou a venda diária de pizzas napolitanas durante um ano (dentro do horário de 12 h a 23 h). Com os dados obtidos das vendas, ajustou-se a seguinte equação de regressão linear:

$$\text{Vendas} = 2 \times (\text{horário do pedido}) - 22$$

Com base nessas informações, o incremento horário no número de vendas é dado por

- a) -22
- b) 22
- c) 2
- d) -2
- e) -20



10. (FCC/COPERGÁS/2023) Considere a equação a seguir como representação do modelo de regressão linear simples.

$$y = \beta_0 + \beta_1 x + \varepsilon$$

Dado:

ε representa o erro aleatório.

De acordo com esse modelo,

- a) os erros associados a diferentes observações devem estar correlacionados.
- b) a equação resulta em uma parábola com concavidade voltada para o eixo das abscissas.
- c) os erros aleatórios devem apresentar heterocedasticidade.
- d) os erros aleatórios têm média zero.
- e) a equação deve relacionar uma variável dependente com inúmeras variáveis independentes.

11. (FGV/BANESTES/2023) Quando se ajusta um modelo de Regressão Linear Simples no qual y é a variável a explicar e x é a variável explicativa, se r é o valor do coeficiente de correlação entre x e y , assinale a afirmativa correta.

- a) Não existe relação entre r e o coeficiente de determinação R^2 da regressão.
- b) O valor de r depende do ângulo formado pela reta de regressão de y contra x com o eixo horizontal.
- c) Se r for igual a zero, não existe nenhum tipo de dependência entre x e y .
- d) r pode assumir qualquer valor real entre $-\infty$ e $+\infty$.
- e) Quanto mais próximo r estiver de $+1$ ou de -1 , mais próximos os pontos estarão da reta de regressão.

12. (FGV/CGE SC/2023) Considere o modelo de regressão linear simples:

$$y_i = a + bx_i + u_i,$$

em que y é a variável dependente, x é a variável explicativa, a é o intercepto, b é o coeficiente de inclinação e u , o termo aleatório do modelo.

A partir de uma amostra aleatória, obtém-se as seguintes informações:

$$\bar{x} = 10, \bar{y} = 20, \text{Corr}(x, y) = 0,5, s_x = 5 \text{ e } s_y = 10$$



Assim, os estimadores dos parâmetros a e b que minimizam a soma dos quadrados dos resíduos são, respectivamente, iguais a

- a) 30 e 1.
- b) -20 e 4.
- c) 0 e 2.
- d) 10 e 1.
- e) 17,5 e 0,25.

13. (FGV/RFB/2023) Uma reta de regressão linear simples foi obtida a partir do modelo

$$Y = \alpha X + \beta + e$$

pelo método de mínimos quadrados usual e mostrou as seguintes estimativas dos coeficientes: $a=3,4$ e $b=0,5$; além disso, obteve-se um coeficiente de correlação amostral igual a 0,9.

Com base nesses dados, avalie se as afirmativas a seguir estão corretas.

- I. A porcentagem da variação total dos dados que é explicada pela regressão é menor do que 60%.
- II. A reta de regressão obtida ajusta bem o modelo.
- III. O intercepto $\alpha = 3,4$ mostra que a valor grandes de x correspondem valores grandes de y .

Está correto o que se afirma em

- a) I, apenas.
- b) II, apenas.
- c) I e III, apenas.
- d) II e III, apenas.
- e) I e II, apenas.

14. (FGV/RFB/2023) Numa regressão linear simples, verificou-se um coeficiente de correlação amostral igual a 0,756. Nesse caso, o coeficiente de determinação é aproximadamente igual a

- a) 0,48.
- b) 0,51.
- c) 0,54.



d) 0,57.

e) 0,60.

15. (FGV/TCE SC/2023) Um modelo de regressão linear foi utilizado para relacionar 30 observações da variável dependente Y com a variável independente X_1 .

O coeficiente angular estimado foi de -0,10, com erro padrão igual a 0,01. O valor da soma dos quadrados totais foi 32.

A variância residual do modelo foi de:

a) 0,01;

b) 0,10;

c) 0,25;

d) 0,35;

e) 0,40.

16. (VUNESP/CAMPREV/2023) Considere a regressão de Y por X , duas variáveis não nulas. Chame de R os resíduos da regressão de Y por X estimada por mínimos quadrados ordinários. Se estimarmos uma regressão de R por X pelo método dos mínimos quadrados ordinários, o coeficiente angular dessa última regressão será:

a) positivo.

b) negativo.

c) do mesmo sinal que o coeficiente angular da primeira regressão.

d) do mesmo sinal que o coeficiente de correlação entre X e Y .

e) zero.

17. (CESPE/FUB/2022) Julgue o item subsequente, considerando oito pares de valores das variáveis X e Y , tais que $\sum X = 24$; $\sum Y = 49$; $\sum XY = 181$; $\sum X^2 = 100$ e $\sum Y^2 = 343$.

A reta dos mínimos quadrados ordinários que representa a regressão linear simples de Y em X com intercepto não nulo terá coeficiente linear aproximado de 2,48.



18. (CESPE/PC-PB/2022) Para as variáveis Y e X , em que Y denota a variável resposta e X representa a variável regressora, a correlação linear de Pearson entre Y e X é 0,8, o desvio padrão amostral de Y é 2, e o desvio padrão amostral de X é 4. Nesse caso, a estimativa de mínimos quadrados ordinários do coeficiente angular da reta de regressão linear simples é igual a

- a) 0,40.
- b) 1,60.
- c) 0,64.
- d) 0,80.
- e) 0,50.



GABARITO

Regressão Linear Simples

- | | | |
|------------|-------------|-------------|
| 1. LETRA D | 7. LETRA C | 13. LETRA B |
| 2. CERTO | 8. LETRA A | 14. LETRA D |
| 3. CERTO | 9. LETRA C | 15. LETRA C |
| 4. LETRA A | 10. LETRA D | 16. LETRA E |
| 5. LETRA D | 11. LETRA E | 17. CERTO |
| 6. LETRA E | 12. LETRA D | 18. LETRA A |



LISTA DE QUESTÕES

Análise de Variância da Regressão

1. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V , em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.

Estima-se que a variância V seja inferior a 15.

2. (CEBRASPE/ANAC/2024) Mediante a aplicação do critério de mínimos quadrados ordinários, um analista deseja ajustar um modelo de regressão linear simples na forma $y = a + bx + \varepsilon$, com variância V , em que y representa a variável dependente, x é a variável regressora e ε denota um erro aleatório que segue distribuição normal com média zero. A partir de uma amostra aleatória simples de tamanho $n = 46$, o analista obteve as estatísticas descritivas mostradas na tabela a seguir.

Variável	Média Amostral	Desvio Padrão Amostral
Y	10	5
x	20	4

A partir dessas informações, e sabendo que a correlação linear de Pearson entre as variáveis y e x é igual a 0,5, julgue os próximos itens.



50% da variação total de y é explicada por meio do modelo de regressão linear simples em questão.

3. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:

$$\hat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

O coeficiente de determinação do modelo (R^2) é igual ou superior a 0,9.

4. (CEBRASPE/ANATEL/2024) Em um modelo de regressão linear simples representado pela equação

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i,$$

em que j é um índice que varia de 1 a 81; β_0 e β_1 são os coeficientes do modelo; y_i representa a variável resposta; x_i denota a variável regressora; ε_i é o erro aleatório com média zero e variância σ^2 ; e $\varepsilon_1, \dots, \varepsilon_{81}$ formam um conjunto de erros independentes e identicamente distribuídos.

No modelo ajustado pelo método de mínimos quadrados ordinários, representado por

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1$$

têm-se:



$$\widehat{\beta}_1 > 0, \quad \sum_{j=1}^{81} (\hat{y}_j - \bar{y})^2 = 720, \quad \sum_{j=1}^{81} (y_j - \bar{y})^2 = 1.000, \quad \sum_{j=1}^{81} (x_j - \bar{x})^2 = 80,$$

em que

$$\bar{y} = \frac{\sum_{j=1}^{81} y_j}{81} = 20 \quad \text{e} \quad \bar{x} = \frac{\sum_{j=1}^{81} x_j}{81} = 10.$$

Com base nessas informações, julgue o seguinte item:

A estimativa de σ^2 é igual ou inferior a 3,5.

6. (CEBRASPE/CAPES/2024) Um modelo de regressão linear entre uma variável aleatória (dependente) e uma variável não aleatória X (independente) é definido por

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

em que ε , denominado erro aleatório, é uma variável aleatória independente de X com média $E(\varepsilon) = 0$ e desvio padrão $Var(\varepsilon) = \sigma^2$. Um modelo de regressão linear é geralmente um modelo para a probabilidade condicional de Y em relação a X , denotada por $P(Y|X)$, e é chamado de simples se ε for uma variável aleatória gaussiana.

Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Pelo método dos mínimos quadrados, é possível obter estimadores $\widehat{\beta}_0$ e $\widehat{\beta}_1$ para os parâmetros β_0 e β_1 , definindo

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i$$

como o estimador para Y_i . Nesse contexto, são definidos os erros, denominados resíduos, como $\widehat{\varepsilon}_i = Y_i - \widehat{Y}_i$, e a soma dos quadrados dos resíduos

$$SQE = \sum_i \widehat{\varepsilon}_i^2,$$

a soma dos quadrados totais

$$SQT = \sum_i (Y_i - \bar{Y})^2$$

e a soma dos quadrados de regressão

$$SQR = \sum_i (\widehat{Y}_i - \bar{Y})^2,$$

com



$$\bar{Y} = \frac{\sum_i Y_i}{n}.$$

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição t de Student com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95:

$$P(-2,042 < 1 < 2,042) = 0,95.$$

O coeficiente de determinação para um modelo de regressão linear é definido como $r^2 = (SQT - SQE)/SQT$ e sua raiz quadrada corresponde ao coeficiente de correlação linear entre as variáveis Y e X .

7. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

90% da variação do número de mãos por cacho pode ser explicada pela massa do cacho.

8. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

O desvio padrão das massas dos cachos é inferior ao desvio padrão dos números de mãos por cacho.

9. (CEBRASPE/CODEVASF/2024) Considerando um modelo de regressão linear simples na forma $\hat{M} = -10 + 3 \times N$, em que N denote o número de mãos por cacho produzido por um tipo de bananeira e $\hat{M}$ represente a massa do cacho ajustada pelo método de mínimos quadrados ordinários, e sabendo que seu coeficiente de explicação é igual a 0,90 e que o tamanho da amostra é de 102 cachos, julgue os próximos itens.

As estimativas dos coeficientes do modelo invertido $\hat{N} = \frac{10}{3} + \frac{M}{3}$ resultam da aplicação do critério de mínimos quadrados ordinários.



10. (FGV/TJ-AP/2024) Suponha que foram calculados a soma quadrática total (SQT), a soma quadrática explicada (SQE) e a soma quadrática dos resíduos (SQR) de uma regressão.

A partir disso, o cálculo da medida que representa o coeficiente de determinação R^2 é dado por:

- a) $1 - SQE / SQT$;
- b) SQE / SQT ;
- c) SQR / SQT ;
- d) SQE / SQR ;
- e) SQT / SQE .

11. (CESPE/FUB/2022) Uma regressão linear de Y sobre X consiste em obter a equação de uma reta, ou uma função linear, como o modelo que irá melhor representar a relação entre as variáveis; a determinação dos parâmetros dessa reta é denominada ajustamento.

Considerando essas informações, julgue o seguinte item.

Suponha-se que, em uma pesquisa, o coeficiente de correlação entre duas variáveis X e Y tenha gerado um valor para o coeficiente de correlação de Pearson de 0,9200. Nesse caso, considerando-se X a variável independente e Y a variável dependente, o percentual da variância de Y explicado por X será de 84,64%.

12. (CESPE/FUB/2022) Uma regressão linear de Y sobre X consiste em obter a equação de uma reta, ou uma função linear, como o modelo que irá melhor representar a relação entre as variáveis; a determinação dos parâmetros dessa reta é denominada ajustamento.

Considerando essas informações, julgue o seguinte item.

Um coeficiente de determinação entre as variáveis X e Y de 95% implica necessariamente a obtenção de uma reta dos mínimos quadrados crescente, ou seja, em uma correlação positiva.

13. (CESPE/PC PB/2022) Para as variáveis Y e X, em que Y denota a variável resposta e X representa a variável regressora, a correlação linear de Pearson entre Y e X é 0,8, o desvio padrão amostral de Y é 2, e o desvio padrão amostral de X é 4. Nesse caso, a estimativa de mínimos quadrados ordinários do coeficiente angular da reta de regressão linear simples é igual a

- a) 0,40.
- b) 1,60.



- c) 0,64.
- d) 0,80.
- e) 0,50.

14. (CESPE/POLITEC RO/2022) Em relação aos procedimentos técnicos relacionados aos procedimentos de amostragem, julgue os itens a seguir.

- I. Quando se adiciona variáveis explicativas no modelo de regressão linear, espera-se o incremento da estatística R^2 .
- II. Ao se comparar modelos com diferentes quantidades de variáveis explicativas, deve-se analisar o valor de R^2 ajustado.
- III. O aumento de variáveis explicativas aumenta o R^2 ajustado.
- IV. Ao se estimar um modelo com quatro variáveis explicativas e compará-lo com um modelo com três variáveis explicativas, escolhe-se o modelo que retornar o maior valor de R^2 ajustado, tudo o mais constante.

Estão corretos apenas os itens

- a) I e II.
- b) I e III.
- c) I e IV.
- d) II e III.
- e) III e IV.

15. (CESPE/TELEBRAS/2022) O quadro a seguir mostra as estimativas de mínimos quadrados ordinários dos coeficientes de um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, em que $i \in \{1, \dots, 6\}$ e ϵ_i representa o erro aleatório com média zero e variância σ^2 .

Coeficiente	Estimativa	Erro Padrão	Razão t
β_0	0,9	0,10	9
β_1	0,2	0,05	4

Considerando essas informações e sabendo que $\sigma^2 = 0,01$, julgue o item seguinte.



$$SQ_{RESÍDUOS} = \sum_{i=1}^6 (\hat{y}_i - \bar{y})^2 = 0,04, \text{ em que } \hat{y}_i = 0,9 + 0,2x_i.$$

16. (CESPE/TELEBRAS/2022) O quadro a seguir mostra as estimativas de mínimos quadrados ordinários dos coeficientes de um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \epsilon_i$, em que $i \in \{1, \dots, 6\}$ e ϵ_i representa o erro aleatório com média zero e variância σ^2 .

Coeficiente	Estimativa	Erro Padrão	Razão t
β_0	0,9	0,10	9
β_1	0,2	0,05	4

Considerando essas informações e sabendo que $\sigma^2 = 0,01$, julgue o item seguinte.

$$SQ_{TOTAL} = \sum_{i=1}^6 (y_i - \bar{y})^2 = 0,2$$

17. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.

A soma de quadrados dos resíduos é igual ou inferior a 76.



18. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.

A estimativa de mínimos quadrados ordinários para o intercepto do modelo é igual a zero.

19. (CESPE/TELEBRAS/2022) Considere um modelo de regressão linear simples na forma $Y = aX + b + \epsilon$, em que ϵ representa o erro aleatório com média zero e desvio padrão σ , e a variável regressora X é binária. A média amostral e o desvio padrão amostral da variável explicativa Y foram, respectivamente, iguais a 10 e 4. Já para a variável regressora X , encontra-se a distribuição de frequências absolutas mostrada no quadro a seguir. Finalmente, sabe-se que a correlação linear entre Y e X é igual a 0,9.

X	Frequência Absoluta
0	55
1	45
Total	100

Com base nessas informações, com respeito à reta ajustada pelo método dos mínimos quadrados ordinários, julgue o item subsequente.



Se $\hat{a}$ denota a estimativa de mínimos quadrados ordinários do coeficiente angular a , então $\hat{a} = 7,2$.

20. (CESPE/TCE-SC/2022) Em artigo publicado em 2004 no Journal of Political Economy, E. Miguel, S. Satyanath e E. Sergenti mostraram o efeito que o crescimento econômico pode ter na ocorrência de conflitos civis, com dados de 41 países africanos, no período de 1981 até 1999. Em certo estágio da pesquisa, para verificar a possibilidade de usar dados sobre precipitação pluviométrica como variável instrumental, foi feita uma regressão entre o crescimento de tais precipitações (variável explicativa) e uma variável resposta que representa um indicador para a ocorrência de conflito: quanto maior for esse indicador, maior a possibilidade de conflitos no ano t no país i . Os resultados do modelo ajustado pelo método de mínimos quadrados ordinários se encontram na tabela a seguir.

Variável Explicativa	Variável Dependente	
	Conflito civil (mínimo de 25 mortos)	Conflito civil (mínimo de 1000 mortos)
Crescimento na precipitação em t	-0,024 (0,043)	-0,062 (0,030)
Crescimento na precipitação em $t-1$	-0,122 (0,052)	-0,069 (0,032)
Efeitos fixos	sim	sim
R^2	0,71	0,70
Observações	743	743

Internet: <<https://doi.org/10.1086/421174>> (com adaptações).

Os números entre parênteses na tabela apresentada indicam o erro padrão da estimativa dos coeficientes respectivos. Considere os valores críticos t_α da variável t de Student, com significância α para os graus de liberdades adequados aos dados apresentados, como sendo $t_{10\%} = 1,65$, $t_{5\%} = 1,96$ e $t_{1\%} = 2,58$. Considerando as informações precedentes, julgue o próximo item.

As variáveis explicativas usadas explicam em torno de 71% das variações na ocorrência de conflito civil com um mínimo de 25 mortos nos países pesquisados, no período analisado.



GABARITO

Análise de Variância da Regressão

- | | | |
|-----------|------------|-----------|
| 1. ERRADO | 8. ERRADO | 15.CERTO |
| 2. ERRADO | 9. LETRA B | 16.ERRADO |
| 3. ERRADO | 10.CERTO | 17.ERRADO |
| 4. CERTO | 11.ERRADO | 18.CERTO |
| 5. ERRADO | 12.LETRA A | 19.CERTO |
| 6. CERTO | 13.LETRA A | |
| 7. ERRADO | 14.ERRADO | |



ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.