

Aula 13

CBM-PE (Oficial) Estatística

Autor:

**Equipe Exatas Estratégia
Concursos**

06 de Maio de 2026

Índice

1) Regressão Múltipla.	3
2) Variável Binária ou Variável Dummy.	25
3) Problema da Especificação.	30
4) Transformação de Box-Cox.	37
5) Questões Comentadas - Regressão Múltipla - Multibancas	43
6) Questões Comentadas - Variável Binária ou Variável Dummy - Multibancas	93
7) Questões Comentadas - Transformação de Box-Cox - Multibancas	100
8) Lista de Questões - Regressão Múltipla - Multibancas	101
9) Lista de Questões - Variável Binária ou Variável Dummy - Multibancas	124
10) Lista de Questões - Transformação de Box-Cox - Multibancas	128



REGRESSÃO MÚLTIPLA

Como vimos, na regressão linear simples queremos calcular a expressão matemática que relaciona Y (variável dependente) em função de X (variável independente). Trata-se de uma equação que representa uma reta:

$$Y = \alpha + \beta x$$

em que: α é o coeficiente linear da reta (indica em que ponto a reta corta o eixo y); e β é a taxa de variação ou coeficiente angular da reta.

Já na **regressão múltipla** temos **uma variável dependente e duas ou mais variáveis independentes ou explicativas**. Utilizamos a regressão múltipla para **estimar** o valor de **uma variável dependente** com base em um **conjunto de outras variáveis independentes**.

O modelo de regressão múltipla é dado por:

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

em que:

Y: é a variável dependente;

α : é um coeficiente técnico fixo, um valor de base a partir do qual começa Y ou intercepto;

β_i : são coeficientes de regressão;

x_i : são variáveis independentes; e

ε : é o erro.

A equação de regressão estimada a partir de dados amostrais é expressa por:

$$\hat{Y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

em que $\hat{Y}$ é o valor estimado para a variável dependente e números b_i são chamados de coeficientes de regressão parcial.

É importante ressaltar que **o número de observações da amostra deve exceder o número de variáveis explicativas em pelo menos 2**. Isto é, se tivermos 2 variáveis explicativas (independentes), serão necessárias 04 (quatro) observações na amostra.



Assim como ocorreu na regressão linear simples, na regressão múltipla precisamos que os seguintes pressupostos sejam atendidos:

1) $E(\varepsilon_i) = 0$:

A média dos erros deve ser igual a zero.

2) $Var(\varepsilon_i) = \sigma^2$:

A variância do erro deve ser constante. Essa propriedade é denominada de **homocedasticia**. Isto somente é possível se a variável ε tiver variância constante. Ou seja, se ela tiver sempre a mesma variância, independente de qual seja o valor de X .

3) $Corr(\varepsilon_i, \varepsilon_j) = 0$, para $i \neq j$:

Essa propriedade garante que os erros cometidos pelo modelo são independentes, isto é, não se correlacionam.

4) Os erros têm distribuição normal.

Outro importante pressuposto é de que não pode existir nenhuma relação linear entre as variáveis independentes. Se no modelo tivermos duas variáveis explicativas ou independentes proporcionais, ou seja, altamente correlacionadas, teremos um problema denominado de **multicolinearidade**, que, muitas vezes, torna a estimativa dos parâmetros insignificantes. Por exemplo, teríamos um caso de **multicolinearidade** se $X_1 = X_2 + 3 \times X_3$ ou se $X_2 = 2 \times X_1$.

O conceito por trás do modelo de regressão linear múltipla é o de **ceteris paribus**, ou seja, **todo o resto constante**. Significa que mantendo outros fatores fixos, podemos estimar o efeito de X (variável explicativa ou independente) sobre Y (variável dependente).

Na estimativa dos parâmetros do modelo de regressão linear múltipla, precisaremos recorrer aos conceitos de matrizes. Esse modelo, utilizando a notação matricial, pode ser escrito da seguinte forma:

$$y = X\beta + E$$



A matriz-coluna y contém os n valores observados de Y na amostra:

$$y = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}$$

A matriz-coluna E contém os erros aleatórios:

$$E = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

A matriz-coluna β contém os parâmetros desconhecidos da regressão múltipla:

$$\beta = \begin{bmatrix} \alpha \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix}$$

A matriz X representa as variáveis independentes $X_1, X_2, \dots, X_n$. Para cada variável X_i teremos n valores associados. Reparem que a primeira coluna é composta apenas por valores 1, pois corresponde ao termo constante:

$$X = \begin{bmatrix} 1 & x_{11} & x_{21} & \dots & x_{k1} \\ 1 & x_{12} & x_{22} & \dots & x_{k2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \dots & x_{kn} \end{bmatrix}$$

Também podemos empregar a notação matricial para representar a equação de regressão estimada. Nesse caso, temos a seguinte relação:

$$\hat{y} = X\hat{\beta}$$



Agora, a matriz $\hat{\beta}$ representa a estimativa dos parâmetros do modelo de regressão múltipla:

$$\hat{\beta} = \begin{bmatrix} a \\ b_1 \\ b_2 \\ \vdots \\ b_k \end{bmatrix}$$

De igual modo, as estimativas dos valores observados de Y são representadas por:

$$\hat{y} = \begin{bmatrix} \hat{Y}_1 \\ \hat{Y}_2 \\ \vdots \\ \hat{Y}_n \end{bmatrix}$$

Assim, pelo **método dos mínimos quadrados ordinários (MQO)**, podemos demonstrar que o estimador de $\hat{\beta}$ é expresso por:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

em que X^T é a transposta da matriz X ; e $(X^T X)^{-1}$ é a inversa da matriz $X^T X$.

Os **estimadores de mínimos quadrados**, assim como no caso da regressão linear simples, são **lineares**, **não viciados** e **têm variância mínima** na classe de estimadores lineares.

Além disso, assim como no caso da regressão linear simples, os **estimadores de mínimos quadrados dos parâmetros do modelo de regressão linear múltipla são equivalentes aos estimadores de máxima verossimilhança**, sob a suposição de normalidade dos erros.



Se no modelo de regressão linear múltipla tivermos duas variáveis explicativas ou independentes proporcionais, ou seja, altamente correlacionadas, teremos um problema denominado de **multicolinearidade**, que, muitas vezes, torna a estimativa dos parâmetros insignificantes. Assim, não pode haver nenhuma relação linear entre as variáveis independentes.





EXEMPLIFICANDO

Determinar o **modelo de regressão linear múltipla** aplicável aos dados apresentados a seguir:

Y	X ₁	X ₂
1	1	1
2	2	2
3	2	2
4	3	3
5	4	5

Atenção, caros alunos! Busquei detalhar ao máximo as etapas apresentadas no exemplo, porém, é muito importante que vocês revisem as propriedades e operações envolvendo matrizes. Tenham ciência de que as bancas não vão cobrar todas as etapas aqui descritas, pois é um procedimento muito trabalhoso (normalmente, esse tipo de análise é feito com o auxílio de computador).

Nessa questão, teremos que calcular X^T , $X^T X$, $(X^T X)^{-1}$ e $X^T y$, sendo que:

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 2 \\ 1 & 3 & 3 \\ 1 & 4 & 5 \end{bmatrix} \quad \text{e} \quad y = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$

Observem que a primeira coluna da matriz X é composta apenas por valores 1.

a) matriz transposta de X é:

$$X^T = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 3 & 4 \\ 1 & 2 & 2 & 3 & 5 \end{bmatrix}$$

b) calcular $X^T X$ por meio da operação de multiplicação de matrizes:

$$X^T X = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 3 & 4 \\ 1 & 2 & 2 & 3 & 5 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 2 \\ 1 & 3 & 3 \\ 1 & 4 & 5 \end{bmatrix}$$



A multiplicação de uma matriz 3×5 por 5×3 resulta em uma matriz 3×3 . Para encontrar os termos da operação de multiplicação, temos que multiplicar os termos das **linhas** da matriz X^T pelos termos das **colunas** de X :

$$a_{11} = 1 \times 1 + 1 \times 1 + 1 \times 1 + 1 \times 1 + 1 \times 1 = 5$$

$$a_{12} = 1 \times 1 + 1 \times 2 + 1 \times 2 + 1 \times 3 + 1 \times 4 = 12$$

$$a_{13} = 1 \times 1 + 1 \times 2 + 1 \times 2 + 1 \times 3 + 1 \times 5 = 13$$

$$a_{21} = 1 \times 1 + 2 \times 1 + 2 \times 1 + 3 \times 1 + 4 \times 1 = 12$$

$$a_{22} = 1 \times 1 + 2 \times 2 + 2 \times 2 + 3 \times 3 + 4 \times 4 = 34$$

$$a_{23} = 1 \times 1 + 2 \times 2 + 2 \times 2 + 3 \times 3 + 4 \times 5 = 38$$

$$a_{31} = 1 \times 1 + 2 \times 1 + 2 \times 1 + 3 \times 1 + 5 \times 1 = 13$$

$$a_{32} = 1 \times 1 + 2 \times 2 + 2 \times 2 + 3 \times 3 + 5 \times 4 = 38$$

$$a_{33} = 1 \times 1 + 2 \times 2 + 2 \times 2 + 3 \times 3 + 5 \times 5 = 43$$

$$X^T X = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} = \begin{bmatrix} 5 & 12 & 13 \\ 12 & 34 & 38 \\ 13 & 38 & 43 \end{bmatrix}$$

c) calcular matriz inversa $(X^T X)^{-1}$:

A matriz inversa pode ser calculada pelo método da matriz adjunta, em que temos a relação:

$$M^{-1} = \frac{\bar{M}}{\det(M)}$$

Chamando $X^T X$ de M , temos que:

$$M = X^T X$$

Então, o determinante de M é:

$$\begin{array}{ccccc} 5 & 12 & 13 & 5 & 12 & 13 \\ 12 & 34 & 38 & 12 & 34 & 38 \\ 13 & 38 & 43 & 13 & 38 & 43 \end{array}$$

$$\det(M) = 5 \times 34 \times 43 + 12 \times 38 \times 13 + 13 \times 12 \times 38 - 5 \times 38 \times 38 - 12 \times 12 \times 43 - 13 \times 34 \times 13 = 19166 - 19158 = 8$$



A matriz adjunta $\bar{M}$ é a transposta da matriz dos cofatores C :

$$C = \begin{bmatrix} A_{11} & A_{12} & A_{13} \\ A_{21} & A_{22} & A_{23} \\ A_{31} & A_{32} & A_{33} \end{bmatrix}$$

Sendo que cada elemento dessa matriz é calculado da seguinte forma:

$$A_{11} = (-1)^{1+1} \cdot \begin{vmatrix} 34 & 38 \\ 38 & 43 \end{vmatrix} = 34 \times 43 - 38 \times 38 = 18$$

$$A_{12} = (-1)^{1+2} \cdot \begin{vmatrix} 12 & 38 \\ 13 & 43 \end{vmatrix} = (-1) \times (12 \times 43 - 38 \times 13) = -22$$

$$A_{13} = (-1)^{1+3} \cdot \begin{vmatrix} 12 & 34 \\ 13 & 38 \end{vmatrix} = 12 \times 38 - 34 \times 13 = 14$$

$$A_{21} = (-1)^{2+1} \cdot \begin{vmatrix} 12 & 13 \\ 38 & 43 \end{vmatrix} = (-1) \times (12 \times 43 - 38 \times 13) = -22$$

$$A_{22} = (-1)^{2+2} \cdot \begin{vmatrix} 5 & 13 \\ 13 & 43 \end{vmatrix} = 5 \times 43 - 13 \times 13 = 46$$

$$A_{23} = (-1)^{2+3} \cdot \begin{vmatrix} 5 & 12 \\ 13 & 38 \end{vmatrix} = (-1) \times (5 \times 38 - 12 \times 13) = -34$$

$$A_{31} = (-1)^{3+1} \cdot \begin{vmatrix} 12 & 13 \\ 34 & 38 \end{vmatrix} = 12 \times 38 - 13 \times 34 = 14$$

$$A_{32} = (-1)^{3+2} \cdot \begin{vmatrix} 5 & 13 \\ 12 & 38 \end{vmatrix} = (-1) \times (5 \times 38 - 12 \times 13) = -22$$

$$A_{33} = (-1)^{3+3} \cdot \begin{vmatrix} 5 & 12 \\ 12 & 34 \end{vmatrix} = 5 \times 34 - 12 \times 12 = 26$$

Portanto, a matriz de cofatores C é:

$$C = \begin{bmatrix} 18 & -22 & 14 \\ -22 & 46 & -34 \\ 14 & -34 & 26 \end{bmatrix}$$

Como a matriz adjunta $\bar{M}$ é a transposta da matriz dos cofatores C :

$$\bar{M} = \begin{bmatrix} 18 & -22 & 14 \\ -22 & 46 & -34 \\ 14 & -34 & 26 \end{bmatrix}$$

Logo, a matriz inversa de M é:

$$(X^T X)^{-1} = M^{-1} = \frac{\bar{M}}{\det(M)} = \begin{bmatrix} \frac{18}{8} & -\frac{22}{8} & \frac{14}{8} \\ -\frac{22}{8} & \frac{46}{8} & -\frac{34}{8} \\ \frac{14}{8} & -\frac{34}{8} & \frac{26}{8} \end{bmatrix} = \begin{bmatrix} 2,25 & -2,75 & 1,75 \\ -2,75 & 5,75 & -4,25 \\ 1,75 & -4,25 & 3,25 \end{bmatrix}$$



d) calcular a matriz $X^T y$:

$$X^T y = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 3 & 4 \\ 1 & 2 & 2 & 3 & 5 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$

$$X^T y = \begin{bmatrix} 1 \times 1 + 1 \times 2 + 1 \times 3 + 1 \times 4 + 1 \times 5 \\ 1 \times 1 + 2 \times 2 + 2 \times 3 + 3 \times 4 + 4 \times 5 \\ 1 \times 1 + 2 \times 2 + 2 \times 3 + 3 \times 4 + 5 \times 5 \end{bmatrix}$$

$$X^T y = \begin{bmatrix} 15 \\ 43 \\ 48 \end{bmatrix}$$

e) computar as estimativas dos parâmetros $\hat{\beta}$:

$$\hat{\beta} = (X^T X)^{-1} X^T y = \begin{bmatrix} 2,25 & -2,75 & 1,75 \\ -2,75 & 5,75 & -4,25 \\ 1,75 & -4,25 & 3,25 \end{bmatrix} \begin{bmatrix} 15 \\ 43 \\ 48 \end{bmatrix}$$

$$\hat{\beta} = \begin{bmatrix} 2,25 \times 15 - 2,75 \times 43 + 1,75 \times 48 \\ -2,75 \times 15 + 5,75 \times 43 - 4,25 \times 48 \\ 1,75 \times 15 - 4,25 \times 43 + 3,25 \times 48 \end{bmatrix}$$

$$\hat{\beta} = \begin{bmatrix} -0,5 \\ 2 \\ -0,5 \end{bmatrix}$$

f) calcular as estimativas de y :

$$\hat{y} = X \hat{\beta} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 2 \\ 1 & 3 & 3 \\ 1 & 4 & 5 \end{bmatrix} \begin{bmatrix} -0,5 \\ 2 \\ -0,5 \end{bmatrix} = \begin{bmatrix} 1 \\ 2,5 \\ 2,5 \\ 4 \\ 5 \end{bmatrix}$$

$$\hat{y} = \begin{bmatrix} 1 \times (-0,5) - 1 \times 2 + 1 \times (-0,5) \\ 1 \times (-0,5) - 2 \times 2 + 2 \times (-0,5) \\ 1 \times (-0,5) - 2 \times 2 + 2 \times (-0,5) \\ 1 \times (-0,5) - 3 \times 2 + 3 \times (-0,5) \\ 1 \times (-0,5) - 4 \times 2 + 5 \times (-0,5) \end{bmatrix}$$



$$\hat{y} = \begin{bmatrix} 1 \\ 2,5 \\ 2,5 \\ 4 \\ 5 \end{bmatrix}$$

g) calcular a matriz de erros:

$$E = y - \hat{y} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} - \begin{bmatrix} 1 \\ 2,5 \\ 2,5 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 1 - 1 \\ 2 - 2,5 \\ 3 - 2,5 \\ 4 - 4 \\ 5 - 5 \end{bmatrix} = \begin{bmatrix} 0 \\ -0,5 \\ 0,5 \\ 0 \\ 0 \end{bmatrix}$$

h) determinar a equação do modelo de regressão linear múltipla:

$$Y = -0,5 + 2x_1 - 0,5x_2 + \varepsilon$$



(CESPE/ABIN/2018) Determinado estudo socioeconômico considerou o modelo de regressão linear múltipla na forma matricial $y = X\beta + \varepsilon$, em que $y = (y_1, \dots, y_{100})^T$ representa o vetor de respostas (o símbolo sobrescrito T indica a operação de transposição), $y^T y = 2.500$ e $\sum_{i=1}^{100} y_i = 400$. X , a matriz de delineamento, é tal que

$$(X^T X)^{-1} = \begin{bmatrix} 1 & 0,2 & 0,1 \\ 0,2 & 0,8 & 0,2 \\ 0,1 & 0,2 & 1 \end{bmatrix} \text{ e } X^T y = \begin{bmatrix} 30 \\ 20 \\ 10 \end{bmatrix}$$

$\beta = (\beta_1, \beta_2, \beta_3)^T$ é o vetor de parâmetros, e ε é o vetor de erros aleatórios independentes e identicamente distribuídos. Cada componente do vetor ε segue uma distribuição normal com média nula e variância σ^2 .

Tendo essas informações como referência, julgue o próximo item.

A estimativa de β proporcionada pelo método de mínimos quadrados ordinários é $\hat{\beta} = (35, 24, 17)^T$.



Comentários:

Como vimos, pelo método dos mínimos quadrados, a estimativa de β é expressa por $(X^T X)^{-1} X^T y$. O enunciado já nos forneceu as matrizes $(X^T X)^{-1}$ e $X^T y$. Assim, nossa tarefa se resume a fazer a multiplicação dessas matrizes.

$$\hat{\beta} = \begin{bmatrix} 1 & 0,2 & 0,1 \\ 0,2 & 0,8 & 0,2 \\ 0,1 & 0,2 & 1 \end{bmatrix} \times \begin{bmatrix} 30 \\ 20 \\ 10 \end{bmatrix}$$

As matrizes devem ser multiplicadas na ordem em que aparecem na equação anterior. Assim, a primeira matriz é do tipo 3x3 e a segunda matriz é do tipo 3x1. Dessa forma, o resultado será uma matriz 3x1.

Na multiplicação de matrizes, cada elemento da matriz resulta do produto entre a linha correspondente da primeira matriz pela coluna correspondente da segunda matriz. Assim, temos que:

$$\hat{\beta} = \begin{bmatrix} 1 \times 30 + 0,2 \times 20 + 0,1 \times 10 \\ 0,2 \times 30 + 0,8 \times 20 + 0,2 \times 10 \\ 0,1 \times 30 + 0,2 \times 20 + 1 \times 10 \end{bmatrix}$$

e

$$\hat{\beta} = \begin{bmatrix} 30 + 4 + 1 \\ 6 + 16 + 2 \\ 3 + 4 + 10 \end{bmatrix} = \begin{bmatrix} 35 \\ 24 \\ 17 \end{bmatrix}$$

A matriz anterior também pode ser escrita como uma matriz-linha, utilizando a transposição de matrizes:

$$\hat{\beta} = [35 \quad 24 \quad 17]^T$$

Gabarito: Certo.



Análise de Regressão Múltipla

Na interpretação da regressão múltipla, buscamos identificar **se existe alguma variável independente capaz de explicar o comportamento de uma outra variável dependente**. Para isso, testamos se alguma variável independente ou explicativa está relacionada com a variável dependente. Assim, temos que:

$$\hat{Y}_i = a + b_1x_{1i} + b_2x_{2i}$$

em que a é o valor estimado de Y quando $X_1 = 0$ e $X_2 = 0$; b_1 e b_2 representam efeitos parciais.

Assim, se quisermos analisar a variação de Y em função das variações de X_1 e X_2 , podemos fazer:

$$\Delta \hat{Y}_i = b_1 \Delta X_{1i} + b_2 \Delta X_{2i}$$

Portanto, se X_2 for mantido fixo, $\Delta X_{2i} = 0$

$$\Delta \hat{Y}_i = b_1 \Delta X_{1i}$$

De outro modo, se x_1 for mantido fixo, $\Delta x_{1i} = 0$

$$\Delta \hat{Y}_i = b_2 \Delta X_{2i}$$

Logo, **se uma variável independente X_i não estiver** relacionada com a **variável dependente**, então seu **coeficiente será igual a zero**.

Para testar se pelo menos uma das variáveis independentes (explicativas) está relacionada com a variável dependente, utilizamos uma técnica denominada de **Análise de Variância (ANOVA)**. **A ANOVA testa a hipótese nula de que todos os valores de β são iguais a 0 contra a hipótese alternativa de que pelo menos um β não é zero**:

$$\begin{cases} H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0 \\ H_a: \text{pelo menos um } \beta_i \text{ não é zero.} \end{cases}$$

Se a hipótese nula é aceita, então não há relação linear entre Y (variável dependente) e qualquer uma das variáveis independentes.

Na análise de variância da regressão múltipla, a relação entre a soma dos quadrados permanece válida. Assim, a soma dos quadrados total, definida por $\sum (Y_i - \bar{Y})^2$, é igual à soma dos quadrados do modelo de regressão, definida na expressão por $\sum (\hat{Y}_i - \bar{Y})^2$ mais a soma dos quadrados dos resíduos/desvios/erros, definida por $\sum \varepsilon_i^2$.



Portanto, temos a seguinte relação:

$$SQT = SQM + SQR$$

em que:

SQT : soma dos quadrados totais;

SQM : soma dos quadrados do modelo de regressão; e

SQR : soma dos quadrados dos resíduos/erros.

O coeficiente de determinação da regressão múltipla, R^2 , é expresso por:

$$R^2 = \frac{SQM}{SQT}$$



Alguns autores trazem as seguintes nomenclaturas:

SQR : soma dos quadrados da regressão;

SQE : soma dos quadrados dos erros.

No entanto, em nossa aula, adotaremos as nomenclaturas apresentadas anteriormente.



Também podemos reescrever a equação assim:

$$R^2 = \frac{SQT - SQR}{SQT} = \frac{SQT}{SQT} - \frac{SQR}{SQT}$$

$$R^2 = 1 - \frac{SQR}{SQT}$$

Nesse ponto, retomamos a ideia dos graus de liberdade do modelo de regressão linear múltipla. O grau de liberdade total continua sendo $n - 1$. Portanto, no modelo de regressão temos que os graus de liberdade são iguais ao número de parâmetros estimados (p) menos 1, $p - 1$.

Para os graus de liberdade dos resíduos, temos:

$$gl_{total} = gl_{resíduos} + gl_{equação}$$

Substituindo temos:

$$n - 1 = gl_{resíduos} + p - 1$$

$$gl_{resíduos} = p - 1 - n + 1$$

$$gl_{resíduos} = n - p$$

Para os graus de liberdade aplicado às fórmulas, temos:

- graus de liberdade totais: $n - 1$;
- graus de liberdade do modelo: $p - 1$; e
- graus de liberdade dos resíduos: $n - p$.





- $gl_{total} = gl_{resíduos} + gl_{equação}$
- $gl_{total}: n - 1$
- $gl_{resíduos}: n - p$
- $gl_{equação}: p - 1$

Normalmente, o coeficiente de determinação R^2 conforme são adicionadas novas variáveis independentes (explicativas) ao modelo de regressão linear múltipla. Contudo, a inclusão excessiva de variáveis independentes pode restringir os graus de liberdade disponíveis para estimar a variabilidade dos parâmetros. Nesse caso, devemos utilizar o conceito de R^2 ajustado, $\overline{R^2}$, que considera o número de variáveis explicativas do modelo.

Para obtermos $\overline{R^2}$, dividimos SQR e SQT pelos respectivos graus de liberdade. Assim, temos:

$$\overline{R^2} = 1 - \frac{\left(\frac{SQR}{n-p}\right)}{\left(\frac{SQT}{n-1}\right)}$$

Assim, temos que o coeficiente de determinação corrigido pelos graus de liberdade é dado por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n-1)}{(n-p)}$$

Antes de usarmos os dados obtidos na análise de regressão numa previsão, precisamos estabelecer a significância estatística desses resultados, com a finalidade de determinar a confiança a ser aplicada nos resultados da regressão e sua aplicação.



Os quadrados médios são obtidos pela divisão entre as somas dos quadrados e os respectivos graus de liberdade. Assim, temos:

a) quadrado médio do modelo (QMM):

$$QMM = \frac{SQM}{p - 1}$$

b) quadrado médio dos resíduos (QMR):

$$QMR = \frac{SQR}{n - p}$$

c) quadrado médio total (QMT):

$$QMT = \frac{SQT}{n - 1}$$

Para testar $H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0$ contra $H_1: \beta \neq 0$, usamos a seguinte estatística teste, denominada de estatística F (ou razão F):

$$F^* = \frac{\frac{SQM}{(p - 1)}}{\frac{SQR}{(n - p)}}$$

Simplificando, temos:

$$F^* = \frac{QMM}{QMR}$$

em que:

QMM é o quadrado médio do modelo de regressão;

QME é o quadrado médio dos erros/resíduos;



Se o valor de F^* for significativamente grande, teremos evidências para rejeitar H_0 .

Sob a hipótese H_0 , F^* tem distribuição F de Snedecor, com $p - 1$ e $n - p$ graus de liberdade, em que n é o número de observações.

Dessa forma, para avaliar o teste de hipóteses, basta compararmos o valor da estatística teste com o valor crítico tabelado:

- Se $F^* > F_{\text{crítico}}$, podemos rejeitar a hipótese nula;
- Se $F^* < F_{\text{crítico}}$, não podemos rejeitar a hipótese nula.

O valor de $F_{\text{crítico}}$ é consultado em uma tabela F de Snedecor com $p - 1$ grau de liberdade no numerador e $n - p$ graus de liberdade no denominador, para um determinado nível de significância.

Estimadores da Variância dos Erros na Regressão Linear Múltipla

A variância populacional dos erros σ^2 é um parâmetro desconhecido que quantifica a variabilidade dos termos de erro ε_i em toda a população. Podemos definir a variância real dos erros como:

$$\sigma^2 = \text{Var}(\varepsilon_i)$$

No entanto, na prática, não temos acesso direto aos erros verdadeiros ε_i porque apenas observamos os resíduos $e_i = y_i - \hat{y}_i$, onde $\hat{y}_i$ são os valores preditos pelo modelo ajustado.

O Erro Quadrático Médio (EQM, do inglês Mean Squared Error - MSE) é uma medida de qualidade do ajuste de um modelo de regressão, calculada como a média dos quadrados dos resíduos ($e_i = y_i - \hat{y}_i$):

$$EQM = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} = \frac{SQR}{n}$$

em que: y_i são os valores observados; $\hat{y}_i$ são os valores preditos pelo modelo; e n é o número de observações.

O erro quadrático médio é uma estimativa da variância dos erros, **mas não é um estimador não viciado**. Quando calculamos o EQM usando todos os n termos de resíduos e dividimos por n , ele nos fornece uma medida de quão bem o modelo se ajusta aos dados, mas tende a subestimar a verdadeira variância dos erros.

Para obter um estimador não viciado da variância dos erros, ajustamos o EQM pelos graus de liberdade do modelo. Na regressão linear múltipla, isso é feito dividindo a soma dos quadrados dos resíduos por $n - p$, onde p é o número de parâmetros estimados (incluindo o intercepto):



$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - p} = \frac{SQR}{n - p}$$

Ajustar pelos graus de liberdade corrige o viés do Erro Quadrático Médio, tornando $\hat{\sigma}^2$ um estimador não viciado da verdadeira variância dos erros σ^2 .

O EQM é também o **Estimador de Máxima Verossimilhança (EMV)** para a variância dos erros σ^2 . A função de verossimilhança para os erros ε_i assume uma distribuição normal $N(0, \sigma^2)$, e o EMV para σ^2 é obtido maximizando a log-verossimilhança:

$$\tilde{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n} = \frac{SQR}{n}$$

sendo não viciado apenas assintoticamente (quando $n \rightarrow \infty$).

Tabela de Análise de Variância para a Regressão Linear Múltipla

Por fim, as questões de **análise de variância da regressão** normalmente fornecem uma tabela incompleta e pedem alguma medida que está faltando. Para descobrir o valor da medida solicitada, você deve conhecer a estrutura da tabela e as fórmulas apresentadas neste tópico. A estrutura da tabela de análise de variância da regressão múltipla sempre terá o seguinte formato:

Fonte de Variação	Graus de Liberdade	Soma dos Quadrados	Quadrados Médios	Estatística F (Razão F)
Modelo	$p - 1$	SQM	$QMM = \frac{SQM}{p - 1}$	$F^* = \frac{QMM}{QMR}$
Resíduos	$n - p$	SQR	$QMR = \frac{SQR}{n - p}$	
Total	$n - 1$	SQT	$QMT = \frac{SQT}{n - 1}$	





Em um modelo de regressão múltipla do tipo:

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

temos α como intercepto. Desta forma, definimos o número de **parâmetros** p somando a quantidade de variáveis explicativas do modelo mais o intercepto. Assim,

$$p = \text{número de variáveis explicativas} + \text{intercepto}$$

Alguns autores utilizam a fórmula:

$$QMR = \frac{SQR}{n - k - 1}$$

atribuindo k ou p à quantidade de variáveis explicativas, porém, subtraindo o intercepto, representado na fórmula (-1).



Construir a **tabela da análise de variância** para o modelo de regressão múltipla calculado no exemplo anterior. As matrizes obtidas foram:

$$y = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix} \quad \hat{y} = \begin{bmatrix} 1 \\ 2,5 \\ 2,5 \\ 4 \\ 5 \end{bmatrix} \quad E = \begin{bmatrix} 0 \\ -0,5 \\ 0,5 \\ 0 \\ 0 \end{bmatrix}$$

A média aritmética de y é:

$$\bar{y} = \frac{1 + 2 + 3 + 4 + 5}{5} = \frac{15}{5} = 3$$



a) Cálculo da Soma dos Quadrados dos Resíduos (SQR):

$$SQR = \sum \varepsilon_i^2$$
$$SQR = 0^2 + (-0,5)^2 + 0,5^2 + 0^2 + 0^2$$
$$SQR = 0,25 + 0,25 = 0,5$$

b) Cálculo da Soma dos Quadrados do Modelo (SQM):

$$SQM = \sum (\hat{y}_i - \bar{y})^2$$
$$SQM = (1 - 3)^2 + (2,5 - 3)^2 + (2,5 - 3)^2 + (4 - 3)^2 + (5 - 3)^2$$
$$SQM = (-2)^2 + (-0,5)^2 + (-0,5)^2 + (1)^2 + (2)^2$$
$$SQM = 4 + 0,25 + 0,25 + 1 + 4 = 9,5$$

c) Cálculo da Soma dos Quadrados Totais (SQT):

$$SQT = \sum (y_i - \bar{y})^2$$
$$SQT = (1 - 3)^2 + (2 - 3)^2 + (3 - 3)^2 + (4 - 3)^2 + (5 - 3)^2$$
$$SQT = (-2)^2 + (-1)^2 + (0)^2 + (1)^2 + (2)^2$$
$$SQT = 4 + 1 + 0 + 1 + 4 = 10$$

Vejam que $SQT = SQM + SQR$.

d) Cálculo de R^2 :

$$R^2 = 1 - \frac{SQR}{SQT} = 1 - \frac{0,5}{10} = 1 - 0,05 = 0,95$$

e) Cálculo de R^2 ajustado:

$$\overline{R^2} = 1 - \frac{\left(\frac{SQR}{n-p}\right)}{\left(\frac{SQT}{n-1}\right)} = 1 - \frac{\left(\frac{0,5}{5-3}\right)}{\left(\frac{10}{5-1}\right)} = 1 - \frac{\left(\frac{0,5}{2}\right)}{\left(\frac{10}{4}\right)} = 1 - \frac{0,25}{2,5} = 1 - 0,1 = 0,9$$



f) Cálculo dos quadrados médios do modelo:

$$QMM = \frac{SQM}{p - 1} = \frac{9,5}{3 - 1} = \frac{9,5}{2} = 4,25$$

g) Cálculo dos quadrados médios dos resíduos:

$$QMR = \frac{SQR}{n - p} = \frac{0,5}{5 - 3} = \frac{0,5}{2} = 0,25$$

h) Cálculo dos quadrados médios totais:

$$QMT = \frac{SQT}{n - 1} = \frac{10}{5 - 1} = \frac{10}{4} = 2,5$$

i) Cálculo da estatística F^* :

$$F^* = \frac{QMM}{QMR} = \frac{4,25}{0,25} = 17$$

j) Cálculo de $F_{crítico}$:

O valor de $F_{crítico}$ é consultado em uma tabela F de Snedecor com $p - 1 = 3 - 1 = 2$ grau de liberdade no numerador e $n - p = 5 - 3 = 2$ graus de liberdade no denominador, para um determinado nível de significância.

Graus de liberdade do denominador de F: v_2	Distribuição F									
	Grau de liberdade do numerador de F: v_1									
	1	2	3	4	5	6	7	8	9	10
1	161,4	199,5	215,7	224,6	230,2	234,0	236,8	238,9	240,5	241,9
2	18,51	19,00	19,16	19,25	19,30	19,33	19,35	19,37	19,38	19,40
3	10,13	9,55	9,28	9,12	9,01	8,94	8,89	8,85	8,81	8,79
4	7,71	6,94	6,59	6,39	6,26	6,16	6,09	6,04	6,00	5,96
5	6,61	5,79	5,41	5,19	5,05	4,95	4,88	4,82	4,77	4,74
6	5,99	5,14	4,76	4,53	4,39	4,28	4,21	4,15	4,10	4,06
7	5,59	4,74	4,35	4,12	3,97	3,87	3,79	3,73	3,68	3,64
8	5,32	4,46	4,07	3,84	3,69	3,58	3,50	3,44	3,39	3,35
9	5,12	4,26	3,86	3,63	3,48	3,37	3,29	3,23	3,18	3,14
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	3,02	2,98



$$F_{\text{crítico}} = 19,00$$

Como $F^* < F_{\text{crítico}}$, não podemos rejeitar a hipótese nula.

k) Construção da tabela de análise de variância:

Fonte de Variação	Graus de Liberdade	Soma dos Quadrados	Quadrados Médios	Estatística F (Razão F)
Modelo	2	9,5	4,25	14
Resíduos	2	0,5	0,25	
Total	4	10,0	2,5	



(CESPE/CGE-CE/2019) Considerando-se que, em uma regressão múltipla de dados estatísticos, a soma dos quadrados da regressão seja igual a 60.000 e a soma dos quadrados dos erros seja igual a 15.000, é correto afirmar que o coeficiente de determinação R^2 é igual a

- a) 0,25
- b) 0,50
- c) 0,20
- d) 0,80
- e) 0,75

Comentários:

Primeiro, vamos calcular a soma dos quadrados total:

$$SQT = SQM + SQR$$



em que SQT é a soma dos quadrados totais; SQM é a soma dos quadrados do modelo; e SQR é a soma dos quadrados dos resíduos.

Assim, temos:

$$SQT = 60.000 + 15.000 = 75.000$$

Em seguida, calcularemos o coeficiente de determinação:

$$R^2 = \frac{SQM}{SQT}$$
$$R^2 = \frac{60.000}{75.000} = 0,80$$

Gabarito: D.



VARIÁVEL BINÁRIA OU VARIÁVEL DUMMY

As variáveis binárias são utilizadas para indicar a presença ou ausência de determinada característica, ou seja, para incorporar **aspectos qualitativos** ao modelo de regressão. Esses aspectos qualitativos normalmente aparecem na forma de uma **informação binária**, isto é, que assume apenas os valores 0 (zero) ou 1 (um). Uma variável binária é também chamada de variável **dummy**.

Aspectos que podem ser representados por meio de informações binárias são, por exemplo: sexo (0 - homem; 1 - mulher); estações do ano (0 - inverno; 1 - verão); volume (0 - cheio; 1 - vazio); ocupação (0 - empregado; 1 - desempregado).

As variáveis *dummy* podem ser usadas para representar mudanças no intercepto do modelo ou para estimar efeitos não lineares. Quando incluídas diretamente no modelo de regressão, como ocorre nas questões apresentadas a seguir, objetivam estimar as diferenças de intercepto.

Podem também ser usadas interagindo com outras variáveis explicativas, nesse caso objetivam indicar diferenças na inclinação da reta de regressão para diferentes grupos.



(CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.



Fixando-se determinado ponto (X_1, X_2) , a ocorrência do evento representado por D faz que a estimativa de Y diminua em mais de 80 unidades.

Comentários:

A equação que representa o modelo de regressão linear em análise é a seguinte:

$$Y = 340 + 150X_1 + 540X_2 + 89D + e$$

em que D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

Conforme o enunciado, fixando o ponto (X_1, X_2) , a ocorrência do evento representado por D faz com que tenhamos a seguinte situação:

$$Y = 340 + 150X_1 + 540X_2 + 89 \times 1 + e$$

$$Y = 340 + 150X_1 + 540X_2 + e + 89$$

$$Y = (340 + 150X_1 + 540X_2 + e) + 89$$

Assim, concluímos que a estimativa de Y aumenta em 89 unidades.

Gabarito: Errado.

(CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

O coeficiente de determinação ajustado dessa regressão, $\hat{R}^2$, é maior que o coeficiente de determinação R^2 .

Comentários:

O coeficiente de determinação é definido pela seguinte expressão:



$$R^2 = 1 - \frac{SQR}{SQT}$$

em que SQR é a soma dos quadrados dos resíduos/erros e SQT é a soma dos quadrados total.

O coeficiente de determinação ajustado, por sua vez, é expresso por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$

em que n é o número de amostras e p é o número de parâmetros estimados.

Substituindo os valores de n e p na expressão do coeficiente de determinação ajustado, temos que:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(12 - 1)}{(12 - 2)}$$

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(11)}{(10)}$$

$$\overline{R^2} = R^2 - \frac{1}{10}$$

Logo, o coeficiente de determinação ajustado é menor que o coeficiente de determinação R^2 .

Gabarito: Errado.

(CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.



O valor de "a" reflete a quantidade de variáveis explicativas, e deve ser igual a 3.

Comentários:

Na tabela apresentada no enunciado, foram informados os graus de liberdade dos erros ou resíduos e os graus de liberdade total. De posse dessas informações, podemos descobrir o número de graus de liberdade do modelo (equação), isto é, vamos encontrar o valor da variável a . Vejamos:

$$gl_{total} = gl_{resíduos} + gl_{equação}$$

Substituindo, temos:

$$11 = 8 + a$$

$$a = 11 - 8$$

$$a = 3$$

Gabarito: Certo.

(CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

A soma dos quadrados totais é igual a 2.016.000

Comentários:

A soma dos quadrados totais é dada por:

$$SQT = SQM + SQR$$

em que:

SQM : soma dos quadrados do modelo de regressão;



SQR : soma dos quadrados dos resíduos/erros.

Substituindo os valores, temos:

$$SQT = 2.000.000 + 16.000$$

$$SQT = 2.016.000$$

Gabarito: Certo.




PROBLEMA DA ESPECIFICAÇÃO

O problema da especificação consiste na **definição do tipo de função matemática**, ou seja, do modelo matemático que melhor se ajusta ao estudo da relação entre as variáveis da regressão.


No caso da regressão múltipla, quando **mais de uma variável independente** pode afetar a variável dependente, temos o **problema da especificação**. Daí a necessidade de escolha do modelo matemático mais adequado ao estudo da regressão, para uma análise mais efetiva.

Podemos escolher como modelos matemáticos, por exemplo, as seguintes funções:


$$Y_i = \alpha + \beta X_i$$




$$Y_i = \alpha X_i^\beta$$




$$Y_i = \alpha \beta^{X_i}$$



$$Y_i = \alpha + \beta \times \log(X_i)$$



$$Y_i = \alpha + \beta X_i + \gamma X_i^2$$



Notem que a escolha do modelo matemático normalmente é determinada por algum conhecimento que temos a priori ou pela análise gráfica dos dados.



O problema da especificação também pode ser notado no caso em que a equação estimada é obtida **erroneamente**. Além da escolha do modelo matemático, também é necessário determinar quais variáveis independentes são consideradas no modelo de regressão. Por exemplo, caso o modelo correto fosse:

$$Y_i = \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + \varepsilon_i$$

e obtivéssemos a seguinte equação estimada:

$$\hat{Y}_i = b_1 x_{1i} + b_2 x_{2i}$$

Nesse caso, desenvolvendo a matriz da regressão, chegaríamos à equação:

$$E(b_1) = \beta_1 + \theta_1 \beta_3$$

$$E(b_2) = \beta_2 + \theta_2 \beta_3$$

Portanto, temos uma situação em que **duas variáveis explicativas** podem estar **afetando a variável dependente**. Assim, **as estimativas obtidas por meio do modelo equivocado são tendenciosas**.

Agora, vamos considerar que o modelo correto agora fosse:

$$Y_i = \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$$

e fosse obtida a seguinte equação estimada:

$$\hat{Y}_i = b_1 x_{1i} + b_2 x_{2i} + b_3 x_{3i}$$

Nesse caso, desenvolvendo a matriz da regressão, chegaríamos à equação:

$$E(b_1) = \beta_1;$$

$$E(b_2) = \beta_2;$$

$$E(b_3) = 0$$

Assim, podemos notar que, quando incluímos uma **variável desnecessária**, as estimativas dos coeficientes permanecem **não tendenciosas**, ao contrário do que ocorre quando deixamos de incluir variáveis explanatórias importantes.

Com isso, **percebemos que é preferível incluir uma variável desnecessária a não incluir uma variável significativa**. Porém, **é importante salientar que incluir variáveis desnecessárias também pode ser prejudicial, pois geralmente a variância dos estimadores é aumentada**.





EXEMPLIFICANDO

Considere que um pesquisador deseje mensurar os salários médios dos funcionários de uma determinada empresa. Para tanto, ele considerou o salário médio como variável dependente e incluiu algumas variáveis independentes, conforme o modelo matemático apresentado a seguir:

$$\ln(\text{salário médio}) = b_0 + b_1 \times \text{conhecimento} + b_2 \times \text{tempo no cargo} + b_3 \times \text{experiência}^2 + \varepsilon$$

Supondo o termo quadrático do modelo foi omitido pelo pesquisador, o fator experiência^2 passará a ser incluído no erro do modelo. Assim, teremos o seguinte modelo subespecificado:

$$\ln(\widehat{\text{salário médio}}) = \beta_0 + \beta_1 \times \text{conhecimento} + \beta_2 \times \text{tempo no cargo} + \varepsilon$$

Se o fator experiência^2 tiver relação com conhecimento e tempo no cargo, os parâmetros estimados β_0 , β_1 e β_2 serão **tendenciosos**. Esse problema pode ser corrigido com a inclusão do fator experiência^2 no modelo, o que faria com que as estimativas do modelo fossem **não tendenciosas**.

Vale ressaltar que a omissão de variáveis independentes significativas não é a única forma do modelo sofrer problema de especificação, o erro na escolha do modelo matemático também pode contribuir para o problema da especificação, por exemplo, incluir ou deixar de incluir um logaritmo, uma função exponencial, dentre outras.

Vejam que a especificação incorreta do modelo pode levar a uma análise de dados incompatível com a realidade, daí a importância de se conhecer quais variáveis independentes são essenciais para o modelo de regressão.



Teste RESET

Para saber se o modelo tem algum problema de especificação, existem alguns testes propostos, dentre eles o Teste de Erro de Especificação da Regressão (**RESET**, do inglês *Regression Specification Error Test*), proposto por Ramsey.

A ideia do teste RESET é que se o modelo original contém todas as condições para que não haja tendência nos estimadores, nenhuma função não-linear das variáveis independentes deve ser expressiva quando adicionada à equação.

Então, o teste RESET adiciona **polinômios** aos valores estimados pelo método dos mínimos quadrados ordinários (MQO), com a finalidade de detectar os erros de especificação.

Consideremos o modelo original:

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \varepsilon$$

Segundo o teste RESET, vamos adicionar **polinômios quadráticos e cúbicos** ao modelo original para analisar se há não linearidades presentes. Com isso, chegamos ao modelo expandido:

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \delta_1 \hat{y}^2 + \delta_2 \hat{y}^3 + \varepsilon$$

Basicamente, o modelo expandido adiciona dois parâmetros ao modelo de regressão original, tomando como base as próprias estimativas obtidas com o modelo original, $\hat{y}$.

A partir da equação do modelo expandido, podemos testar se existem problemas de especificação no modelo (ausências de não linearidades importantes). Para isso, realizamos um teste de hipótese conjunta:

$$H_0: \delta_1 = \delta_2 = 0$$

$$H_a: H_0 \text{ é falsa.}$$

Portanto, a hipótese nula H_0 indica que o modelo foi especificado corretamente. Por consequência, quando a hipótese nula H_0 é rejeitada, o modelo contém erros de especificação.



O teste RESET utiliza a estatística F^* para testar se a especificação está correta. Se o valor de F^* for significativamente grande, teremos evidências para rejeitar H_0 .

$$F^* = \frac{\left[\frac{(R_{\text{expandido}}^2 - R_{\text{original}}^2)}{2} \right]}{\left[\frac{(1 - R_{\text{expandido}}^2)}{n - p - 2} \right]}$$

$$F^* = \frac{\left[\frac{(SQR_{\text{original}} - SQR_{\text{expandido}})}{2} \right]}{\left[\frac{SQR_{\text{expandido}}}{n - p - 2} \right]}$$

Sob a hipótese H_0 , F^* tem distribuição F de Snedecor, com 2 e $n - p - 2$ graus de liberdade, em que n é o número de observações.

Dessa forma, para avaliar o teste de hipóteses, basta compararmos o valor da estatística teste com o valor crítico tabelado:

- Se $F^* > F_{\text{crítico}}$, podemos rejeitar a hipótese nula;
- Se $F^* < F_{\text{crítico}}$, não podemos rejeitar a hipótese nula.

O valor de $F_{\text{crítico}}$ é consultado em uma tabela F de Snedecor com 2 grau de liberdade no numerador e $n - p - 2$ graus de liberdade no denominador, para um determinado nível de significância.



EXEMPLIFICANDO

Um modelo de regressão linear múltipla, com intercepto, consiste em uma variável dependente, 2 variáveis explicativas e o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Com base em 125 observações e utilizando o método dos mínimos quadrados obteve-se um valor R_{original}^2 igual a 0,90. Em seguida, foi executado um teste de erro de especificação de Ramsey (RESET) nesse mesmo conjunto de dados, tendo sido encontrado um $R_{\text{expandido}}^2$ de 0,95.

Podemos afirmar que há um erro de especificação nesse modelo?



Primeiro temos que calcular o valor da estatística F^* . Sabemos que o número de parâmetros é igual a 3, pois o modelo tem duas variáveis explicativas ou independentes e um intercepto. Além disso, como o número de observações é 125, temos que $n = 125$.

$$F^* = \frac{\left[\frac{(R_{\text{expandido}}^2 - R_{\text{original}}^2)}{2} \right]}{\left[\frac{(1 - R_{\text{expandido}}^2)}{n - p - 2} \right]} = \frac{\left[\frac{(0,95 - 0,90)}{2} \right]}{\left[\frac{(1 - 0,95)}{125 - 3 - 2} \right]} = \frac{\left[\frac{0,05}{2} \right]}{\left[\frac{0,05}{120} \right]} = \frac{120}{2} = 60$$

Para um nível de significância de 5%, o valor tabelado de $F_{\text{crítico}}$ para 2 e $125 - 3 - 2 = 120$ graus de liberdade é 3,04.

Como $F^* > F_{\text{crítico}}$, podemos rejeitar a hipótese nula e afirmar que há erro de especificação.



TRANSFORMAÇÃO DE BOX-COX

Vamos supor que precisássemos que estivessemos diante de um conjunto de dados não-normal ou com variância não-constante. O que poderíamos nesse caso? Para esse tipo de situação, há um conjunto de transformações que visa a corrigir a não normalidade ou a variância não constante (heterocedasticidade).

Uma estratégia muito eficiente para esse tipo de situação é a transformação de potência, X^λ . Essa transformação pode ser aplicada quando temos um problema de **heterocedasticidade**, conjunto de dados não-normais ou variância não-constante.

A transformação de Box-Cox é capaz de tornar linear uma relação não-linear. Também pode ser aplicada quando os resíduos não são normalmente distribuídos ou quando a variância deles não é constante. Em outras palavras, essa técnica pode ser empregada para melhorar a correlação, produzir dados mais próximos de uma distribuição normal e estabilizar a variância.

Sendo o conjunto de dados representado pelas observações $x_1, x_2, \dots, x_n$, a transformação de Box-Cox é expressa por:

$$X^{(\lambda)} = \begin{cases} \frac{x^{(\lambda)} - 1}{\lambda}, & (\lambda \neq 0) \\ \log x, & (\lambda = 0) \end{cases}$$

De acordo com Box e Cox, temos essa definição apenas para variáveis com valores positivos, $x > 0$. Essa transformação pode ser simplificada para:

$$X^{(\lambda)} = \begin{cases} x^{(\lambda)}, & (\lambda \neq 0) \\ \log x, & (\lambda = 0) \end{cases}$$

Box e Cox afirmam que, após a adequada transformação da variável x para x^λ , os valores esperados das observações transformadas serão descritos por um **modelo de estrutura mais simples**, terão **variância constante** e estarão **normalmente distribuídos**.



(FGV/IBGE/2017) Com o objetivo de verificar qual seria a forma funcional mais adequada a um modelo é feita uma transformação Box-Cox, estimando-se repetidas vezes o seguinte modelo:

$$Y^* = \alpha + \beta \cdot X^* + \varepsilon$$



Onde $Y^* = \frac{Y_i^\lambda - 1}{\lambda}$ e $X^* = \frac{X_i^\lambda - 1}{\lambda}$, sendo λ e δ os parâmetros que mudam a cada nova rodada de estimações.

As distribuições de λ e δ foram identificadas para os testes de hipóteses:

$$H_0: \lambda = 0 \quad vs \quad H_a: \lambda = 1$$

$$H_0: \delta = 1 \quad vs \quad H_a: \delta = 0$$

Em ambos os testes H_0 foi rejeitada.

Então a forma funcional mais adequada ao modelo inicial é

a) $Y = \alpha^* + \beta \cdot X + \varepsilon$

b) $\ln Y = \alpha^* + \beta \cdot X + \varepsilon$

c) $Y = \alpha^* + \beta \cdot \ln X + \varepsilon$

d) $\ln Y = \alpha^* + \beta \cdot \ln X + \varepsilon$

e) $Y = \alpha^* + \beta \cdot \left(\frac{1}{x}\right) + \varepsilon$

Comentários:

Conforme o enunciado a hipótese H_0 foi rejeitada nos dois testes. Portanto, temos que

$$\lambda = 1$$

e

$$\delta = 0.$$

Segundo a transformação de Box-Cox, quando o parâmetro é 0, devemos tirar o logaritmo da variável. Logo,

$$X^* = \ln X$$

Para a variável Y , temos que $\lambda = 1$. Logo,

$$Y^* = \frac{Y_i^\lambda - 1}{\lambda} = Y - 1$$

Agora, vamos substituir essas expressões no modelo $Y^* = \alpha + \beta \cdot X^* + \varepsilon$.

$$\underbrace{Y^*}_{Y-1} = \alpha + \beta \cdot \underbrace{X^*}_{\ln X} + \varepsilon$$

$$Y - 1 = \alpha + \beta \cdot \ln X + \varepsilon$$

$$Y = 1 + \alpha + \beta \cdot \ln X + \varepsilon$$

Por fim, tomando $\alpha^* = \alpha + 1$, temos que:

$$Y = \underbrace{1 + \alpha}_{\alpha^*} + \beta \cdot \ln X + \varepsilon$$

$$Y = \alpha^* + \beta \cdot X^* + \varepsilon$$

Gabarito: C.



RESUMO DA AULA

REGRESSÃO MÚLTIPLA

REGRESSÃO MÚLTIPLA

Relaciona uma **variável dependente** e **duas ou mais variáveis independentes** ou explicativas. Utilizamos a regressão múltipla para estimar o valor de uma variável dependente com base em um conjunto de outras variáveis independentes.



O modelo de regressão múltipla é dado por:

$$Y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

A equação de regressão estimada a partir de dados amostrais é expressa por:

$$\hat{Y} = a + b_1 x_1 + b_2 x_2 + \dots + b_k x_k$$

- Propriedades

Sobre a Regressão Múltipla, podemos afirmar que:

I – $E(\varepsilon_i) = 0$: A **média dos erros** deve ser igual **a zero**.

II – $Var(\varepsilon_i) = \sigma^2$: A variância do erro deve ser constante. Essa propriedade é denominada de **homocedasticia**. Isto somente é possível se a variável ε tiver variância constante:

III – $Corr(\varepsilon_i, \varepsilon_j) = 0, para i \neq j$: Essa propriedade garante que os erros cometidos pelo modelo são independentes, isto é, **não se correlacionam**.

IV – **Os erros têm distribuição normal**: Outro importante pressuposto é de que não pode existir nenhuma relação linear entre as variáveis independentes. Se no modelo tivermos duas variáveis explicativas ou independentes proporcionais, ou seja, altamente correlacionadas, teremos um problema denominado de **multicolinearidade**.

- Equação Matricial

Pelo **método dos mínimos quadrados ordinários (MQO)**, podemos demonstrar que o estimador de $\hat{\beta}$ é expresso por:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$



Análise de Regressão Múltipla

Na interpretação da regressão múltipla, buscamos identificar **se existe alguma variável independente capaz de explicar o comportamento de uma outra variável dependente.**

A ANOVA testa a hipótese nula de que todos os valores de β são iguais a 0 contra a hipótese alternativa de que pelo menos um β não é zero:

$$\begin{cases} H_0: \beta_1 = \beta_2 = \dots = \beta_k = 0 \\ H_a: \text{pelo menos um } \beta_i \text{ não é zero.} \end{cases}$$

Se a hipótese nula é aceita, então não há relação linear entre Y (variável dependente) e qualquer uma das variáveis independentes.

- Coeficiente de Determinação Ajustado

O **coeficiente de determinação** da Regressão múltipla, R^2 , é expresso por:

$$R^2 = \frac{SQM}{SQT} \Rightarrow R^2 = 1 - \frac{SQR}{SQT}$$

- Graus de Liberdade

Para os graus de liberdade dos resíduos, temos:

$$gl_{total} = gl_{resíduos} + gl_{equação}$$

Em que:

- $gl_{total}: n - 1$
- $gl_{resíduos}: n - p$
- $gl_{equação}: p - 1$

- Coeficiente de Determinação

O **coeficiente de determinação** corrigido pelos graus de liberdade é dado por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$



- Estatística F

A estatística F é definida por:

$$F = \frac{QMR}{QME}$$

VARIÁVEL BINÁRIA OU VARIÁVEL DUMMY

As variáveis binárias são utilizadas para indicar a presença ou ausência de determinada característica, ou seja, para incorporar **aspectos qualitativos** ao modelo de regressão. Esses aspectos qualitativos normalmente aparecem na forma de uma **informação binária**, isto é, que assume apenas os valores 0 (zero) ou 1 (um). Uma variável binária é também chamada de variável *dummy*

PROBLEMA DA ESPECIFICAÇÃO

Consiste na definição do **tipo de função matemática**, ou seja, do modelo matemático que melhor se ajusta ao estudo da relação entre as variáveis da regressão.

Quando **incluimos** uma **variável desnecessária**, as estimativas dos coeficientes permanecem **não-tendenciosas**, ao contrário do que ocorre quando deixamos de incluir variáveis explanatórias importantes.

Com isso, percebemos que é **preferível incluir** uma variável **desnecessária** a **não incluir** uma variável e **significativa**.

Teste RESET

TESTE RESET

RESET, do inglês **Regression Specification Error Test**

Adiciona polinômios aos valores estimados pelo método dos mínimos quadrados ordinários (**MQO**), com a finalidade de **detectar os erros de especificação**.



TRANSFORMAÇÃO DE BOX-COX

TRANSFORMAÇÃO BOX COX

Aplicada quando temos um **problema de heterocedasticidade**, conjunto de dados não-normais ou variância não-constante.



A transformação de Box-Cox é expressa por:

$$X^{(\lambda)} = \begin{cases} \frac{x^{(\lambda)} - 1}{\lambda}, & (\lambda \neq 0) \\ \log x, & (\lambda = 0) \end{cases}$$

$$X^{(\lambda)} = \begin{cases} x^{(\lambda)}, & (\lambda \neq 0) \\ \log x, & (\lambda = 0) \end{cases}$$



QUESTÕES COMENTADAS

Regressão Múltipla

1. (CEBRASPE/FUNPRES-P-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O desvio padrão dos resíduos do modelo de regressão é igual a 6.

Comentários:

O desvio padrão dos resíduos é a raiz quadrada do erro quadrático médio:



$$\sigma = \sqrt{EQM}$$

Como a tabela nos informa que 36 é o erro quadrático médio, então:

$$\sigma = \sqrt{36} = 6$$

O desvio padrão dos resíduos do modelo de regressão é igual a 6.

Gabarito: Certo.

2. (CEBRASPE/FUNPRES-P-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1 , X^2 , X^3 e X^4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

A variância amostral da variável dependente Y é superior a 85.



Comentários:

Sabemos que o coeficiente de determinação do modelo é $R^2 = 60\%$, o erro quadrático médio (EQM) é 36, o tamanho da amostra é 106 e o modelo inclui quatro variáveis explicativas ($k = 4$), além do intercepto.

A relação entre o coeficiente de determinação e as somas dos quadrados é dada por:

$$R^2 = 1 - \frac{SQR}{SQT}$$

O erro quadrático médio (EQM) é definido como:

$$EQM = \frac{SQR}{n - k - 1}$$

Neste caso, temos $n = 106$ e $k = 4$, então os graus de liberdade dos resíduos são:

$$n - k - 1 = 106 - 4 - 1 = 101$$

Substituindo na fórmula do EQM, encontramos:

$$SQR = EQM \times (n - k - 1) = 36 \times 101 = 3636$$

Agora usamos a fórmula do R^2 para encontrar a soma total dos quadrados (SQT):

$$0,6 = 1 - \frac{3636}{SQT} \Rightarrow \frac{3636}{SQT} = 0,4 \Rightarrow SQT = \frac{3636}{0,4} = 9090$$

A variância amostral de Y é calculada dividindo a soma total dos quadrados pelos graus de liberdade totais, que são $n - 1 = 105$:

$$s_Y^2 = \frac{SQT}{n - 1} = \frac{9090}{105} \cong 86,57$$

Como a variância amostral de Y é aproximadamente 86,57, concluímos que ela é de fato superior a 85.

Gabarito: Certo.

3. (CEBRASPE/FUNPRES-P-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05



X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1 , X^2 , X^3 e X^4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O valor do R^2 ajustado (R^2_{ajustado}) é superior a 60%.

Comentários:

Vamos resolver a questão verificando se o valor do R^2 ajustado é superior a 60%, sabendo que o coeficiente de determinação do modelo é $R^2 = 60\%$, o erro quadrático médio (EQM) é 36, o tamanho da amostra é 106 e o modelo inclui quatro variáveis explicativas ($k = 4$), além do intercepto.

A fórmula do R^2_{ajustado} é:

$$R^2_{\text{ajustado}} = 1 - (1 - R^2) \times \left(\frac{n - 1}{n - k - 1} \right)$$

Substituindo os valores na fórmula:

$$R^2_{\text{ajustado}} = 1 - (1 - 0,6) \times \left(\frac{106 - 1}{106 - 4 - 1} \right)$$

$$R^2_{\text{ajustado}} = 1 - (0,4) \times \left(\frac{105}{101} \right)$$

Convertendo para percentual:



$$R^2_{ajustado} \cong 58,42\%$$

Portanto, o R^2 ajustado é inferior a 60%.

Gabarito: Errado.

4. (CEBRASPE/FUNPRES-P-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1 , X^2 , X^3 e X^4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O coeficiente de explicação deverá aumentar se a variável X_2 for retirada do modelo.

Comentários:



O R^2 nunca aumenta quando se retira uma variável do modelo. Ele pode diminuir ou, no máximo, ficar igual (se a variável retirada for completamente irrelevante). Isso ocorre porque o R^2 é calculado com base na soma dos quadrados dos resíduos, ou seja, quanto menor o resíduo, maior o R^2 . Portanto, adicionar variáveis sempre oferece mais liberdade para o modelo ajustar os dados, enquanto a retirada de variáveis limita essa capacidade.

Gabarito: Errado.

5. (CEBRASPE/TRT 10ª Região/2025)

Fonte de Variação	Graus de Liberdade	Quadrado Médio	p-valor da razão F
regressão	2	14	0,002
erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O coeficiente de determinação do modelo é inferior a 80%.

Comentários:

Para resolver a questão, vamos utilizar os dados fornecidos na tabela ANOVA para calcular o coeficiente de determinação R^2 , e verificar se ele é realmente inferior a 80%, como afirma o item.

A tabela apresenta os quadrados médios e os graus de liberdade da regressão e do erro. Sabemos que a soma dos quadrados (SQ) pode ser obtida multiplicando o quadrado médio (QM) pelo respectivo grau de liberdade (GL). Assim, podemos calcular a soma dos quadrados da regressão como:

$$SQM = QMM \times GL_{Modelo} = 14 \times 2 = 28$$

A soma dos quadrados do erro é:

$$SQR = QMR \times GL_{Erro} = 1 \times 8 = 8$$

A soma total dos quadrados é a soma da regressão com o erro:

$$SQT = SQM + SQR = 28 + 8 = 36$$



Com isso, podemos calcular o coeficiente de determinação R^2 , que é a proporção da variância total explicada pelo modelo:

$$R^2 = \frac{SQM}{SQT} = \frac{28}{36} \cong 0,7778$$

Convertendo para percentual, temos que $R^2 = 77,78\%$, o que confirma que ele é inferior a 80%.

Gabarito: Certo.

6. (CEBRASPE/CAPES/2024) Um modelo de regressão linear entre uma variável aleatória (dependente) e uma variável não aleatória X (independente) é definido por

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

em que ε , denominado erro aleatório, é uma variável aleatória independente de X com média $E(\varepsilon) = 0$ e desvio padrão $Var(\varepsilon) = \sigma^2$. Um modelo de regressão linear é geralmente um modelo para a probabilidade condicional de Y em relação a X , denotada por $P(Y|X)$, e é chamado de simples se ε for uma variável aleatória gaussiana.

Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$

Pelo método dos mínimos quadrados, é possível obter estimadores $\widehat{\beta}_0$ e $\widehat{\beta}_1$ para os parâmetros β_0 e β_1 , definindo

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i$$

como o estimador para Y_i . Nesse contexto, são definidos os erros, denominados resíduos, como $\widehat{\varepsilon}_i = Y_i - \widehat{Y}_i$, e a soma dos quadrados dos resíduos

$$SQE = \sum_i \widehat{\varepsilon}_i^2,$$

a soma dos quadrados totais

$$SQT = \sum_i (Y_i - \bar{Y})^2$$

e a soma dos quadrados de regressão

$$SQR = \sum_i (\widehat{Y}_i - \bar{Y})^2,$$

com



$$\bar{Y} = \frac{\sum_i Y_i}{n}.$$

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição t de Student com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95:

$$P(-2,042 < T < 2,042) = 0,95.$$

Para um modelo de regressão que não seja simples, a soma dos resíduos não será nula.

Comentários:

Duas propriedades fundamentais do método dos mínimos quadrados ordinários (MQO), válidas tanto para o modelo de regressão linear simples quanto para o múltiplo, são:

- a soma dos quadrados dos resíduos é minimizada pelo ajuste do modelo;
- a soma dos resíduos é igual a zero, ou seja, $\sum_{i=1}^n \hat{\varepsilon}_i = 0$.

Essa segunda propriedade decorre diretamente das condições de primeira ordem do método de mínimos quadrados e se mantém independentemente de o modelo ter uma ou várias variáveis explicativas.

Dessa forma, a assertiva apresentada está incorreta, pois afirma que, em modelos que não sejam simples (isto é, modelos de regressão linear múltipla), a soma dos resíduos deixaria de ser. Mesmo em modelos com múltiplas variáveis, a soma dos resíduos estimados continua sendo igual a zero, desde que o modelo inclua um termo constante (intercepto).

Gabarito: Errado.

7. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.



Com base na situação hipotética apresentada, julgue os seguintes itens.

O valor da razão F do teste linear geral, cuja hipótese nula é $H_0: \beta_0 = \beta_1 = \beta_2 = 0$, é igual ou inferior a 10.

Comentários:

Sabemos que o quadrado médio dos erros é expresso por:

$$QMR = \frac{SQR}{n - p}$$

em que:

- SQR : soma dos quadrados dos resíduos/erros;
- n : número da amostra;
- p : parâmetro, número de variáveis explicativas ou independentes + um intercepto.

Substituindo os valores informados no enunciado, temos:

$$QMR = \frac{39}{81 - 3}$$

$$QMR = \frac{39}{78}$$

$$QMR = 0,5$$

Agora, vamos calcular o quadrado médio da regressão:

$$QMM = \frac{SQM}{p - 1}$$

em que:

- QMM : quadrado médio da regressão;
- SQM : soma dos quadrados do modelo de regressão;
- p : parâmetro, número de variáveis explicativas ou independentes + um intercepto.

Assim, substituindo os valores, temos que:

$$QMM = \frac{SQM}{p - 1}$$

$$QMM = \frac{281}{3 - 1}$$

$$QMM = \frac{281}{2}$$



$$QMM = 140,5$$

Agora, vamos calcular a estatística F, que é definida por:

$$F = \frac{QMM}{QMR}$$

$$F = \frac{140,5}{0,5}$$

$$F = 281$$

Portanto, a estatística F não é inferior a 10.

Gabarito: Errado.

8. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

A correlação linear entre y e x_1 é superior a 0,95.

Comentários:

O coeficiente de determinação é determinado por meio da seguinte expressão:

$$R^2 = \frac{SQM}{SQT}$$

$$R^2 = \frac{281}{320} = 0,878$$

Portanto, a correlação é inferior a 0,95.

Gabarito: Errado.



9. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

O coeficiente de explicação ajustado é igual a 0,875.

Comentários:

O coeficiente ajustado possui a característica de penalizar a inclusão de variáveis sem poder explicativo, fazendo seu valor diminuir. Assim, ao adicionarmos uma variável independente com baixo poder explicativo, haverá uma redução no valor do R^2 ajustado, o que não ocorre no R^2 simples.

O coeficiente de determinação ajustado pelos graus de liberdade é expresso por:

$$\overline{R^2} = 1 - \frac{SQR/(n-2)}{SQT/(n-1)}$$

$$\overline{R^2} = 1 - \frac{39/(81-2)}{320/(81-1)}$$

$$\overline{R^2} = 1 - \frac{39/79}{320/80}$$

$$\overline{R^2} = 1 - \frac{39}{79} \times \frac{80}{320}$$

$$\overline{R^2} = 1 - 0,125$$

$$\overline{R^2} = 0,875$$

Gabarito: Certo.



10. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

A estimativa de σ é igual ou superior a 1.

Comentários:

Sabemos que o quadrado médio dos erros é expresso por:

$$QMR = \frac{SQR}{n - p}$$

em que:

- SQR : soma dos quadrados dos resíduos/erros;
- n : é o tamanho da amostra;
- p : é o número de variáveis explicativas ou independentes + um intercepto.

Substituindo os valores informados no enunciado, temos:

$$QMR = \frac{39}{81 - 3}$$

$$QMR = \frac{39}{78}$$

$$QMR = 0,5$$

Gabarito: Errado.

11. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
-------------------	--------------------



Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

O desvio padrão amostral da variável resposta é igual a 2.

Comentários:

O desvio padrão amostral é dado por:

$$s_y = \sqrt{\frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n - 1}}$$

Sabemos que $SQT = \sum_{i=1}^n (Y_i - \bar{Y})^2$, portanto, temos que:

$$s_y = \sqrt{\frac{320}{81 - 1}}$$

$$s_y = \sqrt{\frac{320}{80}}$$

$$s_y = \sqrt{4} = 2$$

Gabarito: Certo.

12. (Instituto Consulplan/TJ-MA/2024) Determinado Ministério Público Estadual coletou dados nas 53 comarcas do Estado com o intuito de estudar a relação entre o tempo médio (Y), em dias, gasto na triagem inicial de denúncias de abuso recebidas pela comarca e duas variáveis explicativas: o número de servidores lotados no setor responsável por avaliar as denúncias na comarca (X_1); e o número de municípios atendidos pela comarca (X_2). Considere o ajuste do modelo de regressão linear múltipla $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i$, onde $i = 1, \dots, 53$ e $\varepsilon_1, \dots, \varepsilon_{53}$ são erros independentes com $\varepsilon_i \sim N(0, \sigma^2)$ para todo i . Os seguintes resultados foram obtidos pelo método de máxima verossimilhança: $\hat{\beta}_0 = 21,5$, $\hat{\beta}_1 = -2,8$ e $\hat{\beta}_2 = 3,5$. Adicionalmente, tem-se que $SQ_{Regressão} = 346,5$ e $SQ_{Resíduos} = 185,5$. Com base nessas informações, é correto afirmar que:



- a) O estimador de máxima verossimilhança para σ^2 será igual a 3,5.
- b) O modelo ajustado é capaz de explicar mais de 70% da variabilidade de Y .
- c) Os valores estimados para β_0 , β_1 e β_2 seriam diferentes se o método de mínimos quadrados fosse utilizado.
- d) Se em vez de X_1 e X_2 o ajuste considerasse as variáveis explicativas $Z_{1i} = X_{1i} - \bar{X}_1$ e $Z_{2i} = X_{2i} - \bar{X}_2$, onde $\bar{X}_1$ e $\bar{X}_2$ representam as médias amostrais de X_1 e X_2 , respectivamente, os valores estimados para β_1 e β_2 seriam diferentes.

Comentários:

Para analisar a questão, vamos utilizar os dados fornecidos. O modelo de regressão linear múltipla ajustado é:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \epsilon_i$$

com $\epsilon_i \sim N(0, \sigma^2)$ e foram obtidos os seguintes resultados:

$$\widehat{\beta}_0 = 21,5, \widehat{\beta}_1 = -2,8, \widehat{\beta}_2 = 3,5$$

$$SQ_{Regressão} = 346,5$$

$$SQ_{Resíduos} = 185,5$$

Para determinar o coeficiente de determinação (R^2), que indica a proporção da variabilidade de Y explicada pelo modelo, usamos a fórmula:

$$R^2 = \frac{SQ_{Regressão}}{SQ_{Total}}$$

Onde:

$$SQ_{Total} = SQ_{Regressão} + SQ_{Resíduos}$$

$$SQ_{Total} = 346,5 + 185,5 = 532$$

Portanto:

$$R^2 = \frac{346,5}{532} \cong 0,6513$$

Ou seja, $R^2 \cong 0,6513$, o que significa que aproximadamente 65,13% da variabilidade de Y é explicada pelo modelo ajustado.

Alternativa A: **Correta**. O estimador de máxima verossimilhança para σ^2 seria igual a 3,5.

Para calcular o estimador de máxima verossimilhança de σ^2 , usamos a relação:



$$\widehat{\sigma^2} = \frac{SQ_{Resíduos}}{n}$$

em que n é o número de observações. Como $n = 53$, temos que:

$$\widehat{\sigma^2} = \frac{185,5}{53} = 3,50$$

Portanto, a afirmativa A está correta.

Alternativa B: **Incorreta**. O modelo ajustado é capaz de explicar mais de 70% da variabilidade de YYY .

O R^2 calculado foi de aproximadamente 65,13%, portanto, menor que 70%.

Alternativa C: **Incorreta**. Os valores estimados para β_0 , β_1 e β_2 seriam diferentes se o método de mínimos quadrados fosse utilizado.

Os valores estimados para os coeficientes β_0 , β_1 e β_2 são os mesmos independentemente do método de estimação utilizado, desde que os erros tenham variância constante e sejam normalmente distribuídos. A máxima verossimilhança e os mínimos quadrados ordinários produzem os mesmos estimadores para os coeficientes.

Alternativa D: **Incorreta**. Se em vez de X_1 e X_2 o ajuste considerasse as variáveis explicativas $Z_{1i} = X_{1i} - \bar{X}_1$ e $Z_{2i} = X_{2i} - \bar{X}_2$, onde $\bar{X}_1$ e $\bar{X}_2$ representam as médias amostrais de X_1 e X_2 , respectivamente, os valores estimados para β_1 e β_2 seriam diferentes.

Se as variáveis X_1 e X_2 são centralizadas (subtraídas de suas respectivas médias), os coeficientes β_1 e β_2 não mudam. O que muda é apenas a interpretação do intercepto β_0 , que passará a incorporar as médias de X_1 e X_2 . Vejamos:

$$Y_i = \beta_0 + \beta_1(X_{1i} - \bar{X}_1) + \beta_2(X_{2i} - \bar{X}_2) + \varepsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_{1i} - \beta_1 \bar{X}_1 + \beta_2 X_{2i} - \beta_2 \bar{X}_2 + \varepsilon_i$$

$$Y_i = \underbrace{(\beta_0 - \beta_1 \bar{X}_1 - \beta_2 \bar{X}_2)}_{\text{novo intercepto}} + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i$$

Gabarito: A.

13. (FGV/TJ-AP/2024) Para testar a significância de um conjunto de parâmetros do modelo de regressão linear múltipla, deve-se utilizar o seguinte teste estatístico:



- a) Friedman;
- b) Z da Normal;
- c) t de Student;
- d) F de Fisher-Snedecor;
- e) Qui-Quadrado de Pearson.

Comentários:

Para testar a significância de um conjunto de parâmetros (ou seja, testar a significância global do modelo) no contexto de regressão linear múltipla, devemos utilizar o teste estatístico F de Fisher-Snedecor.

O teste F é usado para testar a **significância conjunta** de um conjunto de variáveis independentes no modelo de regressão linear múltipla. Ele compara a variabilidade explicada pelo modelo (variabilidade ajustada) com a variabilidade não explicada (variabilidade residual).

Se a relação entre esses dois tipos de variabilidade for estatisticamente significativa, isso sugere que pelo menos uma das variáveis independentes tem um efeito significativo sobre a variável dependente.

Gabarito: D.

14. (FGV/TJ-MS/2024) Em um modelo de regressão linear múltipla, onde há uma variável dependente Y e k variáveis independentes X, o estimador não viesado para a variância do modelo com n observações é dado por:

Obs. O chapéu em $\hat{Y}_i$ indica valor estimado e o traço em $\bar{Y}_i$ indica a média.

a) $\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}{(n-k-1)}$

b) $\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}{(n-k)}$

c) $\frac{\sum_{i=1}^n (Y_i - \bar{Y}_i)^2}{(n-k-1)}$

d) $\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{(n-k-1)}$

e) $\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{(n-k)}$



Comentários:

Em um modelo de regressão linear múltipla, onde há uma variável dependente Y e k variáveis independentes X , o estimador não viesado para a variância do modelo com n observações é dado por:

$$\sigma^2 = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{(n - k - 1)}$$

onde:

- σ^2 é o estimador não viesado da variância do modelo.
- n é o número de observações.
- k é o número de variáveis independentes.
- Y_i é o valor observado da variável dependente.
- $\hat{Y}_i$ é o valor predito da variável dependente.
- $(Y_i - \hat{Y}_i)^2$ são os resíduos ao quadrado, ou seja, os quadrados das diferenças entre os valores observados e os valores preditos da variável dependente.

Gabarito: D.

15. (FGV/TJ-MS/2024) Um pesquisador investiga a eficácia de três diferentes tratamentos para reduzir o colesterol no sangue. Ele divide aleatoriamente os pacientes em três grupos. Após um mês, realiza exames em cada paciente e deseja determinar se há diferença entre os tratamentos. A estatística de teste que deve ser usada para avaliar se há diferença significativa entre os tratamentos é:

- a) teste ANOVA (análise de variância);
- b) teste de Kruskal-Wallis;
- c) teste de Qui-Quadrado;
- d) teste t de Student;
- e) teste de Wilcoxon-Mann-Whitney.

Comentários:

Vamos analisar cada alternativa:



Alternativa A: **Correta**. O teste ANOVA é usado para comparar as médias de três ou mais grupos para ver se pelo menos uma média é diferente das outras. Como o pesquisador está comparando três grupos, o teste ANOVA é apropriado.

Alternativa B: **Incorreta**. O teste de Kruskal-Wallis é um teste não paramétrico usado para comparar três ou mais grupos independentes quando os pressupostos do ANOVA não são atendidos, especialmente quando os dados não são normalmente distribuídos.

Alternativa C: **Incorreta**. O teste de Qui-Quadrado é usado para analisar associações entre variáveis categóricas, não para comparar médias de grupos.

Alternativa D: **Incorreta**. O teste t de Student é usado para comparar as médias de dois grupos, não três ou mais.

Alternativa E: **Incorreta**. O teste de Wilcoxon-Mann-Whitney é um teste não paramétrico usado para comparar duas amostras independentes, não três ou mais.

Gabarito: A.

16. (Instituto Verbena/TJ-AC/2024) Considere um modelo de regressão linear múltipla dado por $Y = X\beta + \varepsilon$, em que Y é um vetor de dimensão $n \times 1$, X tem dimensão $n \times p$, com as colunas linearmente independentes, β é desconhecido com dimensão $p \times 1$ e o valor esperado de ε é igual a 0. A estimativa de mínimos quadrados para β é dada por

a) $(X'Y)^{-1}X'Y$.

b) $(Y'X)^{-1}X'Y$.

c) $(X'X)^{-1}X'Y$.

d) $(Y'Y)^{-1}X'Y$.

Comentários:

A estimativa de mínimos quadrados para o vetor de coeficientes β em um modelo de regressão linear múltipla é dada por:

$$\beta = (X^T X)^{-1} X^T Y$$

Portanto, a alternativa C está correta.

Gabarito: C.



17. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

O grau de explicação do modelo é superior a 90%.

Comentários:

O grau de explicação é o mesmo coeficiente de determinação, ele mede a qualidade do ajuste proporcionado pela reta de regressão, determinando a parcela da variação total de Y que é explicada pelo modelo de regressão. O grau de explicação pode ser calculado pela fórmula:

$$R^2 = \frac{SQM}{SQT}$$

em que SQM é a soma dos quadrados do modelo de regressão e SQT é a soma dos quadrados totais.

Observando a tabela, verificamos que o valor dos quadrados médios do modelo (QM) é 321,4. Ele é determinado pela soma dos quadrados do modelo (SQM) dividido pelo grau de liberdade. Então, temos:

$$QM = \frac{SQM}{GL} \Rightarrow 321,4 = \frac{SQM}{1} \Rightarrow SQM = 321,4$$

Para a soma de quadrados totais SQT, temos que:

$$SQT = SQM + SQR$$

$$SQT = 321,4 + 50,8$$



$$SQT = 372,2$$

Agora, podemos calcular o valor de R^2 :

$$R^2 = \frac{321,4}{372,2}$$

$$R^2 \cong 0,8635 \Rightarrow 86,35\%$$

Portanto, é inferior a 90%.

Gabarito: Errado.

18. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

O parâmetro estimado para X é menor que 2.

Comentários:

O enunciado nos forneceu o valor da variância $Var(X) = 2,35$, que pode ser expressa na forma:

$$\sigma^2 = \overline{x^2} - (\bar{x})^2$$

em que $\overline{x^2}$ é a média dos quadrados; e $(\bar{x})^2$ é o quadrado da média.

A questão também forneceu o valor dos quadrados médios do modelo. Substituindo na fórmula, encontraremos o valor da média:



$$\begin{aligned}\sigma^2 &= \overline{x^2} - (\bar{x})^2 \\ 2,35 &= 321,4 - (\bar{x})^2 \\ (\bar{x})^2 &= 321,4 - 2,35 \\ (\bar{x})^2 &= 319,05 \\ \bar{x} &= \sqrt{319,05} \\ \bar{x} &\cong 17,86\end{aligned}$$

Portanto, o parâmetro estimado para x é **maior** que 2.

Gabarito: Errado.

19. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

No estudo, foram utilizados 30 dados.

Comentários:

O número de graus de liberdade total é:

$$GL_{Total} = n - 1$$

Ora, se o grau de liberdade total é 29, então:

$$GL_{Total} = 30 - 1 = 29$$



Logo, o tamanho da amostra é $n = 30$. Portanto, foram utilizados 30 dados no estudo.

Gabarito: Certo.

20. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

Caso fosse adicionada mais uma variável ao modelo, então, necessariamente o grau de ajuste do modelo aumentaria.

Comentários:

Normalmente, para avaliar a qualidade do ajuste da regressão, usamos o coeficiente de determinação:

$$R^2 = \frac{SQM}{SQT}$$

A análise desse coeficiente sugere que quanto mais próximo de 1 estiver o coeficiente de determinação, mais forte será a correlação entre as variáveis. Implica dizer que grande parte da variação de Y é explicada pelo modelo de regressão linear. Por outro lado, quanto mais próximo de 0 estiver o coeficiente de determinação, mais fraca será a correlação linear entre as variáveis. Significa dizer que grande parte da variação de Y não é explicada pelo modelo de regressão.



O coeficiente de determinação R^2 geralmente aumenta quando uma nova variável explicativa é adicionada ao modelo de regressão. Portanto, quanto mais parâmetros nosso modelo de regressão tiver, maior será o nosso coeficiente de determinação, implicando em uma menor qualidade do ajuste. Por isso, não é interessante usarmos o coeficiente de determinação quando estamos tratando de regressão múltipla, já que queremos um modelo ótimo com o menor número de parâmetros. Para resolver esse problema, usamos o coeficiente de determinação ajustado:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$

Gabarito: Errado.

21. (FCC/TRT 18ª Região/2023) Um conjunto de dados amostrais foram ajustados a um modelo de regressão linear múltipla da forma $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + e_i$. Todos os pressupostos necessários para a validade do modelo foram verificados e atendidos. β_0 , β_1 , β_2 e β_3 são parâmetros desconhecidos e e_i corresponde ao erro aleatório da i -ésima observação com distribuição $N(0, \sigma^2)$. Uma amostra de 24 observações forneceu um coeficiente de determinação múltiplo, R^2 , igual a 0,8. Nesse caso, o coeficiente de determinação ajustado é igual a

- a) 0,77
- b) 0,90
- c) 0,67
- d) 0,52
- e) 0,44

Comentários:

O coeficiente de determinação corrigido pelos graus de liberdade é dado por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$

Em que n é o número de amostras e p é o número de parâmetros estimados. Substituindo os valores informados no enunciado, encontramos:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p)}$$

$$\overline{R^2} = 1 - (1 - 0,8) \times \frac{(24 - 1)}{(24 - 4)}$$



$$\overline{R^2} = 1 - 0,2 \times \frac{23}{20}$$

$$\overline{R^2} = 1 - 0,2 \times 1,15$$

$$\overline{R^2} = 1 - 0,23$$

$$\overline{R^2} = 0,77$$

Gabarito: A.

22. (FGV/BANESTES/2023) Ao adotar um modelo de Regressão Linear Múltipla para expressar matematicamente a forma como determinada variável resposta depende de um conjunto de variáveis explicativas, constatou-se que a complexidade do modelo adotado era alta demais, tendo em vista o número de observações disponíveis.

Neste caso, temos um fenômeno de

- a) multicolinearidade.
- b) sobreajuste (*overfitting*)
- c) presença de observações discrepantes (*outliers* ou pontos de alavanca).
- d) não normalidade do erro aleatório.
- e) autocorrelação do erro aleatório.

Comentários:

Ocorrendo o fenômeno de sobreajuste (*overfitting*), o modelo estimado será capaz de explicar “perfeitamente” a variável de resposta. Isso ocorre, com frequência, em modelos muito complexos, isto é, quando muitas variáveis explicativas são consideradas. A tendência é que modelos sobreajustados errem bastante para a previsão de dados futuros (não observados).

Gabarito: B.

23. (FGV/BANESTES/2023) No contexto de Regressão Linear Múltipla, se o termo referente ao erro aleatório segue uma distribuição de probabilidade específica, pode ser provado que os estimadores de máxima verossimilhança dos coeficientes do modelo coincidem com os respectivos estimadores de mínimos quadrados.

Assinale a opção que apresenta essa distribuição.

- a) Normal.



- b) Exponencial.
- c) Uniforme.
- d) Gama.
- e) Beta.

Comentários:

Assim como no caso da regressão linear simples, os estimadores de mínimos quadrados são lineares, não viesados e têm variância mínima na classe de estimadores lineares. Além disso, os estimadores de mínimos quadrados dos parâmetros do modelo de regressão linear múltipla são equivalentes aos estimadores de máxima verossimilhança, sob a suposição de **normalidade dos erros**. Logo, a distribuição de probabilidade do erro aleatório deveria ser a normal (letra A). A banca, entretanto, considerou erroneamente como gabarito a letra E.

Gabarito: E.

24. (CESPE/PETROBRAS/2022)

Equação 1: $y_i = a + bX_i + e$

Equação 2: $y_i = a + b_1X_i + b_2X_2 + b_3X_3 + e$

Com base nos modelos de regressão linear simples (equação 1) e de regressão linear múltipla (equação 2), julgue o item a seguir.

A homoscedasticidade, conceito que implica que o erro não-observável “e” de uma regressão múltipla seja constante, é uma das condições para que os coeficientes b_1 , b_2 e b_3 da equação 2 sejam não-viesados e consistentes.

Comentários:

A homoscedasticidade é a propriedade da regressão linear múltipla segundo a qual a variância do erro é constante. Significa dizer que a homoscedasticidade somente é possível quando o erro tem variância constante, independentemente do valor de X. Contudo, a homoscedasticidade não é condição para que os coeficientes sejam não-viesados e consistentes, assim os estimadores de mínimos quadrados apresentam o valor esperado igual ao valor do parâmetro estimado.

Gabarito: Errado.



25. (CESPE/TELEBRAS/2022) Considerando que $\hat{y}_k$ denote o valor ajustado - pelo método de mínimos quadrados ordinários - da variável resposta y_k de um modelo de regressão linear múltipla na forma $y_k = \beta_0 + \beta_1 x_{1,k} + \beta_2 x_{2,k} + \epsilon_k$ que, nesse modelo, $\{\epsilon_1, \dots, \epsilon_{10}\}$ seja um conjunto de erros aleatórios independentes com médias iguais a zero e variâncias iguais a σ^2 ; e que cada resíduo produzido pelo ajuste seja escrito como $r_k = y_k - \hat{y}_k$, julgue o próximo item.

Os valores da sequência $r_1, \dots, r_{10}$ são mutuamente independentes.

Comentários:

Segundo o enunciado, a sequência $r_1, \dots, r_{10}$ é composta por todos os resíduos do modelo, os quais podem ser determinados por $r_k = y_k - \hat{y}_k$. Nos modelos com intercepto, isto é, quando o modelo de regressão não passa pela origem, o método dos mínimos quadrados requer que a soma de todos os resíduos seja igual a zero: $\sum_{i=1}^{10} r_k = 0$. Logo, os resíduos não são mutuamente independentes.

Gabarito: Errado.

26. (CESPE/TCE-SC/2022) Em artigo publicado em 2004 no Journal of Political Economy, E. Miguel, S. Satyanath e E. Sergenti mostraram o efeito que o crescimento econômico pode ter na ocorrência de conflitos civis, com dados de 41 países africanos, no período de 1981 até 1999. Em certo estágio da pesquisa, para verificar a possibilidade de usar dados sobre precipitação pluviométrica como variável instrumental, foi feita uma regressão entre o crescimento de tais precipitações (variável explicativa) e uma variável resposta que representa um indicador para a ocorrência de conflito: quanto maior for esse indicador, maior a possibilidade de conflitos no ano t no país i . Os resultados do modelo ajustado pelo método de mínimos quadrados ordinários se encontram na tabela a seguir.

Variável Explicativa	Variável Dependente	
	Conflito civil (mínimo de 25 mortos)	Conflito civil (mínimo de 1000 mortos)
Crescimento na precipitação em t	-0,024 (0,043)	-0,062 (0,030)



Crescimento na precipitação em $t-1$	-0,122 (0,052)	-0,069 (0,032)
Efeitos fixos	sim	sim
R^2	0,71	0,70
Observações	743	743

Internet: <<https://doi.org/10.1086/421174>> (com adaptações).

Os números entre parênteses na tabela apresentada indicam o erro padrão da estimativa dos coeficientes respectivos. Considere os valores críticos t_α da variável t de Student, com significância α para os graus de liberdades adequados aos dados apresentados, como sendo $t_{10\%} = 1,65$, $t_{5\%} = 1,96$ e $t_{1\%} = 2,58$. Considerando as informações precedentes, julgue o próximo item.

Os erros padrões abaixo de 0,05 mostram que o crescimento na precipitação no período t tem efeito significativo, com 95% de confiança, sobre a ocorrência de conflito civil com mínimo de 25 mortos na primeira regressão.

Comentários:

Na primeira regressão, conflito civil com mínimo de 25 mortos, o crescimento na precipitação em t foi de $-0,024$, com erro padrão de $(0,043)$. A estatística t do teste é determinada pela razão entre o valor estimado $(-0,024)$ e o erro padrão $(0,043)$. Assim, temos:

$$t = \frac{-0,024}{0,043} = -0,56$$

Segundo a assertiva, os erros padrões abaixo de 0,05 mostram que o crescimento na precipitação no período t tem efeito significativo, com 95% de confiança, sobre a ocorrência de conflito civil com mínimo de 25 mortos. Como $t_{5\%} = 1,96$, a estatística t , em valor absoluto, é inferior ao valor limite: $|-0,56| < 1,96$. Portanto, a variável apresentada não tem efeito significativo sobre a situação considerada.

Gabarito: Errado.

27. (CESPE/TELEBRAS/2022) Considerando que $\hat{y}_k$ denote o valor ajustado - pelo método de mínimos quadrados ordinários - da variável resposta y_k de um modelo de regressão linear múltipla na forma $y_k = \beta_0 + \beta_1 x_{1,k} + \beta_2 x_{2,k} + \epsilon_k$ que, nesse modelo, $\{\epsilon_1, \dots, \epsilon_{10}\}$ seja um conjunto de erros



aleatórios independentes com médias iguais a zero e variâncias iguais a σ^2 ; e que cada resíduo produzido pelo ajuste seja escrito como $r_k = y_k - \hat{y}_k$, julgue o próximo item.

A razão $\frac{r_k}{\hat{y}_k}$ é denominada resíduo padronizado.

Comentários:

O desvio padronizado é definido como a razão entre o resíduo e o desvio padrão do resíduo:

$$\frac{r_k}{s_{r_k}}$$

Portanto, a afirmativa está errada.

Gabarito: Errado.

28. (FCC/TRT 23ª Região/2022) Deseja-se obter um modelo de regressão para estimar y a partir das variáveis independentes X_1 e X_2 . Com esse objetivo, foram obtidas 5 observações conforme o quadro a seguir:

Y_i	X_{i1}	X_{i2}
1	1	1
3	2	3
2	3	2
1	1	2
3	2	1

Considere o modelo de regressão múltipla $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + e_i$ onde $e_i \sim N(0, \sigma^2)$, atendendo todas as premissas necessárias para o modelo e os dados:

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 2 \\ 1 & 1 & 2 \\ 1 & 2 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} 1 \\ 3 \\ 2 \\ 1 \\ 3 \end{bmatrix} \quad (x^t x)^{-1} x^t y = \begin{bmatrix} 1/2 \\ 2/3 \\ 1/6 \end{bmatrix}$$

onde x^t é a transposta de X . Então, é correto afirmar que

a) a soma dos parâmetros estimados para o modelo é $4/3$.



- b) o valor estimado do intercepto é igual a zero.
- c) o valor estimado para y quando $x_1 = x_2 = 6$ é igual a 3.
- d) o valor estimado para y quando $x_1 = x_2 = 0$ é igual a 0.
- e) o valor estimado para o parâmetro β_1 é igual a $1/6$.

Comentários:

Pelo método dos mínimos quadrados ordinários (MQO), podemos demonstrar que o estimador de $\hat{\beta}$ é expresso por:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

em que X^T é a transposta da matriz X ; e $(X^T X)^{-1}$ é a inversa da matriz $X^T X$.

O enunciado forneceu o valor de $(X^T X)^{-1} X^T y$, portanto, já temos as estimativas dos parâmetros do modelo. Dessa forma, nosso modelo de regressão múltipla será:

$$y_i = (1/2) + (2/3)x_{i1} + (1/6)x_{i2}$$

Sabendo disso, podemos analisar as alternativas propostas:

Alternativa A: **Correta**. A soma dos parâmetros do modelo é $1/2 + 2/3 + 1/6 = 8/6 = 4/3$.

Alternativa B: **Incorreta**. O valor estimado do intercepto é igual a $1/2$.

Alternativa C: **Incorreta**. O valor estimado para y quando $x_1 = x_2 = 6$ é igual a 5,5.

Alternativa D: **Incorreta**. O valor estimado para y quando $x_1 = x_2 = 0$ é igual a 0,5.

Alternativa E: **Incorreta**. O valor estimado para o parâmetro β_1 é igual a $2/3$.

Gabarito: A.

29. (VUNESP/EsFCEX/2020) Um estudo analisa a viscosidade Y de um polímero em função de duas variáveis de processo: temperatura (X_1) e taxa de alimentação do catalizador (X_2). Foram realizados 9 ensaios (amostra de tamanho 9). Após ajustar um modelo de regressão linear múltipla, a soma de quadrados total (ou soma de quadrados total corrigida pela média, conforme algumas bibliografias), SQT, foi igual a 30000; e a soma de quadrados dos erros, SQE, foi igual a 24000.

A esse respeito, assinale a alternativa correta.



Dado: $F(0,95; 2, 6) = 5,14$, onde $P\{X > F(0,95; 2, 6)\} = 0,05$, sendo X uma variável aleatória com distribuição F de graus de liberdade 2 e 6.

- a) O teste de significância do modelo conclui que pelo menos uma das variáveis independentes é significativa ao nível de significância de 0,05.
- b) O resultado do teste mostra que a temperatura e a taxa de alimentação do catalizador relacionam linearmente com a viscosidade na região experimental.
- c) O resultado do teste mostra que ambas as variáveis independentes são significantes ao nível de significância de 0,05.
- d) Os resultados apresentados mostram que, com o conhecimento das duas variáveis independentes, estima-se melhor o valor esperado da viscosidade do que se usar apenas uma variável, ao nível de significância de 0,05.
- e) Considerando nível de significância de 0,05, o teste de significância do modelo aceita a hipótese nula de que os coeficientes de X_1 e X_2 são nulos.

Comentários:

Conforme o enunciado, temos o seguinte teste de hipóteses:

$$H_0: \beta_1 = \beta_2 = 0$$

$$H_0: \beta_j \neq 0, \quad \text{para } j = 1, 2$$

Temos pelo menos uma variável explicativa se a hipótese nula H_0 for rejeitada. Para o teste, vamos considerar a estatística F :

$$F = \frac{QMR}{QME}$$

O quadrado médio da regressão é dado por:

$$QMR = \frac{SQM}{p - 1}$$

$$QMR = \frac{30000 - 24000}{2}$$

$$QMR = \frac{6000}{2}$$

$$QMR = 3000$$

O quadrado médio dos erros/resíduos é dado por:

$$QME = \frac{SQR}{n - p}$$



$$QME = \frac{24000}{6}$$

$$QME = 4000$$

Aplicando a estatística F:

$$F = \frac{QMR}{QME}$$

$$F = \frac{3000}{4000}$$

$$F = 0,75$$

Como a estatística F observada é menor que o valor F tabelado $F(0,95; 2,6) = 5,14$, então aceitamos a hipótese nula, ou seja, os coeficientes de X_1 e X_2 são não significantes (são nulos).

Gabarito: E.

30. (VUNESP/Pref. Campinas/2019) Para um estudo com o objetivo de previsão, optou-se pela utilização do modelo de regressão linear múltipla $Y_i = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i, i = 1, 2, \dots, n$.

Tem-se que:

I. Y é a variável dependente,

II. $X_1, X_2, \dots, X_k$ são as variáveis explicativas,

III. $\alpha, \beta_1, \beta_2, \dots, \beta_k$ são os parâmetros desconhecidos do modelo com as respectivas estimativas obtidas pelo método dos mínimos quadrados,

IV. u é o erro aleatório,

V. i corresponde a i -ésima observação, n é o número de observações e k o número de variáveis explicativas.

Se foi detectado neste modelo um problema de multicolinearidade, então

a) no modelo houve a omissão de variáveis explicativas relevantes.

b) a variância do termo erro não é constante para todos os valores da variável dependente.

c) duas ou mais variáveis explicativas são altamente correlacionadas.

d) o termo erro em um determinado período é positivamente correlacionado com o termo erro no período anterior.

e) no modelo houve inclusão de variáveis explicativas irrelevantes.



Comentários:

Se no modelo tivermos duas variáveis explicativas proporcionais, ou seja, altamente correlacionadas, então teremos **multicolinearidade**. Daí temos um problema no modelo de regressão já que a **multicolinearidade**, muitas vezes, torna as estimativas dos coeficientes dos parâmetros insignificantes. Desta forma, para os estimadores de MQO, a **multicolinearidade** gera um problema, causando erros grosseiros no resultado da regressão produzindo erros bastante relevantes na previsão da variável dependente.

Gabarito: C.

31. (FCC/TRT 14ª Região/2018) Uma amostra aleatória constituída de 20 ternos de observações (X_i, Y_i, Z_i) , $i = 1, 2, 3, \dots, 20$ permitiu obter, por meio do método dos mínimos quadrados, as estimativas dos parâmetros desconhecidos α, β e γ do modelo de regressão linear múltipla $Z_i = \alpha + \beta X_i + \gamma Y_i + \varepsilon_i$ com i correspondendo a i -ésima observação. Sabe-se que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Para testar a existência da regressão de Z sobre as variáveis X e Y , considerou-se o respectivo quadro de análise de variância em que se obteve o valor de 44,625 para a estatística F_c (F calculado) utilizado para comparar com o F tabelado da distribuição F . Se a estimativa da variância σ^2 do modelo teórico foi igual a 8, então o coeficiente de determinação (R^2), definido como o sendo o resultado da divisão da variação explicada pela variação total é, em %, igual a

- a) 64.
- b) 78.
- c) 84.
- d) 80.
- e) 82.

Comentários:

A estatística F é definida por:

$$F = \frac{QMR}{QME}$$

e sabemos que:



$$QME = \frac{SQR}{n - p}$$

e que:

$$QMR = \frac{SQM}{p - 1}$$

em que:

QMR : quadrado médio da regressão;

$\sigma^2 = QME = 8$: quadrado médio dos erros/resíduos;

SQM : soma dos quadrados do modelo de regressão;

SQR : soma dos quadrados dos resíduos/erros;

$n = 20$: número da amostra;

$p = 3$: parâmetro, número de variáveis explicativas ou independentes + um intercepto.

Assim, substituindo os valores, temos que:

$$\sigma^2 = QME = \frac{SQR}{n - p}$$

$$\sigma^2 = QME = \frac{SQR}{20 - 3}$$

$$SQR = 17 \times 8$$

$$SQR = 136$$

Aplicando $F_c = 44,625$:

$$44,625 = \frac{QMR}{QME}$$

$$44,625 = \frac{\frac{SQM}{2}}{8}$$

$$44,625 \times 8 = \frac{SQM}{2}$$

$$SQM = 357 \times 2$$

$$SQM = 714$$

Agora, vamos calcular o coeficiente de determinação:



$$R^2 = \frac{SQM}{SQT}$$

$$R^2 = \frac{SQM}{SQM + SQR}$$

$$R^2 = \frac{714}{714 + 136}$$

$$R^2 = \frac{714}{850}$$

$$R^2 = 0,84 = 84\%$$

Gabarito: C.

32. (FGV/MPE BA/2017) Em um modelo de regressão linear múltipla, após a estimação dos parâmetros, realizou-se uma Análise da Variância, através da decomposição amostral. Os dados foram impressos, mas depois foram em parte perdidos, restando apenas a tabela a seguir, com diversas lacunas:

Fonte	Soma dos Quadrados	G.L.	Q. Médio	F-Snedecor	P-valor
Equação	400	X	100	W	0,0035
Resíduos	R	Y	Z		
Total	640	28			

Com os dados acima é possível concluir que:

- a) a variância estimada dos erros é menor do que 3;
- b) $X = 4$, $Y = 24$, $Z = 8$ e $W = 12,5$;
- c) a amostra empregada é de tamanho $n = 29$ e a regressão é não significativa ao nível de 1%;
- d) o modelo de regressão explica 62,5 da variação da variável explicativa;
- e) $X = 4$, $Y = 24$, $Z = 10$ e $W = 10$.

Comentários:

Para resolvermos a questão, precisamos preencher as lacunas da tabela. Vamos começar com o valor de R:

$$SQT = SQM + SQR$$



$$640 = 400 + SQR$$

$$SQR = 640 - 400$$

$$R = SQR = 240$$

Para encontrarmos o valor X, temos que fazer:

$$QMR = \frac{SQM}{\underbrace{p-1}_{GL \text{ da equação}}}$$

$$100 = \frac{400}{X}$$

$$X = 4$$

Para calcular o valor de Y, devemos proceder da seguinte forma:

$$gl_{total} = gl_{resíduos} + gl_{equação}$$

$$28 = Y + 4$$

$$Y = 28 - 4$$

$$Y = 24$$

Para o valor de Z, temos:

$$QME = \frac{SQR}{\underbrace{n-p}_{GL \text{ dos resíduos}}}$$

$$Z = \frac{240}{24}$$

$$Z = 10$$

Para o valor de W, temos:

$$F = \frac{QMR}{QME}$$

$$W = \frac{100}{10}$$

$$W = 10$$

Assim, temos que: $X = 4$, $Y = 24$, $Z = 10$ e $W = 10$.

Gabarito: E.

33. (FGV/IBGE/2016) Após estimar um modelo de regressão linear múltipla, por MQO, um economista repara que, por algum motivo, a tabela contendo os resultados da análise da variância ficou incompleta, conforme abaixo:



Fonte	Soma dos Quadrados	G. Liberdade	Q. Médio	F-Snedecor	P-valor
Equação	1800	5	360	4.5	1.05%
Resíduos	Y	X	W		
Modelo	3000	20	Z		

Apesar dos valores acima omitidos, é correto afirmar que:

- a) a equação de regressão tem cinco variáveis explicativas;
- b) o coeficiente de determinação R^2 é igual a 0,8;
- c) ao nível de significância de 2% não se rejeita a hipótese nula de que o modelo explica a variável dependente;
- d) o tamanho da amostra é $n = 20$;
- e) a estimativa não tendenciosa da variância dos erros aleatórios do modelo $\hat{\sigma}_e^2$ é igual a 80.

Comentários:

Vamos analisar as alternativas:

Letra A: **Correta**. Observando a tabela percebemos que existem 5 graus de liberdade para o modelo/equação. O grau de liberdade do modelo/equação é obtido da seguinte forma:

$$\begin{aligned}
 p - 1 &= 5 \\
 p &= 5 + 1 \\
 \underset{\text{parâmetro}}{p} &= 6
 \end{aligned}$$

em que p corresponde ao número de variáveis explicativas ou independentes + um intercepto. Portanto, se p vale 6, temos 5 variáveis explicativas e mais 1 intercepto.

Letra B: **Errada**.

O coeficiente de determinação é expresso por:

$$\begin{aligned}
 R^2 &= \frac{SQM}{SQT} \\
 R^2 &= \frac{1800}{3000} = 0,6
 \end{aligned}$$



Letra C: **Errada.**

Rejeitamos a hipótese nula quando o p-valor é menor que o nível de significância. No presente caso, o p-valor vale 1,05%, portanto, é menor que o nível de significância, de 2%.

Letra D: **Errada.**

O número de graus de liberdade total é 20. Portanto, temos que:

$$n - 1 = 20$$

$$n = 20 + 1$$

Assim, concluímos que:

$$n = 21$$

Letra E: **Correta.**

$$\sigma^2 = QME = \frac{SQR}{n - p}$$

$$\sigma^2 = QME = \frac{SQR}{X}$$

Vamos determinar X:

$$5 + X = 20$$

$$X = 20 - 5$$

$$X = 15$$

Calculando SQR:

$$SQR = 3000 - 1800$$

$$Y = 1200$$

Aplicando na fórmula, temos:

$$QME = \frac{SQR}{X}$$

$$W = \frac{Y}{X}$$

$$W = \frac{1200}{15}$$

$$W = 80$$



A banca definiu a letra E como gabarito oficial. Contudo, verificamos que existem duas alternativas corretas (A e E).

Gabarito: E.

34. (FCC/TRE-RR/2015) Um modelo de regressão linear múltipla, com intercepto, consiste em uma variável dependente, 4 variáveis explicativas e o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Com base em 21 observações e utilizando o método dos mínimos quadrados obtiveram-se as estimativas dos parâmetros deste modelo. Dado que a variação total foi igual a 100 e a estimativa da variância do modelo foi igual a 1,25, então o valor da estatística F (F calculado) utilizado para testar a existência da regressão, a um determinado nível de significância, foi igual a

- a) 16.
- b) 27.
- c) 24.
- d) 20.
- e) 18.

Comentários:

Em um modelo de regressão linear múltipla, a estatística F é por:

$$F = \frac{QMR}{QME}$$

em que:

$QMR = \frac{SQM}{p-1}$: quadrado médio da regressão;

$QME = \frac{SQR}{n-p}$: quadrado médio dos erros/resíduos;

SQR : soma dos quadrados dos resíduos/erros;

SQM : soma dos quadrados do modelo de regressão;

Os dados informados na questão foram os seguintes:

$n = 21$, tamanho da amostra;

$p = 5$, número de parâmetros, número de variáveis explicativas ou independentes + um intercepto;



$\sigma^2 = QME = 1,25$, quadrado médio dos erros/resíduos;

$SQT = 100$, soma dos quadrados totais.

Agora, vamos calcular a soma dos quadrados dos erros/resíduos:

$$\sigma^2 = QME = \frac{SQR}{n - p}$$

$$1,25 = \frac{SQR}{21 - 5}$$

$$SQR = 16 \times 1,25$$

$$SQR = 20$$

Na sequência, calculamos a soma dos quadrados do modelo de regressão (SQM):

$$SQT = SQM + SQR$$

$$100 = SQM + 20$$

$$SQM = 100 - 20$$

$$SQM = 80$$

O quadrado médio da regressão é dado por:

$$QMR = \frac{SQM}{p - 1}$$

$$QMR = \frac{80}{5 - 1}$$

$$QMR = 20$$

De posse desses dados, podemos aplicar a fórmula da estatística F:

$$F = \frac{QMR}{QME}$$

$$F = \frac{20}{1,25}$$

$$F = 16$$

Gabarito: A.

35. (FCC/TRT 3ª Região/2015) Um modelo regressivo linear múltiplo correspondente à equação $Z_i = \alpha + \beta X_i + \gamma Y_i + \epsilon_i (i = 1, 2, 3, \dots)$ foi construído para prever Z em função de X e Y. Os parâmetros α, β e γ são desconhecidos, ϵ_i corresponde ao erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla e i refere-se à i-ésima observação. Com base em



21 observações e utilizando o método dos mínimos quadrados obtiveram-se as estimativas de α , β e γ (a , b e c , respectivamente).

Dados: $\sum_{i=1}^{21} (Z_i - \bar{Z})^2 = 288$, $\sum_{i=1}^{21} (Z_i - \hat{Z}_i)^2 = 108$, em que $\hat{Z}_i = a + bX_i + cY_i$

Observação: $\bar{Z}$ é a média de todos os valores

$Z_i (i = 1, 2, 3, \dots, 21)$

O valor da estatística F (F calculado) que permite decidir por meio da comparação com o F tabelado sobre a existência da regressão é igual a

- a) 12.
- b) 18.
- c) 15.
- d) 24.
- e) 9.

Comentários:

Em um modelo de regressão linear múltipla, a estatística F é por:

$$F = \frac{QMR}{QME}$$

em que:

$QMR = \frac{SQM}{p-1}$: quadrado médio da regressão;

$QME = \frac{SQR}{n-p}$: quadrado médio dos erros/resíduos;

SQR : soma dos quadrados dos resíduos/erros;

SQM : soma dos quadrados do modelo de regressão;

Os dados informados na questão foram os seguintes:

$n = 21$, tamanho da amostra;

$p = 3 (\alpha, \beta, \gamma)$, número de parâmetros, número de variáveis explicativas ou independentes + um intercepto;

$SQT = 288$, soma dos quadrados totais;

$SQR = 108$, soma dos quadrados dos resíduos/erros.



Com esses dados, podemos calcular a soma dos quadrados do modelo da regressão (SQM):

$$288 = SQM + 108$$

$$SQM = 288 - 108$$

$$SQM = 180$$

Agora, vamos analisar os graus de liberdade. Os graus de liberdade de SQT são expressos por:

$$n - 1 = 21 - 1 = 20$$

O número de graus de liberdade de SQM:

$$p - 1 = 3 - 1 = 2$$

O número de graus de liberdade de SQR:

$$n - p = 21 - 3 = 18$$

Assim, o quadrado médio da regressão é dado por:

$$QMR = \frac{SQM}{p - 1}$$

$$QMR = \frac{180}{2}$$

$$QMR = 90$$

O quadrado médio dos erros/resíduos é dado por:

$$QME = \frac{SQR}{n - p}$$

$$QME = \frac{108}{18}$$

$$QME = 6$$

Portanto, aplicando a estatística F, temos:

$$F = \frac{QMR}{QME}$$

$$F = \frac{90}{6}$$

$$F = 15$$

Gabarito: C.

36. (CESPE/ANATEL/2014)



Tabela ANOVA

Fonte de Variação	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo		20		0,02
Erro		5		
Total	100			

Estimativas dos Parâmetros

Coeficiente	Estimativa	Erro Padrão	Razão t	P-valor
β_1	0,5	0,5		
β_2	1,2	0,3		<0,001
β_3		0,3	-4,0	

Um estudo econométrico considerou o modelo de regressão linear múltipla na forma $Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \varepsilon_i$, em que $i = 1, \dots, n$; Y_i representa a variável resposta, $X_{1,i}$ e $X_{2,i}$ são as variáveis explicativas; β_0 , β_1 e β_2 , e são os coeficientes (fixos) do modelo; e ε_i representa o erro aleatório normal com média zero e variância σ^2 .

Considerando essas informações e as tabelas acima, que mostram resultados pertinentes ao referido modelo, cujos coeficientes foram obtidos com base no método de mínimos quadrados ordinários, julgue o item a seguir.

A estimativa de máxima verossimilhança do coeficiente β_2 é inferior a -1 e superior a -2.

Comentários:

A estatística de teste t para o coeficiente β_2 é expressa por:

$$t = \frac{\hat{\beta}_2}{\sigma_{\beta_2}}$$



em que $\hat{\beta}_2$ é o coeficiente estimado pelo método dos mínimos quadrados ordinários.

Assim, utilizando os dados da tabela, temos:

$$-4 = \frac{\hat{\beta}_2}{0,3}$$
$$\hat{\beta}_2 = -1,2$$

Gabarito: Certo.

37. (CESPE/TJ-SE/2014) Com relação à análise de regressão linear, julgue o item que se segue.

Um modelo de regressão linear múltipla com duas variáveis explicativas será inequivocamente ajustado se essas variáveis forem proporcionais.

Comentários:

Se no modelo tivermos duas variáveis explicativas proporcionais, então teremos uma situação de **multicolinearidade**. Daí temos um problema no modelo de regressão já que a **multicolinearidade**, muitas vezes, torna as estimativas dos coeficientes dos parâmetros insignificantes. Desta forma, para os estimadores de MQO, a **multicolinearidade** torna-se um problema.

Gabarito: Errado.

38. (FCC/TRT 13ª Região/2014) Suponha que a quantidade consumida (Y) de determinado produto por uma família depende do preço do produto (X_2) e da renda da família (X_3). Consultando, aleatoriamente, 10 famílias e considerando Y_i como sendo o número de unidades consumidas do produto pela família i ($i = 1, 2, 3, \dots, 10$), X_{2i} como sendo o preço unitário (em reais) pago pela família i e X_{3i} como sendo a renda anual (em 1.000 reais) da família i , adotou-se o seguinte modelo linear $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i$ para prever Y , em que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Utilizando o método dos mínimos quadrados, obteve-se as estimativas dos parâmetros desconhecidos β_1 , β_2 e β_3 , com base nas informações apresentadas pelas 10 famílias. Pelo quadro de análise de variância verifica-se que a variação residual corresponde a 17,5% da variação total. Então, o valor da estatística F (F calculado) utilizado para verificar a existência da regressão, a um determinado nível de significância, é igual a

a) 15,00.

b) 12,50.



- c) 14,25.
- d) 10,00.
- e) 16,50.

Comentários:

Em um modelo de regressão linear múltipla, a estatística F é por:

$$F = \frac{QMR}{QME}$$

em que:

QMR : quadrado médio da regressão;

QME : quadrado médio dos erros/resíduos.

Vamos aos dados da questão:

$n = 10$, tamanho da amostra;

$p = 3$, número de parâmetros, número de variáveis explicativas ou independentes + um intercepto;

$SQR = 17,5\%$ de SQT , soma dos quadrados dos resíduos/erros;

$SQM = 82,5\%$ de SQT , soma dos quadrados do modelo da regressão.

Número de graus de liberdade de SQT :

$$n - 1 = 10 - 1 = 9$$

Número de graus de liberdade de SQR :

$$n - p = 10 - 3 = 7$$

O quadrado médio da regressão é dado por:

$$QMR = \frac{SQM}{p - 1}$$

$$QMR = \frac{82,5}{2}$$

$$QMR = 41,25$$

O quadrado médio dos erros/resíduos é dado por:



$$QME = \frac{SQR}{n - p}$$

$$QME = \frac{17,5}{7}$$

$$QME = 2,5$$

Aplicando a estatística F:

$$F = \frac{QMR}{QME}$$

$$F = \frac{41,25}{2,5}$$

$$F = 16,5$$

Gabarito: E.

39. (FCC/TRT 16ª Região/2014) Seja um modelo de regressão linear múltipla, com intercepto, envolvendo uma variável dependente e 2 variáveis explicativas. As estimativas dos respectivos parâmetros foram obtidas pelo método dos mínimos quadrados com base em 18 observações. O coeficiente de explicação (R^2), definido como sendo o resultado da divisão da variação explicada pela variação total, apresentou um valor igual a 76%. Dado que a variação explicada é igual a 95, obtém-se que a estimativa da variância do modelo teórico (σ^2) é igual a

- a) 1,90.
- b) 3,80.
- c) 2,40.
- d) 3,00.
- e) 2,00.

Comentários:

Vamos aos dados da questão:

$n = 18$, número da amostra;

$p = 3$, parâmetros, número de variáveis explicativas ou independentes + um intercepto;

$SQM = 95$, soma dos quadrados da regressão/variação explicada;

$R^2 = 76\% = 0,76$, Coeficiente de determinação/explicação.

$SQT \rightarrow$ soma dos quadrados total;



$SQR \rightarrow$ soma dos quadrados dos resíduos/erros;
 $\sigma^2 = QME \rightarrow$ Quadrado médio dos erros/resíduos;

Temos no enunciado que o R^2 é expresso pela divisão da variação explicada pela variação total, logo:

$$R^2 = \frac{SQM}{SQT}$$

Isolando SQT, temos:

$$SQT = \frac{SQM}{R^2}$$

Com isso, podemos encontrar o valor de SQT:

$$SQT = \frac{95}{0,76}$$

$$SQT = 125$$

Agora, vamos calcular a soma dos quadrados dos erros/resíduos (SQR):

$$SQT = SQM + SQR$$

$$125 = 95 + SQR$$

$$SQR = 125 - 95$$

$$SQR = 30$$

Por fim, vamos calcular um estimador não tendencioso para σ^2 :

$$\hat{\sigma}^2 = QME = \frac{SQR}{n - p}$$

$$\hat{\sigma}^2 = \frac{30}{18 - 3}$$

$$\hat{\sigma}^2 = \frac{30}{15}$$

$$\hat{\sigma}^2 = 2$$

Gabarito: E.

40. (FGV/SEDUC-AM/2014) Em uma regressão linear múltipla, se a soma quadrática total, devido à regressão e devido ao erro são representadas respectivamente por SQT, SQR e SQE, então o coeficiente de determinação pode ser calculado como

a) SQE/SQT



- b) SQR/SQE
- c) $1 - SQR/SQE$
- d) $1 - SQE/SQT$
- e) SQT/SQR

Comentários:

O coeficiente de determinação é dado por:

$$R^2 = \frac{SQM}{SQT}$$
$$R^2 = \frac{SQT - SQR}{SQT} = \frac{SQT}{SQT} - \frac{SQR}{SQT}$$
$$R^2 = 1 - \frac{SQR}{SQT}$$

Em que:

SQT , soma dos quadrados totais.

SQR , soma dos quadrados dos resíduos/erros;

SQM , soma dos quadrados do modelo de regressão.

Logo, verificando a nomenclatura apresentada na questão, temos:

$$R^2 = \frac{SQR}{SQT} = 1 - \frac{SQE}{SQT}$$

O coeficiente de determinação, R^2 , geralmente aumenta quando é adicionada uma nova variável explicativa ao modelo de regressão. Nesse ponto, retomamos a ideia dos graus de liberdade da equação no modelo de regressão. O número de graus de liberdade ainda é $n - 1$. Portanto, no modelo de regressão temos que os graus de liberdade são iguais ao número de parâmetros estimados (p) menos 1: $p - 1$.

Gabarito: D.

41. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.



A variância amostral da variável dependente é igual a 150.

Comentários:

A variância amostral da variável dependente é expressa por:

$$s^2 = \frac{SQT}{n - 1}$$

em que:

SQT : Soma dos quadrados totais;

n : número da amostra.

Substituindo os valores informados no enunciado, temos:

$$s^2 = \frac{15.000}{101 - 1}$$

$$s^2 = \frac{15.000}{100}$$

$$s^2 = 150$$

Gabarito: Certo.

42. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

O quadrado médio dos erros (mse) é superior a 50.

Comentários:

O quadrado médio dos erros é expresso por:

$$QME = \frac{SQR}{n - p}$$

em que:

SQR : soma dos quadrados dos resíduos/erros;

n : número da amostra;



p : parâmetro, número de variáveis explicativas ou independentes + um intercepto.

Substituindo os valores informados no enunciado, temos:

$$QME = \frac{5.000}{101 - 12}$$

$$QME = \frac{5.000}{89}$$

$$QME = 56,18$$

Gabarito: Certo.

43. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

O coeficiente de determinação — R^2 — do modelo de regressão linear múltipla é superior a 70%.

Comentários:

O coeficiente de determinação é expresso por:

$$R^2 = 1 - \frac{SQR}{SQT}$$

em que:

SQR : é a soma dos quadrados dos resíduos/erros;

SQT : é a soma dos quadrados total.

Substituindo os valores informados no enunciado, temos:

$$R^2 = 1 - \frac{5.000}{15.000}$$

$$R^2 = 1 - \frac{1}{3}$$

$$R^2 = 66,6\%$$

Portanto, o coeficiente de determinação é inferior a 70%.

Gabarito: Errado.



44. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

A soma de quadrados do modelo de regressão é inferior a 12.000.

Comentários:

A soma dos quadrados do modelo da regressão é dada por:

$$SQT = SQM + SQR$$

$$SQM = SQT - SQR$$

Em que:

SQT → soma dos quadrados total.

SQR → soma dos quadrados dos resíduos/erros;

SQM → soma dos quadrados do modelo de regressão;

Assim, temos:

$$SQM = 15.000 - 5.000$$

$$SQM = 10.000$$

Gabarito: Certo.



QUESTÕES COMENTADAS

Variável Binária ou Variável Dummy

1. (CESPE/PETROBRAS/2022) Em um processo em que se utiliza a ciência de dados, o número de variáveis necessárias para a realização da investigação de um fenômeno é direta e simplesmente igual ao número de variáveis utilizadas para mensurar as respectivas características desejadas; entretanto, é diferente o procedimento para determinar o número de variáveis explicativas, cujos dados estejam em escalas qualitativas.

Considerando esse aspecto dos modelos de regressão, julgue o item a seguir.

Para evitar um erro de ponderação arbitrária, deve-se recorrer ao artifício de uso de variáveis *dummy*, o que permitirá a estratificação da amostra da maneira que for definido um determinado critério, evento ou atributo, para então serem inseridas no modelo em análise; isso permitirá o estudo da relação entre o comportamento de determinada variável explicativa qualitativa e o fenômeno em questão, representado pela variável dependente.

Comentários:

As variáveis *dummy* são variáveis binárias (0 ou 1) utilizadas para representar uma variável com duas ou mais categorias. Por exemplo, caso fosse necessário incluir a variável sexo em um modelo de regressão linear, teríamos que transformar artificialmente a variável sexo em uma variável *dummy*, assim teríamos:

$$dummy_sexo = \begin{cases} 1, & \text{em caso de sexo feminino} \\ 0, & \text{em caso de sexo masculino} \end{cases}$$

Para uma variável com 3 ou mais categorias, precisamos utilizar $n - 1$ variáveis binárias (*dummies*). Por exemplo, caso quiséssemos incluir a variável Estado (considerando que a base contém apenas os estados da Paraíba, de Pernambuco e do Piauí), teríamos:

$$dummy_PB = \begin{cases} 1, & \text{quando for Paraíba} \\ 0, & \text{nos demais casos} \end{cases}$$
$$dummy_PE = \begin{cases} 1, & \text{quando for Pernambuco} \\ 0, & \text{nos demais casos} \end{cases}$$

Reparem que o número de variáveis binárias a serem criadas sempre será $n - 1$ categorias. Isso acontece porque a última variável representará a exclusão das anteriores.



As variáveis binárias devem ser utilizadas sempre que desejarmos estudar o comportamento de determinada variável explicativa qualitativa e o fenômeno em questão, representado pela variável dependente.

Gabarito: Certo.

2. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

Fixando-se determinado ponto (X_1, X_2) , a ocorrência do evento representado por D faz que a estimativa de Y diminua em mais de 80 unidades.

Comentários:

A equação que representa o modelo de regressão linear em análise é a seguinte:

$$Y = 340 + 150X_1 + 540X_2 + 89D + e$$

em que D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.



Conforme o enunciado, fixando o ponto (X_1, X_2) , a ocorrência do evento representado por D faz com que tenhamos a seguinte situação:

$$Y = 340 + 150X_1 + 540X_2 + 89 \times 1 + e$$

$$Y = 340 + 150X_1 + 540X_2 + e + 89$$

$$Y = (340 + 150X_1 + 540X_2 + e) + 89$$

Assim, concluímos que a estimativa de Y **aumenta** em 89 unidades.

Gabarito: Errado.

3. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

O coeficiente de determinação ajustado dessa regressão, $\hat{R}^2$, é maior que o coeficiente de determinação R^2 .

Comentários:

O coeficiente de determinação é definido pela seguinte expressão:

$$R^2 = 1 - \frac{SQR}{SQT}$$



em que SQR é a soma dos quadrados dos resíduos/erros e SQT é a soma dos quadrados total.

O coeficiente de determinação ajustado, por sua vez, é expresso por:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p - 1)}$$

em que n é o número de amostras e p é o número de parâmetros estimados.

Vamos desenvolver a expressão do coeficiente de determinação ajustado acrescentando $+R^2 - R^2$, que resulta em zero, portanto, em nada altera a expressão:

$$\overline{R^2} = 1 - (1 - R^2) \times \frac{(n - 1)}{(n - p - 1)} + R^2 - R^2$$

Reorganizando os termos, temos:

$$\overline{R^2} = R^2 + (1 - R^2) - (1 - R^2) \times \frac{(n - 1)}{(n - p - 1)}$$

Colocando $(1 - R^2)$ em evidência, temos:

$$\begin{aligned}\overline{R^2} &= R^2 + (1 - R^2) \times \left[1 - \frac{(n - 1)}{(n - p - 1)} \right] \\ \overline{R^2} &= R^2 + (1 - R^2) \times \left[\frac{(n - p - 1) - (n - 1)}{(n - p - 1)} \right] \\ \overline{R^2} &= R^2 + (1 - R^2) \times \left[\frac{-p}{n - p - 1} \right] \\ \overline{R^2} &= R^2 - (1 - R^2) \times \left[\frac{p}{n - p - 1} \right]\end{aligned}$$

Logo, coeficiente de determinação ajustado é determinado pela subtração entre o coeficiente de determinação original e uma parcela formada por $(1 - R^2) \times \left[\frac{p}{n - p - 1} \right]$, resultando em valor que sempre será menor que o coeficiente de determinação original.

Vamos substituir os valores de n e p na expressão do coeficiente de determinação ajustado:

$$\begin{aligned}\overline{R^2} &= R^2 - (1 - R^2) \times \left[\frac{3}{12 - 3 - 1} \right] \\ \overline{R^2} &= R^2 - (1 - R^2) \times \left(\frac{3}{8} \right)\end{aligned}$$

Supondo que R^2 fosse igual a 0,8, por exemplo:

$$\overline{R^2} = 0,8 - (1 - 0,8) \times \left(\frac{3}{8} \right)$$



$$\overline{R^2} = 0,8 - (0,2) \times \left(\frac{3}{8}\right) < 0,8$$

Logo, o coeficiente de determinação ajustado é **sempre menor** que o coeficiente de determinação R^2 .

Gabarito: Errado.

4. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

O valor de "a" reflete a quantidade de variáveis explicativas, e deve ser igual a 3.

Comentários:

Na tabela apresentada no enunciado, foram informados os graus de liberdade dos erros ou resíduos e os graus de liberdade total. De posse dessas informações, podemos descobrir o número de graus de liberdade do modelo (equação), isto é, vamos encontrar o valor da variável a . Vejamos:

$$gl_{total} = gl_{resíduos} + gl_{equação}$$

Substituindo, temos:

$$11 = 8 + a$$

$$a = 11 - 8$$



$$a = 3$$

Gabarito: Certo.

5. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

A soma dos quadrados totais é igual a 2.016.000

Comentários:

A soma dos quadrados totais é dada por:

$$SQT = SQM + SQR$$

em que:

SQM : soma dos quadrados do modelo de regressão;

SQR : soma dos quadrados dos resíduos/erros.

Substituindo os valores, temos:

$$SQT = 2.000.000 + 16.000$$



$$SQT = 2.016.000$$

Gabarito: Certo.



QUESTÕES COMENTADAS

Transformação de Box-Cox

1. (VUNESP/MPE SP/2016) O procedimento de Box e Cox é utilizado para enfrentar problemas de
- a) homoscedasticidade e/ou falta de normalidade, permitindo a linearização de um modelo.
 - b) homoscedasticidade ou insuficiência de dados para a definição de um modelo válido.
 - c) homoscedasticidade ou dificuldade na linearização de um modelo, a partir de dados dispersos.
 - d) heteroscedasticidade e/ou falta de normalidade, permitindo a linearização de um modelo.
 - e) heteroscedasticidade ou falta de confiabilidade de dados para a definição de um modelo válido.

Comentários:

Quando queremos normalizar dados não normais, fazemos uso de transformações das variáveis em estudo. Para isso, uma estratégia bastante eficiente é a transformação exponencial. Assim, quando temos um problema de **heteroscedasticidade**, conjunto de dados não-normais ou variância não-constante, utilizamos a transformação de potência.

Gabarito: D.



LISTA DE QUESTÕES

Regressão Múltipla

1. (CEBRASPE/FUNPRES-P-2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O desvio padrão dos resíduos do modelo de regressão é igual a 6.

2. (CEBRASPE/FUNPRES-P-2025)

	Estimativa do coeficiente	Erro padrão
--	---------------------------	-------------



Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1 , X^2 , X^3 e X^4) para modelar uma variável dependente Y. As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

A variância amostral da variável dependente Y é superior a 85.

3. (CEBRASPE/FUNPRES-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20



X_4	0,01	0,001
-------	------	-------

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1 , X^2 , X^3 e X^4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O valor do R^2 ajustado (R^2_{ajustado}) é superior a 60%.

4. (CEBRASPE/FUNPRES-P-EXE/2025)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%



Erro quadrático médio

36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X^1, X^2, X^3 e X^4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O coeficiente de explicação deverá aumentar se a variável X_2 for retirada do modelo.

5. (CEBRASPE/TRT 10ª Região/2025)

Fonte de Variação	Graus de Liberdade	Quadrado Médio	p-valor da razão F
regressão	2	14	0,002
erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O coeficiente de determinação do modelo é inferior a 80%.

6. (CEBRASPE/CAPES/2024) Um modelo de regressão linear entre uma variável aleatória (dependente) e uma variável não aleatória X (independente) é definido por

$$Y = \beta_0 + \beta_1 X + \varepsilon,$$

em que ε , denominado erro aleatório, é uma variável aleatória independente de X com média $E(\varepsilon) = 0$ e desvio padrão $Var(\varepsilon) = \sigma^2$. Um modelo de regressão linear é geralmente um modelo para a probabilidade condicional de Y em relação a X , denotada por $P(Y|X)$, e é chamado de simples se ε for uma variável aleatória gaussiana.

Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i, \quad i = 1, \dots, n.$$



Pelo método dos mínimos quadrados, é possível obter estimadores $\widehat{\beta}_0$ e $\widehat{\beta}_1$ para os parâmetros β_0 e β_1 , definindo

$$\widehat{Y}_i = \widehat{\beta}_0 + \widehat{\beta}_1 X_i$$

como o estimador para Y_i . Nesse contexto, são definidos os erros, denominados resíduos, como $\widehat{\varepsilon}_i = Y_i - \widehat{Y}_i$, e a soma dos quadrados dos resíduos

$$SQE = \sum_i \widehat{\varepsilon}_i^2,$$

a soma dos quadrados totais

$$SQT = \sum_i (Y_i - \bar{Y})^2$$

e a soma dos quadrados de regressão

$$SQR = \sum_i (\widehat{Y}_i - \bar{Y})^2,$$

com

$$\bar{Y} = \frac{\sum_i Y_i}{n}.$$

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição t de Student com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95:

$$P(-2,042 < T < 2,042) = 0,95.$$

Para um modelo de regressão que não seja simples, a soma dos resíduos não será nula.

7. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.



O valor da razão F do teste linear geral, cuja hipótese nula é $H_0: \beta_0 = \beta_1 = \beta_2 = 0$, é igual ou inferior a 10.

8. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

A correlação linear entre y e x_1 é superior a 0,95.

9. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

O coeficiente de explicação ajustado é igual a 0,875.

10. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
-------------------	--------------------



Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

A estimativa de σ é igual ou superior a 1.

11. (CEBRASPE/CODEVASF/2024)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon$, em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81.

Com base na situação hipotética apresentada, julgue os seguintes itens.

O desvio padrão amostral da variável resposta é igual a 2.

12. (Instituto Consulplan/TJ-MA/2024) Determinado Ministério Público Estadual coletou dados nas 53 comarcas do Estado com o intuito de estudar a relação entre o tempo médio (Y), em dias, gasto na triagem inicial de denúncias de abuso recebidas pela comarca e duas variáveis explicativas: o número de servidores lotados no setor responsável por avaliar as denúncias na comarca (X_1); e o número de municípios atendidos pela comarca (X_2). Considere o ajuste do modelo de regressão linear múltipla $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \varepsilon_i$, onde $i = 1, \dots, 53$ e $\varepsilon_1, \dots, \varepsilon_{53}$ são erros independentes com $\varepsilon_i \sim N(0, \sigma^2)$ para todo i . Os seguintes resultados foram obtidos pelo método de máxima verossimilhança: $\widehat{\beta}_0 = 21,5$, $\widehat{\beta}_1 = -2,8$ e $\widehat{\beta}_2 = 3,5$. Adicionalmente, tem-se que $SQ_{Regressão} = 346,5$ e $SQ_{Resíduos} = 185,5$. Com base nessas informações, é correto afirmar que:

a) O estimador de máxima verossimilhança para σ^2 será igual a 3,5.



- b) O modelo ajustado é capaz de explicar mais de 70% da variabilidade de Y .
- c) Os valores estimados para β_0 , β_1 e β_2 seriam diferentes se o método de mínimos quadrados fosse utilizado.
- d) Se em vez de X_1 e X_2 o ajuste considerasse as variáveis explicativas $Z_{1i} = X_{1i} - \bar{X}_1$ e $Z_{2i} = X_{2i} - \bar{X}_2$, onde $\bar{X}_1$ e $\bar{X}_2$ representam as médias amostrais de X_1 e X_2 , respectivamente, os valores estimados para β_1 e β_2 seriam diferentes.

13. (FGV/TJ-AP/2024) Para testar a significância de um conjunto de parâmetros do modelo de regressão linear múltipla, deve-se utilizar o seguinte teste estatístico:

- a) Friedman;
- b) Z da Normal;
- c) t de Student;
- d) F de Fisher-Snedecor;
- e) Qui-Quadrado de Pearson.

14. (FGV/TJ-MS/2024) Em um modelo de regressão linear múltipla, onde há uma variável dependente Y e k variáveis independentes X , o estimador não viesado para a variância do modelo com n observações é dado por:

Obs. O chapéu em $\hat{Y}_i$ indica valor estimado e o traço em $\bar{Y}_i$ indica a média.

a) $\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}{(n-k-1)}$

b) $\frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y}_i)^2}{(n-k)}$

c) $\frac{\sum_{i=1}^n (Y_i - \bar{Y}_i)^2}{(n-k-1)}$

d) $\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{(n-k-1)}$

e) $\frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{(n-k)}$

15. (FGV/TJ-MS/2024) Um pesquisador investiga a eficácia de três diferentes tratamentos para reduzir o colesterol no sangue. Ele divide aleatoriamente os pacientes em três grupos. Após um mês, realiza exames em cada paciente e deseja determinar se há diferença entre os tratamentos.



A estatística de teste que deve ser usada para avaliar se há diferença significativa entre os tratamentos é:

- a) teste ANOVA (análise de variância);
- b) teste de Kruskal-Wallis;
- c) teste de Qui-Quadrado;
- d) teste t de Student;
- e) teste de Wilcoxon-Mann-Whitney.

16. (Instituto Verbena/TJ-AC/2024) Considere um modelo de regressão linear múltipla dado por $Y = X\beta + \varepsilon$, em que Y é um vetor de dimensão $n \times 1$, X tem dimensão $n \times p$, com as colunas linearmente independentes, β é desconhecido com dimensão $p \times 1$ e o valor esperado de ε é igual a 0. A estimativa de mínimos quadrados para β é dada por

- a) $(X'Y)^{-1}X'Y$.
- b) $(Y'X)^{-1}X'Y$.
- c) $(X'X)^{-1}X'Y$.
- d) $(Y'Y)^{-1}X'Y$.

17. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			



Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

O grau de explicação do modelo é superior a 90%.

18. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

O parâmetro estimado para X é menor que 2.

19. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	



Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

No estudo, foram utilizados 30 dados.

20. (CESPE/TJ ES/2023) Diversos fatores podem influenciar o tempo que um processo leva para ser julgado. Para tentar explicar isso, um analista de um tribunal selecionou algumas variáveis e concluiu que a quantidade de atores envolvidos (X) impacta a variabilidade do tempo que um processo leva até ser julgado. A tabela de análise de variância a seguir mostra os resultados dessa modelagem.

Fonte de Variação (FV)	Grau de liberdade (GL)	Soma de quadrados (SQ)	quadrados médios (QM)	F
Modelo	1		321,4	
Erro		50,8		
Total	29			

Com base nessas informações e sabendo que existe uma correlação positiva entre as variáveis e que $Var(X) = 2,35$, julgue o item a seguir.

Caso fosse adicionada mais uma variável ao modelo, então, necessariamente o grau de ajuste do modelo aumentaria.

21. (FCC/TRT 18ª Região/2023) Um conjunto de dados amostrais foram ajustados a um modelo de regressão linear múltipla da forma $Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 X_{i3} + e_i$. Todos os pressupostos necessários para a validade do modelo foram verificados e atendidos. β_0 , β_1 , β_2 e β_3 são parâmetros desconhecidos e e_i corresponde ao erro aleatório da i-ésima observação com distribuição $N(0, \sigma^2)$. Uma amostra de 24 observações forneceu um coeficiente de determinação múltiplo, R^2 , igual a 0,8. Nesse caso, o coeficiente de determinação ajustado é igual a

a) 0,77



- b) 0,90
- c) 0,67
- d) 0,52
- e) 0,44

22. (FGV/BANESTES/2023) Ao adotar um modelo de Regressão Linear Múltipla para expressar matematicamente a forma como determinada variável resposta depende de um conjunto de variáveis explicativas, constatou-se que a complexidade do modelo adotado era alta demais, tendo em vista o número de observações disponíveis.

Neste caso, temos um fenômeno de

- a) multicolinearidade.
- b) sobreajuste (*overfitting*)
- c) presença de observações discrepantes (*outliers* ou pontos de alavanca).
- d) não normalidade do erro aleatório.
- e) autocorrelação do erro aleatório.

23. (FGV/BANESTES/2023) No contexto de Regressão Linear Múltipla, se o termo referente ao erro aleatório segue uma distribuição de probabilidade específica, pode ser provado que os estimadores de máxima verossimilhança dos coeficientes do modelo coincidem com os respectivos estimadores de mínimos quadrados.

Assinale a opção que apresenta essa distribuição.

- a) Normal.
- b) Exponencial.
- c) Uniforme.
- d) Gama.
- e) Beta.

24. (CESPE/PETROBRAS/2022)

Equação 1: $y_i = a + bX_i + e$



Equação 2: $y_i = a + b_1X_i + b_2X_2 + b_3X_3 + e$

Com base nos modelos de regressão linear simples (equação 1) e de regressão linear múltipla (equação 2), julgue o item a seguir.

A homoscedasticidade, conceito que implica que o erro não-observável “e” de uma regressão múltipla seja constante, é uma das condições para que os coeficientes b_1 , b_2 e b_3 da equação 2 sejam não-viesados e consistentes.

25. (CESPE/TELEBRAS/2022) Considerando que $\hat{y}_k$ denote o valor ajustado - pelo método de mínimos quadrados ordinários - da variável resposta y_k de um modelo de regressão linear múltipla na forma $y_k = \beta_0 + \beta_1x_{1,k} + \beta_2x_{2,k} + \epsilon_k$ que, nesse modelo, $\{\epsilon_1, \dots, \epsilon_{10}\}$ seja um conjunto de erros aleatórios independentes com médias iguais a zero e variâncias iguais a σ^2 ; e que cada resíduo produzido pelo ajuste seja escrito como $r_k = y_k - \hat{y}_k$, julgue o próximo item.

Os valores da sequência $r_1, \dots, r_{10}$ são mutuamente independentes.

26. (CESPE/TCE-SC/2022) Em artigo publicado em 2004 no Journal of Political Economy, E. Miguel, S. Satyanath e E. Sergenti mostraram o efeito que o crescimento econômico pode ter na ocorrência de conflitos civis, com dados de 41 países africanos, no período de 1981 até 1999. Em certo estágio da pesquisa, para verificar a possibilidade de usar dados sobre precipitação pluviométrica como variável instrumental, foi feita uma regressão entre o crescimento de tais precipitações (variável explicativa) e uma variável resposta que representa um indicador para a ocorrência de conflito: quanto maior for esse indicador, maior a possibilidade de conflitos no ano t no país i . Os resultados do modelo ajustado pelo método de mínimos quadrados ordinários se encontram na tabela a seguir.

Variável Explicativa	Variável Dependente	
	Conflito civil (mínimo de 25 mortos)	Conflito civil (mínimo de 1000 mortos)
Crescimento na precipitação em t	-0,024 (0,043)	-0,062 (0,030)
Crescimento na precipitação em $t-1$	-0,122 (0,052)	-0,069 (0,032)



Efeitos fixos	sim	sim
R ²	0,71	0,70
Observações	743	743

Internet: <<https://doi.org/10.1086/421174>> (com adaptações).

Os números entre parênteses na tabela apresentada indicam o erro padrão da estimativa dos coeficientes respectivos. Considere os valores críticos t_{α} da variável t de Student, com significância α para os graus de liberdades adequados aos dados apresentados, como sendo $t_{10\%} = 1,65$, $t_{5\%} = 1,96$ e $t_{1\%} = 2,58$. Considerando as informações precedentes, julgue o próximo item.

Os erros padrões abaixo de 0,05 mostram que o crescimento na precipitação no período t tem efeito significativo, com 95% de confiança, sobre a ocorrência de conflito civil com mínimo de 25 mortos na primeira regressão.

27. (CESPE/TELEBRAS/2022) Considerando que $\hat{y}_k$ denote o valor ajustado - pelo método de mínimos quadrados ordinários - da variável resposta y_k de um modelo de regressão linear múltipla na forma $y_k = \beta_0 + \beta_1 x_{1,k} + \beta_2 x_{2,k} + \epsilon_k$ que, nesse modelo, $\{\epsilon_1, \dots, \epsilon_{10}\}$ seja um conjunto de erros aleatórios independentes com médias iguais a zero e variâncias iguais a σ^2 ; e que cada resíduo produzido pelo ajuste seja escrito como $r_k = y_k - \hat{y}_k$, julgue o próximo item.

A razão $\frac{r_k}{\hat{y}_k}$ é denominada resíduo padronizado.

28. (FCC/TRT 23ª Região/2022) Deseja-se obter um modelo de regressão para estimar y a partir das variáveis independentes X_1 e X_2 . Com esse objetivo, foram obtidas 5 observações conforme o quadro a seguir:

Y_i	X_{i1}	X_{i2}
1	1	1
3	2	3
2	3	2
1	1	2



3 2 1

Considere o modelo de regressão múltipla $y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + e_i$ onde $e_i \sim N(0, \sigma^2)$, atendendo todas as premissas necessárias para o modelo e os dados:

$$X = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 2 \\ 1 & 1 & 2 \\ 1 & 2 & 1 \end{bmatrix} \quad Y = \begin{bmatrix} 1 \\ 3 \\ 2 \\ 1 \\ 3 \end{bmatrix} \quad (x^t x)^{-1} x^t y = \begin{bmatrix} 1/2 \\ 2/3 \\ 1/6 \end{bmatrix}$$

onde x^t é a transposta de X. Então, é correto afirmar que

- a) a soma dos parâmetros estimados para o modelo é 4/3.
- b) o valor estimado do intercepto é igual a zero.
- c) o valor estimado para y quando $x_1 = x_2 = 6$ é igual a 3.
- d) o valor estimado para y quando $x_1 = x_2 = 0$ é igual a 0.
- e) o valor estimado para o parâmetro β_1 é igual a 1/6.

29. (VUNESP/EsFCEX/2020) Um estudo analisa a viscosidade Y de um polímero em função de duas variáveis de processo: temperatura (X_1) e taxa de alimentação do catalizador (X_2). Foram realizados 9 ensaios (amostra de tamanho 9). Após ajustar um modelo de regressão linear múltipla, a soma de quadrados total (ou soma de quadrados total corrigida pela média, conforme algumas bibliografias), SQT, foi igual a 30000; e a soma de quadrados dos erros, SQE, foi igual a 24000.

A esse respeito, assinale a alternativa correta.

Dado: $F(0,95; 2, 6) = 5,14$, onde $P\{X > F(0,95; 2, 6)\} = 0,05$, sendo X uma variável aleatória com distribuição F de graus de liberdade 2 e 6.

- a) O teste de significância do modelo conclui que pelo menos uma das variáveis independentes é significativa ao nível de significância de 0,05.
- b) O resultado do teste mostra que a temperatura e a taxa de alimentação do catalizador relacionam linearmente com a viscosidade na região experimental.
- c) O resultado do teste mostra que ambas as variáveis independentes são significantes ao nível de significância de 0,05.
- d) Os resultados apresentados mostram que, com o conhecimento das duas variáveis independentes, estima-se melhor o valor esperado da viscosidade do que se usar apenas uma variável, ao nível de significância de 0,05.



e) Considerando nível de significância de 0,05, o teste de significância do modelo aceita a hipótese nula de que os coeficientes de X_1 e X_2 são nulos.

30. (VUNESP/Pref. Campinas/2019) Para um estudo com o objetivo de previsão, optou-se pela utilização do modelo de regressão linear múltipla $Y_i = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i$, $i = 1, 2, \dots, n$.

Tem-se que:

I. Y é a variável dependente,

II. $X_1, X_2, \dots, X_k$ são as variáveis explicativas,

III. $\alpha, \beta_1, \beta_2, \dots, \beta_k$ são os parâmetros desconhecidos do modelo com as respectivas estimativas obtidas pelo método dos mínimos quadrados,

IV. u é o erro aleatório,

V. i corresponde a i -ésima observação, n é o número de observações e k o número de variáveis explicativas.

Se foi detectado neste modelo um problema de multicolinearidade, então

a) no modelo houve a omissão de variáveis explicativas relevantes.

b) a variância do termo erro não é constante para todos os valores da variável dependente.

c) duas ou mais variáveis explicativas são altamente correlacionadas.

d) o termo erro em um determinado período é positivamente correlacionado com o termo erro no período anterior.

e) no modelo houve inclusão de variáveis explicativas irrelevantes.

31. (FCC/TRT 14ª Região/2018) Uma amostra aleatória constituída de 20 ternos de observações (X_i, Y_i, Z_i) , $i = 1, 2, 3, \dots, 20$ permitiu obter, por meio do método dos mínimos quadrados, as estimativas dos parâmetros desconhecidos α, β e γ do modelo de regressão linear múltipla $Z_i = \alpha + \beta X_i + \gamma Y_i + \varepsilon_i$ com i correspondendo a i -ésima observação. Sabe-se que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Para testar a existência da regressão de Z sobre as variáveis X e Y , considerou-se o respectivo quadro de análise de variância em que se obteve o valor de 44,625 para a estatística F_c (F calculado) utilizado para comparar com o F tabelado da distribuição F . Se a estimativa da variância σ^2 do modelo teórico foi igual a 8, então o coeficiente de determinação (R^2), definido como o sendo o resultado da divisão da variação explicada pela variação total é, em %, igual a



- a) 64.
- b) 78.
- c) 84.
- d) 80.
- e) 82.

32. (FGV/MPE BA/2017) Em um modelo de regressão linear múltipla, após a estimação dos parâmetros, realizou-se uma Análise da Variância, através da decomposição amostral. Os dados foram impressos, mas depois foram em parte perdidos, restando apenas a tabela a seguir, com diversas lacunas:

Fonte	Soma dos Quadrados	G.L.	Q. Médio	F-Snedecor	P-valor
Equação	400	X	100	W	0,0035
Resíduos	R	Y	Z		
Total	640	28			

Com os dados acima é possível concluir que:

- a) a variância estimada dos erros é menor do que 3;
- b) $X = 4$, $Y = 24$, $Z = 8$ e $W = 12,5$;
- c) a amostra empregada é de tamanho $n = 29$ e a regressão é não significativa ao nível de 1%;
- d) o modelo de regressão explica 62,5 da variação da variável explicativa;
- e) $X = 4$, $Y = 24$, $Z = 10$ e $W = 10$.

33. (FGV/IBGE/2016) Após estimar um modelo de regressão linear múltipla, por MQO, um economista repara que, por algum motivo, a tabela contendo os resultados da análise da variância ficou incompleta, conforme abaixo:

Fonte	Soma dos Quadrados	G. Liberdade	Q. Médio	F-Snedecor	P-valor
Equação	1800	5	360	4.5	1.05%



Resíduos	Y	X	W		
Modelo	3000	20	Z		

Apesar dos valores acima omitidos, é correto afirmar que:

- a) a equação de regressão tem cinco variáveis explicativas;
- b) o coeficiente de determinação R^2 é igual a 0,8;
- c) ao nível de significância de 2% não se rejeita a hipótese nula de que o modelo explica a variável dependente;
- d) o tamanho da amostra é $n = 20$;
- e) a estimativa não tendenciosa da variância dos erros aleatórios do modelo $\hat{\sigma}_\epsilon^2$ é igual a 80.

34. (FCC/TRE-RR/2015) Um modelo de regressão linear múltipla, com intercepto, consiste em uma variável dependente, 4 variáveis explicativas e o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Com base em 21 observações e utilizando o método dos mínimos quadrados obtiveram-se as estimativas dos parâmetros deste modelo. Dado que a variação total foi igual a 100 e a estimativa da variância do modelo foi igual a 1,25, então o valor da estatística F (F calculado) utilizado para testar a existência da regressão, a um determinado nível de significância, foi igual a

- a) 16.
- b) 27.
- c) 24.
- d) 20.
- e) 18.

35. (FCC/TRT 3ª Região/2015) Um modelo regressivo linear múltiplo correspondente à equação $Z_i = \alpha + \beta X_i + \gamma Y_i + \epsilon_i (i = 1, 2, 3, \dots)$ foi construído para prever Z em função de X e Y. Os parâmetros α, β e γ são desconhecidos, ϵ_i corresponde ao erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla e i refere-se à i-ésima observação. Com base em 21 observações e utilizando o método dos mínimos quadrados obtiveram-se as estimativas de α, β e γ (a, b e c, respectivamente).

Dados: $\sum_{i=1}^{21} (Z_i - \bar{Z})^2 = 288$, $\sum_{i=1}^{21} (Z_i - \hat{Z}_i)^2 = 108$, em que $\hat{Z}_i = a + bX_i + cY_i$



Observação: $\bar{Z}$ é a média de todos os valores

$Z_i (i = 1, 2, 3, \dots, 21)$

O valor da estatística F (F calculado) que permite decidir por meio da comparação com o F tabelado sobre a existência da regressão é igual a

- a) 12.
- b) 18.
- c) 15.
- d) 24.
- e) 9.

36. (CESPE/ANATEL/2014)

Tabela ANOVA

Fonte de Variação	Graus de Liberdade	Média dos Quadrados	Razão F	P-valor
Modelo		20		0,02
Erro		5		
Total	100			

Estimativas dos Parâmetros

Coeficiente	Estimativa	Erro Padrão	Razão t	P-valor
β_1	0,5	0,5		
β_2	1,2	0,3		<0,001
β_3		0,3	-4,0	



Um estudo econométrico considerou o modelo de regressão linear múltipla na forma $Y_i = \beta_0 + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \varepsilon_i$, em que $i = 1, \dots, n$; Y_i representa a variável resposta, $X_{1,i}$ e $X_{2,i}$ são as variáveis explicativas; β_0 , β_1 e β_2 , e são os coeficientes (fixos) do modelo; e ε_i representa o erro aleatório normal com média zero e variância σ^2 .

Considerando essas informações e as tabelas acima, que mostram resultados pertinentes ao referido modelo, cujos coeficientes foram obtidos com base no método de mínimos quadrados ordinários, julgue o item a seguir.

A estimativa de máxima verossimilhança do coeficiente β_2 é inferior a -1 e superior a -2.

37. (CESPE/TJ-SE/2014) Com relação à análise de regressão linear, julgue o item que se segue.

Um modelo de regressão linear múltipla com duas variáveis explicativas será inequivocamente ajustado se essas variáveis forem proporcionais.

38. (FCC/TRT 13ª Região/2014) Suponha que a quantidade consumida (Y) de determinado produto por uma família depende do preço do produto (X_2) e da renda da família (X_3). Consultando, aleatoriamente, 10 famílias e considerando Y_i como sendo o número de unidades consumidas do produto pela família i ($i = 1, 2, 3, \dots, 10$), X_{2i} como sendo o preço unitário (em reais) pago pela família i e X_{3i} como sendo a renda anual (em 1.000 reais) da família i , adotou-se o seguinte modelo linear $Y_i = \beta_1 + \beta_2 X_{2i} + \beta_3 X_{3i} + \varepsilon_i$ para prever Y , em que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Utilizando o método dos mínimos quadrados, obteve-se as estimativas dos parâmetros desconhecidos β_1 , β_2 e β_3 , com base nas informações apresentadas pelas 10 famílias. Pelo quadro de análise de variância verifica-se que a variação residual corresponde a 17,5% da variação total. Então, o valor da estatística F (F calculado) utilizado para verificar a existência da regressão, a um determinado nível de significância, é igual a

- a) 15,00.
- b) 12,50.
- c) 14,25.
- d) 10,00.
- e) 16,50.

39. (FCC/TRT 16ª Região/2014) Seja um modelo de regressão linear múltipla, com intercepto, envolvendo uma variável dependente e 2 variáveis explicativas. As estimativas dos respectivos



parâmetros foram obtidas pelo método dos mínimos quadrados com base em 18 observações. O coeficiente de explicação (R^2), definido como sendo o resultado da divisão da variação explicada pela variação total, apresentou um valor igual a 76%. Dado que a variação explicada é igual a 95, obtém-se que a estimativa da variância do modelo teórico (σ^2) é igual a

- a) 1,90.
- b) 3,80.
- c) 2,40.
- d) 3,00.
- e) 2,00.

40. (FGV/SEDUC-AM/2014) Em uma regressão linear múltipla, se a soma quadrática total, devido à regressão e devido ao erro são representadas respectivamente por SQT, SQR e SQE, então o coeficiente de determinação pode ser calculado como

- a) SQE/SQT
- b) SQR/SQE
- c) $1 - \text{SQR/SQE}$
- d) $1 - \text{SQE/SQT}$
- e) SQT/SQR

41. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

A variância amostral da variável dependente é igual a 150.

42. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

O quadrado médio dos erros (mse) é superior a 50.



43. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

O coeficiente de determinação — R^2 — do modelo de regressão linear múltipla é superior a 70%.

44. (CESPE/TRT 17ª Região/2013) Um modelo de regressão linear múltipla, que foi ajustado em uma perícia judicial, possui 11 variáveis explicativas. O tamanho da amostra nessa modelagem foi igual a 101. A soma de quadrados total foi igual a 15.000 e a soma de quadrados residual foi igual a 5.000. Com base nessas informações, julgue o próximo item.

A soma de quadrados do modelo de regressão é inferior a 12.000.



GABARITO

Regressão Múltipla

- | | | |
|-------------|-------------|-------------|
| 1. CERTO | 16. LETRA C | 31. LETRA C |
| 2. CERTO | 17. ERRADO | 32. LETRA E |
| 3. ERRADO | 18. ERRADO | 33. LETRA E |
| 4. ERRADO | 19. CERTO | 34. LETRA A |
| 5. CERTO | 20. ERRADO | 35. LETRA C |
| 6. ERRADO | 21. LETRA A | 36. CERTO |
| 7. ERRADO | 22. LETRA B | 37. ERRADO |
| 8. ERRADO | 23. LETRA E | 38. LETRA E |
| 9. CERTO | 24. ERRADO | 39. LETRA E |
| 10. ERRADO | 25. ERRADO | 40. LETRA D |
| 11. CERTO | 26. ERRADO | 41. CERTO |
| 12. LETRA A | 27. ERRADO | 42. CERTO |
| 13. LETRA D | 28. LETRA A | 43. ERRADO |
| 14. LETRA D | 29. LETRA E | 44. CERTO |
| 15. LETRA A | 30. LETRA C | |



LISTA DE QUESTÕES

Variável Binária ou Variável Dummy

1. (CESPE/PETROBRAS/2022) Em um processo em que se utiliza a ciência de dados, o número de variáveis necessárias para a realização da investigação de um fenômeno é direta e simplesmente igual ao número de variáveis utilizadas para mensurar as respectivas características desejadas; entretanto, é diferente o procedimento para determinar o número de variáveis explicativas, cujos dados estejam em escalas qualitativas.

Considerando esse aspecto dos modelos de regressão, julgue o item a seguir.

Para evitar um erro de ponderação arbitrária, deve-se recorrer ao artifício de uso de variáveis *dummy*, o que permitirá a estratificação da amostra da maneira que for definido um determinado critério, evento ou atributo, para então serem inseridas no modelo em análise; isso permitirá o estudo da relação entre o comportamento de determinada variável explicativa qualitativa e o fenômeno em questão, representado pela variável dependente.

2. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.



Fixando-se determinado ponto (X_1, X_2) , a ocorrência do evento representado por D faz que a estimativa de Y diminua em mais de 80 unidades.

3. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

O coeficiente de determinação ajustado dessa regressão, $\hat{R}^2$, é maior que o coeficiente de determinação R^2 .

4. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro- padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
-------------------	-------------------	--------------------	------------------	---------



Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

O valor de "a" reflete a quantidade de variáveis explicativas, e deve ser igual a 3.

5. (CESPE/STM/2018) A equação seguinte foi obtida de um modelo de regressão linear múltipla ajustado sobre 12 amostras, em que cada valor entre parênteses abaixo do coeficiente representa o erro-padrão desse coeficiente, e representa o erro, D é uma variável *dummy* que assume o valor 0 caso não ocorra determinado evento e 1 caso ocorra, e X_1 e X_2 são duas variáveis regressoras.

$$Y = \underbrace{340}_{(40)} + \underbrace{150}_{(5)} X_1 + \underbrace{540}_{(45)} X_2 + \underbrace{89}_{(20)} D + e$$

A tabela de análise de variância (ANOVA.) proporcionada pelo referido modelo é apresentada a seguir.

Fonte de Variação	Soma de Quadrados	Graus de Liberdade	Quadrados Médios	Teste F
Modelo	2.000.000	a	c	F_c
Erro	16.000	8	2.000	
Total		11	d	

Com base nas informações e na tabela apresentadas, julgue o item.

A soma dos quadrados totais é igual a 2.016.000



GABARITO

Variável Binária ou Variável Dummy

- | | | |
|-----------|-----------|----------|
| 1. CERTO | 3. ERRADO | 5. CERTO |
| 2. ERRADO | 4. CERTO | |



LISTA DE QUESTÕES

Transformação de Box-Cox

1. (VUNESP/MPE SP/2016) O procedimento de Box e Cox é utilizado para enfrentar problemas de
- a) homoscedasticidade e/ou falta de normalidade, permitindo a linearização de um modelo.
 - b) homoscedasticidade ou insuficiência de dados para a definição de um modelo válido.
 - c) homoscedasticidade ou dificuldade na linearização de um modelo, a partir de dados dispersos.
 - d) heteroscedasticidade e/ou falta de normalidade, permitindo a linearização de um modelo.
 - e) heteroscedasticidade ou falta de confiabilidade de dados para a definição de um modelo válido.



GABARITO

Transformação de Box-Cox

1. LETRA D



ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.