

Aula 14

CBM-PE (Oficial) Estatística

Autor:

**Equipe Exatas Estratégia
Concursos**

06 de Maio de 2026

Índice

1) Introdução - Análise de Variância (ANOVA)	3
2) Conceitos Fundamentais.	4
3) Fundamentos do Teste.	10
4) Número Distinto de Repetições.	24
5) Anova da Regressão.	28
6) Questões Comentadas - Conceitos Fundamentais - Multibancas	55
7) Questões Comentadas - Fundamentos do Teste - Multibancas	59
8) Questões Comentadas - Número Distinto de Repetições - Multibancas	68
9) Questões Comentadas - Anova da Regressão - Multibancas	70
10) Lista de Questões - Conceitos Fundamentais - Multibancas	97
11) Lista de Questões - Fundamentos do Teste - Multibancas	101
12) Lista de Questões - Número Distinto de Repetições - Multibancas	106
13) Lista de Questões - Anova da Regressão - Multibancas	108



Olá, amigo(a)!

Nessa aula veremos Análise de Variância, que é um **teste de hipóteses**. Ele compara as **médias** de três ou mais populações, mas também pode ser utilizado para avaliar se um modelo de **regressão linear** é adequado ou não. Essa segunda aplicação é a mais cobrada em concursos.

Vamos começar?

Luana Brandão

Doutora em Engenharia de Produção (UFF)

Auditora Fiscal da SEFAZ-RJ

Se tiver alguma dúvida, entre em **contato** comigo!



professoraluanabrandao@gmail.com



[@professoraluanabrandao](https://www.instagram.com/professoraluanabrandao)

“O que você viverá amanhã é fruto do que você escolhe hoje.”

Angela Davis



ANÁLISE DE VARIÂNCIA

Conceitos Fundamentais

A **análise de variância simples** (ou **ANOVA de um fator** ou ainda **ANOVA One-Way**) é um teste de hipóteses com o objetivo de **comparar as médias de três ou mais grupos**, com o objetivo de concluir se as médias são **iguais** ou se existe **diferença significativa** em relação a alguma delas.

Por exemplo, considere que, em determinada escola, haja 3 professores de matemática que ministram aulas para turmas distintas e que as provas são padronizadas para toda a escola. Vamos supor que a diretora dessa escola esteja desconfiando de que as notas dos alunos variam de acordo com o professor.

Para verificar essa suspeição, deve-se primeiro calcular as médias das notas dos alunos de cada professor. Entretanto, somente com as médias, não é possível concluir se há ou não uma diferença **significativa** entre elas. Para isso, aplicamos um teste estatístico (ANOVA) que nos permitirá concluir, com base em determinado **nível de significância**, se existe ou não diferença significativa entre as notas. Nessa situação, as **hipóteses** nula e alternativa do teste são:

H_0 : As médias das notas dos alunos dos três professores são **iguais**:

$$\mu_1 = \mu_2 = \mu_3$$

H_1 : Há **pelo menos um** professor cujos alunos apresentam média de notas diferente:

$$\mu_i \neq \mu_j, \quad \text{para pelo menos um par } (i, j)$$

Por que a ANOVA compara “três ou mais” grupos? Por que não compara apenas dois grupos?

Porque, para comparar a média de 2 grupos, utilizamos o teste de comparação de 2 populações (que podem ser chamados de **Teste t**).

*Por que utilizamos uma ferramenta chamada Análise de **Variância** para comparar **médias**?*

Com a ANOVA, comparamos as médias dos grupos por meio de uma verificação de quanto elas **variam** – se há apenas uma **variação ao acaso** (pelo fato de as observações serem variáveis aleatórias) ou se há uma **variação significativa** (que seria extremamente improvável de ocorrer ao acaso).

A ANOVA também possui outro ponto de vista. Em relação ao nosso exemplo, o resultado do teste nos permite concluir se o trabalho do professor **influencia** de maneira significativa as notas dos seus alunos ou não. De maneira geral, estando a população dividida em grupos de acordo com determinada característica, a ANOVA permite investigar se essa característica **influencia** significativamente o desempenho dos grupos.

Essa **característica** sendo estudada (no caso, o trabalho do professor) é chamada de **fator** e o **nível** dessa característica para cada grupo é chamado de **tratamento** (no caso, os tratamentos são o professor 1, o professor 2 e o professor 3).



Para realizar o teste, a ANOVA **segrega** as variações de desempenho **entre** os grupos e as variações **dentro** dos grupos. As variações **entre** os grupos podem ser atribuídas ao **tratamento**, enquanto as variações **dentro** dos grupos são atribuídas a outros fatores, estranhos ao estudo, que podemos chamar de **resíduo**, **erro**, **erro experimental**, **erro aleatório** ou **componente estocástica do erro**.

Para aplicar o teste, precisamos nos atentar aos seus **pressupostos** referentes aos erros:

- **Independência**: os erros são independentes;
- **Normalidade**: os erros seguem distribuição normal (com média 0);
- **Homoscedasticidade**: as **variâncias** dos erros são **iguais**.

Para que os erros atendam a esses pressupostos, é necessário que as **observações** da população (para o nosso exemplo, as notas dos alunos) também sejam independentes, sigam distribuição normal e tenham variância constante.

Como existe uma suposição a respeito da distribuição da população, dizemos que o teste é **paramétrico**.



Se os pressupostos **não** forem atendidos, é necessário utilizar métodos alternativos. Uma alternativa **não paramétrica** à ANOVA para um fator é o teste de **Kruskal-Wallis**, que **não** exige a **normalidade** e nem a **homoscedasticidade** da população. Porém, para que esse teste seja aplicado, é necessário que as observações sejam **independentes** e que a variável esteja no mínimo em **escala ordinal**, isto é, que possa ser ordenada.

Trata-se de uma **extensão do teste de Mann-Whitney** (ou Wilcoxon-Mann-Whitney ou teste da soma de postos de Wilcoxon), que compara 2 grupos, isto é, uma **versão não paramétrica do Teste t**. Assim, como o teste de Mann-Whitney, o teste de Kruskal-Wallis **ordena** todas as observações, atribuindo-lhes **postos** (ordens). Em caso de empates, atribui-se o valor médio dos postos das observações.

O teste de Kruskal-Wallis então compara as **médias dos postos** dos grupos, que podem ser chamadas de **pseudo-medianas**. Pontue-se que **não** é necessário que os grupos tenham o mesmo número de elementos.

Por fim, calcula-se a estatística H , que considera o **tamanho da amostra de cada grupo**, a sua **pseudo-mediana** e o **tamanho total** da amostra. Essa estatística é comparada com o valor da tabela da distribuição qui-quadrado com **$g - 1$ graus de liberdade**, em que g corresponde ao número de grupos. A hipótese nula, de que não há diferença significativa entre os grupos, será rejeitada se a estatística **superar** o valor crítico.

Por outro lado, se os erros **não forem independentes**, ou seja, houver correlação entre os erros (**autocorrelação**), será necessário utilizar métodos específicos para corrigi-la.



Para identificar a existência ou não da **autocorrelação**, pode-se efetuar uma **análise gráfica** dos erros em relação às observações, para verificar se há algum padrão, o que indicaria a existência de autocorrelação; ou aplicar métodos estatísticos com tal objetivo, como o **Teste t**, o **Teste Durbin-Watson** e o **Teste Breusch-Godfrey**.



(2013 – BANPARÁ) Uma grande empresa com uma unidade central e três filiais está interessada em comparar a média de horas não trabalhadas devido a afastamento por motivos de saúde de seus trabalhadores, entre suas quatro unidades. Assinale a alternativa abaixo que mostre o melhor teste estatístico para essa comparação.

- a) teste t de Student.
- b) teste do Qui quadrado.
- c) análise de variância.
- d) análise de regressão logística.
- e) estudo de casos e controles.

Comentários:

O enunciado informa que se deseja **comparar** a **média** de horas não trabalhadas entre **4** unidades da empresa. O teste que compara a média de 3 ou mais grupos é a Análise de Variância.

Gabarito: C



(2016 – EBSERH) A técnica da Análise da Variância foi desenvolvida por R. A. Fisher e tem como objetivo e premissas

- a) ajustar um modelo de probabilidade e necessita de correlação e tendenciosidade entre a resposta e a variável explicativa.
- b) ajustar um modelo de probabilidade e necessita de autocorrelação e tendenciosidade entre a resposta e a variável explicativa.
- c) testar hipótese de comparação de médias e necessita de independência, homocedasticidade e distribuição Normal para a componente estocástica do erro.
- d) testar hipótese de que uma média seja igual a um valor específico e necessita de independência, homocedasticidade e distribuição adequada para componente do erro.
- e) verificar se uma amostra de dados segue a distribuição Normal e necessita de pelo menos 30 observações e independência entre as observações.

Comentários:

A Análise de Variância é um teste de hipóteses com o objetivo de **comparar as médias** (de três ou mais grupos). As suas premissas são **independência, homoscedasticidade** (variâncias iguais) e **normalidade**. Logo, a única alternativa correta é a alternativa C.

As alternativas A e B mencionam correlação, autocorrelação e tendenciosidade, que **não** são premissas da ANOVA. Logo, as alternativas A e B estão incorretas.

A alternativa D menciona corretamente as premissas de independência e homoscedasticidade, porém indica que a distribuição deve ser adequada para o erro, em vez de afirmar que a distribuição deve ser normal. Logo, a alternativa D está incorreta.

Por fim, a alternativa E indica corretamente a premissa de independência, mas afirma que há necessidade de no mínimo 30 observações, o que não é uma premissa da ANOVA. Logo, a alternativa E está incorreta.

Gabarito: C

(2015 – EBSERH) A aplicação da técnica da Análise da Variância para verificar a igualdade na média de vários níveis k de um fator supõe que cada observação tem como modelo linear a expressão $y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$, onde μ é a média geral, α_i é o efeito do nível i do fator e ε_{ij} é o erro aleatório associado à observação j do nível i . Desta forma, é correto afirmar que é suposição para o modelo

- a) o erro ε_{ij} tem distribuição “t” de Student com k graus de liberdade.
- b) o erro ε_{ij} tem distribuição $N(0, \sigma^2)$, ou seja, normal com média zero e variância constante σ^2 .
- c) μ e α_i são estatísticas a serem estimadas.
- d) μ e α_i são parâmetros conhecidos.
- e) a variância dos erros ε_{ij} é diferente de nível para nível do fator.

Comentários:



A ANOVA pressupõe que os erros aleatórios sigam **distribuição normal** com **média igual a zero** e **variância constante**. Logo, as alternativas A e E estão incorretas e a alternativa B está correta.

O enunciado define μ como a média geral α_i como a influência do fator. A média geral será aquela observada na amostra (no nosso exemplo, a média das notas dos alunos), a qual é conhecida. Já, a influência do fator é justamente o que desejamos calcular, ou seja, é a estatística a ser estimada. Por isso, as alternativas C e D estão incorretas.

Gabarito: B

(2021 – Prefeitura de Porto Alegre/RS) Queremos comparar 4 amostras distintas em relação à tendência central, verificando se provém da mesma população. A análise preliminar dos dados desta amostra mostrou que todas as amostras apresentam uma forte não normalidade, com uma forte assimetria. Nessa situação, qual seria o melhor tipo de teste de hipóteses para ser utilizado?

- a) Teste de Mann-Whitney
- b) Teste de Kruskal-Wallis.
- c) Teste ANOVA one way.
- d) Teste Friedman.
- e) Teste exato de Fisher.

Comentários:

O enunciado informa que se deseja **comparar 4** amostras em relação à sua **tendência central**, mas a população **não** segue distribuição normal. Nesse caso, não pode ser utilizada a ANOVA, podendo ser utilizada a sua versão não paramétrica, qual seja o teste de **Kruskal-Wallis**.

Gabarito: B

(2015 – EBSERH) O administrador hospitalar de um posto de atendimento observou que o tempo de execução de certo procedimento médico não é o mesmo no turno da manhã, no turno da tarde e no turno da noite. Então, resolve fazer um experimento para verificar se o tempo médio de execução do procedimento é o mesmo nos três turnos. Considere μ_1 o tempo médio pela manhã, μ_2 o tempo médio à tarde e μ_3 o tempo médio à noite. Desta forma o administrador deve tomar amostras do tempo de execução do procedimento, de tamanho n_1 dos tempos pela manhã, n_2 dos tempos à tarde e n_3 dos tempos à noite. Nesse caso, é correto afirmar que

- a) se os tempos do procedimento nos turnos tiverem a mesma variância, ou seja, $\sigma_1 = \sigma_2 = \sigma_3 = \sigma$ e tiverem distribuição Gaussiana o administrador deve aplicar o teste “t” para verificar a igualdade no tempo médio.
- b) se os tempos do procedimento nos turnos tiverem a mesma variância, ou seja, $\sigma_1 = \sigma_2 = \sigma_3 = \sigma$ e tiverem distribuição Gaussiana o administrador deve aplicar o teste de Kruskal-Wallis para verificar a igualdade no tempo médio.



c) se os tempos do procedimento nos turnos tiverem variâncias diferentes, ou seja, $\sigma_1 \neq \sigma_2 \neq \sigma_3$ e tiverem distribuição Gaussiana o administrador deve aplicar o teste de Wilcoxon-Mann-Whitney para verificar a igualdade no tempo médio.

d) se os tempos do procedimento nos turnos tiverem a mesma variância, ou seja, $\sigma_1 = \sigma_2 = \sigma_3 = \sigma$ e tiverem distribuição Gaussiana o administrador deve aplicar a Análise de Variância para verificar a igualdade no tempo médio.

e) se os tempos do procedimento nos turnos tiverem variâncias diferentes, ou seja, $\sigma_1 \neq \sigma_2 \neq \sigma_3$ e tiverem distribuição Gaussiana o administrador deve aplicar o teste “t” para verificar a igualdade no tempo médio.

Comentários:

O enunciado informa que se deseja **comparar 3 grupos** em relação ao tempo **médio** de execução. Para isso, deve ser utilizada a ANOVA caso os seus pressupostos sejam atendidos; ou o teste de Kruskal-Wallis, caso a população não siga a distribuição normal (ou Gaussiana) e/ou caso as variâncias não sejam iguais.

Em relação às alternativas A e E, o teste “t” compara **2 grupos** e por isso não pode ser utilizado, ou seja, ambas as alternativas estão incorretas. Pontue-se, ainda, que esse teste é **paramétrico** (pressupõe normalidade), logo a alternativa E está incorreta também por este ponto.

Em relação à alternativa C, o teste de Wilcoxon-Mann-Whitney é uma versão **não paramétrica** do teste “t”, ou seja, compara apenas **2 grupos** e por isso não pode ser usado. Logo, a alternativa C está incorreta.

Em relação às alternativas B e D, se as variâncias forem iguais (homoscedasticidade) e a população seguir a distribuição normal, então deve ser aplicada a **ANOVA** e não o teste de Kruskal-Wallis (versão não paramétrica da ANOVA). Logo, a alternativa B está incorreta e a alternativa D está correta.

Gabarito: D



FUNDAMENTOS DO TESTE

A Análise de Variância (ANOVA) segrega as variações de desempenho **entre** os grupos (associadas ao **tratamento**) e **dentro** dos grupos (associadas ao **erro** ou **resíduo**), conforme indicado na equação a seguir:

$$x_{ij} - \bar{\bar{x}} = (\bar{x}_i - \bar{\bar{x}}) + (x_{ij} - \bar{x}_i)$$

Em que $\bar{\bar{x}}$ é a média geral de todas as observações; $\bar{x}_i$ é a média do tratamento i (no nosso exemplo, temos i = professor 1, professor 2 ou professor 3) e x_{ij} é a observação j do tratamento i , que representa cada uma das observações.

Ou seja, a equação afirma que a diferença de uma **observação** em relação à **média geral** ($x_{ij} - \bar{\bar{x}}$) corresponde à diferença entre a **média do grupo** e a **média geral** ($\bar{x}_i - \bar{\bar{x}}$) somada à diferença entre a **observação** e a **média do grupo** ($x_{ij} - \bar{x}_i$).

Considera-se que a diferença entre a média do grupo e a média geral ($\bar{x}_i - \bar{\bar{x}}$) está associada ao **tratamento** (no nosso exemplo, ao professor) e a diferença entre a observação e a média do grupo ($x_{ij} - \bar{x}_i$) está associada ao **erro**.

Soma de Quadrados

O fundamento básico da ANOVA é que a soma **total** dos quadrados das diferenças (SQ_{Total}) equivale à soma dos quadrados das diferenças **entre** os grupos, em razão do **tratamento** (SQ_{Entre} ou SQ_{Trat}) adicionada à soma dos quadrados das diferenças **dentro** dos grupos, em razão de motivos alheios ao tratamento, ou seja, decorrente dos **erros** ou resíduos (SQ_{Dentro} ou SQ_{Erro}):



$$\underbrace{\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{\bar{x}})^2}_{SQ_{Total}} = \underbrace{n \cdot \sum_{i=1}^k (\bar{x}_i - \bar{\bar{x}})^2}_{SQ_{Trat}} + \underbrace{\sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2}_{SQ_{Erro}}$$

Sendo n o número observações de cada tratamento (também chamadas de **repetições**; no nosso exemplo, n representa o número de alunos de cada professor); e k o número de **tratamentos** (no nosso exemplo, temos $k = 3$).



Vamos considerar o exemplo de 3 professores, em que cada professor dê aulas para $n = 5$ alunos, cujas notas constam a seguir:

Prof\Aluno	1	2	3	4	5	Soma x_i	Média $\bar{x}_i$	$\bar{x}_i - \bar{\bar{x}}$
A	9	8	10	7	6	40	$\frac{40}{5} = 8$	$8 - 7 = 1$
B	8	6	7	5	9	35	$\frac{35}{5} = 7$	$7 - 7 = 0$
C	6	5	8	7	4	30	$\frac{30}{5} = 6$	$6 - 7 = -1$
Total						105	$\bar{\bar{x}} = \frac{105}{15} = 7$	-

Na coluna “Soma x_i ”, consta a soma das notas dos alunos de cada professor e, na última linha, de todos os alunos; na coluna “Média $\bar{x}_i$ ”, dividimos a soma das notas pelo número de alunos de cada professor e, na última linha, pelo número total de alunos, obtendo assim a média geral de todos os alunos $\bar{\bar{x}}$; na última coluna “ $\bar{x}_i - \bar{\bar{x}}$ ”, calculamos a diferença entre a média $\bar{x}_i$ do professor e a média geral $\bar{\bar{x}}$.

Com base nos valores da última coluna, podemos calcular a **soma dos quadrados do Tratamento** ou **Entre** (SQ_{Trat} ou SQ_{Entre}). Ela é calculada pela soma dos valores da última coluna elevados ao quadrado, multiplicada pelo número de alunos de cada professor, n :

$$SQ_{Trat} = n \cdot \sum_{i=1}^k (\bar{x}_i - \bar{\bar{x}})^2$$

$$SQ_{Trat} = 5 \cdot \sum_{i=1}^3 (\bar{x}_i - \bar{\bar{x}})^2 = 5 \cdot [1^2 + 0^2 + (-1)^2] = 5 \times 2 = 10$$

Para calcular a **soma dos quadrados dos Erros** ou **Resíduos** ou **Dentro** (SQ_{Erro} ou SQ_{Dentro}), precisamos das **diferenças** entre as **notas** de cada aluno e a **média $\bar{x}_i$** de sua turma, indicadas a seguir:

Prof\Aluno	1	2	3	4	5	Média $\bar{x}_i$
A	$9 - 8 = 1$	$8 - 8 = 0$	$10 - 8 = 2$	$7 - 8 = -1$	$6 - 8 = -2$	8
B	$8 - 7 = 1$	$6 - 7 = -1$	$7 - 7 = 0$	$5 - 7 = -2$	$9 - 7 = 2$	7
C	$6 - 6 = 0$	$5 - 6 = -1$	$8 - 6 = 2$	$7 - 6 = 1$	$4 - 6 = -2$	6



A SQ_{Erro} consiste na soma de todos esses valores (em azul) elevados ao quadrado:

$$SQ_{Erro} = \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{x}_i)^2$$

$$= 1^2 + 0^2 + 2^2 + (-1)^2 + (-2)^2 + 1^2 + (-1)^2 + 0^2 + (-2)^2 + 2^2 + 0^2 + (-1)^2 + 2^2 + 1^2 + (-2)^2 \\ = 1 + 4 + 1 + 4 + 1 + 1 + 4 + 4 + 1 + 4 + 1 + 4 + 1 + 4 = 30$$

Por fim, a **soma total dos quadrados** (SQ_{Total}) corresponde à soma dos dois resultados, SQ_{Trat} e SQ_{Erro} , mas podemos obter o seu valor, calculando a **diferença** entre as **notas** de cada aluno e a **média geral** $\bar{\bar{x}} = 7$:

Prof\Aluno	1	2	3	4	5
A	$9 - 7 = 2$	$8 - 7 = 1$	$10 - 7 = 3$	$7 - 7 = 0$	$6 - 7 = -1$
B	$8 - 7 = 1$	$6 - 7 = -1$	$7 - 7 = 0$	$5 - 7 = -2$	$9 - 7 = 2$
C	$6 - 7 = -1$	$5 - 7 = -2$	$8 - 7 = 1$	$7 - 7 = 0$	$4 - 7 = -3$

A SQ_{Total} consiste na soma de todos esses valores (em verde) elevados ao quadrado:

$$SQ_{Total} = \sum_{i=1}^k \sum_{j=1}^n (x_{ij} - \bar{\bar{x}})^2$$

$$= 2^2 + 1^2 + 3^2 + 0^2 + (-1)^2 + 1^2 + (-1)^2 + 0^2 + (-2)^2 + 2^2 + (-1)^2 + (-2)^2 + 1^2 + 0^2 + (-3)^2 \\ = 4 + 1 + 9 + 1 + 1 + 1 + 1 + 4 + 4 + 1 + 4 + 1 + 9 = 40$$



A **soma dos quadrados do tratamento** também pode ser calculada por:

$$SQ_{Trat} = \frac{\sum_{i=1}^k (\text{total do tratamento } i)^2}{n} - \frac{(\text{soma de todos os valores})^2}{N}$$

Em que N é o total de observações ($N = k \times n$).

Utilizando uma notação diferente, temos:

$$SQ_{Trat} = \frac{\sum_{i=1}^k (\sum_{j=1}^n x_{ij})^2}{n} - \frac{(\sum_{i=1}^k \sum_{j=1}^n x_{ij})^2}{k \times n}$$



Para o nosso exemplo, efetuamos os seguintes cálculos:

$$SQ_{Trat} = \frac{40^2 + 35^2 + 30^2}{5} - \frac{105^2}{15}$$
$$SQ_{Trat} = \frac{1600 + 1225 + 900}{5} - \frac{11025}{15} = \frac{3725}{5} - 735 = 745 - 735 = 10$$

Que é o resultado obtido anteriormente.

E a **soma total dos quadrados** pode ser calculada alternativamente por:

$$SQ_{Total} = \text{soma dos quadrados de todos os valores} - \frac{(\text{soma de todos os valores})^2}{N}$$

Utilizando uma notação diferente, temos:

$$SQ_{Total} = \sum_{i=1}^k \sum_{j=1}^n x_{ij}^2 - \frac{(\sum_{i=1}^k \sum_{j=1}^n x_{ij})^2}{k \times n}$$

Para o nosso exemplo, o primeiro termo é:

$$\sum_{i=1}^k \sum_{j=1}^n x_{ij}^2 =$$
$$9^2 + 8^2 + 10^2 + 7^2 + 6^2 + 8^2 + 6^2 + 7^2 + 5^2 + 9^2 + 6^2 + 5^2 + 8^2 + 7^2 + 4^2 =$$
$$81 + 64 + 100 + 49 + 36 + 64 + 36 + 49 + 25 + 81 + 36 + 25 + 64 + 49 + 16 =$$
$$775$$

E o segundo termo é o mesmo que calculamos anteriormente:

$$\frac{(\sum_{i=1}^k \sum_{j=1}^n x_{ij})^2}{k \times n} = \frac{105^2}{15} = 735$$

Logo, a soma total dos quadrados é:

$$SQ_{Total} = 775 - 735 = 40$$

Que também é o mesmo resultado.

Já sabemos calcular as somas dos quadrados, mas ainda não descobrimos se o trabalho do professor faz ou não uma diferença significativa nas notas dos seus alunos. De fato, ainda não acabamos o teste.



Graus de Liberdade

Para dar prosseguimento ao teste, precisamos dos **graus de liberdade**. O número **total** de graus de liberdade equivale ao número total de observações, menos 1:

$$GL_{Total} = k \cdot n - 1 = N - 1$$

Em que N é o número total de observações (ou tamanho total da amostra); k é o número de tratamentos (ou grupos); e n é o número de observações de cada tratamento (ou tamanho da amostra de cada grupo). Para o nosso exemplo, temos $k = 3$ e $n = 5$, logo, o número total de graus de liberdade é:

$$GL_{Total} = 3 \times 5 - 1 = 14$$

O número de graus de liberdade do **modelo** (ou entre) equivale ao número de tratamentos, menos 1:

$$GL_{Trat} = k - 1$$

Para o nosso exemplo, temos:

$$GL_{Trat} = 3 - 1 = 2$$

Por fim, o número de graus de liberdade do **erro** (ou resíduo ou dentro)

$$GL_{Erro} = k \cdot (n - 1) = N - k$$

Para o nosso exemplo, temos:

$$GL_{Erro} = 3 \cdot (5 - 1) = 12$$

Observe que a soma dos graus de liberdade do tratamento e do erro equivale à soma do grau de liberdade total:

$$GL_{Total} = GL_{Trat} + GL_{Erro}$$

Quadrado Médio

Os graus de liberdade representam a quantidade de informações nos dados. Assim, ao **dividirmos** as **somas dos quadrados** pelos respectivos **graus de liberdade**, o que chamamos de **quadrado médio**, estamos calculando uma certa “média da soma dos quadrados **por dado**”.

O quadrado médio do **tratamento** (ou entre) é dado por:

$$QM_{Trat} = \frac{SQ_{Trat}}{GL_{Trat}}$$



E o quadrado médio do **erro** (ou resíduo ou dentro) é:

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}}$$

Para o nosso exemplo, temos $SQ_{Trat} = 10$, $GL_{Trat} = 2$, $SQ_{Erro} = 30$ e $GL_{Erro} = 12$, logo, os quadrados médios do tratamento e do erro são, respectivamente:

$$QM_{Trat} = \frac{10}{2} = 5$$

$$QM_{Erro} = \frac{30}{12} = 2,5$$



O quadrado médio do erro é utilizado para calcular a **variância dos erros**. Mais precisamente, a **esperança do quadrado médio** corresponde à variância dos erros (σ_{erro}^2):

$$\sigma_{erro}^2 = E(QM_{Erro})$$

Como a esperança do quadrado médio não é conhecida, utilizamos o próprio quadrado médio do erro para estimar a variância do erro:

$$\hat{\sigma}_{erro}^2 = QM_{Erro}$$




Para obter o componente da **variância** associado aos efeitos do **tratamento** (σ_{trat}^2), utilizamos a seguinte equação:

$$E(QM_{Trat}) = \sigma_{erro}^2 + n \cdot \sigma_{trat}^2$$

Para estimar $E(QM_{Trat})$, utilizamos o próprio quadrado médio do tratamento (QM_{Trat}) e para estimar a variância dos erros (σ_{erro}^2), utilizamos o quadrado médio dos erros (QM_{Erro}). Logo, a estimativa da componente da variância associada ao tratamento é dada por:

$$\sigma_{trat}^2 = \frac{QM_{Trat} - QM_{Erro}}{n}$$





(VUNESP/2024 – EsFCEEx) Seja um experimento unifatorial considerando um modelo de efeito aleatório com 3 tratamentos e 4 repetições. Sabendo que o quadrado médio dos tratamentos é igual a 360 e que o quadrado médio dos resíduos é igual a 60, então a estimativa do componente da variância do tratamento é igual a:

- a) 90
- b) 100
- c) 60
- d) 360
- e) 75

Comentários:

O componente da variância associada aos efeitos do tratamento σ_{trat}^2 é calculado pela seguinte equação:

$$E(QM_{Trat}) = \sigma_{erro}^2 + n \cdot \sigma_{trat}^2$$

Utilizamos o quadrado médio do tratamento para estimar $E(QM_{Trat})$ e o quadrado médio dos erros para estimar a variância dos erros σ_{erro}^2 .

Assim, a estimativa do componente da variância associada ao tratamento é dada por:

$$QM_{Trat} = QM_{Erro} + n \cdot \hat{\sigma}_{trat}^2$$

$$\hat{\sigma}_{trat}^2 = \frac{QM_{Trat} - QM_{Erro}}{n}$$

O enunciado informa que o quadrado médio do tratamento é $QM_{Trat} = 360$; que o quadrado médio dos erros (ou resíduos) é $QM_{Erro} = 60$; e que o número de repetições é $n = 4$. Logo, a estimativa desejada é:

$$\hat{\sigma}_{trat}^2 = \frac{360 - 60}{4} = \frac{300}{4} = 75$$

Gabarito: E

Estatística F

Por fim, a estatística do teste, que chamamos de **estatística F**, é a razão entre o **quadrado médio do tratamento** (ou **entre**) e o **quadrado médio do erro** (ou **resíduo** ou **dentro**):

$$F = \frac{QM_{Trat}}{QM_{Erro}}$$



Para o nosso exemplo, temos $QM_{Trat} = 5$ e $QM_{Erro} = 2,5$, logo, a estatística do teste é:


$$F = \frac{5}{2,5} = 2$$

Com os valores das somas dos quadrados, dos graus de liberdade, dos quadrados médios e da Estatística F, podemos preencher a **Tabela da ANOVA**, apresentada a seguir, para o nosso exemplo:

Fonte de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	Estatística F
Tratamento	2	10	5	2
Erro	12	30	2,5	
Total	14	40		


Saber preencher essa tabela é bem importante. A linha “**Total**” é a **soma** das outras duas linhas, tanto para os Graus de Liberdade quanto para a Soma de Quadrados. Ademais, o **Quadrado Médio** é a **razão** entre a Soma de Quadrados e os Graus de Liberdade, tanto para o tratamento quanto para o erro (ou resíduo). Por fim, a **Estatística F** é a razão entre os quadrados médios.

Se o valor da Estatística **F** for **pequeno**, ou seja, se o QM_{Trat} não for muito grande em relação ao QM_{Erro} , então a variabilidade **entre** os grupos **não** é muito maior do que a variabilidade **dentro** dos grupos. Na figura a seguir, ilustramos essa situação, em que cada curva representa cada um dos tratamentos (no nosso exemplo, cada curva representaria cada turma).



Nessa situação, deduzimos que a variação das médias ocorre apenas ao **acaso** e **não rejeitamos** a hipótese nula. Sendo assim, concluímos que as **médias são similares** e que **não** há **influência** significativa do fator no desempenho das unidades.

Por outro lado, se o valor da Estatística **F** for **grande**, ou seja, se o QM_{Trat} for bastante superior ao QM_{Erro} , então a variabilidade **entre** os grupos é muito **maior** do que a variabilidade **dentro** dos grupos, conforme ilustrado na figura a seguir.



Nessa situação, deduzimos que a variação das médias é **significativa** e **rejeitamos** a hipótese nula. Sendo assim, concluímos que **nem todas as médias são iguais**, isto é, há **pelo menos uma média diferente**, e que o fator, de fato, **influencia** o desempenho das unidades.

E como saber se o resultado é alto ou baixo?

Resultado do Teste

A Estatística F segue distribuição **F de Fisher-Snedecor**:

$$F_{v_1, v_2} = \frac{\chi_{v_1}^2 / v_1}{\chi_{v_2}^2 / v_2}$$

Em que $\chi_{v_1}^2$ é uma variável qui-quadrado com v_1 graus de liberdade e $\chi_{v_2}^2$ é uma variável qui-quadrado com v_2 graus de liberdade.

Assim, para sabermos se rejeitamos ou não a hipótese nula, **comparamos** a **Estatística F** com o valor da **tabela** para o **nível de significância** desejado (α), considerando o número de graus de liberdade do **tratamento** como o número de graus de liberdade do **numerador** (v_1) e o número de graus de liberdade do **erro** como o número de graus de liberdade do **denominador** (v_2).

Devemos **rejeitar** a hipótese nula se a estatística do teste observada for **superior** ao valor tabelado; e não a rejeitar, caso contrário.




Estatística F observada $> f$ tabelado $\rightarrow$ **Rejeitar** a hipótese nula

Estatística F observada $\leq f$ tabelado $\rightarrow$ **Não rejeitar** a hipótese nula

A distribuição de Fisher-Snedecor apresenta uma tabela para cada nível de significância. Para um nível de significância $\alpha = 5\%$, conforme ilustrado no gráfico abaixo, temos a seguinte tabela:





GL	V1																			
V2	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	20	40	60	120	240
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.0	243.9	244.7	245.4	245.9	248.0	251.1	252.2	253.3	253.8
2	18.513	19.000	19.164	19.247	19.296	19.329	19.353	19.371	19.385	19.396	19.405	19.412	19.419	19.424	19.429	19.446	19.471	19.479	19.487	19.492
3	10.128	9.552	9.277	9.117	9.013	8.941	8.887	8.845	8.812	8.785	8.763	8.745	8.729	8.715	8.703	8.660	8.594	8.572	8.549	8.538
4	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041	5.999	5.964	5.936	5.912	5.891	5.873	5.858	5.803	5.717	5.688	5.658	5.643
5	6.608	5.786	5.409	5.192	5.050	4.950	4.876	4.818	4.772	4.735	4.704	4.678	4.655	4.636	4.619	4.558	4.464	4.431	4.398	4.382
6	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147	4.099	4.060	4.027	4.000	3.976	3.956	3.938	3.874	3.774	3.740	3.705	3.687
7	5.591	4.737	4.347	4.120	3.972	3.866	3.787	3.726	3.677	3.637	3.603	3.575	3.550	3.529	3.511	3.445	3.340	3.304	3.267	3.249
8	5.318	4.459	4.066	3.838	3.688	3.581	3.500	3.438	3.388	3.347	3.313	3.284	3.259	3.237	3.218	3.150	3.043	3.005	2.967	2.947
9	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.102	3.073	3.048	3.025	3.006	2.936	2.826	2.787	2.748	2.727
10	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.943	2.913	2.887	2.865	2.845	2.774	2.661	2.621	2.580	2.559
11	4.844	3.982	3.587	3.357	3.204	3.095	3.012	2.948	2.896	2.854	2.818	2.788	2.761	2.739	2.719	2.646	2.531	2.490	2.448	2.426
12	4.747	3.885	3.490	3.259	3.106	2.996	2.913	2.849	2.796	2.753	2.717	2.687	2.660	2.637	2.617	2.544	2.426	2.384	2.341	2.319
13	4.667	3.806	3.411	3.179	3.025	2.915	2.832	2.767	2.714	2.671	2.635	2.604	2.577	2.554	2.533	2.459	2.339	2.297	2.252	2.230
14	4.600	3.739	3.344	3.112	2.958	2.848	2.764	2.699	2.646	2.602	2.565	2.534	2.507	2.484	2.463	2.388	2.266	2.223	2.178	2.155
15	4.543	3.682	3.287	3.056	2.901	2.790	2.707	2.641	2.588	2.544	2.507	2.475	2.448	2.424	2.403	2.328	2.204	2.160	2.114	2.090
16	4.494	3.634	3.239	3.007	2.852	2.741	2.657	2.591	2.538	2.494	2.456	2.425	2.397	2.373	2.352	2.276	2.151	2.106	2.059	2.035
17	4.451	3.592	3.197	2.965	2.810	2.699	2.614	2.548	2.494	2.450	2.413	2.381	2.353	2.329	2.308	2.230	2.104	2.058	2.011	1.986
18	4.414	3.555	3.160	2.928	2.773	2.661	2.577	2.510	2.456	2.412	2.374	2.342	2.314	2.290	2.269	2.191	2.063	2.017	1.968	1.943
19	4.381	3.522	3.127	2.895	2.740	2.628	2.544	2.477	2.423	2.378	2.340	2.308	2.280	2.256	2.234	2.155	2.026	1.980	1.930	1.905
20	4.351	3.493	3.098	2.866	2.711	2.599	2.514	2.447	2.393	2.348	2.310	2.278	2.250	2.225	2.203	2.124	1.994	1.946	1.896	1.870

Para o nosso exemplo, temos $v_1 = 2$ e $v_2 = 12$. Pela tabela acima, o valor de f constante na 2ª coluna (v_1) e na 12ª linha (v_2) é $f_{0,05;2;12} = 3,885$.

Como a estatística do teste observada $F = 2$ é **inferior** ao valor tabelado, então **não rejeitamos** a hipótese nula de que as médias são iguais e concluímos que as diferenças de trabalho desses professores **não** têm influência significativa nas notas dos alunos.



Se a ordem dos graus de liberdade do numerador e do denominador para o valor tabelado estiver **invertida**, aplicamos a seguinte relação:

$$P(F_{v_1, v_2} > f) = 1 - P(F_{v_2, v_1} > \frac{1}{f}) = P(F_{v_2, v_1} < \frac{1}{f})$$

Considerando os dados do nosso exemplo, temos:

$$P(F_{2;12} > 3,885) = 0,05$$

$$P(F_{12;2} < \frac{1}{3,885}) = 0,05$$

Alternativamente, podemos concluir o teste comparando o **nível de significância** desejado (α) com o **p-valor** do teste.

O p-valor é a **probabilidade** de o resultado do teste ser tão ou mais **extremo** que o resultado obtido, considerando-se a **hipótese nula**. Em outras palavras, essa medida transmite a noção de quão comum ou raro é o resultado obtido, supondo a **hipótese nula** como verdadeira.

Assim, um p-valor **alto** indica que o resultado obtido é **comum**, o que nos levaria à conclusão de que a hipótese nula seria verdadeira; enquanto um p-valor **baixo** indica que o resultado obtido é **incomum**, o que nos levaria a concluir que a hipótese nula seria falsa.

Sendo assim, a hipótese nula será **rejeitada** se o p-valor do teste for **inferior** ao nível de significância, caso em que dizemos que **há evidência estatística** ou que o teste **é estatisticamente significativo**.

Caso contrário, a hipótese nula **não será rejeitada**, situação em que dizemos que **não** há evidência estatística ou que o teste **não** é estatisticamente significativo.



$p\text{-valor} < \alpha \rightarrow$ **Rejeitar** a hipótese nula

$p\text{-valor} \geq \alpha \rightarrow$ **Não rejeitar** a hipótese nula

Para encontrar o p-valor do teste, precisaremos das demais tabelas da distribuição de Fisher-Snedecor. Para $\alpha = 10\%$, temos $f_{0,1;2;12} = 2,807$ e para $\alpha = 25\%$, temos $f_{0,25;2;12} = 1,56$, logo, concluímos que o p-valor do teste para $F = 2$ está no intervalo **entre 10% e 25%**.

Assim, **não rejeitaremos** a hipótese nula para $\alpha \leq 10\%$ e **rejeitaremos** a hipótese nula para um nível de significância $\alpha \geq 25\%$.

Com a ANOVA, descobrimos se as médias dos grupos são todas iguais ou se existe pelo menos uma diferente, mas **não** sabemos **quantas** nem **quais** são diferentes. Para isso, precisamos efetuar outros tipos de testes.



Pode ser que exista outro fator, além do tratamento, que influencie os resultados. Por exemplo, se os alunos estudassem em turnos diferentes, esse fator poderia estar influenciando as notas e mascarando o efeito verdadeiro do trabalho do professor.

Nessa situação, devemos separar as observações conforme o **tratamento** (no caso, o professor), como fizemos há pouco, mas também conforme esse **outro fator**, chamado **bloco** (no caso, o turno).



Assim, a soma total dos quadrados será igual à **soma** dos quadrados dos tratamentos, dos blocos e dos erros (ou resíduos):

$$SQ_{Total} = SQ_{Trat} + SQ_{Bloco} + SQ_{Erro}$$

A soma total dos graus de liberdade também será igual à soma dos graus de liberdade das três fontes (tratamentos, blocos e erros).

Para essa ANOVA, calculamos **2 estatísticas F**, uma pela razão entre o quadrado médio do tratamento e o quadrado médio do erro (como fizemos anteriormente) e outra pela razão entre o quadrado médio do **bloco** e o quadrado médio do **erro**:

$$F_{Trat} = \frac{QM_{Trat}}{QM_{Erro}}$$

$$F_{Bloco} = \frac{QM_{Bloco}}{QM_{Erro}}$$

Se F_{Bloco} for significativo, então a influência do bloco é importante, mas a rejeição ou não da hipótese nula, de que as médias são iguais, permanece baseada na estatística F_{Trat} .

Vale acrescentar que o teste **não paramétrico** correspondente é o **Teste de Friedman**, que considera os postos (ordenação) das observações, como os demais testes não paramétricos que vimos.



(2019 – UFRN) Considere o quadro de análise de variância (ANOVA) apresentado abaixo.

Fonte de Variação	GL	SQ	QM	F
Tratamentos	3	360		
Blocos	2	200		
Resíduo	6	288		
Total	11	848		

Os dados apresentados indicam que o número de tratamentos e a estatística F para comparação dos tratamentos correspondem, respectivamente, a

- a) 3; 2,5
- b) 4; 1,2
- c) 3; 1,2
- d) 4; 2,5.

Comentários:



Essa questão trabalha com blocos, mas isso não irá alterar os cálculos que aprendemos. O número de **graus de liberdade do tratamento** (GL_{Trat}) corresponde ao **número de tratamentos (k)**, menos 1. Pela tabela observamos que $GL_{Trat} = 3$, logo, o número de tratamentos é:

$$GL_{Trat} = k - 1 = 3 \rightarrow k = 3 + 1 = 4$$

Para calcular a estatística F, precisamos dos quadrados médios. O **quadrado médio do tratamento**, QM_{Trat} , é a **razão** entre a **soma dos quadrados do tratamento**, SQ_{Trat} e o respectivo número de **graus de liberdade**, GL_{Trat} . Pela tabela, observamos que $SQ_{Trat} = 360$ e $GL_{Trat} = 3$, logo:

$$QM_{Trat} = \frac{SQ_{Trat}}{GL_{Trat}} = \frac{360}{3} = 120$$

E o **quadrado médio do erro** (ou resíduo), QM_{Erro} , é a **razão** entre a **soma dos quadrados do erro**, SQ_{Erro} e o respectivo número de **graus de liberdade**, GL_{Erro} . Pela tabela, observamos que $SQ_{Erro} = 288$ e $GL_{Erro} = 6$, logo:

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{288}{6} = 48$$

Por fim, a **estatística F** é a razão entre o **quadrado médio do tratamento** e o **quadrado médio do erro**, que acabamos de calcular:

$$F = \frac{QM_{Trat}}{QM_{Erro}} = \frac{120}{48} = 2,5$$

Gabarito: D

(CESPE/2013 – CNJ) A respeito dos modelos de análise de variância, julgue o item subsequente.

Considere que, em um modelo de análise de variância (ANOVA) com um fator fixo em quatro níveis, ajustado em uma amostra de tamanho 25, tenha sido observada uma estatística F igual a 3,5. Nesse caso, se a soma de quadrados totais (SQT) for igual a 31,5, então a soma de quadrados associada ao fator é igual a quatro vezes o valor da soma de quadrados do resíduo.

Comentários:

O enunciado informa que a **estatística F**, dada pela razão entre o **quadrado médio do tratamento** e o **quadrado médio do erro**, é igual a 3,5:

$$F = \frac{QM_{Trat}}{QM_{Erro}} = 3,5$$

$$QM_{Trat} = 3,5 \times QM_{Erro}$$

Os **quadrados médios** correspondem à razão entre a **soma dos quadrados** e os respectivos **graus de liberdade**:

$$\frac{SQ_{Trat}}{GL_{Trat}} = 3,5 \times \frac{SQ_{Erro}}{GL_{Erro}}$$

O enunciado informa que há $k = 4$ níveis (ou tratamentos), logo, o número de graus de liberdade do tratamento é:

$$GL_{Trat} = k - 1 = 4 - 1 = 3$$



E informa que há $N = 25$ observações no total, logo, o número de graus de liberdade do erro é:

$$GL_{Erro} = N - k = 25 - 4 = 21$$

Substituindo essas informações na equação anterior, temos:

$$\frac{SQ_{Trat}}{3} = 3,5 \times \frac{SQ_{Erro}}{21}$$

$$SQ_{Trat} = 3,5 \times \frac{SQ_{Erro}}{7} = 0,5 \cdot SQ_{Erro}$$

Assim, a soma dos quadrados associada ao fator (ou tratamento) é **metade** (não quatro vezes) da soma dos quadrados do resíduo (ou erro). Já sabemos qual é a resposta, mas vamos prosseguir com essa questão, para efetivamente calcular esses valores. O enunciado informa que a soma total dos quadrados é $SQ_{Total} = 31,5$, que equivale à soma dos quadrados do tratamento e do erro:

$$SQ_{Total} = SQ_{Trat} + SQ_{Erro}$$

$$31,5 = 0,5 \cdot SQ_{Erro} + SQ_{Erro} = 1,5 \cdot SQ_{Erro}$$

$$SQ_{Erro} = \frac{31,5}{1,5} = 21$$

Logo:

$$SQ_{Trat} = 0,5 \cdot SQ_{Erro} = 0,5 \times 21 = 10,5$$

Gabarito: Errado



ESQUEMATIZANDO

ANOVA - Teste F

Hipótese nula: Todas as médias iguais

Hipótese alternativa: Pelo menos uma média diferente

Soma dos Quadrados: $SQ_{Total} = SQ_{Modelo} + SQ_{Erro}$

Graus de Liberdade: $GL_{Total} = GL_{Trat} + GL_{Erro}$

$$GL_{Total} = N - 1$$

$$GL_{Trat} = k - 1$$

$$GL_{Erro} = N - k$$

Quadrados Médios: $QM_{Trat} = \frac{SQ_{Trat}}{GL_{Trat}}$ e $QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}}$

Estatística: $F = \frac{QM_{Trat}}{QM_{Erro}}$

Distribuição F-Snedecor com GL_{Trat} no **numerador** e GL_{Erro} no **denominador**

Rejeitar hipótese nula se estatística $F > f$ tabelado



NÚMERO DISTINTO DE REPETIÇÕES

É possível que o número de observações de cada tratamento (que podemos chamar de **repetições**) **não** seja o mesmo para todos os tratamentos. Nessa situação, são necessários alguns ajustes para realizar o teste da ANOVA.

Se o número de observações para cada tratamento $i = 1, 2, 3, \dots, k$ for $n_1, n_2, n_3, \dots, n_k$, respectivamente, a **soma dos quadrados do tratamento** será dada por:

$$SQ_{Trat} = \sum_{i=1}^k n_i (\bar{x}_i - \bar{\bar{x}})^2$$

Em que a média do tratamento é $\bar{x}_i$ é a razão entre a soma das observações do tratamento i e o número de observações do tratamento e a média geral $\bar{\bar{x}}$ é a razão entre a soma de todas as observações e o número total de observações.

E os **graus de liberdade do erro** será:

$$GL_{Erro} = \sum_{i=1}^k (n_i - 1) = N - k$$

Ou seja, o número de graus de liberdade do erro ainda poderá ser calculado por $N - k$.

Para ilustrar, vamos supor que houvesse 3 alunos na turma A, 5 alunos na turma B e 3 alunos na turma C (total de $N = 11$ alunos), com as seguintes notas:

Prof\Aluno	1	2	3	4	5	Soma x_i	Média $\bar{x}_i$	$\bar{x}_i - \bar{\bar{x}}$
A	9	8	7			24	$\frac{24}{3} = 8$	$8 - 7 = 1$
B	8	6	7	5	9	35	$\frac{28}{4} = 7$	$7 - 7 = 0$
C	6	4	8			18	$\frac{18}{3} = 6$	$6 - 7 = -1$
Total						77	$\bar{\bar{x}} = \frac{77}{11} = 7$	-

A **soma dos quadrados do tratamento** será:

$$SQ_{Tratam} = 3 \times 1^2 + 4 \times 0^2 + 3 \times (-1)^2 = 3 + 3 = 6$$



A **soma dos quadrados do erro** é calculada da mesma forma, a partir da diferença entre as notas de cada aluno e a média da turma:

Prof\Aluno	1	2	3	4	5	Média $\bar{x}_i$
A	$9 - 8 = 1$	$8 - 8 = 0$	$7 - 8 = -1$			8
B	$8 - 7 = 1$	$6 - 7 = -1$	$7 - 7 = 0$	$5 - 7 = -2$	$9 - 7 = 2$	7
C	$6 - 6 = 0$	$4 - 6 = -2$	$8 - 6 = 2$			6

$$\begin{aligned}
 SQ_{erro} &= 1^2 + 0^2 + (-1)^2 + 1^2 + (-1)^2 + 0^2 + (-2)^2 + 2^2 + 0^2 + (-2)^2 + 2^2 \\
 &= 1 + 1 + 1 + 1 + 4 + 4 + 4 + 4 = 20
 \end{aligned}$$

A **soma dos quadrados totais** também pode ser calculada pela soma dos quadrados do tratamento e do erro ou a partir da diferença entre as notas de cada aluno e a média geral $\bar{x} = 7$:

Prof\Aluno	1	2	3	4	5
A	$9 - 7 = 2$	$8 - 7 = 1$	$7 - 7 = 0$		
B	$8 - 7 = 1$	$6 - 7 = -1$	$7 - 7 = 0$	$5 - 7 = -2$	$9 - 7 = 2$
C	$6 - 7 = -1$	$4 - 7 = -3$	$8 - 7 = 1$		

$$\begin{aligned}
 SQ_{Total} &= 2^2 + 1^2 + 0^2 + 1^2 + (-1)^2 + 0^2 + (-2)^2 + 2^2 + (-1)^2 + (-3)^2 + 1^2 \\
 &= 4 + 1 + 1 + 1 + 4 + 4 + 1 + 9 + 1 = 26
 \end{aligned}$$





Para utilizar a fórmula **alternativa** para a soma dos quadrados nessa situação, precisamos adaptar a SQ do tratamento, que é dada por:

$$SQ_{Trat} = \sum_{i=1}^k \frac{(total\ do\ tratamento\ i)^2}{n_i} - \frac{(soma\ de\ todos\ os\ valores)^2}{N}$$

Em que $N = \sum_{i=1}^k n_i$. Utilizando uma notação diferente, temos:

$$SQ_{Trat} = \sum_{i=1}^k \frac{(\sum_j^n x_{ij})^2}{n_i} - \frac{(\sum_{i=1}^k \sum_j^n x_{ij})^2}{N}$$

Para o nosso exemplo, temos:

$$SQ_{Trat} = \frac{24^2}{3} + \frac{35^2}{5} + \frac{18^2}{3} - \frac{77^2}{11} = \frac{576}{3} + \frac{1225}{5} + \frac{324}{3} - \frac{5929}{11}$$

$$SQ_{Trat} = 192 + 245 + 108 - 539 = 545 - 539 = 6$$

Que é o resultado obtido anteriormente.

E os **graus de liberdade total, do tratamento e do erro** são, respectivamente:

$$GL_{Total} = N - 1 = 11 - 1 = 10$$

$$GL_{Trat} = k - 1 = 3 - 1 = 2$$

$$GL_{Erro} = \sum_{i=1}^k (n_i - 1) = 2 + 4 + 2 = 8$$

Agora, podemos preencher a **tabela da ANOVA** e calcular os **quadrados médios** e a **estatística F**:

Fonte de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	Estatística F
Tratamento	2	6	$\frac{6}{2} = 3$	$\frac{3}{2,5} = 1,2$
Erro	8	20	$\frac{20}{8} = 2,5$	
Total	10	26		



Como o valor tabelado da distribuição de F-Snedecor com 12 graus de liberdade no numerador e 2 graus de liberdade no denominador, para um nível $\alpha = 25\%$ de significância, é $f_{0,25;12;2} = 1,56$, que é **maior** que a estatística do teste, então o p-valor desse teste é **maior** que 25%.

Assim, não rejeitaremos a hipótese nula, mesmo para um nível de significância $\alpha = 25\%$.



Quando rejeitamos a hipótese nula com base na estatística F, não sabemos qual(is) média(s) é(são) diferente(s) das demais.

Para isso, precisamos efetuar testes de **comparações múltiplas entre pares de médias**, como o Teste t, o Teste (ou método) de Tukey e o Teste Dunnett (ou Teste das Amplitudes Múltiplas de Dunnett).

Esses testes **comparam** a diferença das médias entre cada par de grupos a **uma Diferença Mínima Significativa** (DMS), que depende do quadrado médio do erro, mas o cálculo exato varia de acordo com o método adotado.

O Teste t utiliza a tabela de t-Student, enquanto os demais testes apresentam tabelas próprias, baseadas nas chamadas **amplitudes estudentizadas**.



(2020 – Prefeitura de Novo Hamburgo/RS – Adaptada) No teste de Tukey, o pesquisador avalia dois ou mais tipos de tratamentos e deseja verificar se há interação entre estes.

Comentários:

O teste de Tukey é um teste de comparações múltiplas de tratamentos, porém, o objetivo é verificar se suas médias são significativamente diferentes ou não (e não se há interação entre os grupos).

Resposta: Errado.



ANÁLISE DE VARIÂNCIA DA REGRESSÃO

A Análise de Variância também pode ser utilizada para avaliar o quanto um **modelo de regressão linear** se **ajusta** aos dados, isto é, se vale realmente utilizar o modelo de regressão para aproximar a relação verdadeira entre as variáveis.

No modelo de regressão linear entre **duas** variáveis X e Y, chamado modelo de regressão linear **simples**, indicamos que a relação entre elas é dada por:

$$Y_i = \alpha + \beta \cdot X_i + \varepsilon_i$$

Para todos os pontos (X_i, Y_i) . Nessa equação:

- X_i é o valor da variável X (chamada variável **explicativa**, **regressora** ou **independente**);
- Y_i é o valor da variável Y (chamada variável **explicada**, **resposta** ou **dependente**);
- α é o **intercepto** (ou **coeficiente linear**) da reta de regressão;
- β é o **coeficiente angular** da reta de regressão; e
- ε_i é o erro entre o valor de Y da reta de regressão para X_i e o verdadeiro valor Y_i .

Para estimar os coeficientes α e β , utilizamos os coeficientes a e b , respectivamente, de forma que $a + b \cdot X_i$ é aproximadamente igual Y_i . Na verdade, $a + b \cdot X_i$ é a **estimativa** do modelo de regressão para Y_i , o que indicamos por:

$$\hat{Y}_i = a + b \cdot X_i$$

Para ilustrar o modelo de regressão, vamos considerar o exemplo do Prof. Djefferson Maranhão deste curso de Estatística, com as notas de 5 alunos na disciplina X e na disciplina Y:

Aluno	X	Y
1	5	9
2	5	8
3	8	10
4	8	7
5	9	6

Supondo que existe uma relação aproximadamente linear entre as notas de X e Y, os coeficientes modelo de regressão encontrado pelo método dos mínimos quadrados foi aproximadamente:

$$\hat{Y}_i = 10,5 - 0,36 \cdot X_i$$


Portanto, nesse exemplo, há uma **correlação linear negativa ou inversa** entre as variáveis, isto é, elas variam em sentido contrário.



Para calcular os valores $\hat{Y}_i$, basta substituir X_i por cada um dos valores de X , na equação da reta:

Aluno	X	$\hat{Y}$
1	5	8,7
2	5	8,7
3	8	7,6
4	8	7,6
5	9	7,3

No gráfico a seguir, os pontos em azul representam as notas dos alunos em ambas as disciplinas e a reta em vermelho é a reta de regressão calculada.



Perceba que os pontos não estão muito próximos da reta. Ou seja, a dúvida é:

Será que realmente devemos utilizar um modelo de regressão linear para esse caso? Será que realmente vale aproximar a relação entre as variáveis a uma relação linear?

Para responder a essa questão, utilizamos a **Análise de Variância**! Nessa situação, as hipóteses nula e alternativa são as seguintes, respectivamente:

$H_0: \beta = 0 \rightarrow$ **não** existe relação linear entre as variáveis e o modelo de regressão **não** é adequado

$H_1: \beta \neq 0 \rightarrow$ **existe** relação linear entre as variáveis e o modelo de regressão é **adequado**

Ou seja, iremos concluir que o modelo de regressão linear se **adequa** aos dados se **rejeitarmos** a hipótese nula, isto é, se o teste for estatisticamente significativo (decisão forte).





Para **modelos de regressão múltipla**, isto é, com **mais de uma** variável explicativa, a **hipótese nula** é de que **todos** os coeficientes lineares são simultaneamente **iguais a zero**; e a **hipótese alternativa** é de que **pelo menos um** coeficiente é **diferente de zero**:

$$H_0: \beta_1 = \beta_2 = \dots \beta_n = 0$$

$$H_1: \beta_i \neq 0, \text{ para algum } i = 1, \dots, n$$

A Análise de Variância geral separa os **desvios** em relação à média em desvios associados ao **tratamento** e desvios associados ao **erro**. Para a regressão, a situação é análoga:

$$Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + (Y_i - \hat{Y}_i)$$

Ou seja, a diferença entre o valor **verdadeiro** de Y e a **média** ($Y_i - \bar{Y}$) é segregada na diferença entre a **estimativa** de Y e a **média** ($\hat{Y}_i - \bar{Y}$), **explicada** pelo modelo de regressão, e na diferença entre o valor **verdadeiro** de Y e a sua **estimativa** ($Y_i - \hat{Y}_i$), que corresponde ao **erro** do modelo de regressão, $e_i = Y_i - \hat{Y}_i$.



Assim, a **equação da soma dos quadrados** da ANOVA, para n pontos, é dada por:

$$\underbrace{\sum_{i=1}^n (Y_i - \bar{Y})^2}_{SQ_{Totais}} = \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{SQ_{Modelo}} + \underbrace{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}_{SQ_{erro}}$$

Também podemos representar a soma dos quadrados do erro (dentro dos grupos) como $\sum_{i=1}^k \sum_{j=1}^n e_{ij}^2$.



Vamos efetuar os cálculos para o exemplo dos alunos. Sabendo que a média dos valores de Y é $\bar{Y} = 8$, a **soma dos quadrados do modelo** $\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$ é:

Aluno	$\hat{Y}$	$\hat{Y} - \bar{Y}$	$(\hat{Y} - \bar{Y})^2$
1	8,7	$8,7 - 8 = 0,7$	0,49
2	8,7	$8,7 - 8 = 0,7$	0,49
3	7,6	$7,6 - 8 = -0,4$	0,16
4	7,6	$7,6 - 8 = -0,4$	0,16
5	7,3	$7,3 - 8 = -0,7$	0,49
$\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$			1,79

A **soma dos quadrados do erro** (ou resíduo) é:

Aluno	Y	$\hat{Y}$	$Y - \hat{Y}$	$(Y - \hat{Y})^2$
1	9	8,7	0,3	0,09
2	8	8,7	-0,7	0,49
3	10	7,6	2,4	5,76
4	7	7,6	-0,6	0,36
5	6	7,3	-1,3	1,69
$\sum_{i=1}^n (Y_i - \hat{Y}_i)^2$				8,39

Por fim, a **soma dos quadrados totais** será a soma dos dois resultados ($8,39 + 1,79 = 10,18$), mas vamos utilizar a fórmula $\sum_{i=1}^n (Y_i - \bar{Y})^2$, lembrando que $\bar{Y} = 8$:

Aluno	Y	$Y - \bar{Y}$	$(Y - \bar{Y})^2$
1	9	$9 - 8 = 1$	1
2	8	$8 - 8 = 0$	0
3	10	$10 - 8 = 2$	4
4	7	$7 - 8 = -1$	1
5	6	$6 - 8 = -2$	4
$\sum_{i=1}^n (Y - \bar{Y})^2$			10



Aqui, a soma dos quadrados do modelo e do erro não foi *exatamente* igual à soma dos quadrados totais porque utilizamos **aproximações** (para facilitar os cálculos), tanto para os coeficientes da reta de regressão quanto para os valores de $\hat{Y}$.



Existem formas **alternativas** de calcular as somas dos quadrados. Primeiro, vamos lembrar a fórmula da **variância amostral** de Y:

$$s_Y^2 = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{n-1}$$

Sabendo que $\sum_{i=1}^n (Y_i - \bar{Y})^2$ corresponde à **soma total dos quadrados**, então:

$$SQ_{Total} = s_Y^2 \times (n - 1)$$

E a **soma dos quadrados do modelo** pode ser calculada, utilizando valores de X:

$$SQ_{Modelo} = b \times \sum_{i=1}^n [(X_i - \bar{X}) \times (Y_i - \bar{Y})]$$

$$SQ_{Modelo} = b^2 \times \sum_{i=1}^n (X_i - \bar{X})^2$$

Mais uma vez, sabendo que a variância amostral de X é $s_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$, então:

$$SQ_{Modelo} = b^2 \times s_X^2 \times (n - 1)$$

Para decidirmos se vamos rejeitar ou não a hipótese nula, utilizamos a mesma **estatística F**. Para isso, precisamos dos quadrados médios do modelo e do erro que, por sua vez, depende dos respectivos graus de liberdade. O **número total de graus de liberdade** para N observações é:

$$GL_{Total} = N - 1$$

Para o nosso exemplo temos $GL_{Total} = 5 - 1 = 4$.

Considerando que o modelo de regressão linear **simples** tem 2 parâmetros, quais sejam, os 2 coeficientes da reta (a e b), então o **número de graus de liberdade do modelo** é:

$$GL_{Modelo} = 2 - 1 = 1$$

Sempre que houver apenas duas variáveis (uma em função da outra), o modelo de regressão linear terá 1 grau de liberdade.





De maneira geral, para modelos com qualquer número de variáveis, o número de **graus de liberdade do modelo** corresponde ao número de **variáveis explicativas**.

Por exemplo, se tivermos 4 variáveis explicativas (isto é, um total de 5 variáveis, considerando a variável explicada) $Y = \alpha + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 + \beta_3 \cdot X_3 + \beta_4 \cdot X_4$, o número de graus de liberdade do modelo será $GL_{Modelo} = 4$.

E a **soma** dos graus de liberdade do modelo e do erro equivale ao **número total de graus de liberdade** ($GL_{Total} = GL_{Modelo} + GL_{Erro}$), então o **número de graus de liberdade do erro** pode ser calculado pela **diferença** entre o número total de graus de liberdade e o número de graus de liberdade do modelo:

$$GL_{Erro} = GL_{Total} - GL_{Modelo}$$

Essa equação vale para qualquer modelo de regressão linear (simples ou múltiplo). Para a regressão linear **simples**, em que $GL_{Modelo} = 1$, temos:

$$GL_{Erro} = n - 1 - 1$$

$$GL_{Erro} = n - 2$$

Para o nosso exemplo, temos $GL_{Erro} = 5 - 2 = 3$.

Agora, podemos calcular os **quadrados médios** do modelo e do erro:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}}$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}}$$

Novamente, essas equações valem para **qualquer** modelo de regressão linear. Para a regressão linear **simples**, em que $GL_{Modelo} = 1$ e $GL_{Erro} = n - 2$, logo:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{1} = SQ_{Modelo}$$

$$QM_{Erro} = \frac{SQ_{Erro}}{n - 2}$$





O **quadrado médio dos erros** corresponde ao chamado **Erro Quadrático Médio**.

Para o nosso exemplo, temos $SQ_{Modelo} = 1,79$, $SQ_{Erro} = 8,39$ e $n = 5$, logo:

$$QM_{Modelo} = SQ_{Modelo} = 1,79$$

$$QM_{Erro} = \frac{SQ_{Erro}}{n - 2} = \frac{8,39}{3} \cong 2,80$$

E a estatística do teste (chamado **teste F**) é a razão entre o quadrado médio do modelo e o quadrado médio do erro:

$$F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{1,79}{2,80} \cong 0,64$$



Embora não seja utilizado no cálculo da estatística F, o **quadrado médio total**, isto é, a razão entre a soma total dos quadrados e o número total de graus de liberdade, é uma medida importante:

$$QM_{Total} = \frac{SQ_{Total}}{GL_{Total}} = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

Essa é justamente a fórmula da **variância amostral**!

A tabela ANOVA¹ para esse exemplo é:

¹ Nessa tabela, consideramos $SQ_{Total} = 10,18$, para que fique caracterizada a soma:



Fonte de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	Estatística F
Modelo	1	1,79	$\frac{1,79}{1} = 1,79$	$\frac{1,79}{2,80} \cong 0,64$
Erro	3	8,39	$\frac{8,39}{3} \cong 2,80$	
Total	4	10,18		


Novamente, recorreremos à tabela da distribuição de Fisher-Snedecor, apresentada a seguir (parcialmente), para um nível de significância $\alpha = 5\%$:

GL	V1																			
V2	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	20	40	60	120	240
1	161.4	199.5	215.7	224.6	230.2	234.0	236.8	238.9	240.5	241.9	243.0	243.9	244.7	245.4	245.9	248.0	251.1	252.2	253.3	253.8
2	18.513	19.000	19.164	19.247	19.296	19.329	19.353	19.371	19.385	19.396	19.405	19.412	19.419	19.424	19.429	19.446	19.471	19.479	19.487	19.492
3	10.128	9.552	9.277	9.117	9.013	8.941	8.887	8.845	8.812	8.785	8.763	8.745	8.729	8.715	8.703	8.660	8.594	8.572	8.549	8.538
4	7.709	6.944	6.591	6.388	6.256	6.163	6.094	6.041	5.999	5.964	5.936	5.912	5.891	5.873	5.858	5.803	5.717	5.688	5.658	5.643
5	6.608	5.786	5.409	5.192	5.050	4.950	4.876	4.818	4.772	4.735	4.704	4.678	4.655	4.636	4.619	4.558	4.464	4.431	4.398	4.382
6	5.987	5.143	4.757	4.534	4.387	4.284	4.207	4.147	4.099	4.060	4.027	4.000	3.976	3.956	3.938	3.874	3.774	3.740	3.705	3.687
7	5.591	4.737	4.347	4.120	3.972	3.866	3.787	3.726	3.677	3.637	3.603	3.575	3.550	3.529	3.511	3.445	3.340	3.304	3.267	3.249
8	5.318	4.459	4.066	3.838	3.688	3.581	3.500	3.438	3.388	3.347	3.313	3.284	3.259	3.237	3.218	3.150	3.043	3.005	2.967	2.947
9	5.117	4.256	3.863	3.633	3.482	3.374	3.293	3.230	3.179	3.137	3.102	3.073	3.048	3.025	3.006	2.936	2.826	2.787	2.748	2.727
10	4.965	4.103	3.708	3.478	3.326	3.217	3.135	3.072	3.020	2.978	2.943	2.913	2.887	2.865	2.845	2.774	2.661	2.621	2.580	2.559

Considerando $V1 = 1$ grau de liberdade para o numerador (modelo) e $V2 = 3$ graus de liberdade no denominador (erro), podemos observar que o valor tabelado é $f = 10,128$.

Como o valor da estatística é (muito) **inferior** ao valor tabelado, **não rejeitamos** a hipótese nula e assim concluímos que o modelo de regressão linear **não é adequado** para descrever a relação entre as variáveis.

Também podemos comparar o **p-valor** do teste com o **nível de significância α** , rejeitando a hipótese nula se $p < \alpha$.



(2015 – Secretaria da Criança/DF) Considerando-se que uma empresa de consultoria utilize o modelo de regressão linear para prever o lucro mensal de determinadas empresas (Y), tendo como variáveis regressoras o total de vendas em reais (X1) e o total de funcionários (X2) dessas empresas; considerando-se, ainda, que, no modelo de abril, sejam consideradas 40 empresas e as somas dos quadrados dos resíduos e do total

$$SQ_{Total} = SQ_{Modelo} + SQ_{Erro}$$

Mas, na verdade, o valor correto é aquele que calculamos pela fórmula $\sum_{i=1}^n (\hat{Y} - \bar{Y})^2 = 10$, ao passo que os valores SQ_{Modelo} e SQ_{Erro} são um pouco inferiores aos valores indicados, de modo que a sua soma seja efetivamente igual a 10.



sejam, respectivamente, 555 e 755 e utilizando-se os conhecimentos a respeito da análise de regressão linear e da tabela de análise de variância, é correto afirmar que

- a) a estatística F calculada será igual a 20/3 e terá distribuição F de Snedecor com 1 e 38 graus de liberdade.
- b) a estatística F calculada será igual a 40/3 e terá distribuição F de Snedecor com 1 e 39 graus de liberdade.
- c) a estatística F calculada será igual a 20/3 e terá distribuição F de Snedecor com 2 e 38 graus de liberdade.
- d) a estatística F calculada será igual a 20/6 e terá distribuição F de Snedecor com 2 e 37 graus de liberdade.
- e) a estatística F calculada será igual a 20/3 e terá distribuição F de Snedecor com 2 e 37 graus de liberdade

Comentários:

Essa questão trabalha com $k = 2$ variáveis regressoras e informa que:

- Há $n = 40$ empresas (observações);
- A soma dos quadrados dos erros (ou resíduos) é $SQ_{Erro} = 555$;
- A soma total dos quadrados é $SQ_{Total} = 755$;

E pede o valor da estatística F e os seus graus de liberdade.

Conhecendo as somas dos quadrados dos erros e do total, podemos encontrar a soma dos quadrados do modelo:

$$SQ_{Total} = SQ_{Modelo} + SQ_{Erro}$$

$$SQ_{Modelo} = 755 - 555 = 200$$

O número de graus de liberdade do modelo corresponde ao número de variáveis regressoras:

$$GL_{Modelo} = k = 2$$

E o número total de graus de liberdade é $GL_{Total} = n - 1 = 39$. Assim, o número de graus de liberdade dos erros é a **diferença**:

$$GL_{Total} = GL_{Modelo} + GL_{Erro}$$

$$GL_{Erro} = 39 - 2 = 37$$

Agora, podemos calcular os **quadrados médios**:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} = \frac{200}{2} = 100$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{555}{37} = 15$$

Por fim, a **estatística F** é a razão entre esses resultados:

$$F = \frac{QM_{Modelo}}{QM_{Erros}} = \frac{100}{15} = \frac{20}{3}$$

Sendo $GL_{Modelo} = 2$ o número de graus de liberdade do numerador e $GL_{Erro} = 37$ o número de graus de liberdade do denominador.

Gabarito: E



Coeficiente de Determinação

Um outro parâmetro importante para determinar se o modelo de regressão linear está adequado ou não é o **coeficiente de determinação** (ou **coeficiente de explicação**), dado pela razão entre a soma dos quadrados do modelo e a soma total dos quadrados:

$$R^2 = \frac{SQ_{Modelo}}{SQ_{Totais}}$$

Ou seja, R^2 mede **quanto da variância total é explicada pelo modelo** e assume valores entre 0 e 1. *Em geral*, quanto **maior** o seu valor, **mais adequado** está o modelo de regressão, ou seja, mais forte é a relação linear entre as variáveis.

Para o nosso exemplo das notas dos 5 alunos, o **coeficiente de determinação** é:

$$R^2 = \frac{1,79}{10} \cong 0,18$$

Ou seja, para o nosso exemplo, o modelo explica apenas 18% das variações.

A raiz quadrada do coeficiente de determinação corresponde ao módulo do **coeficiente de correlação** (de Pearson), que também assume valores entre 0 e 1. Quanto **maior** for o valor de R , **mais forte** será a correlação entre as variáveis:

$$|R| = \sqrt{R^2} = \sqrt{\frac{SQ_{Modelo}}{SQ_{Totais}}}$$



A **raiz quadrada do coeficiente de determinação** fornece o **módulo** do coeficiente de correlação, o qual pode ser positivo ou negativo. Assim, podemos reescrever a fórmula acima como:

$$R = \pm \sqrt{R^2} = \pm \sqrt{\frac{SQ_{Modelo}}{SQ_{Totais}}}$$

O sinal do coeficiente de correlação acompanha o sinal do **coeficiente angular** da reta de regressão (b).



Para o nosso exemplo, temos:

$$|R| = \sqrt{\frac{1,79}{10}} \cong 0,4$$

Como o coeficiente angular é negativo ($b = -0,36$), então o coeficiente de correlação também é negativo ($R = -0,4$).

Por que extrair a raiz quadrada?

Os dados do coeficiente de determinação R^2 compara as somas dos **quadrados**. Por exemplo, se os dados estiverem em anos, as somas dos quadrados estarão em anos². Quando extraímos a raiz quadrada do coeficiente de determinação, o resultado representa a comparação na mesma unidade de medida dos dados (no caso, em anos), o que facilita a sua interpretação.



(2019 – IF-PA) Para duas variáveis X e Y, foi ajustado o modelo na estrutura $Y = a + bX$. A hipótese de existência de regressão foi comprovada a partir de ANOVA abaixo, ao nível de significância de 5%.

Fonte de Variação	GL	SQ	QM	F	P
Regressão	1	4096,1644	4096,1644	14,8685	0,0051
Erro	8	2203,9356	275,4920		
Total	9	6300,1000	-		

Considerando os resultados da Análise de Variância (ANOVA), pode-se então afirmar que o coeficiente de explicação R^2 que representa a medida descritiva da qualidade do ajuste, é de:

- a) 75,32%
- b) 65,02%
- c) 85,90%
- d) 35,90%
- e) 98,20%

Comentários:

O **coeficiente de explicação** (ou **determinação**) é a razão entre a soma dos quadrados do modelo e a soma total dos quadrados:

$$R^2 = \frac{SQ_{Modelo}}{SQ_{Totais}}$$



Pela tabela, podemos observar que $SQ_{Modelo} = 4096,1644$ e $SQ_{Totais} = 6300,1000$. Logo, a razão é

$$R^2 = \frac{4096,1644}{6300,1000} \cong 0,6502 = 65,02\%$$

Gabarito: B.

Coeficiente de Determinação Ajustado

Sempre que incluímos uma **nova** variável explicativa no modelo de regressão (por exemplo, se em vez de termos uma função de X tivermos uma função de X_1 e X_2 , $Y = a + b.X_1 + c.X_2$), o coeficiente de determinação R^2 **aumenta**. Isso ocorre mesmo se a nova variável tiver **pouca relação** com a variável dependente (Y). Em outras palavras, **não** podemos comparar o valor de R^2 entre modelos com **diferentes números** de variáveis.

Para superar essa limitação, temos o **coeficiente de determinação ajustado**, que leva em consideração os **graus de liberdade**.

Antes de apresentá-lo, vamos reescrever a fórmula do coeficiente de determinação (sem ajuste). Sabendo que $SQ_{Totais} = SQ_{Modelo} + SQ_{Erro}$, outra forma de escrever $R^2 = \frac{SQ_{Modelo}}{SQ_{Totais}}$ é:

$$R^2 = \frac{SQ_{Totais} - SQ_{Erro}}{SQ_{Totais}} = 1 - \frac{SQ_{Erro}}{SQ_{Totais}}$$

O ajuste consiste na **divisão** das somas dos quadrados pelos respectivos **graus de liberdade**:

$$R^2_{\alpha} = 1 - \frac{SQ_{Erro}/GL_{Erro}}{SQ_{Totais}/GL_{Totais}}$$

O número total de graus de liberdade é $GL_{Total} = n - 1$ e o número de graus de liberdade do erro é a **diferença** entre GL_{Totais} e GL_{Modelo} .

Quando há apenas 1 variável explicativa (X), vimos que $GL_{Modelo} = 1$ e $GL_{Erro} = n - 2$.

Então, para um modelo de **regressão linear simples**, o coeficiente ajustado é dado por:

$$R^2_{\alpha} = 1 - \frac{SQ_{Erro}/n - 2}{SQ_{Totais}/n - 1}$$

$$R^2_{\alpha} = 1 - \frac{n - 1}{n - 2} \cdot \frac{SQ_{Erro}}{SQ_{Totais}}$$



Para o nosso exemplo, com $n = 5$, $SQ_{Erro} = 8,39$ e $SQ_{Totais} = 10$, temos:

$$R^2_{\alpha} = 1 - \frac{4}{3} \times \frac{8,39}{10} \cong -0,12$$

Observe que para o nosso exemplo, o coeficiente ajustado foi **negativo**, o que, de fato, pode acontecer. De modo geral, coeficiente ajustado será **sempre inferior** ao coeficiente não ajustado.

Considerando que o coeficiente não ajustado é $R^2 = 1 - \frac{SQ_{Erro}}{SQ_{Totais}}$, ou seja, $\frac{SQ_{Erro}}{SQ_{Totais}} = 1 - R^2$, outra forma reescrever R^2_{α} em função de R^2 , para um modelo de **regressão linear simples**, é:

$$R^2_{\alpha} = 1 - \frac{n-1}{n-2} \cdot (1 - R^2)$$

De maneira **geral**, para um modelo com k variáveis explicativas ($X_1, X_2, \dots, X_k$), o número de graus de liberdade do modelo será $GL_{Modelo} = k$, logo, o do erro será $GL_{Erro} = n - k - 1$. Nessa situação, o coeficiente de determinação ajustado é dado por:

$$R^2_{\alpha} = 1 - \frac{n-1}{n-k-1} \cdot (1 - R^2)$$




Uma outra medida que auxilia na escolha entre modelos de regressão é o **Cp de Mallows**, que avalia a **precisão** das estimativas. Para isso, o método compara o número de **parâmetros** (p), isto é, o número de **variáveis explicativas mais um**, referente ao intercepto ($p = k + 1$).

A **estatística Cp** é dada por:

$$C_p = \frac{SQ_{Erro}}{QM_{Erro}} - n + 2 \cdot p$$

Para bons modelos, a estatística se aproxima do valor de **p**; e para modelos ruins, essa estatística é bastante **superior** a **p**.





(CESPE/2018 – EBSEH) Determinado estudo considerou um modelo de regressão linear simples na forma $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, em que y_i representa o número de leitos por habitante existente no município i ; x_i representa um indicador de qualidade de vida referente a esse mesmo município i , para $i = 1, \dots, n$. A componente ε_i representa um erro aleatório com média 0 e variância σ^2 . A tabela a seguir mostra a tabela ANOVA resultante do ajuste desse modelo pelo método dos mínimos quadrados ordinários.

Fonte de Variação	Soma dos quadrados	Graus de liberdade	Média dos quadrados	Razão F	p-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

A partir das informações e da tabela apresentadas, julgue o item subsequente

O R^2 ajustado (*Adjusted R Square*) foi inferior a 0,9.

Comentários:

O R^2 ajustado é dado por:

$$R^2_{\alpha} = 1 - \frac{SQ_{\text{Erro}}/GL_{\text{Erro}}}{SQ_{\text{Totais}}/GL_{\text{Totais}}}$$

Esses dados foram fornecidos pela tabela do enunciado:

Fonte de Variação	Soma dos quadrados	Graus de liberdade	Média dos quadrados	Razão F	p-valor
Modelo	900	1	900	90	< 0,001
Erro	100	10	10		
Total	1.000	11			

Portanto, temos:

$$R^2_{\alpha} = 1 - \left(\frac{100}{10} \times \frac{11}{1.000} \right) = 1 - \frac{11}{100} = \frac{89}{100} = 0,89$$

Que é inferior a 0,9.

Gabarito: Certo.




Intervalos de Confiança

Os coeficientes da reta de regressão são estimados a partir dos dados obtidos a partir de **amostras aleatórias**. Assim, caso repetíssemos o procedimento, selecionando uma nova amostra, os dados seriam **diferentes**, assim como as estimativas para os coeficientes.

O quanto essas estimativas **variam** de amostra para amostra afeta a sua **precisão**: quanto maior for a variação, menos precisas são as estimativas.

Para ilustrar essa variação, a figura a seguir representa as estimativas das retas de regressão obtidas com base em 1000 simulações para a reta $Y = 1 + 2X$, para $X = 10, 11, \dots, 30$, cuja variância do erro é $\sigma^2 = 15$:²



Nessa figura, as variações das estimativas são representadas pela grossura da reta. Podemos observar que a variação aumenta, à medida que nos **afastamos da média** $\bar{X} = 20$.

Para capturar essa variabilidade, construímos um **intervalo de confiança** em torno das estimativas.

Considerando o pressuposto de **normalidade** das observações e que a **variância** verdadeira dos coeficientes não é conhecida, mas sim **estimada** a partir dos dados observados, utilizamos a distribuição de **t-Student**, na construção dos intervalos de confiança.

Em relação ao **coeficiente angular**, no caso da regressão linear simples (ou aos coeficientes angulares, no caso da regressão múltipla), o intervalo de confiança **bilateral** é dado por:

² Figura obtida no capítulo 19 – Regressão Linear do livro eletrônico “Bioestatística Básica” de Sérgio Miranda Freire, disponível em <http://www.lampada.uerj.br/bioestatisticabasica>.



$$\hat{\beta} \pm t_{GLE} \cdot s_{\beta} = (\hat{\beta} - t_{GLE} \cdot s_{\beta}; \hat{\beta} + t_{GLE} \cdot s_{\beta})$$

Em que:

- $\hat{\beta}$ é a estimativa calculada para o coeficiente linear;
- t_{GLE} é o valor tabelado da distribuição de t-Student, considerando o número de **graus de liberdade dos erros** ou resíduos (GLE), para o nível de confiança desejado; e
- s_{β} é o **erro padrão** de $\hat{\beta}$.

O número de **graus de liberdade dos erros** (GLE) é dado pela **diferença** entre o número total de graus de liberdade GLT e o número de graus de liberdade do model GLM.

$$GLE = GLT - GLM$$

Para um modelo de regressão múltipla, com k variáveis explicativas (isto é, $k + 1$ variáveis, no total), havendo n observações, o número de **graus de liberdade dos erros** é dado por:

$$GLT = n - 1$$

$$GLM = k$$

$$GLE = GLT - GLM = n - k - 1$$

Para um modelo de regressão simples, em que $k = 1$, o número de graus de liberdade dos erros é:

$$GLE = n - 1 - 1 = n - 2$$

E como calculamos o **erro padrão** de $\hat{\beta}$?

Em uma regressão linear **simples**, a **variância** do coeficiente (quadrado do erro padrão) é a razão entre a **variância dos erros** (que pode ser estimada pelo seu quadrado médio) e a **soma dos quadrados dos desvios** da variável explicativa (X):

$$s_{\beta}^2 = \frac{\sigma_E^2}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{QME}{\sum_{i=1}^n (X_i - \bar{X})^2}$$

Ou seja, para um mesmo QME, quanto **maior a variância de X** (e, consequentemente, maior a soma dos quadrados dos desvios), **menor a variância do coeficiente**.

Em relação ao exemplo das notas dos alunos, em que a reta de regressão calculada foi $\hat{Y}_i = 10,5 - 0,36 \cdot X_i$, temos QME = 2,8 e $\sum_{i=1}^n (X_i - \bar{X})^2 = 14$. Assim, a variância de $\hat{\beta}$ é:

$$s_{\beta}^2 = \frac{2,8}{14} = 0,2$$



E o erro padrão é a raiz quadrada desse resultado:


$$s_{\beta} = \sqrt{s_{\beta}^2} = \sqrt{0,2} \cong 0,45$$



Em uma **regressão linear múltipla**, os erros padrão dos coeficientes são as raízes dos elementos da diagonal principal da matriz $(X^T \cdot X)^{-1} \cdot \sigma^2$, em que X é a matriz com os valores observados das variáveis explicativas.

Vamos então calcular o intervalo de confiança, em relação ao mesmo exemplo das notas dos alunos, para um nível de confiança $1 - \alpha = 90\%$, em que o número de graus de liberdade dos erros é GLE = 3.

A seguir, temos a tabela (parcial) da distribuição de t-Student, para $P(|T| > t) = P(T < -t) + P(T > t)$.



GL \ α	0,5	0,4	0,3	0,2	0,1	0,05	0,02	0,01	0,005	0,002	0,001
1	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,656	127,321	318,289	636,578
2	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925	14,089	22,328	31,600
3	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841	7,453	10,214	12,924
4	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604	5,598	7,173	8,610
5	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032	4,773	5,894	6,869

Para GLE = 3 graus de liberdade e $\alpha = 0,1$, observamos que $t_3 = 2,353 \cong 2,35$.

Sabendo que $\hat{\beta} = -0,36$ e $s_{\beta} \cong 0,45$, o intervalo de confiança para $\hat{\beta}$ é:

$$-0,36 \pm 2,35 \times 0,45 \cong -0,36 \pm 1,06 = (-1,42; 0,70)$$

Em relação ao **intercepto** da reta de regressão, o intervalo de confiança bilateral é calculado de maneira análoga:

$$\hat{\alpha} \pm t_{GLE} \cdot s_{\alpha}$$



A diferença está no cálculo do **erro padrão** do estimador, dado por:

$$s_{\alpha} = \sqrt{\sigma_E^2 \left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]} = \sqrt{QME \left[\frac{1}{n} + \frac{\bar{X}^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}$$

Para o nosso exemplo, temos $QME = 2,8$, $n = 5$, $\bar{X} = 7$ e $\sum_{i=1}^n (X_i - \bar{X})^2 = 14$. Assim, o erro padrão do estimador do intercepto é:

$$s_{\alpha} = \sqrt{2,8 \left[\frac{1}{5} + \frac{7^2}{14} \right]} = \sqrt{2,8[0,2 + 3,5]} = \sqrt{10,36} \cong 3,22$$

Assim, sendo $\hat{\alpha} = 10,5$ $t_3 \cong 2,35$, o seu intervalo de confiança bilateral é:

$$10,5 \pm 2,35 \times 3,22 \cong 10,5 \pm 7,5 = (3; 18)$$

Também podemos calcular um intervalo de confiança para uma **predição individual**, isto é, para um valor da variável dependente em particular $\hat{Y}_0$, calculado a partir de um dado valor da variável independente X_0 :

$$\hat{Y}_0 = \hat{\alpha} + \hat{\beta} \cdot X_0$$

Considerando que essa estimativa também é baseada na distribuição de t-Student, o intervalo de confiança é construído com base nessa distribuição, similarmente ao que vimos para os demais intervalos de confiança:

$$\hat{Y}_0 \pm t_{GLE} \cdot s_Y = (\hat{Y}_0 - t_{GLE} \cdot s_Y; \hat{Y}_0 + t_{GLE} \cdot s_Y)$$

A diferença, em relação aos intervalos de confiança que vimos anteriormente, está no cálculo do erro padrão:

$$s_Y = \sqrt{\sigma_E^2 \left[1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]} = \sqrt{QME \left[1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}$$

Vale notar que o erro padrão da predição depende da **distância entre a observação X_0 e a média $\bar{X}$** , como observamos no gráfico anterior. Quanto **maior** for a relação entre o quadrado dessa diferença e a soma dos quadrados dos desvios da variável, **maior** será o erro padrão da predição.

Considerando o nosso exemplo $\hat{Y}_i = 10,5 - 0,36 \cdot X_i$, podemos calcular um intervalo de confiança para a predição correspondente a $x = 10$, por exemplo. A **estimativa** da variável dependente é:

$$\hat{Y}_0 = 10,5 - 0,36 \times 10 = 10,5 - 3,6 = 6,9$$

Sabendo que $QME = 2,8$, $n = 5$, $\bar{X} = 7$ e $\sum_{i=1}^n (X_i - \bar{X})^2 = 14$, a **variância** dessa estimativa é dada por:

$$s_Y^2 = 2,8 \left[1 + \frac{1}{5} + \frac{(10 - 7)^2}{14} \right] = 2,8 \left[1 + 0,2 + \frac{9}{14} \right] = 5,16$$



O **erro padrão** é a raiz quadrada desse resultado:

$$s_Y = \sqrt{s_Y^2} = \sqrt{5,16} \cong 2,27$$

Sendo $t_3 \cong 2,35$, o **intervalo de confiança** para essa predição é:

$$6,9 \pm 2,35 \times 2,27 \cong 6,9 \pm 5,3 = (1,6; 12,2)$$

Pontue-se que, para **amostras grandes**, podemos aproximar a distribuição de t-Student à distribuição **normal** e utilizar a tabela normal padrão.



(FGV/2022 – TJDF) Um estatístico utilizou um modelo de regressão linear simples, $Y = \beta_0 + \beta_1 X + \epsilon$, para fazer predições. O modelo, com 20 observações, foi bem ajustado, atendendo a todos os pressupostos necessários, e os resultados foram:

$\widehat{\beta}_0 = 5$; $\widehat{\beta}_1 = 1,5$; soma dos quadrados dos resíduos, 9; variância de x , 28; e média de x , 22.

O intervalo bilateral de 95% de confiança para predição quando $x = 18$ é, aproximadamente:

- a) $32 \pm 2,10 \cdot \sqrt{0,54}$
- b) $32 \pm 2,10 \cdot \sqrt{1,08}$
- c) $32 \pm 2,08 \cdot \sqrt{1,08}$
- d) $32 \pm 1,96 \cdot \sqrt{0,54}$
- e) $32 \pm 1,96 \cdot \sqrt{1,08}$

Essa prova forneceu a tabela t-Student para $P(T > t)$ (área da cauda superior) parcialmente replicada a seguir:

Grau de liberdade	Área da cauda superior				
	0,1	0,05	0,025	0,01	0,005
15	1,341	1,753	2,131	2,602	2,947
16	1,337	1,746	2,120	2,583	2,921
17	1,333	1,740	2,110	2,567	2,898
18	1,330	1,734	2,101	2,552	2,878
19	1,328	1,729	2,093	2,539	2,861
20	1,325	1,725	2,086	2,528	2,845

Comentários:



Essa questão pede o intervalo de confiança para a **predição** individual de Y, quando $x = 18$, dado por:

$$\hat{Y}_0 \pm t_{GLE} \cdot s_Y$$

Para isso, o primeiro passo é substituir $X_0 = 18$, na fórmula $\hat{Y}_0 = 5 + 1,5 \cdot X_0$:

$$\hat{Y}_0 = 5 + 1,5 \times 18 = 5 + 27 = 32$$

Em seguida, precisamos do valor tabelado da distribuição de t-Student. Por se tratar de um modelo de regressão linear **simples**, o número de graus de liberdade dos erros é:

$$GLE = n - 2$$

O enunciado informa que o número de observações é $n = 20$, logo:

$$GLE = 20 - 2 = 18$$

Para um nível de confiança bilateral de $95\% = 0,95$, a área da cauda superior é $P(T > t) = \frac{0,05}{2} = 0,025$.

Pela tabela, observamos que, para essa probabilidade, $t_{18} = 2,101 \cong 2,10$.

Por fim, precisamos calcular o erro padrão da predição, dado por:

$$s_Y = \sqrt{QME \left[1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]}$$

Para isso, precisamos do **quadrado médio dos erros** (ou resíduos):

$$QME = \frac{SQE}{GLE}$$

O enunciado informa que a soma dos quadrados dos resíduos (ou erros) é $SQE = 9$, logo:

$$QME = \frac{9}{18} = \frac{1}{2}$$

Também vamos precisar da **soma dos quadrados dos desvios de X**. Para isso, o enunciado informa a **variância amostral** de X, $s_X^2 = 28$. Sabendo que a variância amostral é a razão entre a soma dos quadrados dos desvios e $n - 1$, temos:

$$s_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

$$\sum_{i=1}^n (X_i - \bar{X})^2 = s_X^2 \times (n - 1) = 28 \times 19 = 532$$

Sabendo que a média é $\bar{X} = 22$, podemos calcular o **erro padrão**:

$$s_Y = \sqrt{\frac{1}{2} \left[1 + \frac{1}{20} + \frac{(18 - 22)^2}{532} \right]} = \sqrt{\frac{1}{2} \left[1 + 0,05 + \frac{16}{532} \right]} \cong \sqrt{\frac{1}{2} [1,08]} = \sqrt{0,54}$$

Portanto, o intervalo de confiança é $32 \pm 2,10 \cdot \sqrt{0,54}$.

Gabarito: A



Teste de Significância Individual

Podemos, ainda, conduzir um **teste de hipóteses** para avaliar a **significância das estimativas** de cada coeficiente linear. Embora possa ser conduzido em modelos de regressão linear simples, esse teste é especialmente útil em modelos de regressão linear múltipla, em que há múltiplos coeficientes lineares.

Considerando que as estimativas dos coeficientes lineares seguem distribuição de t-Student (por isso, chamamos esse teste de **teste t**), a **estatística do teste** consiste na fórmula da **transformação** para a distribuição padrão:

$$t = \frac{\hat{\beta}_i - \beta_0}{s_{\beta}}$$

Nessa fórmula, $\hat{\beta}_i$ é o valor estimado para o **coeficiente** da variável i em questão, β_0 é o valor do coeficiente indicado na **hipótese nula** e s_{β} é a estimativa para o **erro padrão** (ou desvio padrão) do estimador.

Em geral, a **hipótese nula** é de que **não existe relação linear** entre a variável explicativa e a variável explicada, ou seja, o valor verdadeiro do coeficiente em questão é **nulo**:

$$H_0: \beta_0 = 0$$

Assim, considerando essa hipótese nula, a **estatística do teste** consiste na **razão** entre a estimativa do coeficiente e o erro padrão do estimador:

$$t = \frac{\hat{\beta}_i}{s_{\beta}}$$

Sabendo que o erro padrão é sempre maior ou igual a zero, a estatística t terá o **mesmo sinal** da estimativa do coeficiente $\hat{\beta}_i$.

Em relação ao exemplo das notas dos alunos, em que o coeficiente linear calculado foi $\hat{\beta} = -0,36$, a **estatística do teste**, sob a hipótese nula $H_0: \beta_0 = 0$, sabendo que o erro padrão é $s_{\beta} = 0,45$, é dada por:

$$t = \frac{\hat{\beta}}{s_{\beta}} = \frac{-0,36}{0,45} = -0,8$$

Em geral, utilizamos o **teste bilateral**, em que rejeitaremos a hipótese nula de que o verdadeiro coeficiente é **nulo**, se o resultado for superior ao limite crítico máximo ou inferior ao limite crítico mínimo:

$$H_1: \beta_0 \neq 0$$




No entanto, a questão pode especificar um **outro valor** para a hipótese nula e/ou um **outro tipo de teste** (unilateral à esquerda ou à direita).

De todo modo, **rejeitaremos** a hipótese nula se o **p-valor** do teste foi **inferior** ao nível de significância α definido; e não rejeitamos a hipótese nula, caso contrário.

O p-valor é calculado com base na distribuição de **t-Student**, considerando o número de graus de liberdade dos erros ou resíduos **GLE**.

Para ilustrar, vamos considerar o nosso exemplo de regressão linear simples, em que $GLE = 3$. A seguir, replicamos a tabela (parcial) da distribuição de t-Student para $P(|T| > t) = P(T < -t) + P(T > t)$, isto é, para o teste **bilateral**.



GL \ p	0,5	0,4	0,3	0,2	0,1	0,05	0,02	0,01	0,005	0,002	0,001
1	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,656	127,321	318,289	636,578
2	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925	14,089	22,328	31,600
3	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841	7,453	10,214	12,924
4	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604	5,598	7,173	8,610
5	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032	4,773	5,894	6,869

Para 3 graus de liberdade, observamos que o valor absoluto da estatística do teste $|t| = 0,8$ está entre as probabilidades $p = 0,5$ (em que $t = 0,765$) e $p = 0,4$ (em que $t = 0,978$). Em outras palavras, o p-valor do nosso teste **bilateral** pertence ao **intervalo** de probabilidades:

$$p_{Bi} = P(|T| > 0,8) \in (0,4; 0,5)$$

$$0,4 < p_{Bi} < 0,5$$

Se o teste for **unilateral**, o p-valor é calculado com base em apenas um dos extremos. Nessa situação, precisamos **dividir** as probabilidades por **2**.

Se, em relação ao nosso exemplo, estivermos em um teste **unilateral** à esquerda, em que rejeitaríamos a hipótese nula se a estimativa para o coeficiente for apenas inferior ao limite crítico mínimo, o p-valor estaria no intervalo:

$$p_{Uni} = P(T < -0,8) \in (0,2; 0,25)$$

$$0,2 < p_{Uni} < 0,25$$

Pontue-se que, para **amostras grandes**, podemos aproximar a distribuição de t-Student à distribuição **normal** e utilizar a tabela normal padrão.



Enquanto o **teste F** representa o nível de significância **global** da reta de regressão, o **teste t** representa o nível de significância **individual** dos coeficientes.



Em modelos de **regressão linear simples**, a estatística F corresponde ao **quadrado** da estatística t , sob a hipótese nula $H_0: \beta_0 = 0$:

$$t^2 = F$$

Com essa fórmula, podemos calcular o valor de uma estatística a partir da outra. A partir da estatística F , podemos calcular o **módulo** da estatística t , que pode ser positiva ou negativa. O seu sinal será igual ao sinal da estimativa do coeficiente linear, sob a hipótese nula $H_0: \beta_0 = 0$.

Para o nosso exemplo, obtivemos $F = 0,64$, logo poderíamos calcular o módulo da estatística t , fazendo:

$$t = \pm\sqrt{0,64} = \pm 0,8$$

Que, de fato, é o valor de t que calculamos.



(FGV/2016 – IBGE - Adaptada) Um econometrista resolve propor e estimar um modelo de regressão linear simples como forma de estimar o efeito da temperatura sobre o volume de venda de sorvetes. Emprega, para esse fim, a formulação:

$$QS_i = \alpha + \beta \cdot T_i + \varepsilon_i, \quad i = 1, 2, 3, 4, \dots, 20$$

Onde QS é a quantidade de sorvetes (em milhares), T é a temperatura (célsius) e ε é o termo de erro do modelo.

Apenas estatísticas descritivas básicas sobre QS e T são dadas, como $\sigma_T^2 = 64$, $\sigma_{QS}^2 = 100$, $\mu_T = 24$ e $\mu_{QS} = 58$, $\sigma_{T, QS} = 48$, onde variâncias (σ^2), médias (μ) e covariância ($\sigma_{T, QS}$).

Supondo-se válidos todos os pressupostos clássicos, a partir das informações disponíveis, julgue o item:

Considerando que o estimador de β é igual a 0,75, então a estatística do teste t-Student de significância para esse estimador é igual a 1.

Comentários:



O item pede a estatística t do **teste de significância**. Como a questão não informa qual é a hipótese nula, presumimos a hipótese nula geral $H_0: \beta_0 = 0$. Nessa situação, a **estatística do teste** é dada por:

$$t = \frac{\hat{\beta}}{s_{\beta}}$$

O item informa que $\hat{\beta} = 0,75$ e, então, precisamos calcular o **erro padrão** desse estimador s_{β} .

A variância do estimador s_{β}^2 é a razão entre a variância do erro (QME) e a soma dos quadrados dos desvios da variável explicativa T :

$$s_{\beta}^2 = \frac{QME}{\sum_{i=1}^n (T_i - \bar{T})^2}$$

Sabendo que a **variância amostral** da variável explicativa T é a razão entre a soma dos quadrados dos desvios $\sum_{i=1}^n (T_i - \bar{T})^2$ e $n - 1$, então:

$$\sum_{i=1}^n (T_i - \bar{T})^2 = Var(T) \times (n - 1)$$

O enunciado informa que $Var(T) = 64$ e $n = 20$, logo:

$$\sum_{i=1}^n (T_i - \bar{T})^2 = 64 \times 19 = 1216$$

Para calcular o **quadrado médio dos erros**, precisamos das somas dos quadrados. A **soma total dos quadrados** pode ser calculada, em função da variância amostral da variável dependentes:

$$SQT = \sum_{i=1}^n (QS_i - \overline{QS})^2 = Var(QS) \times (n - 1) = 100 \times 19 = 1900$$

E a **soma dos quadrados do modelo**, como:

$$SQM = \hat{\beta}^2 \times \sum_{i=1}^n (T_i - \bar{T})^2 = (0,75)^2 \times 1216 = 684$$

A soma dos quadrados dos erros ou resíduos é a **diferença**:

$$SQE = SQT - SQM = 1900 - 684 = 1216$$

Por se tratar de um modelo de regressão linear, temos:

$$GLE = n - 2 = 20 - 2 = 18$$

Agora, podemos calcular o **quadrado médio do erro**:

$$QME = \frac{SQE}{GLE} = \frac{1216}{18}$$

E a **variância do estimador**:



$$s_{\hat{\beta}}^2 = \frac{QME}{\sum_{i=1}^n (T_i - \bar{T})^2} = \frac{1216}{18 \times 1216} = \frac{1}{18}$$

A estatística desejada é a razão entre a estimativa $\hat{\beta} = 0,75$ e a raiz quadrada da variância do estimador:

$$t = \frac{\hat{\beta}}{s_{\hat{\beta}}} = \frac{0,75}{\sqrt{\frac{1}{18}}} \cong 3,2$$

Assim, concluímos que o item está errado.

Resposta: Errado



RESUMO DA AULA

ANOVA

- ⇒ Comparar as **médias** de **3 ou mais** grupos (cada um com seu **tratamento**)
- ⇒ Hipótese nula: todas as médias são **iguais**; Hipótese alternativa: **pelo menos 1 é diferente**
- ⇒ Pressupostos: **Independência**; **Normalidade**; **Homocedasticidade** (variância constante)
- ⇒ **Soma total dos quadrados** = Soma dos quadrados tratamento + Soma dos quadrados erro

$$SQ_{Total} = SQ_{Trat} + SQ_{Erro}$$

- ⇒ **Graus de liberdade total** = Graus de liberdade do tratamento + Graus de liberdade do erro

$$GL_{Total} = GL_{Trat} + GL_{Erro}$$

- Graus de liberdade total = total de elementos – 1

$$GL_{Total} = N - 1$$

- Graus de liberdade do tratamento = número de tratamentos – 1

$$GL_{Trat} = k - 1$$

- Graus de liberdade do erro = total de elementos – número de tratamentos

$$GL_{Erro} = N - k$$

- ⇒ **Quadrado médio** = Soma dos quadrados / Graus de Liberdade

$$QM_{Trat} = \frac{SQ_{Trat}}{GL_{Trat}}$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}}$$

- Quadrado médio do erro QM_{Erro} = **estimativa da variância do erro**

- ⇒ **Estatística F do teste** = Quadrado médio do tratamento / quadrado médio do erro:

$$F = \frac{QM_{Trat}}{QM_{Erro}}$$



ANOVA da Regressão

⇒ Hipótese nula: **não** existe relação linear; Hipótese alternativa: **existe relação linear**

⇒ **Graus de Liberdade do Modelo** = Número de Variáveis Explicativas

⇒ **Coeficiente de determinação** = Soma dos quadrados do modelo / soma total dos quadrados

$$R^2 = \frac{SQ_{Modelo}}{SQ_{Totais}}$$

- Coeficiente de determinação = quadrado do coeficiente de correlação de Pearson R

⇒ **Coeficiente de determinação ajustado**:

$$R^2_{\alpha} = 1 - \frac{SQ_{Erro} / GL_{Erro}}{SQ_{Totais} / GL_{Totais}}$$

⇒ **Estatística t** (para $H_0: \beta_0 = 0$) = Valor do coeficiente / erro padrão:

$$t = \frac{\hat{\beta}}{s_{\beta}}$$

- Estatística F = quadrado da estatística t (para $H_0: \beta_0 = 0$): $t^2 = F$



QUESTÕES COMENTADAS – MULTIBANCAS

Conceitos Fundamentais

1. (COMPEC/2024 – UFAM) A aplicação apropriada da Análise de Variância depende do cumprimento de um conjunto de pressupostos. Os pressupostos relativos à exigência de que os erros tenham mesma variância e que sejam não correlacionados são, respectivamente,

- a) aditividade e normalidade.
- b) independência e homoscedasticidade.
- c) homoscedasticidade e independência.
- d) homoscedasticidade e normalidade.
- e) normalidade e aditividade.

Comentários:

A Análise de Variância pressupõe, em relação aos erros, que eles têm a mesma variância, o que chamamos de homoscedasticidade, e que eles são não correlacionados ou independentes.

Gabarito: C

2. (AOCP/2024 – PM/PE) Suponha que se deseje comparar, em média, a quantidade de certo produto tóxico apreendido, por ocorrência, nas cidades A, B, C e D. Então, para um período de tempo, obtiveram-se $n_A = n_B = n_C = n_D = n$ registros dos pesos do produto apreendido em cada cidade. Analisando os números, verificou-se que eles seguem a Distribuição Normal de Probabilidade e têm mesma variância.

Assim, para testar a hipótese de que os pesos do produto apreendido são iguais na média, ou seja, a hipótese nula $H_0: \mu_A = \mu_B = \mu_C = \mu_D = \mu$, deve-se aplicar aos dados a técnica estatística.

- a) do teste “t” de Student Clássico.
- b) do teste F na comparação das variâncias duas a duas.
- c) do teste “t” de Student na versão de Aspin-Welch.
- d) da Análise da Variância.
- e) do teste “t” de Student Pareado.

Comentários:

O teste que verifica se as médias de 3 ou mais grupos independentes são iguais, para populações normais com a mesma variância, é a Análise de Variância. A hipótese nula do teste é de que todas as médias são iguais, enquanto a hipótese alternativa é de que existe pelo menos uma média diferente.



Pontue-se que o teste t de Student compara as médias de 2 grupos, o que não atende, já que o enunciado informa que há 4 grupos; e que o teste F compara as variâncias, e não as médias.

Gabarito: D

3. (FGV/2024 – TJ/MS) Um pesquisador investiga a eficácia de três diferentes tratamentos para reduzir o colesterol no sangue. Ele divide aleatoriamente os pacientes em três grupos. Após um mês, realiza exames em cada paciente e deseja determinar se há diferença entre os tratamentos. A estatística de teste que deve ser usada para avaliar se há diferença significativa entre os tratamentos é:

- a) teste ANOVA (análise de variância);
- b) teste de Kruskal-Wallis;
- c) teste de Qui-Quadrado;
- d) teste t de Student;
- e) teste de Wilcoxon-Mann-Whitney.

Comentários:

O teste que avalia se as médias de 3 (ou mais) grupos são iguais ou se há diferença significativa entre elas é a ANOVA. É essa comparação de médias que permitirá avaliar os tratamentos.

Pontue-se que o teste de Kruskal-Wallis (B) é indicado apenas quando os pressupostos da ANOVA não são atendidos; o teste qui-quadrado (C) não é utilizado para comparar médias; o teste t de Student pode ser utilizado com apenas 2 grupos; e o teste de Wilcoxon (E) é um teste não paramétrico utilizado para comparar amostras pareadas (por exemplo, antes e depois de um tratamento).

Gabarito: A

4. (FGV/2024 – TCE/GO) Em relação à Análise da Variância (ANOVA), as afirmativas a seguir estão corretas, à exceção de uma. Assinale-a.

- a) É um método para testar a igualdade de três ou mais médias populacionais, baseado na análise das variâncias amostrais.
- b) Os dados amostrais são separados em grupos segundo uma característica denominada fator. Fator (ou tratamento) é uma característica que permite distinguir diferentes populações umas das outras.
- c) Cada fator contém dois ou mais grupos (classificações).
- d) Amostras são aleatórias e mutuamente dependentes.
- e) Suposições incluem: populações normalmente distribuídas e de mesma variância.

Comentários:



Precisamos identificar a alternativa INCORRETA em relação aos pressupostos da ANOVA. Em relação à alternativa A, a ANOVA realmente verifica se as médias de 3 ou mais grupos são iguais ou não, analisando a variação dos dados. Logo, a alternativa A está correta.

Em relação à alternativa B, a característica que o método estuda é chamada de fator ou tratamento, logo, a alternativa B está correta.

Em relação à alternativa C, o fator deve ter mais de uma classificação para distinguir as populações, logo a alternativa C está correta.

Em relação à alternativa D, as amostras devem ser aleatórias e **independentes** (não, dependentes). Logo, a alternativa D está errada.

Em relação à alternativa E, dentre as premissas da ANOVA, temos a normalidade e a homoscedasticidade (mesma variância), logo a alternativa E está correta.

Gabarito: D

5. (Cebbraspe/2022 – PC-PB) Deseja-se avaliar, por experimentos laboratoriais, amostras contendo uma mistura de proteínas e peptídeos, juntamente com outras moléculas, obtidas a partir de extratos vegetais. Em uma das etapas experimentais, os peptídeos foram enriquecidos nas amostras. Em outra etapa, a mistura de peptídeos foi diluída em ácido fórmico e submetida a uma análise cromatográfica e, em uma terceira etapa, peptídeos isolados por cromatografia foram analisados por espectrometria de massas. Sabe-se que em todas as amostras há um peptídeo de maior interesse, que é composto por 10 aminoácidos, sem repetições, e apresenta absorção máxima de luz no comprimento de onda de 215 nm. Com pertinência a essa situação hipotética, considere que amostras de 30 plantas nativas (chamadas de N), 30 plantas transgênicas (chamadas de T) e 30 plantas cultivadas em hidroponia (chamadas de H) tenham sido analisadas e tenha sido feita a quantificação da concentração em quantidade de matéria do peptídeo-alvo em cada amostra, com o objetivo de se determinar se há diferença estatisticamente significativa entre as plantas N, T e H. Observou-se que a distribuição dos valores de concentração do peptídeo é compatível com a distribuição normal, que as amostras foram obtidas de forma aleatória e independente e que há homogeneidade de variâncias.

Assinale a opção que corresponde ao teste estatístico que deve ser aplicado para detectar se há diferença significativa quanto à concentração do peptídeo entre quaisquer dos tipos de plantas, sendo este capaz de detectar a diferença se aplicado e calculado apenas uma vez, sem repetições do teste.

- a) qui quadrado
- b) ANOVA
- c) Levene
- d) t de Student
- e) Kolmogorov-Smirnov

Comentários:



O objetivo do teste é determinar se há diferença estatisticamente significativa entre as plantas N, T e H. O enunciado informa, ainda, que a distribuição é normal, que as amostras são aleatórias e independentes, e que há homogeneidade de variâncias (homocedasticidade).

Considerando que os seus pressupostos foram atendidos, o teste paramétrico que verifica se há diferença significativa entre as médias de 3 ou mais populações é a ANOVA.

Gabarito: B.

6. (VUNESP/2021 – EsFCEx) Ao realizar uma análise de variância (ANOVA), estamos interessados em fazer algumas comparações. Quanto aos pressupostos dessa análise, é correto afirmar que:

- a) os erros são variáveis aleatórias independentes de uma distribuição Normal com média zero e variância desconhecida.
- b) a hipótese nula do modelo da ANOVA é de que as variâncias entre os grupos sejam iguais.
- c) no modelo da ANOVA, a variável dependente (resposta) pode ser qualitativa ou quantitativa.
- d) para a estimação do modelo da ANOVA, deveremos utilizar somente os estimadores de máxima verossimilhança.
- e) no quadro da ANOVA, o “quadrado médio entre” representa a variância residual.

Comentários:

Em relação à alternativa A, como pressuposto da ANOVA, os erros devem ser independentes e seguir distribuição normal com média zero e a mesma variância, cujo valor é estimado a partir do modelo. Logo, a alternativa A está certa.

Em relação à alternativa B, a hipótese nula da ANOVA é de que as **médias** são iguais, não as variâncias. Logo, a alternativa B está errada.

Em relação à alternativa C, como os erros seguem distribuição normal, a variável dependente também segue tal distribuição, não podendo ser quantitativa. Logo, a alternativa C está errada.

Em relação à alternativa D, não há qualquer exigência quanto ao uso dos estimadores de máxima verossimilhança.

Em relação à alternativa E, as variações **entre** os grupos são atribuídas ao **tratamento**, enquanto as variações **dentro** dos grupos são atribuídas ao **resíduo**. Logo, a alternativa E está errada.

Gabarito: A



QUESTÕES COMENTADAS – MULTIBANCAS

Fundamentos do Teste

1. (IMPARH/2025 – CGM Fortaleza) Três grupos amostrais são fornecidos, cada um com $n = 5$ observações:

- Grupo 1: {10,12,11,13,14}
- Grupo 2: {20,22,19,21,23}
- Grupo 3: {30,32,31,33,34}

Calcule o valor da estatística F utilizada em Análise de Variância (ANOVA) para avaliar a diferença das médias entre grupos. É fornecido que a soma dos quadrados entre os grupos é igual a 1003,33 e a soma de quadrados total é 1033,33.

- a) F é aproximadamente 200,00, rejeitar H_0 .
- b) F é aproximadamente 4,50, não rejeitar H_0 .
- c) F é aproximadamente 0,005, rejeitar H_0 .
- d) F é aproximadamente 3,25, não rejeitar H_0 .

Comentários:

A estatística F é a razão entre o quadrado médio do tratamento (ou entre os grupos) e o quadrado médio do erro (ou dentro dos grupos). Por sua vez, o quadrado médio é a razão entre a soma dos quadrados e o número de graus de liberdade correspondente.

O enunciado informa que a soma dos quadrados entre os grupos é $SQ_{Entre} = 1003,33$. O número de graus de liberdade entre os grupos é igual ao número de tratamentos (ou grupos) menos 1. Sabendo que há 3 grupos, temos:

$$GL_{Entre} = 3 - 1 = 2$$

E o quadrado médio entre os grupos é a razão:

$$QM_{Entre} = \frac{SQ_{Entre}}{GL_{Entre}} = \frac{1003,33}{2} \cong 501,7$$

Por sua vez, a soma dos quadrados dentro dos grupos é a diferença entre a soma total dos quadrados (que o enunciado informa que é $SQ_{Total} = 1033,33$) e a soma dos quadrados entre os grupos:

$$SQ_{Total} = SQ_{Entre} + SQ_{Dentro} \rightarrow SQ_{Dentro} = SQ_{Total} - SQ_{Entre}$$
$$SQ_{Dentro} = 1033,33 - 1003,33 = 30$$

Similarmente, o número de graus de liberdade dentro dos grupos é a diferença entre o número total de graus de liberdade e o número de graus de liberdade entre os grupos:



$$GL_{Total} = GL_{Entre} + GL_{Dentro} \rightarrow GL_{Dentro} = GL_{Total} - GL_{Entre}$$

O número total de graus de liberdade é igual ao tamanho total da amostra menos 1. Sabendo que há 3 grupos com 5 elementos cada um, o tamanho da amostra é $n = 15$:

$$GL_{Total} = n - 1 = 14$$

Sabendo que $GL_{Entre} = 2$, então o número de graus de liberdade dentro dos grupos é a diferença:

$$GL_{Dentro} = 14 - 2 = 12$$

E o quadrado médio dentro dos grupos é:

$$QM_{Dentro} = \frac{SQ_{Dentro}}{GL_{Dentro}} = \frac{30}{12} = 2,5$$

E a estatística F é a razão:

$$F = \frac{QM_{Entre}}{QM_{Dentro}} = \frac{501,7}{2,5} \cong 200$$

Como esse valor é muito grande, vamos rejeitar a hipótese nula, mesmo para níveis de significância bem pequenos.

Gabarito: A

2. (VUNESP/2024 – EsFCEx) Um experimento foi conduzido em delineamento inteiramente casualizado com 3 tratamentos e 4 repetições, totalizando 12 unidades amostrais. Os resultados da Análise de Variância são observados na tabela a seguir.

Causas de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	F calculado
Tratamento	2	1.000	500	B
Resíduo	9	180	A	

Os valores de A e B são, respectivamente,

- a) 20 e 0,04
- b) 20 e 25
- c) 0,18 e 0,22
- d) 90 e 5,5.
- e) 90 e 0,18.

Comentários:

A estatística F é a razão entre o quadrado médio do tratamento e o quadrado médio do erro ou resíduo. A tabela fornece o quadrado médio do tratamento $QM_{Tratamento} = 500$.



Por sua vez, o quadrado médio do erro (valor A) é a razão entre a soma dos quadrados do erro e o número de graus de liberdade do erro:

$$A = QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{180}{9} = 20$$

E a estatística F (valor B) é a razão:

$$B = F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{500}{20} = 25$$

Gabarito: B

3. (VUNESP/2021 – EsFCEx) Um estudo, com o objetivo de avaliar o desempenho dos alunos submetidos a três diferentes métodos de ensino (A, B, C), selecionou aleatoriamente cinco alunos em cada um dos métodos e aplicou uma prova de conhecimentos específicos, em que a nota zero indica pior desempenho, e a nota 10, melhor desempenho. As notas dos alunos na prova estão apresentadas na tabela a seguir.

Método de Ensino	Notas				
A	3	4	6	5	7
B	6	1	7	3	8
C	0	9	3	5	8

Ao realizar uma análise de variância (ANOVA) para comparar os métodos de ensino, é correto afirmar que

- a) o Quadrado Médio do Erro é zero.
- b) existe diferença entre os três métodos, ao nível de significância 0,05.
- c) a Soma de Quadrados do Total é zero.
- d) o Quadrado Médio do Método é zero.
- e) a Soma de Quadrados do Total é maior do que a Soma de Quadrados do Erro.

Comentários:

Para analisar as alternativas, vamos começar calculando a média de cada método de ensino, que corresponde ao tratamento, que a questão chama de método, bem como a média geral:

Método de Ensino	Notas					Soma	Média
A	3	4	6	5	7	25	5
B	6	1	7	3	8	25	5
C	0	9	3	5	8	25	5
Total						75	5



Como as médias de todos os métodos são iguais à média geral ($\bar{x}_i = \bar{\bar{x}} = 5$), as diferenças entre a média do método e a média geral ($\bar{x}_i - \bar{\bar{x}}$) é nula e, conseqüentemente, a soma dos quadrados dos métodos também é nula:

$$SQ_{Met} = n. \sum_{i=1}^k (\bar{x}_i - \bar{\bar{x}})^2 = 0$$

Dessa forma, o quadrado médio do método, dado pela razão entre a soma dos quadrados do método e o seu número de graus de liberdade também é igual a zero, conforme indicado na alternativa D.

Isso significa que toda a variabilidade dos dados (e ela existe, uma vez que nem todos os valores são iguais à média geral, $\bar{\bar{x}} = 5$) decorre dos erros, assim as alternativas A e C estão erradas.

Ademais, a alternativa E está errada porque a soma total dos quadrados é igual à soma dos quadrados dos erros, nessa situação. De modo geral, a soma total dos quadrados é sempre maior ou igual à dos erros.

Para qualquer nível de significância, a conclusão desse teste será de que não existe diferença entre os tratamentos, o que torna a alternativa B errada.

Gabarito: D

4. (VUNESP/2021 – EsFCEx) Um estudo com 12 atletas de 3 equipes diferentes, com 4 atletas em cada equipe, visou a avaliar a distância percorrida por eles em um período de 12 minutos. Deseja-se saber, a um determinado nível de significância, se a distância média percorrida pelos atletas nas 3 equipes é a mesma. Considere as informações do quadro de análise de variância:

Fonte de Variação	Soma de Quadrados
Equipes	20
Erro	X
Total	20 + X

Se o valor da estatística F, utilizado para testar a igualdade da distância percorrida entre as equipes, é igual a 10, então X é igual a

- a) 9
- b) 5
- c) 13
- d) 1
- e) 17

Comentários:



A estatística F é a razão entre o quadrado médio do modelo (que a questão chama de equipes) e o quadrado médio do erro. Por sua vez, os quadrados médios são a razão entre a soma dos quadrados e o número de graus de liberdade:

$$F = \frac{QMM}{QME} = \frac{\frac{SQM}{GLM}}{\frac{SQE}{GLE}}$$

O número de graus de liberdade do modelo corresponde, no caso, ao número de equipes (3), menos 1:

$$GLM = k - 1 = 3 - 1 = 2$$

E o número de graus de liberdade do erro corresponde ao número total de indivíduos (12), menos o número de equipes (3):

$$GLE = N - k = 12 - 3 = 9$$

Pela tabela, observamos que a soma dos quadrados do modelo é $SQM = 20$ e que a soma dos quadrados dos erros é $SQE = X$. Sabendo que $F = 10$, podemos calcular o valor de X:

$$\frac{\frac{20}{2}}{\frac{X}{9}} = 10$$

$$10 \times \frac{9}{X} = 10$$

$$X = 9$$

Gabarito: A

5. (VUNESP/2020 – EsFCEx) Uma etapa de um estudo consiste em testar a hipótese de igualdade das médias de satisfação, a um nível de significância de 5%, correspondente aos tratamentos dados a 4 grupos independentes (I, II, III e IV), cada um contendo 10 observações obtidas aleatoriamente. Pelo quadro de análise de variância, obtiveram-se as seguintes informações:

Fonte de Variação	Soma de Quadrados
Tratamentos (entre grupos)	360
Erro (dentro dos grupos)	288
Total	648

O valor da estatística F obtida (F calculado) utilizada para a tomada de decisão é igual a

- a) 10,0
- b) 12,0
- c) 9,6



d) 15,0

e) 8,0

Comentários:

Para calcular a estatística F, primeiro vamos calcular os quadrados médios dos tratamentos e dos erros. Para isso, precisamos dos respectivos números de graus de liberdade.

O número de graus de liberdade do tratamento é igual ao número de grupos (no caso, 4), menos 1:

$$GL_{Trat} = 4 - 1 = 3$$

Sabendo que a soma dos quadrados dos tratamentos é $SQ_{Trat} = 360$, conforme indicado na tabela, o quadrado médio dos tratamentos é:

$$QM_{Trat} = \frac{360}{3} = 120$$

E o número de graus de liberdade dos erros é igual ao número total de observações, menos o número de tratamentos. Sabendo que há 10 observações para cada um dos 4 grupos, então o número total de observações é $10 \times 4 = 40$. E o número de graus de liberdade dos erros é:

$$GL_{Erro} = 40 - 4 = 36$$

Sabendo que a soma dos quadrados dos erros é $SQ_{Erros} = 288$, conforme indicado na tabela, o quadrado médio dos erros é:

$$QM_{Erro} = \frac{288}{36} = 8$$

E a estatística F é a razão entre o quadrado médio dos tratamentos e o quadrado médio dos erros:

$$F = \frac{QM_{Trat}}{QM_{Erro}} = \frac{120}{8} = 15$$

Gabarito: D

6. (VUNESP/2020 – Pref. Ilhabela) A prefeitura de um município, desejando realizar um planejamento turístico, desenvolveu um estudo com relação a 3 pontos turísticos (X, Y, e Z) localizados na cidade, sendo que cada turista consegue visitar um e somente um dos pontos em um determinado dia. O objetivo desse estudo consistia em testar, ao nível de significância de 5%, a igualdade das médias das notas de satisfação em cada ponto dadas pelos turistas. Em um dia, uma amostra aleatória de 27 turistas, 9 em cada ponto, formando 3 grupos independentes, foi retirada da população de turistas e anotado as notas de cada turista. Pelo quadro de análise de variância, observou-se que a soma dos quadrados, devido à fonte de variação entre grupos, foi igual a 24 e o valor da estatística F, utilizada para comparação com F tabelado (distribuição F de Snedecor), igual a 8. A fonte de variação total foi então igual a

a) 36

b) 42



- c) 48
d) 60
e) 72

Comentários:

O enunciado informa que o objetivo do teste é verificar a igualdade entre as médias, o que corresponde à ANOVA. Sabemos que há $k = 3$ grupos (tratamentos) e um total de $N = 27$ turistas (número total de elementos na amostra). Com base nesses dados, podemos calcular os números de graus de liberdade. O dos tratamentos é igual ao número de grupos, menos:

$$GL_{Trat} = 3 - 1 = 2$$

E o dos erros é igual ao número total de elementos na amostra, menos o número de tratamentos:

$$GL_{Erro} = 27 - 3 = 24$$

Ademais, o enunciado informa que a variação entre grupos (soma dos quadrados dos tratamentos) é $SQ_{Trat} = 24$ e que a estatística $F = 8$. A estatística F é a razão entre o quadrado médio dos tratamentos e o quadrado médio dos erros. Por sua vez, os quadrados médios correspondem à razão entre a soma dos quadrados e o número de graus de liberdade:

$$F = \frac{QM_{Trat}}{QM_{Erro}} = \frac{\frac{SQ_{Trat}}{GL_{Trat}}}{\frac{SQ_{Erro}}{GL_{Erro}}} = \frac{\frac{24}{2}}{\frac{SQ_{Erro}}{24}} = 8$$

$$12 \times \frac{24}{SQ_{Erro}} = 8$$

$$SQ_{Erro} = \frac{12 \times 24}{8} = 12 \times 3 = 36$$

E a soma dos quadrados totais é:

$$SQ_{Total} = SQ_{Erro} + SQ_{Trat} = 36 + 24 = 60$$

Gabarito: D

7. (FGV/2018 – ALERO) Suponha que se deseja testar a hipótese nula de que k médias populacionais são iguais (não há efeito de tratamento) contra a alternativa de que nem todas as médias são iguais (há efeito de tratamento) por meio de uma análise da variância de 1 fator usual, com base em um conjunto de n observações. Uma tabela ANOVA terá basicamente a seguinte estrutura:

Fonte de Variação	SQ	gl	Variância	Estatística F
Entre	SQE	a		
Dentro	SQD	b		
Total	SQT	c		



Os valores de a, b e c são respectivamente:

- a) $n-k, k-1, n-1$.
- b) $k-1, n-k, n-1$
- c) $k, n-k, n-1$.
- d) $n-k-1, k, n-1$.
- e) $k, n-k-1, n-1$.

Comentários:

Essa questão pede as fórmulas dos graus de liberdade. O número **total** de graus de liberdade GLT (que a tabela identifica como c) é igual ao número total de observações (n), menos 1:

$$c = GLT = n - 1$$

O número de graus de liberdade do **modelo** ou **entre** GLE (que a tabela identifica como a) é igual ao número de tratamentos (k), menos 1:

$$a = GLE = k - 1$$

E o número de graus de liberdade dos **erros** ou **dentro** GLD (que a tabela identifica como b) é igual à diferença:

$$b = GLD = GLT - GLE = n - 1 - (k - 1) = n - 1 - k + 1 = n - k$$

Portanto, temos $a = k - 1$; $b = n - k$; $c = n - 1$.

Gabarito: B

8. (FGV/2018 – ALERO) Suponha que se deseja testar a hipótese nula de que k médias populacionais são iguais (não há efeito de tratamento) contra a alternativa de que nem todas as médias são iguais (há efeito de tratamento) por meio de uma análise da variância de 1 fator usual, com base em um conjunto de n observações. Uma tabela ANOVA terá basicamente a seguinte estrutura:

Fonte de Variação	SQ	gl	Variância	Estatística F
Entre	SQE	a		
Dentro	SQD	b		
Total	SQT	c		

Obtidos corretamente os valores de SQE, SQD e SQT, o valor da estatística de teste F será dado por:

- a) $F = SQE(n - k)/SQT(k - 1)$
- b) $F = SQD(n - k)/SQD(k - 1)$



c) $F = SQE(n - k)/SQD(k - 1)$

d) $F = SQD(n - k)/SQT(k - 1)$

e) $F = SQT(n - k)/SQD(k - 1)$

Comentários:

A estatística F é a razão entre o quadrado médio do modelo ou entre QME e o quadrado médio dos erros ou dentro QMD:

$$F = \frac{QME}{QMD}$$

Por sua vez, o quadrado médio é a razão a soma dos quadrados e o respectivo número de graus de liberdade:

$$F = \frac{SQE / GLE}{SQD / GLD}$$

Essa fórmula pode ser reorganizada:

$$F = \frac{SQE}{GLE} \times \frac{GLD}{SQD} = \frac{SQE \times GLD}{SQD \times GLE}$$

Na questão anterior, vimos que o grau de liberdade entre (ou do tratamento) é $GLE = k - 1$; e que o grau de liberdade dentro (ou dos erros) é $GLD = n - k$. Assim, a estatística F é:

$$F = \frac{SQE \times (n - k)}{SQD \times (k - 1)}$$

Gabarito: C



QUESTÕES COMENTADAS – MULTIBANCAS

Número Distinto de Repetições

1. (Consulplan/2024 – TJ/MA) Um estudo foi realizado para comparar o tempo (em minutos) de execução de uma tarefa entre três grupos independentes de funcionários recém-contratados treinados com métodos distintos. Os dados obtidos são apresentados a seguir.

Treinamento	Média Amostral	Tamanho da Amostra
1	17,47	19
2	17,94	18
3	13,70	20

Considerando que os dados são normalmente distribuídos nos três grupos, realizou-se uma análise de variância para verificar se existe diferença significativa entre o tempo médio de realização da tarefa sob os três tipos de treinamento na população de funcionários. A soma de quadrados entre os grupos foi igual a 210 e a soma de quadrados total foi igual a 345. Se $F_{x,y}$ denota uma variável aleatória com distribuição F de Fisher com x graus de liberdade no numerador e y graus de liberdade no denominador, o p-valor do teste de hipóteses associado é dado por:

- a) $P(F_{2,54} > 27,5)$.
- b) $P(F_{3,53} > 27,5)$.
- c) $P(F_{2,54} > 42,0)$.
- d) $P(F_{54,2} > 42,0)$.

Comentários:

Para responder a essa questão, precisamos calcular a estatística F e conhecer o número de graus de liberdade do numerador e do denominador da distribuição.

O enunciado informa que a soma dos quadrados entre os grupos (ou do tratamento) foi $SQ_{Entre} = 210$. Ademais, sabemos que há $k = 3$ tratamentos e que o número de graus de liberdade entre os grupos é $GL_{Entre} = k - 1 = 2$. Logo, o quadrado médio entre os grupos é a razão:

$$QM_{Entre} = \frac{SQ_{Entre}}{GL_{Entre}} = \frac{210}{2} = 105$$

Por sua vez, a soma dos quadrados dentro dos grupos é a diferença entre a soma total dos quadrados (que o enunciado informa que é $SQ_{Total} = 345$) e a soma dos quadrados entre os grupos:

$$SQ_{Total} = SQ_{Entre} + SQ_{Dentro} \rightarrow SQ_{Dentro} = SQ_{Total} - SQ_{Entre}$$
$$SQ_{Dentro} = 345 - 210 = 135$$



Similarmente, o número de graus de liberdade dentro dos grupos é a diferença entre o número total de graus de liberdade e o número de graus de liberdade entre os grupos:

$$GL_{Total} = GL_{Entre} + GL_{Dentro} \rightarrow GL_{Dentro} = GL_{Total} - GL_{Entre}$$

O número total de graus de liberdade é igual ao tamanho total da amostra menos 1. Sabendo que há 19 elementos do grupo 1, 18 elementos do grupo 2 e 20 elementos do grupo 3, temos:

$$GL_{Total} = n - 1 = 19 + 18 + 20 - 1 = 56$$

Sabendo que $GL_{Entre} = 2$, então o número de graus de liberdade dentro dos grupos é a diferença:

$$GL_{Dentro} = 56 - 2 = 54$$

E o quadrado médio dentro dos grupos é:

$$QM_{Dentro} = \frac{SQ_{Dentro}}{GL_{Dentro}} = \frac{135}{54} = 2,5$$

E a estatística F é a razão:

$$F = \frac{QM_{Entre}}{QM_{Dentro}} = \frac{105}{2,5} = 42$$

Considerando que essa distribuição tem $GL_{Entre} = 2$ graus de liberdade no numerador e $GL_{Dentro} = 54$ graus de liberdade no denominador, o p-valor é a probabilidade de a distribuição $F_{2,54}$ superar a estatística observada $F = 42$.

Gabarito: C



QUESTÕES COMENTADAS – MULTIBANCAS

Análise de Variância da Regressão

1. (FGV/2025 – TRT 24ª Região) Considere que no ajuste de uma reta de regressão linear $Y = \beta_0 + \beta_1 X + \varepsilon$ a seguinte tabela de Análise da Variância (com dados parcialmente omitidos) foi obtida:

Fonte	Soma dos Quadrados	Graus de Liberdade	Média Quadrática
Regressão	4.800		
Resíduo			s^2
Total	10.190	99	

O valor de s^2 é igual a

- a) 50
- b) 55
- c) 60
- d) 65
- e) 70

Comentários:

Pela tabela fornecida, observamos que s^2 corresponde à média quadrática do resíduo (ou quadrado médio do erro). Para isso, precisamos calcular a soma dos quadrados do erro e o seu número de graus de liberdade.

A soma dos quadrados do erro corresponde à diferença entre a soma total dos quadrados e a soma dos quadrados do modelo de regressão, que constam na tabela:

$$SQ_{Total} = SQ_{Modelo} + SQ_{Erro} \rightarrow SQ_{Erro} = SQ_{Total} - SQ_{Modelo}$$

$$SQ_{Erro} = 10.190 - 4.800 = 5.390$$

Fazemos as mesmas contas em relação ao número de graus de liberdade, sabendo que o número de graus de liberdade do modelo de regressão é igual ao número de variáveis explicativas. Como há uma única variável explicativa (regressão simples), temos $GL_{Modelo} = 1$:

$$GL_{Total} = GL_{Modelo} + GL_{Erro} \rightarrow GL_{Erro} = GL_{Total} - GL_{Modelo}$$

$$GL_{Erro} = 99 - 1 = 98$$

Por fim, o valor buscado é a razão:

$$s^2 = QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{5.390}{98} = 55$$

Gabarito: B



2. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

Com nível de significância de 1%, o p-valor da tabela ANOVA indica que todos os coeficientes do modelo são estatisticamente significativos.

Comentários:

Pela tabela fornecida, observamos que o p-valor é $0,002 = 0,2\%$ e, portanto, inferior ao nível de significância fornecido no item, de 1%. Isso nos leva à rejeição da hipótese nula de que não existe relação linear entre as variáveis e concluímos que **pelo menos um** dos coeficientes é **diferente de zero**. Em outras palavras, o teste F da ANOVA não nos permite concluir a respeito de **todos** os coeficientes do modelo.

Gabarito: Errado

3. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O modelo é constituído por três coeficientes que foram estimados pelo método de mínimos quadrados ordinários.

Comentários:

Pela tabela, observamos que o número de graus de liberdade do modelo de regressão, que corresponde ao número de variáveis explicativas, é igual a 2. Cada variável explicativa acompanha um coeficiente e há, ainda, o intercepto da reta. Portanto, há realmente 3 coeficientes a serem estimados pelo modelo de regressão. O enunciado informa que foi utilizado o método de mínimos quadrados, logo, o item está correto.

Gabarito: Certo



4. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

A variância dos resíduos é inferior a 0,90.

Comentários:

Para estimar a variância dos resíduos, utilizamos o **quadrado médio do erro**. Pela tabela, observamos que o quadrado médio do erro é igual a 1, que é **superior** a 0,90.

Gabarito: Errado

5. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O valor da razão F é igual a 14.

Comentários:

O valor da estatística F é a razão entre o quadrado médio do modelo de regressão e o quadrado médio do erro, que constam na tabela fornecida:

$$F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{14}{1} = 14$$

Gabarito: Certo

6. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	



Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

A variância amostral da variável resposta (dependente) do modelo é igual a 14.

Comentários:

A variância amostral da variável resposta ou dependente, que em geral indicamos como Y , é igual ao quadrado médio total, ou seja, à razão entre a soma total dos quadrados e o número total de graus de liberdade (igual a $n - 1$):

$$s_Y^2 = \frac{SQ_{Total}}{n - 1} = \frac{SQ_{Total}}{GL_{Total}}$$

Para calcular a soma total dos quadrados, utilizamos a soma dos quadrados do modelo de regressão e do erro, que correspondem ao produto do quadrado médio pelo respectivo número de graus de liberdade:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} \rightarrow SQ_{Modelo} = QM_{Modelo} \times GL_{Modelo}$$

$$SQ_{Modelo} = 14 \times 2 = 28$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} \rightarrow SQ_{Erro} = QM_{Erro} \times GL_{Erro}$$

$$SQ_{Erro} = 1 \times 8 = 8$$

A soma total dos quadrados é a soma dos quadrados do modelo e do erro:

$$SQ_{Total} = SQ_{Modelo} + SQ_{Erro} = 28 + 8 = 36$$

E o número total de graus de liberdade pode ser calculado pela soma dos graus de liberdade do modelo e do erro:

$$GL_{Total} = GL_{Modelo} + GL_{Erro} = 2 + 8 = 10$$

A variância amostral da variável resposta é a razão:

$$s_Y^2 = \frac{36}{10} = 3,6$$

Gabarito: Errado

7. (CEBRASPE/2025 - TRF 6ª Região) Um modelo de regressão linear simples é especificado como $Y_i = \alpha + X_i \cdot \beta + \varepsilon_i$ em que $E[\varepsilon_i] = 0$ e $Var[\varepsilon_i] = \sigma^2$. Para estimadores α' e β' , o valor do predito para observação i (Y'_i) com característica X_i é dado por $Y'_i = \alpha' + X_i \cdot \beta'$. O resíduo para observação i (ε'_i) é definido como $\varepsilon'_i = Y_i - Y'_i$.

De uma amostra aleatória de tamanho 49, coletada da população desse modelo de regressão linear simples, obteve-se:



- $\sum_i (Y_i - Y'_i)^2 = 17.173$ e
- $\sum_i (Y'_i - m_y)^2 = 36.464$, em que m_y é a média amostral de Y

Em relação às informações precedentes, julgue o item a seguir, considerando que o percentil 95% de uma distribuição F, com 1 grau de liberdade no numerador e 47 graus de liberdade no denominador, é igual a 4,05, e que o percentil 95% de uma distribuição qui-quadrado com 47 graus de liberdade é 64.

Se ε segue uma distribuição normal, o teste de hipótese da hipótese nula que $\beta=0$ contra a alternativa de $\beta \neq 0$ leva à rejeição da hipótese nula ao nível de significância de 5%.

Comentários:

A questão se refere ao teste F (ANOVA) para regressão, cuja estatística é a razão entre o quadrado médio do modelo e o quadrado médio do erro:

$$F = \frac{QM_{Modelo}}{QM_{Erro}}$$

O quadrado médio do modelo é igual à soma dos quadrados do modelo, associada à diferença entre a estimativa e a média (fornecida no enunciado), dividida pelo número de graus de liberdade do modelo, sendo este igual a 1, na regressão linear simples:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} = \frac{SQ_{Modelo}}{1} = SQ_{Modelo} = 36.464$$

O quadrado médio do erro é igual à soma dos quadrados do erro, associada à diferença entre o verdadeiro valor de Y e a sua estimativa (fornecida no enunciado), dividida pelo número de graus de liberdade do erro, sendo este igual ao número de observações menos 2, na regressão linear simples:

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{SQ_{Erro}}{n - 2} = \frac{17.173}{47} \cong 365$$

E a estatística é:

$$F \cong \frac{36.464}{365} \cong 100$$

Para tomar a decisão do teste, precisamos comparar a estatística com o valor tabelado da distribuição F, com $GL_{Modelo} = 1$ grau de liberdade no numerador e $GL_{Erro} = n - 2 = 47$ graus de liberdade no denominador, para o nível de significância desejado.

O enunciado informa que o percentil 95% dessa distribuição (o que corresponde ao nível de 5% de significância) é igual a 4,05.

Como a estatística é (muito) superior ao valor tabelado, devemos **rejeitar** a hipótese nula do teste de que o verdadeiro coeficiente linear β é **nulo** (e assim concluir que o modelo de regressão é adequado).

Gabarito: Certo



8. (CEBRASPE/2025 - TRF 6ª Região) Um modelo de regressão linear simples é especificado como $Y_i = \alpha + X_i \cdot \beta + \varepsilon_i$ em que $E[\varepsilon_i] = 0$ e $Var[\varepsilon_i] = \sigma^2$. Para estimadores α' e β' , o valor do predito para observação i (Y'_i) com característica X_i é dado por $Y'_i = \alpha' + X_i \cdot \beta'$. O resíduo para observação i (ε'_i) é definido como $\varepsilon'_i = Y_i - Y'_i$. De uma amostra aleatória de tamanho 49, coletada da população desse modelo de regressão linear simples, obteve-se:

- $\sum_i (Y_i - Y'_i)^2 = 17.173$ e
- $\sum_i (Y'_i - m_y)^2 = 36.464$, em que m_y é a média amostral de Y

Em relação às informações precedentes, julgue o item a seguir, considerando que o percentil 95% de uma distribuição F, com 1 grau de liberdade no numerador e 47 graus de liberdade no denominador, é igual a 4,05, e que o percentil 95% de uma distribuição qui-quadrado com 47 graus de liberdade é 64.

$$\sum_i (Y_i - m_Y)^2 = 53.637.$$

Comentários:

O enunciado fornece a soma dos quadrados do modelo, associada à diferença entre o valor da estimativa de Y e a média ($\sum_i (Y'_i - m_y)^2$); e a soma dos quadrados dos erros, associada à diferença entre o verdadeiro valor de Y e a sua estimativa ($\sum_i (Y_i - Y'_i)^2$).

A soma total dos quadrados, associada à diferença entre o verdadeiro valor de Y e a média, que o item pede, é igual à soma dos quadrados do modelo, mais a soma dos quadrados do erro:

$$\begin{aligned} \sum_i (Y_i - m_Y)^2 &= \sum_i (Y'_i - m_y)^2 + \sum_i (Y_i - Y'_i)^2 \\ \sum_i (Y_i - m_Y)^2 &= 36.464 + 17.173 = 53.637 \end{aligned}$$

Gabarito: Certo

9. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X₁	5,0	0,05
X₂	-3,0	0,03
X₃	0,2	0,20
X₄	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R²)	60%
Erro quadrático médio	36



As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O valor do R^2 ajustado (R^2_{ajustado}) é superior a 60%.

Comentários:

O coeficiente de determinação ajustado (R^2_{ajustado}) é sempre menor ou igual ao não ajustado (R^2). Pela tabela, observamos que o coeficiente de determinação (R^2) é igual a 60%, logo, o coeficiente de determinação ajustado é **inferior** a 60%.

Gabarito: Errado

10. (CEBRASPE/2025 - FUNPRESP-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O coeficiente de explicação deverá aumentar se a variável X_2 for retirada do modelo.

Comentários:

O coeficiente de determinação (ou de explicação) sempre **aumenta** quando **acrescentamos** uma nova variável ao modelo. Desse modo, quando **retiramos** uma variável do modelo, o coeficiente irá **reduzir**.

Gabarito: Errado



11. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X ₁	5,0	0,05
X ₂	-3,0	0,03
X ₃	0,2	0,20
X ₄	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R ²)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X₁, X₂, X₃ e X₄) para modelar uma variável dependente Y. As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R²) e o erro quadrático médio desse modelo, que foi igual a 36.

Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

Se a variável Y for considerada normal, e assumindo-se que a aproximação normal seja válida para a distribuição dos estimadores dos coeficientes do modelo, é correto concluir que todos os coeficientes são estatisticamente significativos com p-valores inferiores a 1%.

Comentários:

Para determinar se os coeficientes são estatisticamente significativos, utilizamos o teste de significância individual, cuja estatística do teste é dada pela razão entre a estimativa do coeficiente e o seu erro padrão.

Considerando os dados apresentados na primeira tabela, temos:

$$t_0 = \frac{10}{3} = 3,33$$

$$t_1 = \frac{5}{0,05} = 100$$

$$t_2 = \frac{-3}{0,03} = -100$$

$$t_3 = \frac{0,2}{0,2} = 1$$

$$t_4 = \frac{0,01}{0,001} = 10$$



Cada estatística deve ser comparada ao valor tabelado da distribuição de t-Student, cujo grau de liberdade é igual ao número de graus de liberdade dos erros. No entanto, o item assume a aproximação dessa distribuição à normal.

Na distribuição normal padrão, sabemos que a probabilidade de $|Z| > 3$ é inferior a 1%, logo, os p-valores dos coeficientes são inferiores a 1%, **exceto** para o coeficiente associado à variável X_3 . Sabendo que $P(|Z| \leq 1) = 68\%$, temos:

$$p_3 = P(|Z| > 1) = 1 - 0,68 = 0,32$$

Assim, concluímos que o coeficiente de X_3 **não** é estatisticamente significativo.

Gabarito: Errado

12. (CEBRASPE/2025 - FUNPRESP-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y. As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36.

Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O desvio padrão dos resíduos do modelo de regressão é igual a 6.

Comentários:

O erro quadrático médio (EQM) corresponde ao quadrado médio dos erros, isto é, à estimativa da variância dos erros (ou resíduos). Sabendo que o EQM é igual a 36, conforme indicado na segunda tabela, então o desvio padrão dos resíduos é a raiz quadrada:

$$\sigma = \sqrt{\sigma^2} = \sqrt{36} = 6$$

Gabarito: Certo



13. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X ₁	5,0	0,05
X ₂	-3,0	0,03
X ₃	0,2	0,20
X ₄	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R ²)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X₁, X₂, X₃ e X₄) para modelar uma variável dependente Y. As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R²) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

A variância amostral da variável dependente Y é superior a 85.

Comentários:

Vamos utilizar as informações fornecidas nas tabelas, para calcular a variância amostral de Y.

O erro quadrático médio (EQM) corresponde ao quadrado médio dos erros, que, por sua vez, é igual à razão entre a soma dos quadrados dos erros e o número de graus de liberdade dos erros:

$$EQM = QM_{Erros} = \frac{SQ_{Erros}}{GL_{Erros}}$$

Já o número de graus de liberdade dos erros é a diferença entre o número total de graus de liberdade (n-1) e o número de graus de liberdade do modelo (igual ao número de variáveis explicativas). Pela primeira tabela, observamos que há 4 variáveis explicativas e, pela segunda tabela, observamos que n = 106, logo:

$$GL_{Erro} = GL_{Total} - GL_{Modelo} = n - 1 - k = 106 - 1 - 4 = 101$$

Sabendo que o EQM = 36, então a soma dos quadrados dos erros é:

$$36 = \frac{SQ_{Erros}}{101}$$

$$SQ_{Erros} = 101 \times 36 = 3636$$

Conhecendo o coeficiente de determinação, podemos calcular a soma total dos quadrados:

$$R^2 = 1 - \frac{SQ_{Erros}}{SQ_{Total}}$$



$$0,6 = 1 - \frac{3636}{SQ_{Total}}$$

$$\frac{3636}{SQ_{Total}} = 0,4$$

$$SQ_{Total} = \frac{3636}{0,4} = 9090$$

Finalmente, a variância amostral é igual à soma total dos quadrados, dividida por $n - 1$ (que corresponde ao quadrado médio total):

$$s_Y^2 = \frac{SQ_{Total}}{n - 1} = \frac{9090}{106 - 1} \cong 86,6$$

Que é superior a 85.

Gabarito: Certo

14. (CEBRASPE/2024 - ANTT) Julgue o item seguinte, referente a regressão linear e séries temporais.

Para o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$, em que $\varepsilon \sim N(0, \sigma^2)$ é uma variável aleatória independente de X , se $Y' = \beta_0 + \beta_1 X$, então $E[(Y - EY)^2] = E[Y' - EY]^2$.

Comentários:

A esperança $E[(Y - E(Y))^2]$ corresponde à variância de Y :

$$Var(Y) = E[(Y - E(Y))^2]$$

E a esperança $E[Y' - E(Y)]^2$ corresponde à variância da estimativa Y' , uma vez que a média de Y' é igual à média da variável Y (pois a média dos erros ε é nula):

$$Var(Y') = E[(Y' - E(Y'))^2] = E[(Y' - E(Y))^2]$$

Em outras palavras, o item afirma que a variância de Y é igual à variância de Y' . No entanto, essas variâncias não são iguais. Enquanto a variância de Y pode ser estimada pela variância amostral, que corresponde ao quadrado médio total, a variância da estimativa Y' é dada por:

$$Var(Y') = \sigma^2 \left[1 + \frac{1}{n} + \frac{(X_0 - \bar{X})^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]$$

Em que a variância dos erros σ^2 pode ser estimada pelo quadrado médio dos erros.

Gabarito: Errado

15. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$.



Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Na análise de adequação do modelo, é fundamental verificar se a variância dos resíduos não depende da variável X .

Comentários:

De fato, uma das premissas do modelo de regressão é de que a variância dos erros (ou resíduos) é **constante** (homoscedasticidade). Assim, a variância realmente não pode depender de X .

Gabarito: Certo

16. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Para um modelo de regressão que não seja simples, a soma dos resíduos não será nula.

Comentários:



Outra premissa do modelo de regressão é de que a esperança (ou média) dos erros (ou resíduos) é **nula**. Assim, mesmo que os erros não sigam uma distribuição normal, os erros positivos devem compensar, em média, os erros negativos, ou seja, a soma deve ser nula.

Gabarito: Errado

17. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

O coeficiente de determinação para um modelo de regressão linear é definido como $r^2 = (SQT - SQE)/SQT$ e sua raiz quadrada corresponde ao coeficiente de correlação linear entre as variáveis Y e X .

Comentários:

O coeficiente de determinação é a razão entre a soma dos quadrados do modelo e a soma total dos quadrados:

$$R^2 = \frac{SQM}{SQT}$$

Sabendo que a soma dos quadrados do modelo pode ser calculada pela diferença entre a soma total dos quadrados e a soma dos quadrados dos erros, $SQM = SQT - SQE$, então:

$$R^2 = \frac{SQT - SQE}{SQT}$$

Que corresponde à expressão indicada no item. Ademais, o coeficiente de determinação é o quadrado do coeficiente de correlação.

Gabarito: Certo



18. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Um estimador não viciado para a variância de $\hat{\beta}_1$ é obtido pela variância amostral dada por $S^2 = SQE / [(n - 2) \sum_i (X_i - \bar{X})^2]$, em que $\bar{X} = \sum_i X_i / n$ e a variável centralizada de $\hat{\beta}_1$, normalizada por S , tem uma distribuição *t de Student* com $n - 1$ graus de liberdade.

Comentários:

A variância do estimador $\hat{\beta}_1$ do coeficiente angular é dado pela razão entre o quadrado médio dos erros e a soma dos quadrados da variável independente:

$$s_{\hat{\beta}_1}^2 = \frac{QME}{\sum_i (X_i - \bar{X})^2}$$

Em que o quadrado médio dos erros (QME) é a razão entre a soma dos quadrados dos erros (SQE) e o número de graus de liberdade dos erros (GLE). Quando há uma única variável explicativa, temos $GLE = n - 2$, logo:

$$s_{\hat{\beta}_1}^2 = \frac{SQE}{(n - 2) \cdot \sum_i (X_i - \bar{X})^2}$$

Que é igual à expressão indicada no item.

No entanto, o estimador $\hat{\beta}_1$ segue distribuição de t-Student com $GLE = n - 2$ (e não $n - 1$) graus de liberdade. Logo, o item está errado.

Gabarito: Errado

19. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana.



Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Considere que, para uma regressão linear simples da relação $Y = \beta_0 + \beta_1 X$, em uma amostra de 32 valores de X , obteve-se: $\hat{\beta}_1 = 2$ como estimativa para β_1 ; soma dos quadrados dos resíduos igual a 600; e $\sum_i (X_i - \bar{X})^2 = 2.000$, em que $\bar{X}$ é a média dos valores de X na amostra. Considere ainda que tenha sido feito o teste da hipótese de não existir a relação linear $Y = \beta_0 + \beta_1 X$, tomando-se como hipótese nula que $\beta_1 = 0$. Nessas condições, assumindo um teste com erro de tipo I igual a 5%, é correto afirmar que a hipótese de não existir a relação linear deve ser aceita.

Comentários:

Para verificar se existe a relação linear $Y = \beta_0 + \beta_1 X$, podemos utilizar o teste de significância individual para o coeficiente angular, em que a hipótese nula é $\beta_1 = 0$, como descrito no enunciado. A estatística desse teste é dada por:

$$t = \frac{\hat{\beta}_1}{s_{\beta_1}}$$

Em que o erro padrão do estimador pode ser calculado como:

$$s_{\beta_1} = \sqrt{\frac{QME}{\sum_i (X_i - \bar{X})^2}} = \sqrt{\frac{SQE}{(n - 2) \cdot \sum_i (X_i - \bar{X})^2}}$$

O enunciado informa que a soma dos quadrados dos erros (ou resíduos) é $SQE = 600$, que o tamanho da amostra é $n = 32$ e que $\sum_i (X_i - \bar{X})^2 = 2.000$, logo:

$$s_{\beta_1} = \sqrt{\frac{600}{(32 - 2) \times 2.000}} = \sqrt{\frac{600}{30 \times 2.000}} = \sqrt{\frac{20}{2.000}} = \sqrt{\frac{1}{100}} = \frac{1}{10}$$

Sabendo que $\hat{\beta}_1 = 2$, a estatística do teste é dada por:

$$t = \frac{2}{1/10} = 20$$

Como a estatística do teste é (muito) superior ao limite crítico, **rejeitamos** a hipótese nula de que o coeficiente angular é nulo e, assim, concluímos que **existe** relação linear entre X e Y .

Gabarito: Errado



20. (CEBRASPE/2024 - CODEVASF)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon_y$ em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81. Com base na situação hipotética apresentada, julgue o seguinte item.

A estimativa de σ é igual ou superior a 1.

Comentários:

A estimativa da variância do erro aleatório é dada pelo quadrado médio do erro, que é a razão entre a soma dos quadrados do erro e o número de graus de liberdade:

$$\hat{\sigma}^2 = QM_{Erro} = \frac{SQ_{Erros}}{GL_{Erros}}$$

O número de graus de liberdade do erro corresponde à diferença entre o número total de graus de liberdade e o número de graus de liberdade do modelo de regressão:

$$GL_{Total} = GL_{Erros} + GL_{Modelo} \rightarrow GL_{Erros} = GL_{Total} - GL_{Modelo}$$

O número total de graus de liberdade é $n - 1$, em que $n = 81$ é o tamanho da amostra, logo:

$$GL_{Total} = n - 1 = 80$$

E o número de graus de liberdade do modelo é igual ao número de variáveis explicativas. Pela equação fornecida, observamos que há 2 variáveis explicativas, x_1 e x_2 , logo:

$$GL_{Modelo} = 2$$

E o número de graus de liberdade do erro é a diferença:

$$GL_{Erros} = 80 - 2 = 78$$

Pela tabela, observamos que $SQ_{Erros} = 39$, logo, a estimativa da variância é:

$$\hat{\sigma}^2 = \frac{39}{78} = 0,5$$

E o desvio padrão é a raiz quadrada:

$$\hat{\sigma} = \sqrt{0,5} \cong 0,7$$

Que é inferior a 1.

Gabarito: Errado



21. (CEBRASPE/2024 - CODEVASF)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon_y$ em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81. Com base na situação hipotética apresentada, julgue o seguinte item.

O valor da razão F do teste linear geral, cuja hipótese nula é $H_0: \beta_0 = \beta_1 = \beta_2 = 0$ é igual ou inferior a 10.

Comentários:

O valor da estatística F é a razão entre o quadrado médio do modelo de regressão e o quadrado médio do erro. No item anterior, calculamos o quadrado médio do erro:

$$QM_{Erro} = \frac{SQ_{Erros}}{GL_{Erros}} = \frac{39}{78} = 0,5$$

Assim como o número de graus de liberdade do modelo:

$$GL_{Modelo} = 2$$

Sabendo que a soma dos quadrados do modelo é $SQ_{Modelo} = 281$, então o quadrado médio do modelo é:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} = \frac{281}{2} = 140,5$$

E a estatística F do teste é a razão:

$$F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{140,5}{0,5} = 281$$

Que é **superior** a 10.

Gabarito: Errado

22. (VUNESP/2024 – APS) Na Análise de Variância de um modelo de regressão linear simples obteve-se um valor de Soma de Quadrados de Regressão de 9,5 e Soma de Quadrados de Resíduos de 3,8. Sabendo que havia 1 grau de liberdade para a regressão e 19 graus de liberdade para os resíduos, e considerando o valor tabelado $F_{1;19;5\%} = 2,99$, é correto afirmar que:

- a estatística F calculada será 0,2, logo, não se rejeita a hipótese nula, ou seja, a regressão não é significativa.
- a estatística F calculada será 2,5, logo, não se rejeita a hipótese nula, ou seja, a regressão não é significativa.



- c) a estatística F calculada será 5,7, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.
d) a estatística F calculada será 36,1, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.
e) a estatística F calculada será 47,5, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.

Comentários:

A estatística F é a razão entre o quadrado médio do modelo de regressão e o quadrado médio do erro. Por sua vez, o quadrado médio é a razão entre a soma dos quadrados e o número de graus de liberdade, que o enunciado informa:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} = \frac{9,5}{1} = 9,5$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{3,8}{19} = 0,2$$

E a estatística é a razão:

$$F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{9,5}{0,2} = 47,5$$

Como a estatística é superior ao valor tabelado, qual seja $F_{1;19;5\%} = 2,99$, rejeitamos a hipótese nula de que não existe relação linear e concluímos que o modelo é significativo.

Gabarito: E

23. (AOCP/2024 – Pref. Uberaba) A prefeitura de uma cidade, visando planejar o imposto predial e territorial, solicitou a uma imobiliária os preços (Y, em mil reais) de casas aleatoriamente selecionadas de um bairro cujos moradores têm alto poder aquisitivo, as correspondentes idades das casas (x_1 , em anos) e o tamanho (x_2 , em metros quadrados). Uma tabela de análise de variância (ANOVA) foi construída para os dados observados, conforme apresentado a seguir.

Fonte	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	F-Snedecor	p-valor
Regressão	2	827,026	413,5	2,57	0,299
Resíduos	3	482,700	160,9		
Total	5	1309,726			

Considerando as informações contidas na tabela ANOVA, é correto afirmar que

- a) a regressão é significativa ao nível de 5% no teste F de Snedecor.
b) não é possível estimar a variância dos erros.
c) pelo teste F para as hipóteses " $H_0: \beta_1 = \beta_2 = 0$ contra H_1 : pelo menos um dos $\beta_i \neq 0$ " com base no valor p, não se pode rejeitar a hipótese nula para nível de significância menor do que 30%.
d) $R^2=0,99$



Comentários:

Precisamos analisar as alternativas, considerando a tabela fornecida, que apresenta todos os valores referentes à ANOVA.

Em relação à alternativa A, observamos que o p-valor do teste é $p = 0,299 = 29,9\%$. Assim, para o nível de significância $\alpha = 5\%$, temos $p > \alpha$, o que nos leva à não rejeição da hipótese nula, ou seja, concluímos que a regressão não é significativa. Logo, a alternativa A está errada.

Similarmente, verificamos que a alternativa C está correta, porque não podemos rejeitar a hipótese nula para um nível de significância menor que 30%, já que o p-valor é igual a 29,9%.

Em relação à alternativa B, a variância dos erros é estimada pelo quadrado médio dos resíduos, que a tabela fornece:

$$\hat{\sigma}^2 = QM_{\text{Erros}} = 160,9$$

Logo, a alternativa B está errada.

Em relação à alternativa D, o coeficiente de determinação é a razão entre a soma dos quadrados do modelo de regressão e a soma total dos quadrados:

$$R^2 = \frac{SQ_{\text{Modelo}}}{SQ_{\text{Total}}} = \frac{827,026}{1309,726} \cong 0,63$$

E não 0,99, logo a alternativa D está errada.

Gabarito: C

24. (FGV/2022 – EPE) O seguinte modelo de regressão múltipla foi estimado por Mínimos Quadrados Ordinários com o objetivo de fazer previsões para o preço de 21 ativos da área de petróleo de uma amostra aleatória:

$$\ln(\text{preço}) = 5,25 + 2,05 \ln(\text{preçoaval}) + 3,10 \text{ Brent} + 1,10 \text{ cam} + 0,82 \text{ Ibov} + 0,75 \text{ Prod}$$

em que o preço e o preçoaval são, respectivamente, preço de venda e preço de avaliação do ativo, em reais; Brent é a cotação diária do barril; cam é a cotação cambial ao fim do dia para a compra; Ibov é o índice da bolsa de valores de São Paulo e Prod é a produção diária de petróleo.

Outras informações importantes do modelo:

$$R^2 = 0,87; \text{SQT} = 6; \hat{\sigma} = 0,15$$

na qual R^2 é o coeficiente de explicação do modelo, SQT é a soma dos quadrados totais e $\hat{\sigma}$ é o desvio padrão estimado.

Para a resolução dessa questão talvez seja útil saber que se Z tem distribuição normal padrão, então:

$$P(|Z| > 1,645) = 0,10 \text{ e } P(|Z| > 1,96) = 0,05.$$

Com base nos dados acima, o valor da estatística de significância da regressão é, aproximadamente, igual a



- a) 2;
- b) 5;
- c) 12;
- d) 15;
- e) 20.

Comentários:

A questão pede a estatística de significância da regressão, que consiste na razão entre o quadrado médio do modelo (QMM) e o quadrado médio dos erros (QME). Por sua vez, o quadrado médio corresponde à razão entre a soma dos quadrados e o número de graus de liberdade:

$$F = \frac{QMM}{QME} = \frac{SQM/GLM}{SQE/GLE}$$

O enunciado informa que a soma total dos quadrados é $SQT = 6$ e que o coeficiente de determinação é $R^2 = 0,87$. Com base nisso, podemos calcular a soma dos quadrados do modelo:

$$R^2 = \frac{SQM}{SQT}$$

$$SQM = R^2 \times SQT = 0,87 \times 6 = 5,22$$

E sabemos que a soma dos quadrados dos erros é a diferença entre a soma total dos quadrados e a soma dos quadrados do modelo:

$$SQE = SQT - SQM = 6 - 5,22 = 0,78$$

Vejamos agora os graus de liberdade. O número de graus de liberdade do modelo corresponde ao número de variáveis explicativas (ou ao número total de variáveis, menos 1). Pela equação fornecida, observamos que há 5 variáveis explicativas (ou 6 variáveis ao total), logo:

$$GLM = 5$$

Para obter o número de graus de liberdade dos erros, precisamos do número total de graus de liberdade, que por sua vez corresponde ao número de elementos analisados, menos 1. O enunciado informa que há 21 ativos na amostra, portanto:

$$GLT = N - 1 = 21 - 1 = 20$$

E o número de graus de liberdade dos erros é a diferença entre o número total de graus de liberdade e o número de graus de liberdade do modelo:

$$GLE = GLT - GLM = 20 - 5 = 15$$

Agora, temos todos os dados para calcular a estatística F do teste:



$$F = \frac{SQM/GLM}{SQE/GLE} = \frac{5,22/5}{0,78/15} = \frac{5,22}{0,78/3} = \frac{5,22}{0,26} \cong 20,08$$

Gabarito: E

25. (FGV/2022 – SEFAZ/ES) As informações a seguir referem-se aos resultados parciais da aplicação de um modelo de regressão linear simples, $Y = \beta_0 + \beta_1 X_1 + \epsilon$, em uma amostra aleatória simples de 60 pares de observações.

Alguns dos resultados aproximados foram:

- $\sum_{i=1}^{60} (Y_i - \bar{Y})^2 = 5.350$
- $\frac{1}{58} \sum_{i=1}^{60} (Y_i - \hat{Y})^2 = 16,98$
- $F_{calculado} = 257,21$
- $F_{significância} = 5,50E - 23$
- Intercepto = 34,52; e
- Inclinação = - 0,84

O valor da estatística t de Student e o p-valor para o teste da significância de β_1 são, aproximadamente e respectivamente,

- a) -41 e 5,50E-23.
- b) -16 e 5,50E-23.
- c) 17 e 2,75E-23.
- d) 34 e 2,75E-23.
- e) 41 e 2,75E-23.

Comentários:

A estatística t de Student para o teste de significância do coeficiente angular β_1 , em uma regressão simples (isto é, com um único coeficiente angular) pode ser calculada (em módulo) pela raiz quadrada da estatística F, que o enunciado chama de $F_{calculado}$:

$$t = \pm\sqrt{F} = \pm\sqrt{257,21} \cong \pm 16$$

O sinal da estatística t de Student acompanha o sinal do coeficiente angular β_1 , que o enunciado chama de inclinação. Como o sinal da inclinação é negativo, o sinal da estatística t de Student também é negativo:

$$t = -16$$



O p-valor do teste de significância (que é a probabilidade de obter um resultado mais extremo, considerando a premissa da hipótese nula de que o coeficiente angular da reta é nulo) é chamado pelo enunciado de $F_{\text{significância}}$:

$$p - \text{valor} = F_{\text{significância}} = 5,50E - 23$$

Gabarito: B

26. (VUNESP/2020 – EBSERH) Numa regressão linear simples em que foi utilizada uma amostra com 52 observações, a soma dos quadrados totais é de 50 e a soma dos quadrados dos resíduos é de 20. O coeficiente de determinação e a estatística F dessa regressão são, respectivamente:

- a) 0,6 e 75
- b) 0,6 e 12
- c) 0,8 e 1,5
- d) 0,8 e 12
- e) 0,8 e 75

Comentários:

O enunciado informa que:

- A soma total dos quadrados é $SQ_{\text{Total}} = 50$
- A soma dos quadrados dos resíduos (ou erros) é $SQ_{\text{Erro}} = 20$

Com esses dados, podemos calcular a soma dos quadrados do modelo:

$$\begin{aligned} SQ_{\text{Total}} &= SQ_{\text{Modelo}} + SQ_{\text{Erro}} \\ SQ_{\text{Modelo}} &= 50 - 20 = 30 \end{aligned}$$

Logo, o coeficiente de determinação, dado pela razão entre a soma dos quadrados do modelo e a soma total dos quadrados, é:

$$R^2 = \frac{SQ_{\text{Modelo}}}{SQ_{\text{Total}}} = \frac{30}{50} = 0,6$$

Para calcular o valor da estatística F, precisamos dos graus de liberdade. Nesse sentido, o enunciado informa que:

- A regressão linear é simples, logo concluímos que o número de graus de liberdade do modelo é $GL_{\text{Modelo}} = 1$
- A amostra teve $n = 52$ observações, logo o número total de graus de liberdade é $GL_{\text{Total}} = n - 1 = 51$.

Com essas informações, podemos calcular o número de graus de liberdade do erro:



$$GL_{Total} = GL_{Modelo} + GL_{Erro}$$

$$GL_{Erro} = 51 - 1 = 50$$

Os quadrados médios do modelo e do erro são, respectivamente:

$$QM_{Modelo} = \frac{SQ_{Modelo}}{GL_{Modelo}} = \frac{30}{1} = 30$$

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}} = \frac{20}{50} = 0,4$$

E a estatística é a razão entre o quadrado médio do modelo e o quadrado médio do erro:

$$F = \frac{QM_{Modelo}}{QM_{Erro}} = \frac{30}{0,4} = 75$$

Gabarito: A

27. (Cesgranrio/2018 – Petrobrás) Um modelo de regressão linear simples, $Y = \beta_0 + \beta_1 X + \mu$, foi aplicado para explicar o consumo de um certo bem em função da taxa de desemprego. Uma amostra aleatória de tamanho 40 foi selecionada e forneceu a informação de que, para cada elevação de 1% na taxa de desemprego, a demanda diminui em 1.000 unidades. A tabela de ANOVA apresenta informações para testar a significância do modelo, fornecendo a estatística do teste $F = 400$ com $F_{sig} = 9,0 \times 10^{-22}$. O valor da estatística t de Student para o teste da significância de β_1 é

- a) -100
- b) -20
- c) 10
- d) 20
- e) 100

Comentários:

A estatística F da ANOVA corresponde ao quadrado da estatística t para o teste de significância do coeficiente linear:

$$F = t_{\beta_1}^2$$

$$t_{\beta_1} = \pm\sqrt{F}$$

Sabendo que $F = 400$, temos:

$$t_{\beta_1} = \pm\sqrt{400} = \pm 20$$

Para encontrarmos o sinal correto do coeficiente, o enunciado informa que para uma elevação na taxa (X), a demanda (Y) diminui, ou seja, tais grandezas variam em sentidos **opostos**, o que significa que o sinal do coeficiente linear é **negativo**:



$$t_{\beta_1} = -20$$

Gabarito: B

28. (Cesgranrio/2018 – Petrobrás) Uma empresa de marketing contrata um estatístico para analisar a eficiência de uma propaganda de TV na divulgação de um novo sorvete. O estatístico mostra a propaganda em um bairro específico, por um período de tempo. Após este período, ele escolhe adultos, aleatoriamente, quando saem de um supermercado local, para perguntar se eles “viram a propaganda” e se “compraram o novo sorvete”.

O consultor também pergunta qual a “renda familiar anual” e se eles “tinham filhos”. O estatístico precisa determinar como a propaganda, o ter filhos e a renda anual estão relacionadas à compra do sorvete pelos adultos amostrados. Um primeiro modelo de regressão logística binária foi estimado e apresentou os seguintes resultados.

	Coeficiente estimado	Erro padrão	Estatística Z
Termo Constante	-3,04	0,95	-3,20
Renda	0,014	0,02	0,70
Filhos SIM	1,740	0,87	2,00
Viu anúncio SIM	1,044	0,40	2,61

Considerando a Tabela da distribuição normal e um nível de significância de 5%, verifica-se que as variáveis preditoras

- a) renda, filhos e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete, indicando que há evidência suficiente para concluir que o modelo se ajusta aos dados.
- b) renda, filhos e viu anúncio **não possuem** uma relação estatisticamente significativa com a variável resposta compra do sorvete, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.
- c) renda e filhos **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e viu anúncio **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.
- d) renda e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e filhos **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.
- e) filhos e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e renda **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.

Para resolver essa questão, utilize a tabela ao final desta seção de questões, fornecida na prova.



Comentários:

A tabela apresenta as estimativas dos coeficientes calculadas pelo modelo de regressão, os seus erros padrão e os valores da estatística Z (que usualmente chamamos de t), que consiste na razão entre a estimativa de cada coeficiente e o seu erro padrão.

Com base nessa estatística, decidimos se o coeficiente deve ser considerado significativo ou não, para um nível de 5% de significância. Pontue-se que a **hipótese nula** do teste é de que o verdadeiro coeficiente é **nulo**, a qual será rejeitada se o p-valor da estimativa for **inferior** ao nível de significância.

Em relação à **renda**, observamos que $Z = 0,70$. Pela tabela normal, observamos que $P(0 < Z < 0,70) \cong 0,258$. Pela simetria da normal padrão, temos:

$$P(|Z| < 0,70) = 2 \times 0,258 = 0,516$$

$$P(|Z| \geq 0,70) = 1 - 0,516 = 0,484$$

Essa probabilidade, que corresponde ao p-valor, é (muito) **superior** ao nível de significância de 0,05. Portanto, **não rejeitamos** a hipótese nula de que o verdadeiro coeficiente é nulo, ou seja, concluímos que a variável **renda não tem** relação significativa com a variável resposta.

Em relação a **filhos**, observamos que $Z = 2,00$. Pela tabela normal, observamos que $P(0 < Z < 2) \cong 0,477$, logo:

$$P(|Z| < 2) = 2 \times 0,477 = 0,954$$

$$P(|Z| \geq 2) = 1 - 0,954 = 0,046$$

Que é **inferior** ao nível de significância de 0,05. Portanto, **rejeitamos** a hipótese nula de que o verdadeiro coeficiente é nulo e concluímos que a variável **filhos tem** relação significativa com a variável resposta.

Em relação à variável "viu anúncio", a estatística é ainda maior que a de filhos, o que leva a um p-valor **menor**. Portanto, **rejeitamos** a hipótese nula e concluímos que a variável "**viu anúncio**" **tem** relação significativa com a variável resposta.

Gabarito: E

29. (FCC/2018 – TRT – 14ª Região) Uma amostra aleatória constituída de 20 ternos de observações (X_i, Y_i, Z_i) , $i = 1, 2, 3, \dots, 20$ permitiu obter, por meio do método dos mínimos quadrados, as estimativas dos parâmetros desconhecidos α , β e γ do modelo de regressão linear múltipla $Z_i = \alpha + \beta X_i + \gamma Y_i + \varepsilon_i$ com i correspondendo a i -ésima observação. Sabe-se que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Para testar a existência da regressão de Z sobre as variáveis X e Y , considerou-se o respectivo quadro de análise de variância em que se obteve o valor de 44,625 para a estatística F_c (F calculado) utilizado para comparar com o F tabelado da distribuição F . Se a estimativa da variância σ^2 do modelo teórico foi igual a 8, então o coeficiente de determinação (R^2), definido como o sendo o resultado da divisão da variação explicada pela variação total é, em %, igual a

a) 64

b) 78



- c) 84
- d) 80
- e) 82

Comentários:

O enunciado informa o valor da estatística F e a estimativa da variância do erro σ^2 (que é igual ao quadrado médio do erro) pede o valor do coeficiente de determinação.

A estatística F é a razão entre o quadrado médio do tratamento e o quadrado médio do erro:

$$F = \frac{QM_{Trat}}{QM_{Erro}}$$

Sabendo que $F = 44,625$ e que $QM_{Erro} = 8$, podemos calcular o quadrado médio do tratamento:

$$QM_{Trat} = F \times QM_{Erro} = 8 \times 44,625 = 357$$

Sabendo que há 2 variáveis explicativas (X e Y), o número de graus de liberdade do tratamento é $GL_{Trat} = 2$. Assim, podemos calcular a soma dos quadrados do tratamento:

$$QM_{Trat} = \frac{SQ_{Trat}}{GL_{Trat}}$$

$$SQ_{Trat} = QM_{Trat} \times GL_{Trat} = 357 \times 2 = 714$$

E o número de graus de liberdade do erro, sabendo que $GL_{Trat} = 2$ e que o número total de observações é $n = 20$, é:

$$GL_{Erro} = n - 1 - 2 = 20 - 3 = 17$$

Assim, podemos calcular a soma dos quadrados do erro:

$$QM_{Erro} = \frac{SQ_{Erro}}{GL_{Erro}}$$

$$SQ_{Erro} = QM_{Erro} \times GL_{Erro} = 8 \times 17 = 136$$

E a soma total dos quadrados é:

$$SQ_{Total} = SQ_{Trat} + SQ_{Erro} = 714 + 136 = 850$$


Por fim, o coeficiente de determinação é dado pela razão entre a soma dos quadrados do tratamento e a soma total dos quadrados:

$$R^2 = \frac{SQ_{Trat}}{SQ_{Total}} = \frac{714}{850} = 0,84 = 84\%$$

Gabarito: C



Distribuição Normal Padrão $Z \sim N(0,1)$ Corpo da tabela dá a probabilidade p, tal que $p = P(0 < Z < Z_c)$											
parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
	$p = 0$										
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4
3,5	49977	49978	49978	49979	49980	49981	49981	49982	49983	49983	3,5
3,6	49984	49985	49985	49986	49986	49987	49987	49988	49988	49989	3,6
3,7	49989	49990	49990	49990	49991	49991	49992	49992	49992	49992	3,7
3,8	49993	49993	49993	49994	49994	49994	49994	49995	49995	49995	3,8
3,9	49995	49995	49996	49996	49996	49996	49996	49996	49997	49997	3,9
4,0	49997	49997	49997	49997	49997	49997	49998	49998	49998	49998	4,0
4,5	49999	50000	50000	50000	50000	50000	50000	50000	50000	50000	4,5



LISTA DE QUESTÕES – MULTIBANCAS

Conceitos Fundamentais

1. (COMPEC/2024 – UFAM) A aplicação apropriada da Análise de Variância depende do cumprimento de um conjunto de pressupostos. Os pressupostos relativos à exigência de que os erros tenham mesma variância e que sejam não correlacionados são, respectivamente,

- a) aditividade e normalidade.
- b) independência e homoscedasticidade.
- c) homoscedasticidade e independência.
- d) homoscedasticidade e normalidade.
- e) normalidade e aditividade.

2. (AOCP/2024 – PM/PE) Suponha que se deseje comparar, em média, a quantidade de certo produto tóxico apreendido, por ocorrência, nas cidades A, B, C e D. Então, para um período de tempo, obtiveram-se $n_A = n_B = n_C = n_D = n$ registros dos pesos do produto apreendido em cada cidade. Analisando os números, verificou-se que eles seguem a Distribuição Normal de Probabilidade e têm mesma variância.

Assim, para testar a hipótese de que os pesos do produto apreendido são iguais na média, ou seja, a hipótese nula $H_0: \mu_A = \mu_B = \mu_C = \mu_D = \mu$, deve-se aplicar aos dados a técnica estatística.

- a) do teste “t” de Student Clássico.
- b) do teste F na comparação das variâncias duas a duas.
- c) do teste “t” de Student na versão de Aspin-Welch.
- d) da Análise da Variância.
- e) do teste “t” de Student Pareado.

3. (FGV/2024 – TJ/MS) Um pesquisador investiga a eficácia de três diferentes tratamentos para reduzir o colesterol no sangue. Ele divide aleatoriamente os pacientes em três grupos. Após um mês, realiza exames em cada paciente e deseja determinar se há diferença entre os tratamentos. A estatística de teste que deve ser usada para avaliar se há diferença significativa entre os tratamentos é:

- a) teste ANOVA (análise de variância);
- b) teste de Kruskal-Wallis;
- c) teste de Qui-Quadrado;



- d) teste t de Student;
- e) teste de Wilcoxon-Mann-Whitney.

4. (FGV/2024 – TCE/GO) Em relação à Análise da Variância (ANOVA), as afirmativas a seguir estão corretas, à exceção de uma. Assinale-a.

- a) É um método para testar a igualdade de três ou mais médias populacionais, baseado na análise das variâncias amostrais.
- b) Os dados amostrais são separados em grupos segundo uma característica denominada fator. Fator (ou tratamento) é uma característica que permite distinguir diferentes populações umas das outras.
- c) Cada fator contém dois ou mais grupos (classificações).
- d) Amostras são aleatórias e mutuamente dependentes.
- e) Suposições incluem: populações normalmente distribuídas e de mesma variância.

5. (Cebbraspe/2022 – PC-PB) Deseja-se avaliar, por experimentos laboratoriais, amostras contendo uma mistura de proteínas e peptídeos, juntamente com outras moléculas, obtidas a partir de extratos vegetais. Em uma das etapas experimentais, os peptídeos foram enriquecidos nas amostras. Em outra etapa, a mistura de peptídeos foi diluída em ácido fórmico e submetida a uma análise cromatográfica e, em uma terceira etapa, peptídeos isolados por cromatografia foram analisados por espectrometria de massas. Sabe-se que em todas as amostras há um peptídeo de maior interesse, que é composto por 10 aminoácidos, sem repetições, e apresenta absorção máxima de luz no comprimento de onda de 215 nm. Com pertinência a essa situação hipotética, considere que amostras de 30 plantas nativas (chamadas de N), 30 plantas transgênicas (chamadas de T) e 30 plantas cultivadas em hidroponia (chamadas de H) tenham sido analisadas e tenha sido feita a quantificação da concentração em quantidade de matéria do peptídeo-alvo em cada amostra, com o objetivo de se determinar se há diferença estatisticamente significativa entre as plantas N, T e H. Observou-se que a distribuição dos valores de concentração do peptídeo é compatível com a distribuição normal, que as amostras foram obtidas de forma aleatória e independente e que há homogeneidade de variâncias.

Assinale a opção que corresponde ao teste estatístico que deve ser aplicado para detectar se há diferença significativa quanto à concentração do peptídeo entre quaisquer dos tipos de plantas, sendo este capaz de detectar a diferença se aplicado e calculado apenas uma vez, sem repetições do teste.

- a) qui quadrado
- b) ANOVA
- c) Levene
- d) t de Student
- e) Kolmogorov-Smirnov



6. (VUNESP/2021 – EsFCEEx) Ao realizar uma análise de variância (ANOVA), estamos interessados em fazer algumas comparações. Quanto aos pressupostos dessa análise, é correto afirmar que:

- a) os erros são variáveis aleatórias independentes de uma distribuição Normal com média zero e variância desconhecida.
- b) a hipótese nula do modelo da ANOVA é de que as variâncias entre os grupos sejam iguais.
- c) no modelo da ANOVA, a variável dependente (resposta) pode ser qualitativa ou quantitativa.
- d) para a estimação do modelo da ANOVA, deveremos utilizar somente os estimadores de máxima verossimilhança.
- e) no quadro da ANOVA, o “quadrado médio entre” representa a variância residual.



GABARITO

- | | | |
|------------|------------|------------|
| 1. LETRA C | 3. LETRA A | 5. LETRA B |
| 2. LETRA D | 4. LETRA D | 6. LETRA A |



LISTA DE QUESTÕES – MULTIBANCAS

Fundamentos do Teste

1. (IMPARH/2025 – CGM Fortaleza) Três grupos amostrais são fornecidos, cada um com $n = 5$ observações:

- Grupo 1: {10,12,11,13,14}
- Grupo 2: {20,22,19,21,23}
- Grupo 3: {30,32,31,33,34}

Calcule o valor da estatística F utilizada em Análise de Variância (ANOVA) para avaliar a diferença das médias entre grupos. É fornecido que a soma dos quadrados entre os grupos é igual a 1003.33 e a soma de quadrados total é 1033.33.

- a) F é aproximadamente 200,00, rejeitar H_0 .
- b) F é aproximadamente 4,50, não rejeitar H_0 .
- c) F é aproximadamente 0,005, rejeitar H_0 .
- d) F é aproximadamente 3,25, não rejeitar H_0 .

2. (VUNESP/2024 – EsFCEx) Um experimento foi conduzido em delineamento inteiramente casualizado com 3 tratamentos e 4 repetições, totalizando 12 unidades amostrais. Os resultados da Análise de Variância são observados na tabela a seguir.

Causas de Variação	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	F calculado
Tratamento	2	1.000	500	B
Resíduo	9	180	A	

Os valores de A e B são, respectivamente,

- a) 20 e 0,04
- b) 20 e 25
- c) 0,18 e 0,22
- d) 90 e 5,5.
- e) 90 e 0,18.



3. (VUNESP/2021 – EsFCEEx) Um estudo, com o objetivo de avaliar o desempenho dos alunos submetidos a três diferentes métodos de ensino (A, B, C), selecionou aleatoriamente cinco alunos em cada um dos métodos e aplicou uma prova de conhecimentos específicos, em que a nota zero indica pior desempenho, e a nota 10, melhor desempenho. As notas dos alunos na prova estão apresentadas na tabela a seguir.

Método de Ensino	Notas				
A	3	4	6	5	7
B	6	1	7	3	8
C	0	9	3	5	8

Ao realizar uma análise de variância (ANOVA) para comparar os métodos de ensino, é correto afirmar que

- a) o Quadrado Médio do Erro é zero.
- b) existe diferença entre os três métodos, ao nível de significância 0,05.
- c) a Soma de Quadrados do Total é zero.
- d) o Quadrado Médio do Método é zero.
- e) a Soma de Quadrados do Total é maior do que a Soma de Quadrados do Erro.

4. (VUNESP/2021 – EsFCEEx) Um estudo com 12 atletas de 3 equipes diferentes, com 4 atletas em cada equipe, visou a avaliar a distância percorrida por eles em um período de 12 minutos. Deseja-se saber, a um determinado nível de significância, se a distância média percorrida pelos atletas nas 3 equipes é a mesma. Considere as informações do quadro de análise de variância:

Fonte de Variação	Soma de Quadrados
Equipes	20
Erro	X
Total	20 + X

Se o valor da estatística F, utilizado para testar a igualdade da distância percorrida entre as equipes, é igual a 10, então X é igual a

- a) 9
- b) 5
- c) 13
- d) 1
- e) 17



5. (VUNESP/2020 – EsFCEEx) Uma etapa de um estudo consiste em testar a hipótese de igualdade das médias de satisfação, a um nível de significância de 5%, correspondente aos tratamentos dados a 4 grupos independentes (I, II, III e IV), cada um contendo 10 observações obtidas aleatoriamente.

Pelo quadro de análise de variância, obtiveram-se as seguintes informações:

Fonte de Variação	Soma de Quadrados
Tratamentos (entre grupos)	360
Erro (dentro dos grupos)	288
Total	648

O valor da estatística F obtida (F calculado) utilizada para a tomada de decisão é igual a

- a) 10,0
- b) 12,0
- c) 9,6
- d) 15,0
- e) 8,0

6. (VUNESP/2020 – Pref. Ilhabela) A prefeitura de um município, desejando realizar um planejamento turístico, desenvolveu um estudo com relação a 3 pontos turísticos (X, Y, e Z) localizados na cidade, sendo que cada turista consegue visitar um e somente um dos pontos em um determinado dia. O objetivo desse estudo consistia em testar, ao nível de significância de 5%, a igualdade das médias das notas de satisfação em cada ponto dadas pelos turistas. Em um dia, uma amostra aleatória de 27 turistas, 9 em cada ponto, formando 3 grupos independentes, foi retirada da população de turistas e anotado as notas de cada turista. Pelo quadro de análise de variância, observou-se que a soma dos quadrados, devido à fonte de variação entre grupos, foi igual a 24 e o valor da estatística F, utilizada para comparação com F tabelado (distribuição F de Snedecor), igual a 8.

A fonte de variação total foi então igual a

- a) 36
- b) 42
- c) 48
- d) 60
- e) 72



7. (FGV/2018 – ALERO) Suponha que se deseja testar a hipótese nula de que k médias populacionais são iguais (não há efeito de tratamento) contra a alternativa de que nem todas as médias são iguais (há efeito de tratamento) por meio de uma análise da variância de 1 fator usual, com base em um conjunto de n observações. Uma tabela ANOVA terá basicamente a seguinte estrutura:

Fonte de Variação	SQ	gl	Variância	Estatística F
Entre	SQE	a		
Dentro	SQD	b		
Total	SQT	c		

Os valores de a , b e c são respectivamente:

- a) $n-k$, $k-1$, $n-1$.
- b) $k-1$, $n-k$, $n-1$
- c) k , $n-k$, $n-1$.
- d) $n-k-1$, k , $n-1$.
- e) k , $n-k-1$, $n-1$.

8. (FGV/2018 – ALERO) Suponha que se deseja testar a hipótese nula de que k médias populacionais são iguais (não há efeito de tratamento) contra a alternativa de que nem todas as médias são iguais (há efeito de tratamento) por meio de uma análise da variância de 1 fator usual, com base em um conjunto de n observações. Uma tabela ANOVA terá basicamente a seguinte estrutura:

Fonte de Variação	SQ	gl	Variância	Estatística F
Entre	SQE	a		
Dentro	SQD	b		
Total	SQT	c		

Obtidos corretamente os valores de SQE, SQD e SQT, o valor da estatística de teste F será dado por:

- a) $F = \text{SQE}(n - k) / \text{SQT}(k - 1)$
- b) $F = \text{SQD}(n - k) / \text{SQD}(k - 1)$
- c) $F = \text{SQE}(n - k) / \text{SQD}(k - 1)$
- d) $F = \text{SQD}(n - k) / \text{SQT}(k - 1)$
- e) $F = \text{SQT}(n - k) / \text{SQD}(k - 1)$



GABARITO

- | | | |
|------------|------------|------------|
| 1. LETRA A | 4. LETRA A | 7. LETRA B |
| 2. LETRA B | 5. LETRA D | 8. LETRA C |
| 3. LETRA D | 6. LETRA D | |



LISTA DE QUESTÕES – MULTIBANCAS

Número Distinto de Repetições

1. (Consulplan/2024 – TJ/MA) Um estudo foi realizado para comparar o tempo (em minutos) de execução de uma tarefa entre três grupos independentes de funcionários recém-contratados treinados com métodos distintos. Os dados obtidos são apresentados a seguir.

Treinamento	Média Amostral	Tamanho da Amostra
1	17,47	19
2	17,94	18
3	13,70	20

Considerando que os dados são normalmente distribuídos nos três grupos, realizou-se uma análise de variância para verificar se existe diferença significativa entre o tempo médio de realização da tarefa sob os três tipos de treinamento na população de funcionários. A soma de quadrados entre os grupos foi igual a 210 e a soma de quadrados total foi igual a 345. Se $F_{x,y}$ denota uma variável aleatória com distribuição F de Fisher com x graus de liberdade no numerador e y graus de liberdade no denominador, o p-valor do teste de hipóteses associado é dado por:

- a) $P(F_{2,54} > 27,5)$.
- b) $P(F_{3,53} > 27,5)$.
- c) $P(F_{2,54} > 42,0)$.
- d) $P(F_{54,2} > 42,0)$.



GABARITO

1. LETRA C



LISTA DE QUESTÕES – MULTIBANCAS

Análise de Variância da Regressão

1. (FGV/2025 – TRT 24ª Região) Considere que no ajuste de uma reta de regressão linear $Y = \beta_0 + \beta_1 X + \varepsilon$ a seguinte tabela de Análise da Variância (com dados parcialmente omitidos) foi obtida:

Fonte	Soma dos Quadrados	Graus de Liberdade	Média Quadrática
Regressão	4.800		
Resíduo			s^2
Total	10.190	99	

O valor de s^2 é igual a

- a) 50
- b) 55
- c) 60
- d) 65
- e) 70

2. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

Com nível de significância de 1%, o p-valor da tabela ANOVA indica que todos os coeficientes do modelo são estatisticamente significativos.

3. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	



Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O modelo é constituído por três coeficientes que foram estimados pelo método de mínimos quadrados ordinários.

4. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

A variância dos resíduos é inferior a 0,90.

5. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

O valor da razão F é igual a 14.

6. (CEBRASPE/2025 - TRT 10ª Região)

Fonte de Variação	graus de liberdade	quadrado médio	p-valor da razão F
Regressão	2	14	0,002
Erro	8	1	

Considerando o quadro precedente, que mostra parte de uma típica tabela de análise de variância (ANOVA) referente ao ajuste de um modelo de regressão linear que possui um intercepto e cujos coeficientes foram estimados pelo método de mínimos quadrados ordinários, julgue o item a seguir.

A variância amostral da variável resposta (dependente) do modelo é igual a 14.



7. (CEBRASPE/2025 - TRF 6ª Região) Um modelo de regressão linear simples é especificado como $Y_i = \alpha + X_i \cdot \beta + \varepsilon_i$ em que $E[\varepsilon_i] = 0$ e $Var[\varepsilon_i] = \sigma^2$. Para estimadores α' e β' , o valor do predito para observação i (Y'_i) com característica X_i é dado por $Y'_i = \alpha' + X_i \cdot \beta'$. O resíduo para observação i (ε'_i) é definido como $\varepsilon'_i = Y_i - Y'_i$. De uma amostra aleatória de tamanho 49, coletada da população desse modelo de regressão linear simples, obteve-se:

- $\sum_i (Y_i - Y'_i)^2 = 17.173$ e
- $\sum_i (Y'_i - m_y)^2 = 36.464$, em que m_y é a média amostral de Y

Em relação às informações precedentes, julgue o item a seguir, considerando que o percentil 95% de uma distribuição F, com 1 grau de liberdade no numerador e 47 graus de liberdade no denominador, é igual a 4,05, e que o percentil 95% de uma distribuição qui-quadrado com 47 graus de liberdade é 64.

Se ε segue uma distribuição normal, o teste de hipótese da hipótese nula que $\beta=0$ contra a alternativa de $\beta \neq 0$ leva à rejeição da hipótese nula ao nível de significância de 5%.

8. (CEBRASPE/2025 - TRF 6ª Região) Um modelo de regressão linear simples é especificado como $Y_i = \alpha + X_i \cdot \beta + \varepsilon_i$ em que $E[\varepsilon_i] = 0$ e $Var[\varepsilon_i] = \sigma^2$. Para estimadores α' e β' , o valor do predito para observação i (Y'_i) com característica X_i é dado por $Y'_i = \alpha' + X_i \cdot \beta'$. O resíduo para observação i (ε'_i) é definido como $\varepsilon'_i = Y_i - Y'_i$. De uma amostra aleatória de tamanho 49, coletada da população desse modelo de regressão linear simples, obteve-se:

- $\sum_i (Y_i - Y'_i)^2 = 17.173$ e
- $\sum_i (Y'_i - m_y)^2 = 36.464$, em que m_y é a média amostral de Y

Em relação às informações precedentes, julgue o item a seguir, considerando que o percentil 95% de uma distribuição F, com 1 grau de liberdade no numerador e 47 graus de liberdade no denominador, é igual a 4,05, e que o percentil 95% de uma distribuição qui-quadrado com 47 graus de liberdade é 64.

$$\sum_i (Y_i - m_Y)^2 = 53.637.$$

9. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X ₁	5,0	0,05
X ₂	-3,0	0,03
X ₃	0,2	0,20
X ₄	0,01	0,001

Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R ²)	60%
Erro quadrático médio	36



As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O valor do R^2 ajustado (R^2_{ajustado}) é superior a 60%.

10. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O coeficiente de explicação deverá aumentar se a variável X_2 for retirada do modelo.

11. (CEBRASPE/2025 - FUNPRES-P-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36



As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36.

Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

Se a variável Y for considerada normal, e assumindo-se que a aproximação normal seja válida para a distribuição dos estimadores dos coeficientes do modelo, é correto concluir que todos os coeficientes são estatisticamente significativos com p-valores inferiores a 1%.

12. (CEBRASPE/2025 - FUNPRESP-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001

Tamanho da amostra (n)	106
Coeficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1 , X_2 , X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36.

Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

O desvio padrão dos resíduos do modelo de regressão é igual a 6.

13. (CEBRASPE/2025 - FUNPRESP-EXE)

	Estimativa do coeficiente	Erro padrão
Intercepto	10,0	3,00
X_1	5,0	0,05
X_2	-3,0	0,03
X_3	0,2	0,20
X_4	0,01	0,001



Tamanho da amostra (n)	106
Coefficiente de determinação do modelo (R^2)	60%
Erro quadrático médio	36

As tabelas precedentes mostram as estimativas dos coeficientes e seus respectivos erros padrão proporcionados pelo método de mínimos quadrados ordinários em um modelo de regressão linear com um intercepto e 4 variáveis regressoras (X_1, X_2, X_3 e X_4) para modelar uma variável dependente Y . As tabelas mostram, ainda, o tamanho da amostra, o coeficiente de determinação (R^2) e o erro quadrático médio desse modelo, que foi igual a 36. Com base nessas informações e nos dados das tabelas, julgue o item subsequente.

A variância amostral da variável dependente Y é superior a 85.

14. (CEBRASPE/2024 - ANTT) Julgue o item seguinte, referente a regressão linear e séries temporais.

Para o modelo de regressão linear simples $Y = \beta_0 + \beta_1 X + \varepsilon$, em que $\varepsilon \sim N(0, \sigma^2)$ é uma variável aleatória independente de X , se $Y' = \beta_0 + \beta_1 X$, então $E[(Y - EY)^2] = E[Y' - EY]^2$.

15. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Na análise de adequação do modelo, é fundamental verificar se a variância dos resíduos não depende da variável X .

16. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$.



Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Para um modelo de regressão que não seja simples, a soma dos resíduos não será nula.

17. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$. Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

O coeficiente de determinação para um modelo de regressão linear é definido como $r^2 = (SQT - SQE) / SQT$ e sua raiz quadrada corresponde ao coeficiente de correlação linear entre as variáveis Y e X .

18. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X_i + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .



Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Um estimador não viciado para a variância de $\hat{\beta}_i$ é obtido pela variância amostral dada por $S^2 = SQE / [(n - 2) \sum_i (X_i - \bar{X})^2]$, em que $\bar{X} = \sum_i X_i / n$ e a variável centralizada de $\hat{\beta}_i$, normalizada por S , tem uma distribuição *t de Student* com $n - 1$ graus de liberdade.

19. (CEBRASPE/2024 - CAPES) Um modelo de regressão linear entre uma variável aleatória Y (dependente) e uma variável não aleatória X (independente) é definido por $Y = \beta_0 + \beta_1 X + \epsilon$ em que ϵ , denominado erro aleatório, é uma variável aleatória independente de X com $E(\epsilon) = 0$ e $Var(\epsilon) = \sigma^2$. Um modelo de regressão linear é essencialmente um modelo para a probabilidade condicional de Y com relação a X , denotada por $P(Y|X)$; ele é chamado de simples se ϵ for uma variável aleatória gaussiana. Fixando-se n valores $X_1, X_2, \dots, X_n$ para a variável independente X , pode-se definir n variáveis aleatórias $Y_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, com $i = 1, \dots, n$. Pelo método dos mínimos quadrados, é possível obter estimadores $\hat{\beta}_0$ e $\hat{\beta}_1$ para os parâmetros β_0 e β_1 e definir $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ como o estimador para Y_i .

Nesse contexto, são definidos os erros, denominados resíduos, como $Y_i - \hat{Y}_i = e_i$, a soma dos quadrados dos resíduos $SQE = \sum_i e_i^2$, a soma dos quadrados totais $SQT = \sum_i (Y_i - \bar{Y})^2$, e a soma dos quadrados de regressão $SQR = \sum_i (\hat{Y}_i - \bar{Y})^2$, com $\bar{Y} = \sum_i Y_i / n$.

Com base nessas informações, julgue o próximo item, considerando uma variável T , com média nula e desvio padrão unitário, definida por uma distribuição *t de Student* com 30 graus de liberdade, que tenha o seguinte intervalo com probabilidade de 0,95: $P(-2,042 < T < 2,042) = 0,95$.

Considere que, para uma regressão linear simples da relação $Y = \beta_0 + \beta_1 X$, em uma amostra de 32 valores de X , obteve-se: $\hat{\beta}_1 = 2$ como estimativa para β_1 ; soma dos quadrados dos resíduos igual a 600; e $\sum_i (X_i - \bar{X})^2 = 2.000$, em que $\bar{X}$ é a média dos valores de X na amostra. Considere ainda que tenha sido feito o teste da hipótese de não existir a relação linear $Y = \beta_0 + \beta_1 X$, tomando-se como hipótese nula que $\beta_1 = 0$. Nessas condições, assumindo um teste com erro de tipo I igual a 5%, é correto afirmar que a hipótese de não existir a relação linear deve ser aceita.

20. (CEBRASPE/2024 - CODEVASF)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320



A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon_y$ em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81. Com base na situação hipotética apresentada, julgue o seguinte item.

A estimativa de σ é igual ou superior a 1.

21. (CEBRASPE/2024 - CODEVASF)

Fonte de Variação	Soma dos quadrados
Regressão	281
Erro	39
Total	320

A tabela de análise de variância precedente diz respeito ao ajuste de um modelo de regressão linear na forma $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \varepsilon_y$ em que β_0 , β_1 e β_2 denotam os coeficientes do modelo e ε se refere a um erro aleatório normal com média zero e desvio padrão σ . O ajuste é feito pelo critério de mínimos quadrados ordinários e o tamanho da amostra é igual a 81. Com base na situação hipotética apresentada, julgue o seguinte item.

O valor da razão F do teste linear geral, cuja hipótese nula é $H_0: \beta_0 = \beta_1 = \beta_2 = 0$ é igual ou inferior a 10.

22. (VUNESP/2024 – APS) Na Análise de Variância de um modelo de regressão linear simples obteve-se um valor de Soma de Quadrados de Regressão de 9,5 e Soma de Quadrados de Resíduos de 3,8. Sabendo que havia 1 grau de liberdade para a regressão e 19 graus de liberdade para os resíduos, e considerando o valor tabelado $F_{1;19;5\%} = 2,99$, é correto afirmar que:

- a) a estatística F calculada será 0,2, logo, não se rejeita a hipótese nula, ou seja, a regressão não é significativa.
- b) a estatística F calculada será 2,5, logo, não se rejeita a hipótese nula, ou seja, a regressão não é significativa.
- c) a estatística F calculada será 5,7, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.
- d) a estatística F calculada será 36,1, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.
- e) a estatística F calculada será 47,5, logo, rejeita-se a hipótese nula, ou seja, a regressão é significativa.

23. (AOC/2024 – Pref. Uberaba) A prefeitura de uma cidade, visando planejar o imposto predial e territorial, solicitou a uma imobiliária os preços (Y, em mil reais) de casas aleatoriamente selecionadas de um bairro cujos moradores têm alto poder aquisitivo, as correspondentes idades das casas (x_1 , em anos) e o tamanho (x_2 , em metros quadrados). Uma tabela de análise de variância (ANOVA) foi construída para os dados observados, conforme apresentado a seguir.



Fonte	Graus de Liberdade	Soma de Quadrados	Quadrado Médio	F-Snedecor	p-valor
Regressão	2	827,026	413,5	2,57	0,299
Resíduos	3	482,700	160,9		
Total	5	1309,726			

Considerando as informações contidas na tabela ANOVA, é correto afirmar que

- a) a regressão é significativa ao nível de 5% no teste F de Snedecor.
- b) não é possível estimar a variância dos erros.
- c) pelo teste F para as hipóteses " $H_0: \beta_1 = \beta_2 = 0$ contra H_1 : pelo menos um dos $\beta_i \neq 0$ " com base no valor p, não se pode rejeitar a hipótese nula para nível de significância menor do que 30%.
- d) $R^2=0,99$

24. (FGV/2022 – EPE) O seguinte modelo de regressão múltipla foi estimado por Mínimos Quadrados Ordinários com o objetivo de fazer previsões para o preço de 21 ativos da área de petróleo de uma amostra aleatória:

$$\ln(\text{preço}) = 5,25 + 2,05 \ln(\text{preçoaval}) + 3,10 \text{ Brent} + 1,10 \text{ cam} + 0,82 \text{ Ibov} + 0,75 \text{ Prod}$$

em que o preço e o preçoaval são, respectivamente, preço de venda e preço de avaliação do ativo, em reais; Brent é a cotação diária do barril; cam é a cotação cambial ao fim do dia para a compra; Ibov é o índice da bolsa de valores de São Paulo e Prod é a produção diária de petróleo.

Outras informações importantes do modelo:

$$R^2 = 0,87; \text{SQT} = 6; \hat{\sigma} = 0,15$$

na qual R^2 é o coeficiente de explicação do modelo, SQT é a soma dos quadrados totais e $\hat{\sigma}$ é o desvio padrão estimado.

Para a resolução dessa questão talvez seja útil saber que se Z tem distribuição normal padrão, então:

$$P(|Z| > 1,645) = 0,10 \text{ e } P(|Z| > 1,96) = 0,05.$$

Com base nos dados acima, o valor da estatística de significância da regressão é, aproximadamente, igual a

- a) 2;
- b) 5;
- c) 12;
- d) 15;
- e) 20.



25. (FGV/2022 – SEFAZ/ES) As informações a seguir referem-se aos resultados parciais da aplicação de um modelo de regressão linear simples, $Y = \beta_0 + \beta_1 X_1 + \epsilon$, em uma amostra aleatória simples de 60 pares de observações. Alguns dos resultados aproximados foram:

- $\sum_{i=1}^{60} (Y_i - \bar{Y})^2 = 5.350$
- $\frac{1}{58} \sum_{i=1}^{60} (Y_i - \hat{Y})^2 = 16,98$
- $F_{calculado} = 257,21$
- $F_{significância} = 5,50E - 23$
- Intercepto = 34,52; e
- Inclinação = - 0,84

O valor da estatística t de Student e o p-valor para o teste da significância de β_1 são, aproximadamente e respectivamente,

- a) -41 e 5,50E-23.
- b) -16 e 5,50E-23.
- c) 17 e 2,75E-23.
- d) 34 e 2,75E-23.
- e) 41 e 2,75E-23.

26. (VUNESP/2020 – EBSERH) Numa regressão linear simples em que foi utilizada uma amostra com 52 observações, a soma dos quadrados totais é de 50 e a soma dos quadrados dos resíduos é de 20. O coeficiente de determinação e a estatística F dessa regressão são, respectivamente:

- a) 0,6 e 75
- b) 0,6 e 12
- c) 0,8 e 1,5
- d) 0,8 e 12
- e) 0,8 e 75

27. (Cesgranrio/2018 – Petrobrás) Um modelo de regressão linear simples, $Y = \beta_0 + \beta_1 X + \mu$, foi aplicado para explicar o consumo de um certo bem em função da taxa de desemprego. Uma amostra aleatória de tamanho 40 foi selecionada e forneceu a informação de que, para cada elevação de 1% na taxa de desemprego, a demanda diminui em 1.000 unidades. A tabela de ANOVA apresenta informações para testar a significância do modelo, fornecendo a estatística do teste $F = 400$ com $F_{sig} = 9,0 \times 10^{-22}$.



O valor da estatística t de Student para o teste da significância de β_1 é

- a) -100
- b) -20
- c) 10
- d) 20
- e) 100

28. (Cesgranrio/2018 – Petrobrás) Uma empresa de marketing contrata um estatístico para analisar a eficiência de uma propaganda de TV na divulgação de um novo sorvete. O estatístico mostra a propaganda em um bairro específico, por um período de tempo. Após este período, ele escolhe adultos, aleatoriamente, quando saem de um supermercado local, para perguntar se eles “viram a propaganda” e se “compraram o novo sorvete”.

O consultor também pergunta qual a “renda familiar anual” e se eles “tinham filhos”. O estatístico precisa determinar como a propaganda, o ter filhos e a renda anual estão relacionadas à compra do sorvete pelos adultos amostrados. Um primeiro modelo de regressão logística binária foi estimado e apresentou os seguintes resultados.

	Coeficiente estimado	Erro padrão	Estatística Z
Termo Constante	-3,04	0,95	-3,20
Renda	0,014	0,02	0,70
Filhos SIM	1,740	0,87	2,00
Viu anúncio SIM	1,044	0,40	2,61

Considerando a Tabela da distribuição normal e um nível de significância de 5%, verifica-se que as variáveis preditoras

- a) renda, filhos e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete, indicando que há evidência suficiente para concluir que o modelo se ajusta aos dados.
- b) renda, filhos e viu anúncio **não possuem** uma relação estatisticamente significativa com a variável resposta compra do sorvete, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.
- c) renda e filhos **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e viu anúncio **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.



d) renda e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e filhos **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.

e) filhos e viu anúncio **têm** uma relação estatisticamente significativa com a variável resposta compra do sorvete e renda **não tem**, indicando que há evidência suficiente para concluir que o modelo não se ajusta aos dados.

Para resolver essa questão, utilize a tabela ao final desta seção de questões, fornecida na prova.


29. (FCC/2018 – TRT – 14ª Região) Uma amostra aleatória constituída de 20 ternos de observações (X_i, Y_i, Z_i) , $i = 1, 2, 3, \dots, 20$ permitiu obter, por meio do método dos mínimos quadrados, as estimativas dos parâmetros desconhecidos α , β e γ do modelo de regressão linear múltipla $Z_i = \alpha + \beta X_i + \gamma Y_i + \varepsilon_i$ com i correspondendo a i -ésima observação. Sabe-se que ε_i é o erro aleatório com as respectivas hipóteses do modelo de regressão linear múltipla. Para testar a existência da regressão de Z sobre as variáveis X e Y , considerou-se o respectivo quadro de análise de variância em que se obteve o valor de 44,625 para a estatística F_c (F calculado) utilizado para comparar com o F tabelado da distribuição F .

Se a estimativa da variância σ^2 do modelo teórico foi igual a 8, então o coeficiente de determinação (R^2), definido como o sendo o resultado da divisão da variação explicada pela variação total é, em %, igual a

- a) 64
- b) 78
- c) 84
- d) 80
- e) 82



Distribuição Normal Padrão $Z \sim N(0,1)$ Corpo da tabela dá a probabilidade p, tal que $p = P(0 < Z < Z_c)$											
parte inteira e primeira decimal de Z_c	Segunda decimal de Z_c										parte inteira e primeira decimal de Z_c
	0	1	2	3	4	5	6	7	8	9	
	$p = 0$										
0,0	00000	00399	00798	01197	01595	01994	02392	02790	03188	03586	0,0
0,1	03983	04380	04776	05172	05567	05962	06356	06749	07142	07535	0,1
0,2	07926	08317	08706	09095	09483	09871	10257	10642	11026	11409	0,2
0,3	11791	12172	12552	12930	13307	13683	14058	14431	14803	15173	0,3
0,4	15542	15910	16276	16640	17003	17364	17724	18082	18439	18793	0,4
0,5	19146	19497	19847	20194	20540	20884	21226	21566	21904	22240	0,5
0,6	22575	22907	23237	23565	23891	24215	24537	24857	25175	25490	0,6
0,7	25804	26115	26424	26730	27035	27337	27637	27935	28230	28524	0,7
0,8	28814	29103	29389	29673	29955	30234	30511	30785	31057	31327	0,8
0,9	31594	31859	32121	32381	32639	32894	33147	33398	33646	33891	0,9
1,0	34134	34375	34614	34850	35083	35314	35543	35769	35993	36214	1,0
1,1	36433	36650	36864	37076	37286	37493	37698	37900	38100	38298	1,1
1,2	38493	38686	38877	39065	39251	39435	39617	39796	39973	40147	1,2
1,3	40320	40490	40658	40824	40988	41149	41309	41466	41621	41774	1,3
1,4	41924	42073	42220	42364	42507	42647	42786	42922	43056	43189	1,4
1,5	43319	43448	43574	43699	43822	43943	44062	44179	44295	44408	1,5
1,6	44520	44630	44738	44845	44950	45053	45154	45254	45352	45449	1,6
1,7	45543	45637	45728	45818	45907	45994	46080	46164	46246	46327	1,7
1,8	46407	46485	46562	46638	46712	46784	46856	46926	46995	47062	1,8
1,9	47128	47193	47257	47320	47381	47441	47500	47558	47615	47670	1,9
2,0	47725	47778	47831	47882	47932	47982	48030	48077	48124	48169	2,0
2,1	48214	48257	48300	48341	48382	48422	48461	48500	48537	48574	2,1
2,2	48610	48645	48679	48713	48745	48778	48809	48840	48870	48899	2,2
2,3	48928	48956	48983	49010	49036	49061	49086	49111	49134	49158	2,3
2,4	49180	49202	49224	49245	49266	49286	49305	49324	49343	49361	2,4
2,5	49379	49396	49413	49430	49446	49461	49477	49492	49506	49520	2,5
2,6	49534	49547	49560	49573	49585	49598	49609	49621	49632	49643	2,6
2,7	49653	49664	49674	49683	49693	49702	49711	49720	49728	49736	2,7
2,8	49744	49752	49760	49767	49774	49781	49788	49795	49801	49807	2,8
2,9	49813	49819	49825	49831	49836	49841	49846	49851	49856	49861	2,9
3,0	49865	49869	49874	49878	49882	49886	49889	49893	49897	49900	3,0
3,1	49903	49906	49910	49913	49916	49918	49921	49924	49926	49929	3,1
3,2	49931	49934	49936	49938	49940	49942	49944	49946	49948	49950	3,2
3,3	49952	49953	49955	49957	49958	49960	49961	49962	49964	49965	3,3
3,4	49966	49968	49969	49970	49971	49972	49973	49974	49975	49976	3,4
3,5	49977	49978	49978	49979	49980	49981	49981	49982	49983	49983	3,5
3,6	49984	49985	49985	49986	49986	49987	49987	49988	49988	49989	3,6
3,7	49989	49990	49990	49990	49991	49991	49992	49992	49992	49992	3,7
3,8	49993	49993	49993	49994	49994	49994	49994	49995	49995	49995	3,8
3,9	49995	49995	49996	49996	49996	49996	49996	49996	49997	49997	3,9
4,0	49997	49997	49997	49997	49997	49997	49998	49998	49998	49998	4,0
4,5	49999	50000	50000	50000	50000	50000	50000	50000	50000	50000	4,5



GABARITO

- | | | |
|------------|------------|-------------|
| 1. LETRA B | 11. ERRADO | 21. ERRADO |
| 2. ERRADO | 12. CERTO | 22. LETRA E |
| 3. CERTO | 13. CERTO | 23. LETRA C |
| 4. ERRADO | 14. ERRADO | 24. LETRA E |
| 5. CERTO | 15. CERTO | 25. LETRA B |
| 6. ERRADO | 16. ERRADO | 26. LETRA A |
| 7. CERTO | 17. CERTO | 27. LETRA B |
| 8. CERTO | 18. ERRADO | 28. LETRA E |
| 9. ERRADO | 19. ERRADO | 29. LETRA C |
| 10. ERRADO | 20. ERRADO | |



ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.